



KDT 생성형AI

2. LLM 모델 이해 및 활용

2026.07

전임 교수 : 임성열 Ph.D.

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.



1. Intro
2. NLP Technical Summary
3. Background knowledge
4. Transformer
5. LLM Application

Intro

- 소프트웨어 개발 방식의 진화 : Software 3.0
- AI 시대의 도래

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

전통적 개발은

[] 이다.

AI 소프트웨어는

[] 이다.

전통적 개발 (프로그래밍 등)

“**현재**에 유용한 무언가(App)를 만들어서
컴퓨터 또는 기계에게 일을 시키는 과정, 도구”

AI 소프트웨어 (ML/DL/LLM 등)

“**앞으로** 유용한 무언가(App)를 만들어서
컴퓨터 또는 기계가 스스로 처리할 수 있게 준비시키는 과정, 도구 ”

[]은 함수를 만든다.

[]은 모델을 만든다.

소프트웨어 개발 방식의 진화

전통적인 App 만들기

1. 직접 모든 함수를 작성하지 않는다.
2. 앱을 완성하기 위해 필요한 함수를 모아놓은 Library / Framework를 찾는다.
3. Library / Framework에서 필요한 함수를 이용하는 방법을 익힌다.
4. 필요한 함수를 이용하여 App을 완성한다.

우리는 어떤 Software 시대에 살고 있는가?

Software 3.0, 세번째 전환점에 서있는 Software


“

우리는 소프트웨어를 만들고 있는가?

아니면 '지능이 일하는 시스템' 을 설계하고 있는가?

”

- 지금은 코드를 작성하는 시대에서, 지능을 설계하는 시대로 전환 중..
- 규칙을 코드로 작성하는 시대나 데이터로 모델을 학습하는 시대로 진화했지만..
- 복잡한 사고와 판단은 어떻게 구현할 것인가?




Software, 이렇게 바뀌어 왔다 (개발 방식의 진화)

Software 1.0 : 사람이 규칙을 코드로 직접 작성

Concept

- 프로그래머가 Python, C++, JS, CSS 등의 언어로 작성
- 컴파일러/인터프리터에 대한 명시적(선언적 또는 명령적) 명령으로 구성
- 프로그래머는 각 코드/명령어 줄을 작성함으로써 프로그램 내에서 원하는 동작을 수행
- 인간이 만든 소스 코드(예: 일부 .cpp 파일)가 가치 있는 작업을 수행하는 바이너리로 컴파일




Software, 이렇게 바뀌어 왔다 (개발 방식의 진화)

Software 2.0 : 사람이 데이터를 주고 모델을 학습

Concept

- 신경망의 가중치처럼 훨씬 더 추상적이고 인간 친화적이지 않은 언어로 작성
- 일반적인 신경망은 수백만 개의 가중치를 가질 수 있음
- 가중치가 매우 많기 때문에 이 코드 작성에는 인간이 관여하지 않음
- 소스 코드는 대부분 1) 비즈니스 로직, 데이터 전처리 등의 S/W 1.0 코드, 2) 데이터와의 상호작용, 3) 신경망(NN) 아키텍처, 4) 신경망을 컴파일하기 위한 코드로 구성




Software, 이렇게 바뀌어 왔다 (개발 방식의 진화)

Software 3.0 : 사람이 목표(역할)을 정의하면 모델이 스스로 사고하고 행동

Concept

- 소프트웨어 3.0에서는 프로그래머가 프로그램의 원하는 동작을 정의하는 일련의 명령어와 데이터셋을 제공
- 그러면 AI agent가 이러한 명령어와 데이터 세트를 기반으로 프로그램을 생성
- 이 생성 과정에는 AI agent가 코드를 생성하고 신경망 모델을 학습하는 과정이 포함될 수 있음
- 비즈니스 로직 등 필요한 부분을 AI agent에 의해 부분적으로 또는 완전히 생성




Software, 이렇게 바뀌어 왔다 (개발 방식의 진화)

Software 3.0, 표현력의 확장 그 끝은 어디인가?

Program space

- SW 3.0의 표현력(프로그램 공간)은 SW 1.0과 SW 2.0 프로그램을 포함
- 즉 SW 3.0 스택에서 생성된 프로그램은 SW 1.0 및 SW 2.0 스택의 모든 코드 라인, 데이터 포인트, 신경망 계층의 지식이나 연산 능력을 포함할 수 있음



Software, 이렇게 바뀌어 왔다 (개발 방식의 진화)

Software 3.0, 패러다임의 전환

Software 1.0

- 전체 애플리케이션의 상당 부분을 **프로그래머가 수동으로 작성**
- 대부분의 논리와 코드는 최적화 프로세스 중에 기계에 의해 제안되지 않음

Software 2.0


- 대부분의 **머신 러닝 기반 실무 애플리케이션**에서 신경망 아키텍처와 학습 시스템은 점점 더 표준화되어 상품화
- 알고리즘의 선정과 레이블이 지정된 **데이터셋을 큐레이팅, 확장, 수정, 정제하는 일이 중요**

Software 3.0

- 최신 대규모 언어 모델(LLM) 기술과 학습 체계 덕분에 프로그래밍 패러다임에 새로운 변화가 일어나고 있음
- **LLM을 활용한 지능형 에이전트가 코드를 작성(제안)**하는 방식

Software 3.0 : 언어가 코드가 되는 순간

자연어가 새로운 프로그래밍 언어가 된다



“

이제 소프트웨어의 인터페이스는 API가 아니라 언어(Language) 다

”

Key message

- 개발자는 코드 작성자에서 문제정의자 혹은 사고 설계자로 역할 변화
- 소프트웨어는 더 이상 컴파일 하지 않을런지 모른다. 대신 대화하고 지시하는 존재

Software 3.0 시대에서의 LLM

LLM은 모델이 아니라 새로운 실행환경

패러다임 변화 속, LLM의 역할

- LLM은 단순한 AI가 아니라 사고를 실행하는 플랫폼
- 추론엔진, 지식 인터페이스, 자연어 컴파일러, 에이전트의 두뇌..


LLM의 원리와 한계를 잘 이해한다는 것은?

- LLM을 잘 쓰는 사람을 넘어서 LLM으로 시스템을 만드는 사람으로..
- LLM 기반의 다양한 추론 시스템 설계를 가능하게 함
- Ex) 반복 업무를 수행하는 AI Agent, 복잡도가 높고 불안정한 요구사항을 처리하는 Ai Agent

“

LLM은 도구가 아니라 함께 일하는 새로운 형태의 소프트웨어다

”



Software 3.0 을 향하여..

Software 3.0은 인간과 기계가 긴밀히 협력하여 지능형 소프트웨어 개발을 구현하는 것

Limitation

- SW 2.0은 최적화가 완료되면 프로그램이 잘 작동하는 대규모 네트워크로 구성되지만, 어떻게 작동하는지 파악하기가 매우 어려움
- 훈련 데이터에서의 편향으로 실패할 수 있고, 이를 적절하게 식별, 분석 및 해결하기가 매우 어려울 수 있음 (silently fail)
- 위의 제한 사항은 3.0 스택에도 적용
- 이와 더불어 SW 3.0의 경우, 코드가 통계적 모델(언급된 AI 에이전트)에 의해 생성되므로 버그가 있고 최적화되지 않은 코드(인간의 코드와 같이..)가 생성될 수 있음

Software 3.0 을 향하여..

Software 3.0은 인간과 기계가 긴밀히 협력하여 지능형 소프트웨어 개발을 구현하는 것

Benefit

- 결정론적 모델과 통계적 모델의 조합을 제공 : 결정론적 행동은 코드로, 통계적 행동은 신경망으로 인코딩
- 코드를 수정하거나 변경하는 것이 더 쉬움 (vs 프로그래머가 신경망 가중치를 조작하는 것)
- 더 많은 사람들이 프로그래머가 될 수 있음 : Application의 많은 부분이 자연어와 같은 명령어로 표현되므로 프로그래머 풀을 확대하는 것이 더욱 용이
- SW 1.0과 SW 2.0 스택 모두 온라인 교육 자료의 증가에도 불구하고 상당한 진입 장벽이 있는데, 이의 해소에 기여
- 개발 속도 향상 : SW 애플리케이션 구축에 자동화가 도입되므로 SW 프로그램을 더 빠르게 작성할 수 있음
- AGI(Artificial General Intelligence)를 향한 교두보

새로운 AI 시대의 도래

자신이 개척한 AI 기술의 위험성에 대한 AI 대부의 경고

A Godfather of AI Just Won a Nobel. He Has Been Warning the Machines Could Take Over the World.

Geoffrey Hinton hopes the prize will add credibility to his claims about the dangers of AI technology he pioneered



새로운 AI 시대의 도래

출시 5일 만에 사용자 100만 명을 확보한 ChatGPT



Elon Musk ✓
@elonmusk

Replying to @sama

ChatGPT is scary good. We are not far from dangerously strong AI.

6:48 AM · Dec 4, 2022

1,963 Retweets 243 Quote Tweets 21.3K Likes

새로운 AI 시대의 도래

사람들이 AI를 사용함에 따라 생산성 향상은 더욱 커질 것

AI has been somewhat demystified because people really use it now. And that's always the best way to pull the world forward with a new technology.

- 2024, Sam Altman, CEO, OpenAI



새로운 AI 시대의 도래

LLM시대의 Prompt Engineering



Andrej Karpathy ✓

@karpathy

The hottest new programming language is English

[게시물 번역하기](#)

오전 5:14 · 2023년 1월 25일 · 481.8만 조회수

864

5.4천

3.3만



DALL-E : A symbolic artwork emphasizing the phrase 'The hottest new programming language is English,' featuring a human figure with a brain design that blends ...

새로운 AI 시대의 도래

Large Language Models (LLMs)

“Large Language Models (LLMs) are advanced AI systems trained on vast amounts of text data to understand, generate, and process human language, enabling them to perform tasks like translation, summarization, and question answering with remarkable accuracy.”

Brown et al., 2020, “Language Models are Few-Shot Learners”, NeurIPS

새로운 AI 시대의 도래

Large Language Models (LLMs)

- ✓ AI 연구와 서비스 발전 속도가 매우 빨라지는 추세
- ✓ 24.01 ~ 25.08 Google Scholar 기준 “Large Language Model” 논문 검색 결과 8.8만편+

The screenshot shows a Google Scholar search for "Large Language Model". The search bar at the top contains the text "Large Language Model" and a magnifying glass icon. Below the search bar, the results are displayed in a list format. On the left side of the results, there are filters for "학술자료" (Academic Data), "모든 날짜" (All Dates), "모든 언어" (All Languages), and "모든 유형" (All Types). The main results list includes three entries, each with a title, authors, publication information, and a brief description. The first entry is "Large language model based multi-agents: A survey of progress and challenges" by T Guo, X Chen, Y Wang, R Chang, S Pei, et al., published in arXiv preprint arXiv in 2024. The second entry is "[HTML] A survey of GPT-3 family large language models including ChatGPT and GPT-4" by KS Kalyan, published in the Natural Language Processing Journal in 2024. The third entry is "Large language model (llm) for telecommunications: A comprehensive survey on principles, key techniques, and opportunities" by H Zhou, C Hu, Y Yuan, Y Cui, Y Jin, et al., published in Surveys & Tutorials in 2024. Each entry also shows the number of citations and a link to the full text.

Google 학술검색

Large Language Model

학술자료 검색결과 약 88,000개 (0.09초)

모든 날짜
2025 년부터
2024 년부터
2021 년부터
기간 설정...

관련도별 정렬
날짜별 정렬

모든 언어
한국어 웹

모든 유형
검토 자료

☐ 특허 포함
☐ 서지정보 포함

☒ 알림 만들기

Large language model based multi-agents: A survey of progress and challenges
T Guo, X Chen, Y Wang, R Chang, S Pei... - arXiv preprint arXiv ..., 2024 - arxiv.org
Large Language Models (LLMs) have achieved remarkable success across a wide array of tasks. Due to the impressive planning and reasoning abilities of LLMs, they have been used ...
☆ 저장 50 인용 743회 인용 관련 학술자료 전체 10개의 버전

[HTML] A survey of GPT-3 family **large language models** including ChatGPT and GPT-4
KS Kalyan - Natural Language Processing Journal, 2024 - Elsevier
... OpenAI models, including ChatGPT and GPT4, as GPT-3 family **large language models** (... supervised learning, pretrained **language models** and **large language models**. We then present ...
☆ 저장 50 인용 443회 인용 관련 학술자료 전체 4개의 버전

Large language model (llm) for telecommunications: A comprehensive survey on principles, key techniques, and opportunities
H Zhou, C Hu, Y Yuan, Y Cui, Y Jin... - Surveys & Tutorials, 2024 - ieeeexplore.ieee.org
... **large language models** or multi-modal LLMs. Although LLM development is originally motivated by natural **language** ... that are beyond the conventional **language** processing tasks, eg, ...
☆ 저장 50 인용 166회 인용 관련 학술자료 전체 5개의 버전

Redpajama: an open dataset for training **large language models**
M Weber, D Fu, Q Anthony, Y Oren... - Advances in neural ..., 2024 - proceedings.neurips.cc
... in the training of strong **language models** used in production, ... studies with decoder-only **language models** with up to 1.6B ... transparent and high-performing **language models** at scale. ...
☆ 저장 50 인용 105회 인용 관련 학술자료 전체 7개의 버전

새로운 AI 시대의 도래

AI, 2~3년 주기로 Quantum Jump

- 
- 2012 제프리 힌튼 토론토대 교수팀이 이끈 '알렉스넷(AlexNet)'이 이미지 인식 대회 이미지넷에서 우승
 - 2014 딥마인드가 구글에 인수되며 알파고 개발 본격화
 - 2016 이세돌 9단과 알파고의 대국이벤트, 이른바 '알파고 쇼크'가 전 세계를 강타
 - 2017 AI의 역사를 바꾼 논문 'Attention Is All You Need'가 발표, by Google
 - 2020 트랜스포머 아키텍처는 오픈AI의 대규모 언어 모델(LLM) 개발을 촉발, 오픈AI가 GPT-3 발표
 - 2022 더 많은 파라미터를 가진 AI 모델 개발 경쟁시대, ChatGPT가 세상에 등장
 - 2026 ?

새로운 AI 시대의 도래

Augmented Intelligence, 적이 아닌 친구로..

증강 지능(Augmented Intelligence)

- AI가 인간의 지능과 의사 결정을 향상하는 데 미치는 역할에 초점을 맞춘 인공지능 활용 방식
 - 사람과 인공지능이 협력하여 사람의 업무 방식을 대체하는 것이 아니라, 개선하는 것을 의미
 - AI를 이용하여 인간의 경험과 지식을 확장, 인간의 경쟁자가 아닌, 도구로의 AI 접근
 - 예를 들어 소매업에서는 증강 지능이 쇼핑객 데이터(예: 이동 인구 패턴)를 기반으로 상품 담당자에게 최적의 매장 레이아웃과 제품 배치를 제안
 - 자율주행차는 인간의 감독이 전혀 필요 없을 수도 있지만, 사실은 그렇지 않음 : 테슬라의 오토파일럿과 완전 자율주행 소프트웨어는 차량이 대부분 자율 주행을 할 수 있도록 개발되고 있지만 , 차량이 갑자기 차선을 침범하거나 급브레이크를 밟는 등 비상 상황에는 인간 운전자가 개입
- ✓ 우리가 본질적으로 대체되는 미래를 원한다면, 이것이 바로 AI로 우리가 만들어가는 미래, 하지만 인간이 생산적인 역할을 수행하는 미래를 원한다면, 증강 지능의 중요성은 점점 더 커질 것

새로운 AI 시대의 도래

● 사실상 AI가 이끄는 혁신

- 2024 노벨 물리학상 : 딥 러닝의 대부
- 2024 화학상 수상 : 단백질 구조 예측 AI

● AI를 이용하여, 기존 연구자의 역량을 수십~수백배 확장한 사례

● 향후 인간 업무 지식을 확장하는 역할로, AI를 활용하려는 시도는 더욱 더 확산되며, 고도화될 것

분야	수상자	국적	주요 업적
노벨 물리학상	존 홉필드	미국	홉필드 네트워크를 제안하여 인공 신경망과 기계 학습 발전에 기여.
	제프리 힌튼	영국 태생, 캐나다	딥러닝 및 인공 신경망 분야의 선구자로 현대 AI 기술의 기초를 마련.
노벨 화학상	데이비드 베이커	미국	컴퓨터 기반 단백질 설계의 선구자로, 의약품 및 나노물질 개발에 기여.
	데미스 하사비스	영국	AlphaFold2를 개발하여 단백질 구조 예측의 혁신을 이룸.
	존 점퍼	미국	AlphaFold2 개발에 참여하며 단백질 구조 예측 분야에 기여.

새로운 AI 시대의 도래

트랜스포머: LLM 시대의 일등 공신

● 2017년 구글 논문 : "Attention is All You Need"


- 문장-문장 변환 문제에서 높은 성능 대표적

문제 : 번역(영어 → 불어)

● 인코더-디코더 구조

- 인코더 : 입력 문장의 의미를 벡터로 추출

- 디코더 : 인코더 결과를 해석하여 목표 문장 생성



Source: <https://arxiv.org/abs/1706.03762>


새로운 AI 시대의 도래

Transformer 모델은 LLM과 Foundation 모델의 기반 기술로 작동하며, 두 모델의 핵심적인 구조를 제공. Foundation 모델은 대규모 데이터와 사전 학습을 통해 LLM의 확장 가능성을 열어주었으며, 프롬프트 기반 학습과 같은 혁신적인 기법을 도입함


또한 Foundation 모델은 멀티모달(이미지, 비디오, 오디오 등) 학습을 통해 다양한 데이터를 통합적으로 처리할 수 있는 방향으로 나아가고 있는 추세임

구분	Transformer 모델 [1]	Large Language Model (LLM) [2]	Foundation 모델 [3]
영향을 미친 논문	Vaswani et al. "Attention Is All You Need", 2017	Devlin et al., "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding", 2018	Brown et al., "Language Models are Few-Shot Learners", 2020
핵심 개념	Self-Attention 메커니즘을 이용한 병렬 처리 기반 언어 모델	Transformer를 기반으로 한 대규모 사전 학습 및 미세 조정 모델	프롬프트 기반의 대규모 사전 학습 언어 모델, Foundation 모델의 기반이 됨
주요 활용 분야	자연어 처리, 컴퓨터 비전	자연어 이해에 초점, 질의응답, 텍스트 분류	텍스트 생성, 번역, 요약, 질의응답, 이미지 비디오 등 확장
장점	병렬화로 인해 학습 속도가 빠르고 확장성이 뛰어남	문맥 이해를 바탕으로 다양한 작업에서 높은 정확도	다양한 작업에서 사전 학습만으로 높은 성능
단점	긴 문맥을 처리하는 데 어려움이 있으며 메모리 요구량이 높음	훈련 시간과 자원 소모가 크며, 특화 작업에는 추가 미세 조정 필요	학습에 많은 자원이 필요하며, 특정 영역에 대한 성능 한계
발전 방향 및 연구 동향	Efficient Transformer (Linformer, Longformer 등) 개발, 메모리 최적화	Few-shot 및 Zero-shot 학습 강화, 멀티모달 확장	모달리티 확장 (이미지, 비디오 포함), 효율적인 학습 방법 개발


LLM 활용하기 (기본)




실습) CoT-SC-ReAct Prompt Practice



실습) Deep Learning (LSTM) Demo Practice



실습) Transformer Demo Practice



```
# 모델과 토큰라이저 준비
tokenizer = GPT2Tokenizer.from_pretrained('gpt2')
model = GPT2LMHeadModel.from_pretrained('gpt2')

# 문장 생성 함수
def generate_text(prompt, max_length=50):
    inputs = tokenizer(prompt, return_tensors="pt")
    input_ids = inputs["input_ids"]
    attention_mask = inputs["attention_mask"]

    outputs = model.generate(
        input_ids=input_ids,
        attention_mask=attention_mask,
        max_length=max_length,
        do_sample=True,
        temperature=0.7,
        pad_token_id=tokenizer.eos_token_id # GPT-2는 pad_token_id가 없어
    )
    return tokenizer.decode(outputs[0], skip_special_tokens=True)

# 가상 지식베이스 입력 (미니 사전)
knowledge_base = {
    "South Korea": "The capital of South Korea is Seoul.",
    "France": "The capital of France is Paris.",
    "Italy": "The capital of Italy is Rome."
}
```

LLM 기본 이해 - NLP Technical Summary

- 빠르게 살펴보는 NLP의 어제와 오늘 (NLP에서 LLM까지)

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

[illegible]

- 언어를 Machine이 이해하려면 수치로 변환해야 함
- 어떻게 수치로 변환할 수 있을까?
- 수집하여 가지고 있는 모든 단어들..Corpus
- NLP Task를 위해 Corpus로부터 뽑은 단어들..Vocabulary

언어 이해의 시작, NLP(Natural Language Processing)

사람이 사용하는 언어를 Machine이 어떻게 이해할 수 있을까?

여기	지금	아주	위험	합니다
$\begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$	$\begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$

1: 여기
2: 지금
3: 아주
4: 위험
5: 합니다

$$\begin{matrix} \text{아주} & \text{아주} & \text{위험} & \text{합니다} & \text{"아주 아주 위험 합니다"} \\ \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 0 \end{bmatrix} & + & \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 0 \end{bmatrix} & + & \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix} & + & \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 1 \end{bmatrix} & = & \begin{bmatrix} 0 \\ 0 \\ 2 \\ 1 \\ 1 \end{bmatrix} \end{matrix}$$

Bit를 활용해 연속형 수치(Vector)로 변환

- 모든 단어에 Indexing 하는 것과 유사
- 0/1 이진법을 활용해서 "N(단어개수) * 1"의 column vector으로 표현하면 그게 바로 "One-hot vector"

단어의 빈도를 활용한 문장 표현

- 문장을 단어의 빈도수로 표현한 것이 BoW(Bag of Words) vector
- BoW vector 의 size는?
- 각 단어가 몇 번 사용되었는지 알 수 있지만, 사용된 단어의 순서는 알 수 없음



빈도기반의 표현법, 조금 더 신경 써보자

사람이 사용하는 언어를 Machine이 어떻게 이해할 수 있을까?

N-Gram : 순서를 고려해 보자

- 연속된 n개의 단어 묶기
- 순서정보를 일부 보존하여 국소적 의미를 구분 할 수 있음
- Ex) (not good) <> (good not)
- bi-gram (n=2)을 만든다면 데이터 속 순차적인 모든 단어 pair쌍을 vocabulary에 넣어야 함
- n이 커질수록 너무 많은 단어 쌍이 생김, 현실적으로 확장에 제한

I am studying bigram model



{ "I am", "am studying", "studying bigram", "bigram model" }

TF-IDF : 어떤 단어가 중요한 단어일까?

- Term Frequency - Inverse Document Frequency
- Term Frequency : 많이 출현하는 단어가 중요
- Inverse Document Frequency : 다른 문서에도 자주 출현하는 단어는 중요도가 떨어짐

$$TF(t, d) = \frac{(\text{Number of occurrences of term } t \text{ in document } d)}{(\text{Total number of terms in the document } d)}$$

$$IDF(t, D) = \log_e \frac{(\text{Total number of documents in the corpus})}{(\text{Number of documents with term } t \text{ in them})}$$

$$TF-IDF(t, d, D) = TF(t, d) \times IDF(t, D)$$

빈도기반 표현의 한계는 무엇일까?

BoW, TF-IDF Vector 등 빈도 기반 언어 표현의 한계

- ✓ 순서가 중요하지 않은 Task (Topic Classification, 문서검색)에서는 강점을 가지지만..
- ✓ 단어 나열의 순서가 중요한 Task라면 활용이 어려움
- ✓ 사용되는 단어수(Corpus)가 커질수록 엄청나게 커지는 vector size.. 어떤 문제를 가져올까?.. 차원의 저주(Curse of Dimensionality)
- ✓ 단어 간의 관계 표현에 취약

“사과는 가방보다 오렌지와 관련이 있음”



“동생”과 “아우”는 쓰임이 다르지만 의미가 같음



모든 단어들의 관계를 정리할 수 있을까?


의미 관계를 담고 있는 Thesaurus의 구축 시도

Thesaurus란?

- 단어의 의미를 정의하여 저장하고 있는 사전
- 기본적으로 동의어 또는 유의어가 한 그룹으로 분류되어 있음
- 단어 간 다양한 관계를 그래프 구조로 정의함

WordNet

- 프린스턴 대학교에서 1985년부터 구축하기 시작한 시소러스
 - 표제어를 통해 특정 단어가 갖는 다양한 의미 표현 (하나의 의미 그룹에 여러 단어가 포함)
 - 단어 네트워크를 사용하여 유의어를 찾거나 단어 간 유사도를 구할 수 있음
-
- 신조어 또는 의미가 변하는 어휘에 대응하기 어려움
 - 시소러스 구축에 비용이 많이 듦



```
print(car.path_similarity(novel))
print(car.path_similarity(dog))
print(car.path_similarity(motorcycle))
```

```
0.05555555555555555
0.07692307692307693
0.3333333333333333
```

맥락(Context)을 이해한다는 것

You shall know a word by the company it keeps. ,Zellig Harris

분포가설(distributional hypothesis)

- 단어의 의미는 그 단어가 나타나는 문맥에 의해 정의된다.
- 즉, 비슷한 문맥(주변 단어)에서 쓰이는 단어들은 의미도 비슷하다.
- 언어학적으로, 단어의 의미를 그 분포(distribution), 즉 주변 문맥을 기반으로 분석할 수 있음을 시사

- 같은 부모한테서 태어난 형제 중 나이가 적은 쪽을 부를 때 아우라 부른다
- 친척 형제들 혹은 같은 부모에게서 태어난 형제 중에서 나이가 적은 사람을 동생이라 부른다.
→ "아우"와 "동생" 의 주변 단어가 유사하다면 그 의미도 유사


- *"Words that are similar in meaning occur in similar contexts."*
- *"The meaning of a word is determined by the contexts in which it occurs."*
- *"If two elements have the same distribution, we can substitute one for the other anywhere in the text."*

의미적 추론을 가능하게 한 워드 임베딩(Word Embedding)

Deep Learning을 통한 분포가설의 구현, Word2Vec

빠르게 살펴보는 Deep Learning 학습 과정

- Input 데이터를 넣었을 때, 나와야 하는 답(Y)를 정해 놓고, 그렇게 되도록 중간 방정식을 변화시키는 과정
- 내가 원하는 중간 방정식을 얻어서, 그 방정식을 활용하겠다(예측/분류)
- 필요한 것은 Input-Label(Y)쌍의 데이터 집합과 방정식을 변화시킬 수 있는 알고리즘



의미적 추론을 가능하게 한 워드 임베딩(Word Embedding)


Deep Learning을 통한 분포가설의 구현, Word2Vec

Word2Vec 학습 과정

- 함께 출현한 단어로 이루어진 Train Data를 구성한 후 주변단어와 타겟 단어간의 분류(Classification) 문제로 정의한 후 학습
- Neural Network를 통해 학습이 진행될 수록 주변 단어들과의 관계가 임베딩 공간에 투영됨

you say goodbye and i say hello.

Input	Target(Y)
You	Goodbye
Say	Goodbye
And	Goodbye
I	Goodbye







의미적 추론을 가능하게 한 워드 임베딩(Word Embedding)

Deep Learning을 통한 분포가설의 구현, Word2Vec

Reasoning

- 놀이매트에서 뒹굴며 놀고 있는 ()가 나를 바라보고 있다.
 - ()에 들어갈 만한 단어는? 탁자, 컴퓨터, 어른, 아이.. 무엇이 적당할까?
- **King - Man + Woman = ()**
 - 단어간의 더하기, 빼기가 가능할까?

- 충분한 양의 유사 문장을 찾아서 읽다 보면 위 질문에 답할 수 있음
- 단어간 관계는 수많은 문장 읽기를 통해 형성됨
- Word2Vec을 통해 생성된 벡터는 유사도 기반의 색인 등에 활용할 수 있음



What is LM(Language Model)?

LM은 가장 자연스러운 단어 시퀀스를 찾아내는 모델

퇴근 후 공항에 택시를 타고 갔는데, 탑승시간에 늦어서 결국 비행기를 ()

- 앞에 순차적으로 나열된 단어들을 살펴보았을 때 ()에 들어갈 만한 그럴듯한(likeliness) 단어는?
- 앞의 단어들의 history를 보고, 다음 단어를 추론하는 것은 언어를 이해하는 것(Language Understanding)과 일맥상통

- 가장 자연스러운 단어 시퀀스를 찾아낸다 = 단어 시퀀스에 확률을 할당한다
- 어떤 문장(단어 시퀀스)이 주어졌을 때, “얼마나 그럴 듯 하나”를 수리적(확률)으로 나타내거나 문장의 앞부분이 주어졌을 때 다음 단어를 예측할 수 있음

다음 단어를 어떻게 예측하나?


- 앞에 어떤 단어들이 나왔는지를 고려하여 후보가 될 수 있는 여러 단어들에 대해서 등장 확률을 추정하고 가장 높은 확률을 가진 단어를 선택
- 등장 확률은 가지고 있는 데이터로부터 계산할 수 있음, 이것은 마치 사람이 지속적으로 읽고 듣는 것을 통해서 언어를 배우는 것과 유사

현재와 과거의 의존성을 모델링하는 RNN(Recurrent Neural Network)

순차적인 문장의 단어는 시계열 모델에 적합한 데이터

문장의 단어를 순차적으로 처리하는(컨베이어 벨트) RNN

- 오늘 주가를 예측한다면 어제 주가가 x원 이었다는 사실이 중요할 것
- 글을 읽고 맥락을 파악하는 행위는 한 단어, 한 단어 순차적으로 보고 이해하는 것
- RNN 은 앞 선 단어의 기록을 hidden state(h)를 통해 기억하고 있고, 이를 현재의 예측(다음 단어는 무엇?)에 활용
- hidden state(h)는 input들 간의 의존성을 저장하는 메모리



RNN의 문제점, vanishing gradient


- Neural Network의 학습 과정에서 기울기가 점점 작아져 앞 시점이 거의 학습되지 않는 현상
- 과거 정보가 현재까지 전달되지 않는 문제
- 시계열이 길수록 장기 의존성(long-term dependency) 학습 실패

보다 많은 맥락을 LM에 효율적으로 담아 생성하자

단어의 순차적인 컨베이어 벨트에서 문장을 압축해 한번에 넘기는 구조로..


장기 의존성 소실 문제를 해결하기 위한 후속 연구, Gate mechanism

- LSTM(Long Short-Term Memory)
 - 모델 안에 여러 개의 gate를 추가하여 input, output, memory 간 흐르는 정보를 보다 섬세하게 제어
 - RNN보다 구조가 복잡하고 더 많은 연산비용이 필요
- GRU(Gated Recurrent Unit)
 - LSTM과 유사한 성능을 유지하면서 연산비용을 경량화



전체 맥락을 하나로 압축하여 전달하자, Sequence-to-Sequence Based LM

- Encoder의 전체 단어의 맥락을 가지고 있는 Hidden state vector(Context vector)를 Decoder로 전달함
- Decoder에서는 Input과 Encoder의 Context vector를 고려하여 출력
- 입력 Sequence가 길어지면, 출력 Sequence의 정확도가 떨어짐
- Why? 너무 많은 단어가 하나의 sentence vector로 압축되어 정보 소실



보다 많은 맥락을 LM에 효율적으로 담아 생성하자


장기의존성 문제, 병렬처리 문제의 한계를 극복한 Attention 매커니즘

퇴근 후 티켓을 들고 공항에 택시를 타고 갔는데, 탑승시간에 늦어서 그것을 (환불했다)

- “그것이” 이 무엇일까?, 유추하려면 마지막 단어 (환불했다)를 고려해야 함
- 앞선 Model은 순차적으로 단어를 처리하기 때문에 뒤 단어를 고려하는 처리가 불가능함

순서의 파괴, 전체를 조망하는 Attention Based LM, Transformer

- Decoder에서 단어 출력시마다 매 시점 Encoder의 전체 입력 문장을 다시 보자
- 입력 Sequence를 하나로 압축한 context vector를 보지 않고, 매 시점 Encoder의 hidden state를 전부 참고하자
- 지금 출력하고 있는 단어에 따라 살펴봐야 할 단어들은 다르다.
- 각 단어가 출력할 때 도움이 되는 정도를 Scoring하여 함께 전달 (= Attention Score)
- Attention 기반의 병렬처리가 가능한 생성 모델 구조인 Transformer는 대규모 사전 학습 모델(LLM)의 시대를 열




문맥적 뉘앙스까지..Contextual Embedding

Attention 매커니즘으로 극복한 Word Embedding의 한계


Word Embedding의 한계

- Word2Vec, GloVe 같은 워드 임베딩은 "한 단어 = 하나의 고정 벡터", 즉 고정 임베딩
- 동음이의어 구분 불가: "배" = 과일/선박/신체 → 항상 같은 벡터
- 다의어(polysemy) 표현 불가: "paper" = 종이 / 논문 / 과목 → 하나의 벡터에 섞임
- 문맥 변화 반영 불가: "cold beer" vs "cold weather" → "cold"이 다른 뉘앙스를 가짐

<Word Embedding>



<Contextual Embedding>



Transformer 기반(BERT, GPT 등) Contextual Embedding


- 같은 단어라도 문맥에 따라 다른 벡터를 생성, 보다 정교한 Context를 내포
- He deposited money in the **bank**
- They had a picnic on the river **bank**

미리 배운 걸 잘 써먹자, 전이학습(Transfer Learning)

이걸 잘하면 저것도 잘하지 않을까?

Transfer Learning

- 딥러닝 모델이 스스로 풀기위한 최종 문제를 위해 중간 단계의 개념들을 구조화 하는 것 = Representation Learning
- 풀어야 할 문제가 유사하다면 미리 중간 단계의 개념들을 구조화 해 두어도 되지 않을까?
- 이렇게 유사한 데이터로 미리 학습된 모델을 Pretrained Model이라 함
- 사전에 학습된 Pretrained Model을 바탕으로 나의 최종 문제를 풀어내는 접근 = Transfer Learning
- 초기에 이미지(Vision) 분야를 바탕으로 발전
- 자연어 영역에서 활용할 수 있는 대표적인 Pretrained Model은 Word Embedding과 Language Model



대규모 데이터와 Transformer의 만남, GPT

대규모 데이터와 엄청나게 큰 Transformer 모델이 만난다면 어떤 일이 벌어질까?

GPT(Generative Pretrained Transformer).. Better, Faster, Stronger

- Transformer는 기존 모델과는 다르게 분산 컴퓨팅(distributed computing)을 가능하게 한다는 점에서 큰 의미가 있는데, GPT-2,3 같이 미친듯이 큰 모델이 나오게 된 가장 중요한 이유
- GPT가 다른 모델보다 월등하게 좋은 성능을 보이는 가장 큰 이유는 학습 데이터의 양

Dataset	Quantity (tokens)	Weight in training mix	Epochs elapsed when training for 300B tokens
Common Crawl (filtered)	410 billion	60%	0.44
WebText2	19 billion	22%	2.9
Books1	12 billion	8%	1.9
Books2	55 billion	8%	0.43
Wikipedia	3 billion	3%	3.4

- 약 500bil (5,000억) Token이 포함된 데이터셋 학습
- Common Crawl : 웹사이트의 텍스트를 크롤링 방식을 통해 수집한 자료
- 45TB


Table 2.2: Datasets used to train GPT-3. “Weight in training mix” refers to the fraction of examples during training that are drawn from a given dataset, which we intentionally do not make proportional to the size of the dataset. As a result, when we train for 300 billion tokens, some datasets are seen up to 3.4 times during training while other datasets are seen less than once.

Scale up, Scale up.. LLM 시대..

대규모 데이터와 엄청나게 큰 Transformer 모델이 만난다면 어떤 일이 벌어질까?

세 버전의 가장 큰 차이는 Size

- GPT1 - 2018, Improving Language Understanding with Unsupervised Learning
- GPT2 - 2019, Language Models are Unsupervised Multitask Learners
- GPT3 - 2020, Language Models are Few-shot Learners
- GPT3의 Parameter수는 GPT2의 100배+



LLM 기본 이해 - Background knowledge

- Distance
- Inner product


본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Cosine Similarity

각도 기반의 유사도 측정

Concept

- 두 벡터가 가리키는 방향이 얼마나 유사한지 측정 (벡터 크기 무관)
- 방향이 완전히 일치하면 1, 완전히 반대이면 -1
- 벡터의 모든 원소가 양수라면, 코사인 유사도의 최소값은 0
- $1 - \text{Cosine Similarity} = \text{Cosine Distance}$
- 두 값의 방향성이 정확히 일치하는 0도일 때 값이 1이므로 가장 유사도가 높고 각도가 늘어날수록 1보다 값이 작아지며 직교할 때(직각일때)이 유사도가 가장 낮다고 판단
- 유사도는 0과 1 사이의 범위를 가지므로 코사인 유사도는 보통 두 값의 방향이 0도~90도일 때를 기준으로 측정



Cosine Similarity

각도 기반의 유사도 측정

Calculation

- 내적의 결과를 총 벡터 크기로 정규화(L2 Normalization)

$$similarity = \cos(\Theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}}$$

Why use?

- 유사도 기준으로 거리를 사용한다면? → 벡터의 방향과 크기를 고려하는 것
- 유사도 기준으로 코사인 값을 사용한다면? → 벡터의 방향만을 고려하는 것
- 코사인 유사도 → 문서의 길이가 다르기 때문에 벡터간 거리를 벡터의 크기로 정규화 하여 사용

Example - A(1,1,0), C(3,3,0)의 코사인 유사도

- 분자 : $(1*3)+(1*3)+(0*0) = 6$
- 분모 : $\sqrt{1^2+1^2+0^2} * \sqrt{3^2+3^2+0^2}$
 $= 1.414.. * 4.242.. = 6$

→ AC의 코사인 유사도 = $6/6 = 1$


Case Study

자연어 처리에서의 유사도 측정

문서1은 문서2와 문서3중 어느 문서와 더 유사한가요?

- 유클리드 거리와 코사인 유사도를 산출하여 비교해보고 그 의미를 파악해보세요

	내용	Vector(apple,banana, carrot)
문서1	apple banana	(1,1,0)
문서2	apple banana carrot	(1,1,1)
문서3	apple apple apple banana banana banana	(3,3,0)



Dot Product (inner product)

내적의 의미

Calculation

- 두 벡터 $\mathbf{a}$, $\mathbf{b}$ 가 이루는 각이 θ 일 때 다음을 두 벡터 $\mathbf{a}$, $\mathbf{b}$ 의 내적이라 함

$$\vec{a} \cdot \vec{b} = |\vec{a}| |\vec{b}| \cos \theta = \sum_{i=1}^d a_i b_i$$

$$\mathbf{a} = (2, -1, 3), \mathbf{b} = (4, 0, -2)$$


- 내적: $\mathbf{a} \cdot \mathbf{b} = 2 \cdot 4 + (-1) \cdot 0 + 3 \cdot (-2) = 8 + 0 - 6 = 2$
- 길이: $\|\mathbf{a}\| = \sqrt{4 + 1 + 9} = \sqrt{14}$, $\|\mathbf{b}\| = \sqrt{16 + 0 + 4} = \sqrt{20}$
- 각도: $\cos \theta = \frac{2}{\sqrt{14}\sqrt{20}} \approx 0.1195 \Rightarrow \theta \approx 83.1^\circ$

Dot Product (inner product)

내적의 의미

Implicit meaning

- 벡터의 내적은 기하학적으로 한 벡터를 다른 벡터 위로 정사영시킨 길이와 그 다른 벡터의 길이를 곱한 것을 의미
- 크기와 방향을 모두 고려한 유사도 개념
- 정사영된 길이가 짧다는 것 = 벡터간 각도가 크다 = 유사도가 작다
- 정사영된 길이가 길다는 것 = 벡터간 각도가 작다 = 유사도가 크다



$$\begin{aligned}
 \vec{a} \cdot \vec{b} &= |\vec{a}| \times |\vec{b}| \times \cos \theta \\
 &= |\vec{b}| \times |\vec{a}| \times \cos \theta \\
 &= \overline{OH} \times \overline{OB}
 \end{aligned}$$

LLM 기본 이해 - Transformer

- Attention Is All You Need
- Self Attention
- Multi-head Attention
- Masked Self Attention

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Attention Is All You Need

현대 Transformer 기반 모델(BERT, GPT 등)의 출발점

Motivation

- 2017년 Google Brain 팀에서 "Neural Machine Translation(NMT)"

프로젝트를 하던 연구자들에 의해 작성

- 당시 주류 기계번역 모델은 한계를 가지고 있었음
 - RNN/LSTM/GRU 기반 Seq2Seq 모델 : 병렬화 어려움, 장기의존성(long-term dependency) 문제
 - CNN 기반 모델 : 멀리 떨어진 토큰간 관계위해 너무 깊은 계층 필요

Proposal

- Transformer Architecture
- RNN이나 CNN 없이 Self-Attention만으로 시퀀스를 처리하자

Provided proper attribution is provided, Google hereby grants permission to reproduce the tables and figures in this paper solely for use in journalistic or scholarly works.

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com	Noam Shazeer* Google Brain noam@google.com	Niki Parmar* Google Research nikip@google.com	Jakob Uszkoreit* Google Research uszk@google.com
Llion Jones* Google Research llion@google.com	Aidan N. Gomez*[†] University of Toronto aidan@cs.toronto.edu	Lukasz Kaiser* Google Brain lukaszkaier@google.com	
Illia Polosukhin*[‡] illia.polosukhin@gmail.com			

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.8 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature. We show that the Transformer generalizes well to other tasks by applying it successfully to English constituency parsing both with large and limited training data.

*Equal contribution. Listing order is random. Jakob proposed replacing RNNs with self-attention and started the effort to evaluate this idea. Ashish, with Illia, designed and implemented the first Transformer models and has been crucially involved in every aspect of this work. Noam proposed scaled dot-product attention, multi-head attention and the parameter-free position representation and became the other person involved in nearly every detail. Niki designed, implemented, tuned and evaluated countless model variants in our original codebase and tensor2tensor. Llion also experimented with novel model variants, was responsible for our initial codebase, and efficient inference and visualizations. Lukasz and Aidan spent countless long days designing various parts of and implementing tensor2tensor, replacing our earlier codebase, greatly improving results and massively accelerating our research.

[†]Work performed while at Google Brain.

[‡]Work performed while at Google Research.

Attention Is All You Need

현대 Transformer 기반 모델(BERT, GPT 등)의 출발점

Results by the paper

- WMT (Workshop on Machine Translation)는 기계번역 분야의 가장 권위있는 학회로, 매년 번역경진대회를 개최
- 연구자들은 공통된 데이터셋으로 모델 성능을 비교할 수 있음
- WMT 2014 English-German와 English-French 데이터를 통해

성과 측정

- English-German → BLEU 28.4 (당시 SOTA)
- English-French → BLEU 41.8 (당시 SOTA)
- 기존의 모델들과 비교해 훨씬 적은 연산 비용(training cost)으로

SOTA 달성

Table 2: The Transformer achieves better BLEU scores than previous state-of-the-art models on the English-to-German and English-to-French newstest2014 tests at a fraction of the training cost.

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [18]	23.75			
Deep-Att + PosUnk [39]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [38]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [9]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [32]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [39]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [9]	26.36	41.29	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	$3.3 \cdot 10^{18}$	
Transformer (big)	28.4	41.8	$2.3 \cdot 10^{19}$	

[참고] BLEU : Bilingual Evaluation Understudy

Attention Is All You Need

현대 Transformer 기반 모델(BERT, GPT 등)의 출발점

Contribution

- Self-Attention만으로 이루어진 최초의 Seq2Seq 모델제안
- RNN/CNN 의존 없이 병렬 학습 + 장기 의존성 처리 가능성을 증명
- 이후 모든 대규모 언어모델(BERT, GPT 등)의 기반 아키텍처가 됨

Attention Is All You Need

현대 Transformer 기반 모델(BERT, GPT 등)의 출발점

Transformer Architecture

- 인코더-디코더 구조

Encoder

입력 문장을 여러 층의 **self-attention**

+ feed-forward network로 **벡터**로

추출

Decoder

인코딩된 벡터와 자기 자신의

출력에 대한 masked self-attention을

통해 **번역(목표 문장)**을 생성





Figure 1: The Transformer - model architecture.


Transformer Encoder

Scaled Dot-Product Attention – Self Attention



Transformer Encoder

Scaled Dot-Product Attention – Self Attention




Score Matrix

	I	study	AI	hard
I				
study				
AI				
hard				

- Q 와 Transpose된 K간 matrix multiplication
- Score Matrix의 첫 row는 Q의 "I"와 K의 각 토큰 벡터가 매칭되서 만들어짐 (Dot product)
- 단어간 문맥상 관계가 높을수록 큰 값
- (i,j)셀값의 의미 : i번째 토큰이 j번째 토큰을 얼마나 주목하느냐?

Transformer Encoder

Scaled Dot-Product Attention – Self Attention




Attention Score

	I	study	AI	hard
I	0.8	0.2	0.0	0.0
study				
AI				
hard				

(1) Divide by $\sqrt{d_k}$




(2) Softmax (확률화)



- Q, K 벡터 차원(d_k)이 커질수록 내적 값의 분산이 커져서, Softmax 함수의 기울기(gradient)가 매우 작아지는 문제 해소하기 위해 K 차원수의 제곱근으로 나누어줌, 일종의 Scaling
- 이후 Softmax 를 통해 확률화를 진행
- 이로써 내적 값의 크기 범위가 안정화되고, Softmax가 적당한 기울기를 유지

Transformer Encoder


Scaled Dot-Product Attention – Self Attention



- 토큰간 연관성(유사도)를 담고 있는 Attention Score Matrix는 각 토큰이 다른 토큰을 얼마나 주목해야 하는지에 대한 가중치 행렬
- 이에 실제 정보(V)를 행렬곱하여 문맥 벡터를 생성 = 각 토큰이 다른 토큰들의 정보를 비율대로 섞어 만든 새 표현


Transformer Encoder

Scaled Dot-Product Attention – Self Attention




$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

Scaled Dot-Product Attention



Transformer Encoder


Multi-head Attention



- 입력 시퀀스를 서로 다른 관점에서 주목(attend) 해보자
- 여러 "관점"을 합쳐서 다시 하나의 통합 표현으로 만들자

Transformer Encoder

Multi-head Attention



Linear transformation



Attention Output Concatenate



Why Linear Layer?

- Concatenate한 벡터는 헤드별 특징이 흩어져 있음
- Ex) 문법적관계 집중(첫번째 output) + 의미적 유사성 집중(두번째 output)
- 이를 융합(재조합)해서 모델이 사용하기 적절한 표현 공간으로 투영
- 다양한 관점의 정보를 통합하고, 차원을 맞추며, 다음 레이어가 쓸 수 있는 형태로 재배치하는 과정

Transformer Encoder

Encoder Process

Normalization

- LayerNorm은 각 토큰의 벡터 차원별 평균과 분산을 정규화해서, 입력 분포가 일정하게 유지되도록 도움
- 그 결과 학습이 빠르고 안정적이 됨, 그래디언트 소실 방지

잔차 연결, Residual Connection

- 정보 보존 : 어텐션이 계산한 값만 쓰면, 원래 입력 정보가 손실될 수 있음
- → 기존 정보 위에 어텐션이 계산한 추가적인 관계 정보를 보강하는 방식
- 학습안정화 : 입력을 그대로 출력에 더해줌으로써, Gradient 소실 문제를 방지함. 결과적으로 학습이 더 잘 수렴

$$\text{Output} = \text{LayerNorm}(\text{Input} + \text{MultiHeadAttention}(\text{Input}))$$




Figure 1: The Transformer - model architecture.

Transformer Encoder

Encoder Process

Feed Forward

- Attention은 거의 선형변환의 조합이므로, 모델 표현력이 부족할 수 있음
- 문맥이 반영된 벡터표현을 더 풍부하게 하기 위해 비선형성 추가 (ReLU)




Figure 1: The Transformer - model architecture.

Transformer Encoder

Positional Encoding

Problem

- 트랜스포머는 '모든 토큰을 함께 보는 컨셉' → 토큰간 순서를 직접 알 수 없음
- Ex) 나는 밥을 먹었다 vs 밥이 나를 먹었다
- Query, Key, Value로 이루어진 어텐션 구조 자체가 토큰의 순서와는 상관없이 모두 연결되어 있어 추가적 정보없이 두 문장의 차이구분이 어려움

Solution

- 포지션 임베딩 레이어 학습
- 학습없이 삼각함수를 활용, 정해진 계산식에 따라 결과값을 인코딩값으로 사용




Figure 1: The Transformer - model architecture.


Transformer Decoder

Concept

Problem

- 어텐션 메카니즘은 모든 단어들이 나와 있을 때 서로 간의 문맥을 파악하는 것이지 그 주어진 문장 그 다음에 토큰을 예상하기 위한 구조는 아님
- 주어진 정보를 가지고 다음 단어를 예측하는 구조로 변경하려면..

Ideation, 셀프어텐션 디코더로 사용하기



- 주어진 토큰들만 가지고 서로를 참조하여 알맞은 피쳐들을 뽑아내고 그를 기반으로 다음 토큰을 예측하도록 한다면..
- 생성은 주어진 토큰안에서 다음 토큰을 예상하는 것, 그렇게 해보자

Transformer Decoder

Masked Self Attention

Q (query)


I				
study				
AI				
hard				

K(key) transpose

I	study	AI	hard

Attention Score

I	study	AI	hard



Learning

- 주어진 토큰들 사이의 문맥을 학습하여 다음 토큰 예측
- 이때 Y는 다음 토큰
- Training step마다 Attention Score와 Ground Truth 와 비교하여 Loss 계산

LLM Application

- LLM Leader board
- Market leaders of LLM

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.


현대 LLM 모델 특징

딥러닝 기반의 모델로 다양한 Task를 처리할 수 있는 범용 모델

- **매개변수의 규모**: LLM은 매우 많은 수의 매개변수(파라미터)를 가진 모델 (OpenAI의 GPT-3 모델은 약 1750억 개의 매개변수), 이 정도 규모의 모델은 언어의 복잡한 패턴을 학습하고 추론하는 데 필수적
- **사전 학습(Pre-training)**: LLM은 대량의 텍스트 데이터를 통해 사전 학습을 진행함. 이 과정에서 모델은 문법, 의미, 문맥 등을 파악하고, 다양한 언어 패턴을 이해할 수 있음. 이후 특정 작업에 맞게 미세 조정(Fine-tuning)을 통해 성능을 최적화
- **자연어 처리 작업 수행**: LLM은 다양한 NLP 작업을 수행할 수 있음. 예를 들어, 문장 생성, 번역, 요약, 감정 분석, 질문 답변 등 여러 언어 관련 작업뿐만 아니라, 주어진 입력에 대해 자연스러운 텍스트를 생성할 수 있는 능력이 뛰어남
- **Transformer 아키텍처**: LLM의 주요 기술적 특징 중 하나는 바로 Transformer 아키텍처. Transformer는 문맥을 이해하고, 병렬적으로 데이터를 처리할 수 있는 능력을 갖춘 딥러닝 모델로, 자연어 처리에 매우 적합

Timeline of existing large language models

Having a size larger than 10B



LLM Leader Board

신뢰할 수 있는 성능 순위, 어디서 살펴보나?

학계

Stanford HELM (Holistic Evaluation of Language Models)

- 스탠퍼드 CRFM 연구소가 운영하는 LLM 벤치마크 대시보드, 다양한 모델을 하나의 틀에서 공정하게 비교할 수 있도록 설계되어 있음
- 평가범위가 방대하고 엄밀한 평가를 시행해 업데이트의 적시성이 떨어짐 (23.11)
- <https://crfm.stanford.edu/helm/classic/latest>

- Accuracy / F1 / EM: 정답률 계열 (MMLU, GSM8K, TruthfulQA 등)
- Calibration: 모델의 확률 예측이 얼마나 잘 맞는지
- Fairness & Bias: 특정 그룹에 대한 편향성 여부
- Robustness: 입력 변형(노이즈, 패러프레이즈)에 대한 강인성
- Efficiency: 처리 속도, 비용(토큰당 가격)
- Toxicity / Safety: 유해 발화 생성 여부



Leaderboard Models Scenarios Predictions GitHub Release v0.4.0 (2023-11-17)

Leaderboard: Core scenarios

The scenarios where we evaluate all the models.

Select a group:

Core scenarios

Accuracy	Calibration	Robustness	Fairness	Efficiency	General information	Bias	Toxicity	Summarization metrics
Model	Mean win rate	MMLU - EM	BoolQ - EM	NarrativeQA - F1	NaturalQuestions (closed) - F1			
Llama 2 (70B)	0.944 ^{1/2}	0.582	0.886	0.77	0.458			
LLaMA (65B)	0.908 ^{1/2}	0.584	0.871	0.755	0.431			
text-davinci-002	0.905 ^{1/2}	0.568	0.877	0.727	0.383			
Mistral v0.1 (7B)	0.884 ^{1/2}	0.572	0.874	0.716	0.365			
Cohere Command beta (52.4B)	0.874 ^{1/2}	0.452	0.856	0.752	0.372			
text-davinci-003	0.872 ^{1/2}	0.569	0.881	0.727	0.406			

LLM Leader Board


신뢰할 수 있는 성능 순위, 어디서 살펴보나?

산업계

Vellum Leaderboard

- 다양한 SOTA 모델들을 대상으로 추론, 수학, 코딩, 시각 이해 등 여러 영역별 벤치마크 결과를 공개
- 기업·실무 관점에서 인기가 높으며, 비교적 최신 모델을 대상으로 제공
- <https://www.vellum.ai/llm-leaderboard>

- Reasoning (논리 추론 능력, 예: GPQA Diamond)
- High School Math (수학 능력, 예: AIME 2024)
- Coding (코딩 및 에이전트 작업, 예: SWE Bench)
- Tool Use (도구 활용 능력, BFCL 벤치마크)
- 평균 성능: 여러 벤치마크를 종합한 'Average GRIND' 같은 지표로 전반적인 성능도 표시
- 문맥 길이(context window), 토큰당 비용, 속도 등 실무 적용에 필수적인 지표도 함께 제공



LLM Leader Board

신뢰할 수 있는 성능 순위, 어디서 살펴보나?

연구자 중심

Hugging Face — Open LLM Leaderboard

- 오픈소스 모델을 중심으로 다양한 평가 지표(지식, reasoning, 문제 해결력 등)를 기준으로 모델을 순위화하고, 데이터와 쿼리를 투명하게 제공
- 오픈소스 LLM의 “성능 경쟁장” 같은 곳, 표준 벤치마크로 비교하며 누구나 제출 가능 + 공정한 자동 평가를 통해 신뢰성 있는 순위를 제공
- <https://huggingface.co/open-llm-leaderboard>

- MMLU : 57개 분야(과학, 역사, 법학 등)의 지식·추론 문제
- HellaSwag : 상식적 문장 완성 문제 (추론 + 상식 테스트)
- ARC : 초·중등 수준 과학 문제 풀기
- TruthfulQA : 사실과 거짓 구분하기 (허소리/환각 방지 능력)
- Winogrande : 상식적 대명사 해석 문제
- GSM8K : 초등학교 수준 수학 문제 (수학적 추론 능력)
- HumanEval : 코딩 문제 (파이썬 함수 작성 → 정답률)

Open LLM Leaderboard Enterprise Community

https://huggingface.co/spaces/open-llm-leaderboard

Activity Feed Follow 1,305

AI & ML interests
Evaluating open LLMs

Recent Activity

- alozowski new activity 5 days ago
open-llm-leaderboard/results: Create README.md
- alozowski new activity 5 days ago
open-llm-leaderboard/open_llm_leaderboard: Cre...
- alozowski new activity 7 days ago
open-llm-leaderboard/open_llm_leaderboard: Fre...

View all activity

Team members 18

Collections 3

Details
A gated collection of datasets containing evaluation details

- open-llm-leaderboard/tensopolis_virtuosos...
Viewer · Updated Mar 10 · 43.2k · 19


Open LLM Leaderboard 2

Open LLM Leaderboard 13.4k
Track, rank and evaluate open LLMs and chatbots


LLM Leader Board

SOTA LLM 모델들에 대한 최신 성능평가 (25.08.07기준)


추론 능력
(생물학, 물리학 등 전반에 걸친..)



수학문제 풀이 능력
(고등학교 수준 수학문제 풀이)



코드작성 능력
(GitHub 이슈 해결할 수 있는지..)



LLM Leader Board


SOTA LLM 모델들에 대한 최신 성능평가 (25.12.15 기준)

추론 능력
(생물학, 물리학 등 전반에 걸친..)


수학문제 풀이 능력
(고등학교 수준 수학문제 풀이)

코드작성 능력
(GitHub 이슈 해결할 수 있는지..)


Best in Reasoning (GPQA Diamond) ⓘ



Best in High School Math (AIME 2025) ⓘ



Best in Agentic Coding (SWE Bench) ⓘ



LLM Leader Board


SOTA LLM 모델들에 대한 최신 성능평가 (25.12.15 기준)

가장 어려운 인간의 시험문제 풀이
(여러 도메인에 걸친..)


시각적 추론 능력

다국어 추론 능력
(57개 전문분야, 14개 언어)


Best Overall (Humanity's Last Exam) ⓘ



Best in Visual Reasoning (ARC-AGI 2) ⓘ



Best in Multilingual Reasoning (MMMLU) ⓘ



LLM Leader Board


SOTA LLM 모델들에 대한 최신 성능평가 (25.12.15기준)

초당 토큰 수, 높을수록 좋음


첫 번째 토큰 청크를 수신할 때까지 걸리는
시간(초), 낮을수록 좋음

토큰 100만 개당 가격(USD),
낮을수록 좋음


Fastest Models ⓘ



Lowest Latency (TTFT) ⓘ



Cheapest Models ⓘ



Open-source LLM Leader Board


오픈소스 모델 버전에 대한 최신 공개 벤치마크 성능 (25.11.19기준)

추론 능력
(생물학, 물리학 등 전반에 걸친..)


수학문제 풀이 능력
(고등학교 수준 수학문제 풀이)

코드작성 능력
(GitHub 이슈 해결할 수 있는지..)


Best in Reasoning (GPQA Diamond) ⓘ



Best in High School Math (AIME 2024) ⓘ



Best in Agentic Coding (SWE Bench) ⓘ



Market leaders : GPT 5

LLM 원조 기업의 또 한번의 약진, 모두에게 전문가 수준의 인텔리전스를 제공하자

Introduction

- 25.08.07 출시된 OpenAI사의 최신 세대 대규모 언어 모델
- 전체 GPT 모델 라인을 통합
- PhD 수준의 전문가 역할, 즉 AGI(Artificial General Intelligence)로 가기 위한 중대한 이정표로 소개

특장점


- 자동 라우팅 : 여러 내부 모델을 상황에 따라 자동 선택, 예) 빠른 응답이 필요하면 'main' 모델, 복잡한 문제는 'thinking' 모델로 처리가 자동 분기
- 향상된 추론 : PhD 수준의 글쓰기 지원 능력 크게 강화
- 가장 강력한 코딩 모델 : 단 한 번의 프롬프트로 복잡한 FE 구현 가능
- 환각현상 대폭 감소
- 아첨 최소화 : 지나치게 호의적이지 않고, 불필요한 이모티콘을 덜 사용
- AI와 대화하는 것"보다는 박사급 지능을 갖춘 친절한 친구와 대화하는 것 지향

구분	Regular (Full)	Mini	Nano
제공 방식	API, ChatGPT	API, ChatGPT	API 전용
추론 수준	Deep reasoning (full)	경량화된 reasoning	초경량 reasoning 모델
속도	중간~느림 (정교한 응답)	빠름 (균형 지향)	매우 빠름 (최소 대기)
모델 구조	API: 생각 (Thinking) 모델 사용	API: Mini Thinking 모델 사용	API: Thinking-nano 모델

* 지식차단 : 24.09.30 / mini,nano ; 24.05.30

Market leaders : GPT 5

LLM 원조 기업의 또 한번의 약진, 모두에게 전문가 수준의 인텔리전스를 제공하자



Prompt

다음 요구 사항을 따라 단일 HTML 파일에서 단일 페이지 앱을 만들어줘.

- 이름: 점핑 플랫폼 러너
- 목표: 장애물을 뛰어넘어 최대한 오래 살아남기.
- 기능: 속도 향상, 높은 점수 기록, 재시도 버튼.
- UI는 시야에 따라 물체의 위치나 방향이 달라지는 배경에 다양한 색상이 있어야 해.
- 누구나 즐길 수 있는 수준이어야 해.

LLM 원조 기업의 또 한번의 약진, 모두에게 전문가 수준의 인텔리전스를 제공하자


<코드를 생성중인 GPT5>

88

Market leaders : GPT 5

LLM 원조 기업의 또 한번의 약진, 모두에게 전문가 수준의 인텔리전스를 제공하자


<Prompt로 완성된 web game>



[참고] Open AI GPT Series

비즈니스 성과

- ChatGPT의 대중적 성공 : 2022년 11월 ChatGPT 공개 → 5일 만에 100만 사용자, 2개월 만에 1억 사용자 달성
- 역사상 가장 빠르게 성장한 소비자 서비스 중 하나. 덕분에 "LLM 기반 대화형 AI" 시장을 개척
- GPT 출시 전(2020년) OpenAI 기업가치: 약 140억 달러에서 ChatGPT 이후(2024년): 900억 달러로 평가
- Microsoft는 OpenAI에 약 130억 달러 투자 → Azure와 GPT 모델 통합
- OpenAI는 API 사용량 기반 과금 모델 확립 → 안정적 수익 창출



Market leaders : Gemini 3

구글 AI전략의 중심, AI를 모든 사람에게 유용하게..

Introduction

- 2024년 2월, Bard(기존 대화형 AI)와 Duet AI를 통합하여 보다 통합적인 AI 브랜드인 Gemini 런칭
- 23년 구글의 AI 연구 조직인 Google Brain과 DeepMind가 합병되어 Google DeepMind라는 새로운 통합 조직 → 이의 대규모 협업 결과물
- 25.03 Gemini 2.5 출시

특장점

- 멀티 모달 : 텍스트뿐 아니라 이미지, 오디오, 비디오, 코드 등 다양한 형식의 입력을 모두 처리 할 수 있도록 설계
- Google 서비스와 연동 : Gmail, Docs, Slides, Workspace 등에서 직접 Gemini의 기능을 통해 문서 요약, 초안 작성, 기획 등을 빠르게 수행
- 광범위한 AI 활용 플랫폼 지향 : 복잡한 추론부터 이미지, 음성, 코드까지

Gemini

2.5 Flash ▼

모델을 선택하세요

어디에서든 빠르게 도움받기
2.5 Flash

신규

추론, 수학 및 코딩
2.5 Pro

신규

Google AI Pro로 업그레이드하기
Google의 가장 뛰어난 모델과 기능을
사용해 보세요.

업그
레이
드


모델	특징
2.5 Pro	최고 성능·추론력·긴 컨텍스트·멀티모달
2.5 Flash	빠른 응답·효율적 비용·추론 가능
2.5 Flash-Lite	초저가형·고처리량

Market leaders : Gemini 3

구글 AI전략의 중심, AI를 모든 사람에게 유용하게..

Prompt:

Create an animated bubble chart using Plotly Express of how economic and health indicators have evolved over the years for each continent.



Market leaders : Gemini 3

구글 AI전략의 중심 , AI를 모든 사람에게 유용하게..

Gemini

업그레이드



지난 일주일 동안의 Gmail 중에서 광고 메일만 찾아서 보낸이를 포함해서 각각 1줄로 요약해줘

Workspace ▾

지난 일주일(2025년 11월 21일 ~ 11월 27일) 동안 받은 광고 메일 목록을 보낸이와 함께 1줄로 요약했습니다.

- 전자신문 seksmail@etnews.com: 서울AI재단 뉴스레터(제5호)로, 서울 AI 혁신을 이끌 핵심 인재 9명을 공개 채용 중이라는 광고입니다.
- <https://www.google.com/url?sa=E&source=gmail&q=Investing.com>
newsletter@investingmail.com: 2025년 시장 전략 분석 및 2026년 승자 예측, 블랙 프라이데이 할인 혜택을 제공하는 투자 뉴스레터입니다.
- <https://www.google.com/url?sa=E&source=gmail&q=Investing.com>
newsletter@investingmail.com: 데이터 기반 월간 리뷰 웨비나(텐배거 시리즈 2탄)를 통해 지난달 성과 공개 및 이달 유망주를 발굴한다는 광고입니다.
- 한이음 hanium@fkii.org: 2026년 주요 산업별 AI 시장 전망 세미나에 대한 안내 및 참가 신청을 요청하는 광고입니다.
- 전자신문 seksmail@etnews.com: 사전등록 중인 "2025 글로벌 소재부품장비 테크페어"(12월 10일 개최)에 초대하는 광고입니다.

Gemini에게 물어보기

+ 🛠 도구

빠른 모드 ▾



Google Workspace를 연결하시겠습니까?

bs

@gmail.com

요청을 완료하기 위해 Gemini에서 다음 작업을 수행합니다.

- 이메일, 문서 등 Google Workspace 항목에 액세스하고 이를 관리합니다.
- 대화의 일부분과 기타 관련 정보를 Google Workspace와 공유하며 이러한 대화와 정보는 서비스를 개선하는 데 사용될 수 있습니다.

Gemini가 다른 연결된 앱을 사용해 대답하는 경우 대화에 포함된 Google Workspace 콘텐츠는 이러한 앱에 공유될 수 있습니다.

Google이 사용자의 개인 정보를 보호하는 방식:

사용자의 Google Workspace 콘텐츠는 Gemini를 개선하는 데 사용되지 않습니다. 앱 페이지에서 Google Workspace를 사용 중지할 수 있습니다. [콘텐츠가 사용되는 방식 알아보기](#).

취소

연결

Market leaders : Claude 4.5

전통적인 코드 생성 분야의 강자, 문제 해결사(problem solver)를 위한 AI

Introduction

- Anthropic사가 개발한 생성형 인공지능/대형 언어 모델(LLM)
- 2023년 초 최초 공개된 이후, 2025.11.24 Claude Opus 4.5 출시
- 코딩, 연구 등 복잡한 문제에 도전하는 사람들을 위한 사고 파트너(thinking partner)로 포지셔닝

언제 사용할까?

- 코드 생성 & 개발 Assist로써의 활용 - 다양한 개발언어로 프로그래밍 코드, Prototype 코드를 작성하는데 강점, 점진적 개선에 유리
- 방대한 문서 입력 또는 긴 대화/텍스트도 한 번에 처리 가능 : 리서치, 보고서, 긴 기획서 작업에 유리



```
← Shopify Landing Page React Component Preview Code X

import React from 'react';
import { ShoppingCart, Globe, Package, CreditCard, BarChart } from 'l

const ShopifyLandingPage = () => {
  return (
    <div className="font-sans">
      {/* Navigation */}
      <nav className="bg-white p-4 flex justify-between items-center">
        
          <a href="#" className="text-gray-600">Solutions</a>
          <a href="#" className="text-gray-600">Pricing</a>
          <a href="#" className="text-gray-600">Resources</a>
        </div>
        <div>
          <button className="bg-green-600 text-white px-4 py-2 rounde
        </div>
      </nav>

      {/* Hero Section */}
      <section className="bg-gray-900 text-white py-20 px-10">
        <div className="max-w-4xl mx-auto">
          <h1 className="text-5xl font-bold mb-6">Making Commerce Bet
          <p className="text-xl mb-8">Shopify is commerce for anyone,
          <button className="bg-white text-black px-6 py-3 rounded-md
        </div>
      </section>
    </div>
  );
};
```

Last edited 2일 전

Market leaders : Grok 4

Elon Musk의 행보, 인류에 안전하고 유익한 AI를 만들자..

Introduction

- OpenAI(공동 창립자였던 Musk가 2018년 떠남)에 대한 견제와, Google DeepMind, Anthropic 등과 경쟁하기 위한 새로운 AI 연구 조직 xAI를 23.07에 설립
- 2025.07.09, AI 모델 lineup Grok 4와 더 강력한 Grok 4 Heavy를 공개

특장점

- 추론능력 : Grok 4는 수학, 논리, 프로그래밍, 과학 분야에서 석박사 수준 이상의 문제 해결 능력을 보임
- 실시간 웹 검색 : DeepSearch 기능을 통해 X(전 트위터) 등의 실시간 데이터를 활용해 답변. 이로 인해 최신 정보 반영이 가능
- 군사 및 정부 계약: 미국 국방부 대상으로 'Grok for Government' , \$200M 규모 계약 수주
- 테슬라 차량 통합: Tesla 차량 내 탑재

Market leaders : Grok 4

Elon Musk의 행보, 인류에 안전하고 유익한 AI를 만들자..

<음성채팅 + 비디오 활성화>

“이제 Grok이 당신이 보는 것을 볼 수 있습니다!

카메라를 겨누고 바로 말하면 Grok이 실시간

인사이트를 도출하여 음성 채팅 환경에서 장면을

분석하고 실시간으로 응답합니다. 최첨단 강화 학습

프레임워크와 음성 압축 기술을 활용하여

자체적으로 학습된 이 모델을 선보이게 되어

자랑스럽습니다. ”



Market leaders : LLaMA 4 (Large Language Model Meta AI)

개방형 생태계로 차별화, 오픈소스는 혁신을 가속화하고, 더 안전한 AI를 만든다

Introduction

- OpenAI의 ChatGPT의 성공 이후, Meta는 누구나 접근 가능한 고성능 언어 모델을 만들기 위해 LLaMA를 개발
- 소형이면서도 뛰어난 성능을 목표함
- 2023. 02, LLaMA 1세대(7B-65B)는 논문과 함께 공개, LLaMA-13B는 GPT-3(175B)를 대부분의 벤치마크에서 뛰어넘는 성능을 보임
- 24.07 LLaMA 3.1 이후 2025.04 LLaMA 4 출시

특장점

- 오픈소스, 접근성 : LLaMA 시리즈는 누구나 활용할 수 있도록 설계되었고, 연구자·개발자 사이에서 빠르게 확산. LLaMA 2부터는 상업적 이용도 제한적으로 가능해짐
- 다양한 모델 크기 : 7B부터 2T 까지 사용 목적에 따라 선택
- 파인튜닝 가능성 제공 : 모델의 학습된 매개변수(parameter)들을 공개
- GPT 등과 달리 LLaMA의 'weights'를 다운로드해 활용할 수 있음

"openwashing" issue

- 일정 규모 이상의 기업(예: 월간 활성 사용자 수 7억 명 초과) 사용이 제한
- 특정 분야(예: 민감 인프라 등)에서도 사용이 제한

Market leaders : LLaMA 4 (Large Language Model Meta AI)

개방형 생태계로 차별화, 오픈소스는 혁신을 가속화하고, 더 안전한 AI를 만든다

LLaMA: Open and Efficient Foundation Language Models

Hugo Touvron*, Thibaut Lavril*, Gautier Izacard*, Xavier Martinet
Marie-Anne Lachaux, Timothee Lacroix, Baptiste Rozière, Naman Goyal
Eric Hambro, Faisal Azhar, Aurelien Rodriguez, Armand Joulin
Edouard Grave, Guillaume Lample*

Meta AI

Abstract

We introduce LLaMA, a collection of foundation language models ranging from 7B to 65B parameters. We train our models on trillions of tokens, and show that it is possible to train state-of-the-art models using publicly available datasets exclusively, without resorting to proprietary and inaccessible datasets. In particular, LLaMA-13B outperforms GPT-3 (175B) on most benchmarks, and LLaMA-65B is competitive with the best models, Chinchilla-70B and PaLM-540B. We release all our models to the research community¹.

1 Introduction

Large Languages Models (LLMs) trained on massive corpora of texts have shown their ability to perform new tasks from textual instructions or from a few examples (Brown et al., 2020). These few-shot properties first appeared when scaling models to a sufficient size (Kaplan et al., 2020), resulting in a line of work that focuses on further scaling these models (Chowdhery et al., 2022; Rae et al., 2021). These efforts are based on the assumption that more parameters will lead to better performance. However, recent work from Hoffmann et al. (2022) shows that, for a given compute budget, the best performances are not achieved by the largest models, but by smaller models trained on more data.

The objective of the scaling laws from Hoffmann et al. (2022) is to determine how to best scale the dataset and model sizes for a particular training compute budget. However, this objective disregards the inference budget, which becomes critical when serving a language model at scale. In this context, given a target level of performance, the preferred model is not the fastest to train but the fastest at inference, and although it may be cheaper to train a large model to reach a certain level of

performance, a smaller one trained longer will ultimately be cheaper at inference. For instance, although Hoffmann et al. (2022) recommends training a 10B model on 200B tokens, we find that the performance of a 7B model continues to improve even after 1T tokens.

The focus of this work is to train a series of language models that achieve the best possible performance at various inference budgets, by training on more tokens than what is typically used. The resulting models, called LLaMA, ranges from 7B to 65B parameters with competitive performance compared to the best existing LLMs. For instance, LLaMA-13B outperforms GPT-3 on most benchmarks, despite being 10× smaller. We believe that this model will help democratize the access and study of LLMs, since it can be run on a single GPU. At the higher-end of the scale, our 65B-parameter model is also competitive with the best large language models such as Chinchilla or PaLM-540B.

Unlike Chinchilla, PaLM, or GPT-3, we only use publicly available data, making our work compatible with open-sourcing, while most existing models rely on data which is either not publicly available or undocumented (e.g. “Books – 2TB” or “Social media conversations”). There exist some exceptions, notably OPT (Zhang et al., 2022), GPT-NeoX (Black et al., 2022), BLOOM (Scao et al., 2022) and GLM (Zeng et al., 2022), but none that are competitive with PaLM-62B or Chinchilla.

In the rest of this paper, we present an overview of the modifications we made to the transformer architecture (Vaswani et al., 2017), as well as our training method. We then report the performance of our models and compare with others LLMs on a set of standard benchmarks. Finally, we expose some of the biases and toxicity encoded in our models, using some of the most recent benchmarks from the responsible AI community.

```
from trl import SFTTrainer
from datasets import load_dataset
from transformers import AutoTokenizer, AutoModelForCausalLM, TrainingArguments
from peft import LoraConfig, TaskType
import torch

MODEL = "meta-llama/Meta-Llama-3-8B-Instruct"
DATA = "path/to/your.jsonl" # 또는 HF datasets 0/1

ds = load_dataset("json", data_files=DATA, split="train")

tok = AutoTokenizer.from_pretrained(MODEL, use_fast=True, padding_side="right")
tok.pad_token = tok.eos_token

base = AutoModelForCausalLM.from_pretrained(
    MODEL,
    torch_dtype=torch.bfloat16,
    device_map="auto"
)

peft_cfg = LoraConfig(
    task_type=TaskType.CAUSAL_LM,
    r=16, lora_alpha=32, lora_dropout=0.05,
    target_modules=["q_proj", "k_proj", "v_proj", "o_proj", "gate_proj", "up_proj", "down_proj"]
)

args = TrainingArguments(
```


* Equal contribution. Correspondence: {htouvron, thibautlav, gizacard, egrave, glample}@meta.com
¹<https://github.com/facebookresearch/llama>

Market leaders : LLaMA 4 (Large Language Model Meta AI)

개방형 생태계로 차별화, 오픈소스는 혁신을 가속화하고, 더 안전한 AI를 만든다

“생태계 구축을 통해 오픈소스 커뮤니티, 스타트업, 학계까지 아우르는 AI 표준을 Meta가 주도하려는 방향성”

Our partner ecosystem



Market leaders : LLaMA 4 (Large Language Model Meta AI)

RAG 분야에서도 차별화된 접근..

REFRAG: Rethinking RAG based Decoding

Xiaoqiang Lin^{1,2,*}, Aritra Ghosh¹, Bryan Kian Hsiang Low², Anshumali Shrivastava^{1,3}, Vijai Mohan¹

¹Meta Superintelligence Labs, ²National University of Singapore, ³Rice University

*Work done at Meta

Large Language Models (LLMs) have demonstrated remarkable capabilities in leveraging extensive external knowledge to enhance responses in multi-turn and agentic applications, such as retrieval-augmented generation (RAG). However, processing long-context inputs introduces significant system latency and demands substantial memory for the key-value cache, resulting in reduced throughput and a fundamental trade-off between knowledge enrichment and system efficiency. While minimizing latency for long-context inputs is a primary objective for LLMs, we contend that RAG systems require specialized consideration. In RAG, much of the LLM context consists of concatenated passages from retrieval, with only a small subset directly relevant to the query. These passages often exhibit low semantic similarity due to diversity or deduplication during re-ranking, leading to block-diagonal attention patterns that differ from those in standard LLM generation tasks. Based on this observation, we argue that most computations over the RAG context during decoding are unnecessary and can be eliminated with minimal impact on performance. To this end, we propose REFRAG, an efficient decoding framework that compresses, senses, and expands to improve latency in RAG applications. By exploiting this attention sparsity structure, we demonstrate a 30.85× the time-to-first-token acceleration (3.75× improvement to previous work) without loss in perplexity. In addition, our optimization framework for large context enables REFRAG to extend the context size of LLMs by 16×. We provide rigorous validation of REFRAG across diverse long-context tasks, including RAG, multi-turn conversations, and long document summarization, spanning a wide range of datasets. Experimental results confirm that REFRAG delivers substantial speedup with no loss in accuracy compared to LLaMA models and other state-of-the-art baselines across various context sizes. Additionally, our experiments establish that the expanded context window of REFRAG further enhances accuracy for popular applications.

Date: October 14, 2025

Correspondence: Aritra Ghosh at arighosh@meta.com

Code: Will be available at <https://github.com/facebookresearch/refrag>



1 Introduction

Large Language Models (LLMs) have demonstrated impressive capabilities in contextual learning, leveraging information from their input to achieve superior performance across a range of downstream applications. For instance, in multi-turn conversations (Roller et al., 2021; Zhang et al., 2020), incorporating historical dialogue into the context enables LLMs to respond more effectively to user queries. In retrieval-augmented generation (RAG) (Guu et al., 2020; Izacard et al., 2022), LLMs generate more accurate answers by utilizing relevant search results retrieved from external sources. These examples highlight the power of LLMs to learn

Meta Superintelligence(MSI)


- 인간 수준을 넘어서는 범용 지능을 개방적(open)·분산형 생태계로 개발하겠다는 Meta의 장기 AI 방향성

REpresentation For RAG의 기술 구조

- RAG 구조를 대폭 개선해 30배 빠른 응답 속도 달성
- 핵심은 문서 조각을 토큰이 아닌 LLM이 직접 이해할 수 있는 'Chunk Embedding' 형태로 변환해, LLM의 임베딩 공간에 사상

AI는 어떤 방향으로 진화하고 있는가?

급속도로 발전하는 AI, 커져가는 AI 활용 격차



최근의 흐름

- 2023: AI가 답변을 한다는 것에 놀라워 하던 시기
- 2024: 우리가 의도한 대로 AI에게 답변을 받아내는 법을 익혔던 시기
- 2025 : AI가 우리가 시킨 일을 스스로 다 알아서 하길 원하는 시기
- AI 요소의 병렬적 진화 : 인지AI는 텍스트, 이미지, 음성, 영상 등을 더 잘 인지하는 방향으로..생성형 AI는 생성형 AI대로..
- AI 사용경험과 AI 활용 격차는 커지고 있음

LLM 활용하기 (심화)

다양한 LLM Agent 소개 : 2) Crew AI

● Multi-Agent로 동작하는 LLM

LLM에게 지시하는 코드 작성

```

planner = Agent(
    role="콘텐츠 기획자",
    goal="{topic}에 대한 흥미로운 콘텐츠 기획",
    backstory="당신은 {topic}에 대한 글을 "
        "기획하는 일을 하고 있습니다. ",
    allow_delegation=False,
    verbose=True
)
writer = Agent(
    role="콘텐츠 작성자",
    goal="{topic}에 대한"
        "의견을 포함한 글을 작성",
    backstory="당신은 {topic}에 대한"
        "의견을 포함한 기사를 작성하고 있습니다. ",
    allow_delegation=False,
    verbose=True
)
editor = Agent(
    role="편집자",
    goal="주어진 기사 글을 올바른 표준 국어 형식 및 조직의 글
    서식에 맞게 편집",
    backstory="당신은 콘텐츠 작성자로부터 "
        "기사 글을 받는 편집자입니다. ",
    allow_delegation=False,
    verbose=True
)

```

Multi-Agent로 동작 결과

```

[DEBUG]: == Working Agent: 콘텐츠 기획자
[INFO]: == Starting Task: 1. LLM(Large Language Model)을 이용한 지능형 에이전트
경쟁력 제고 방안에 대한 최신 트렌드, 주요 인물, 그리고 주목할 만한 뉴스를 우선 순위화하기.
2. 목표 독자층의 관심사와 pain point를 고려하여 파악하기.
3. 서론, 핵심 요점, 행동 유도(CTA)를 포함한 상세한 콘텐츠 개요 개발하기.
4. SEO 키워드와 관련 데이터 또는 출처 포함하기.
> Entering new CrewAgentExecutor chain...
Final Answer:
## 콘텐츠 기획 문서: LLM(Large Language Model)을 이용한 지능형 에이전트 경쟁력 제고
방안
### 1. 개요
이 글은 LLM을 활용하여 지능형 에이전트의 경쟁력을 높이는 다양한 방법과 최신 트렌드를 탐
구합니다. 독자들은 LLM의 작동 원리, 실제 사례, 그리고 이를 통해 지능형 에이전트의 성능을
개선할 수 있는 전략들에 대해 배우게 됩니다.
### 2. 독자층 분석
- **목표 독자층**: IT 전문가, 데이터 과학자, 기업의 AI 개발자, 스타트업 창업자 및 경영진
- **관심사**:
  - 최신 AI 기술 트렌드
  - 비즈니스 및 산업 내 AI의 활용 사례
  - LLM의 기술적 발전 및 적용 가능성
- **Pain Point**:
  - LLM의 복잡한 작동 원리 이해 부족
  - LLM을 통한 비즈니스 효율성 개선의 어려움
  - AI 기술 투자에 대한 불확실성
### 3. 콘텐츠 개요
#### 서론
- LLM의 개념 및 중요성 소개
- 지능형 에이전트의 역할과 필요성 강조
- 이 글의 목표 및 독자에게 제공할 가치 설명
#### 핵심 요점
...

```




지능형 보고서 작성 에이전트 데모

업무처리 에이전트는 사용자의 업무 지식을 가지고 있다가 적절한 답변을 제공하는 에이전트이다. 이러한 에이전트는 특정 도메인 또는 주제에 대한 지식을 갖추고 있으며, 사용자의 질문에 대한 답변을 찾아 제공한다.


업무처리 에이전트는 대화형 인터페이스를 통해 사용자와 상호 작용하며, 자연어 처리 기술을 사용하여 사용자의 질문을 이해하고 적절한 답변을 생성한다. 이러한 에이전트는 고객 지원, 교육, 정보 검색 등 다양한 분야에서 활용될 수 있다.

LLM기반 Agent 생성 실습을 위한 업무 템플릿



LLM 활용하기 (심화)

실습) LLM을 이용한 Multi-Agent (CrewAI)





End of Documents

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.