

RNN 소개



Deep Learning


윤재성

RNN 소개

- 순환 신경망(RNN)
- 기존의 DNN(심층 신경망)이나 CNN(합성곱 신경망)은 입력 데이터가 독립적이라고 가정합니다.
- 하지만 문장 속의 단어나 주가 데이터처럼 시간의 흐름이나 순서가 중요한 데이터를 처리하기 위해서는 이전의 정보를 기억할 수 있는 구조가 필요하며, 이것이 RNN(Recurrent Neural Network)의 출발점입니다.

RNN의 핵심 구조 (Hidden State)

- RNN은 은닉층의 결과값이 출력층으로만 향하는 것이 아니라, 다음 시간 단계(Time Step)의 은닉층 입력으로 다시 들어가는 순환 구조를 가집니다.
- 이 순환되는 값을 은닉 상태(Hidden State, h_t)라고 부릅니다.




기억 메커니즘 (수식적 이해)

- 시간 t 에서의 은닉 상태 h_t 는 현재의 입력 x_t 와 이전 시간의 은닉 상태 h_{t-1} 을 모두 사용하여 계산됩니다
- $h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t + b_h)$
- 여기서 W_{hh} 와 W_{xh} 는 가중치 행렬이고, b_h 는 편향입니다. 즉, h_{t-1} 안에는 과거 시간($t-1, t-2, \dots$)의 정보들이 압축되어 담겨 있으며, 이를 통해 모델은 일종의 '단기 기억'을 갖게 됩니다.

장기 의존성 문제와 기울기 소실

- RNN은 이론상으로는 과거의 모든 정보를 기억할 수 있어야 하지만, 실제로는 입력 데이터의 길이가 길어질수록 과거의 정보가 끝까지 전달되지 못하는 치명적인 단점이 있습니다.
- 이를 장기 의존성 문제(Long-Term Dependency Problem)라고 합니다.




BPTT (Backpropagation Through Time)

- RNN을 학습시킬 때는 시간을 거슬러 올라가며 오차를 전파(역전파)합니다.
- 이 과정에서 체인 룰(Chain Rule)에 의해 같은 가중치 행렬(W_{hh})이 시간 단계의 수만큼 반복적으로 곱해지게 됩니다.
- 만약 가중치의 값(또는 행렬의 고윳값)이 1보다 작다면, 역전파 과정에서 값이 계속 곱해지면서 기울기(Gradient)가 기하급수적으로 작아져 결국 0에 수렴하게 됩니다.
- 결과적으로 모델은 먼 과거의 데이터(x_1, x_2)가 현재의 정답에 미치는 영향을 전혀 학습하지 못하게 되고, 오직 최근의 데이터에만 편향된 예측을 하게 됩니다.

LSTM (Long Short-Term Memory)의 등장과 구조

- 장기 의존성 문제를 해결하기 위해 1997년에 제안된 구조가 바로 LSTM입니다.
- RNN의 은닉 상태(h_t) 외에 셀 상태(Cell State, C_t)라는 새로운 뼈대를 추가하고, 정보의 흐름을 통제하는 3가지 게이트(Gate)를 도입했습니다.



컨베이어 벨트 (Cell State, C_t)

- 셀 상태는 정보가 모듈 전체를 관통하며 흐르는 일종의 컨베이어 벨트입니다.
- 선형적인 연산(덧셈)만 이루어지기 때문에 정보가 왜곡되거나 소실되지 않고 길게 전달될 수 있어, 기울기 소실 문제를 구조적으로 방지합니다.

3가지 게이트 (Gates) 메커니즘

- 망각 게이트 (Forget Gate, f_t): 과거의 정보를 얼마나 버릴지 결정합니다.
- $f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$
- 입력 게이트 (Input Gate, i_t): 현재의 새로운 정보를 셀 상태에 얼마나 저장할지 결정합니다.
- $i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$
- $\hat{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$

3가지 게이트 (Gates) 메커니즘

- 셀 상태 업데이트 (Cell State Update): 망각 게이트와 입력 게이트의 결과를 결합하여 새로운 셀 상태를 만듭니다. (곱셈이 아닌 덧셈 연산이 기울기 소실을 막는 핵심입니다.)
- $C_t = f_t * C_{t-1} + i_t * \hat{C}_t$
- 출력 게이트 (Output Gate, o_t): 업데이트된 셀 상태를 바탕으로 다음 은닉 상태(h_t)를 얼마나 출력할지 결정합니다.
- $o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$
- $h_t = o_t * \tanh(C_t)$