

SKALA

데이터분석 및 AIOps

데이터 분석 개요 및 기초통계

2026.07

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.



1. 데이터 분석 개요

2. 분석 프로세스 이해

3. 기초통계

(1) EDA

(2) Preprocessing

(3) Statistics

(4) 확률분포

(5) 상관관계

(6) 회귀분석

데이터 분석 및 AIOps

1. 데이터 분석 개요

- 데이터 분석이란?
- 데이터 분석 유형
- 데이터 분석 필요 역량
- 데이터를 보는 관점

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

데이터 분석이란?

"데이터 분석(Data Analytics)이란? "

수집된 데이터로부터 유용한 정보(Insight)를 추출하고, 이를 통해 의사결정을 지원하는 일련의 과정
기업에서 데이터 분석을 배우고 활용하는 이유는 기업의 더 나은 의사결정을 내리기 위함

의사결정 종류

"어떤 의사결정을 돕기 위한 것인가?"

- 어떤 제품을 만들 것인가?
- 얼마에 팔 것인가?
- 누구에게 팔 것인가?
- 어디에 투자할 것인가?
- 생산을 언제 멈출 것인가?

...

데이터 있는 모든 **Decision** 이 해당




데이터 분석 유형

✓ 데이터 분석 4가지 유형

유형	질문	설명	사례
기술적 분석 (Descriptive)	무엇이 일어났는가?	과거/현재 데이터 요약	"지난달 매출은 10억원, 전월 대비 5% 증가"
진단적 분석 (Diagnostic)	왜 그런일이 일어났는가?	원인 파악	"매출 증가 원인은 신규 고객 30% 유입 때문"
예측적 분석 (Predictive)	앞으로 무슨 일이 일어날까?	미래 예측	"다음 달 매출은 11억원으로 예측됨"
처방적 분석 (Prescriptive)	어떻게 해야 할까?	최적 행동 제안	"프로모션 예산을 A채널에 60% 배정 권장"

데이터의 가치 사슬

데이터 분석의 시작은 "데이터"로 부터



“ 데이터 분석의 목적은
데이터를 지식과 지혜로 전환하여
더 나은 의사결정을 지원하는 것”


데이터 직무 구분

✓ 데이터 관련 직무 구분


구분	Data Scientist	Data Engineer
핵심 역할	데이터를 분석하고 ML/DL 모델을 개발하여 비즈니스 문제를 해결	데이터 수집·저장·처리 및 대용량 데이터 파이프라인(Pipeline) 구축
주요 업무	EDA, 통계 분석, ML/DL 모델링 및 성능 평가	ETL, DB 설계, 데이터 인프라 구축
주요 도구	Python, R, SQL, Scikit-Learn, PyTorch	SQL, Spark, Airflow, Kafka, AWS/GCP, Snowflake
필요 역량	통계, 데이터 분석, ML/DL	데이터 처리, 백엔드 개발 능력, 클라우드 아키텍처, 데이터베이스 최적화
주요 질문	"무슨 일이 일어났는가?" + "무엇이 일어날 것인가?"	"필요한 데이터를 어떻게 안정적으로 제공할 것인가?"

데이터 활용 체계

✓ 기업에서 데이터 활용 체계



데이터 분석 필요 역량



필요 역량

Biz. Insights

- Biz 목표 이해
- Biz관점의 문제 이해



Analytic Insights

- 분석적 관점의 문제 정의 능력
- 적절한 분석 기법 선택 능력




Data Insights

- 정형/비정형 데이터 처리
- 대용량 데이터 처리

데이터를 보는 관점

- 모든 데이터 분석의 시작은 데이터
- 같은 데이터도 바라보는 관점에 따라 다른 의미를 가짐
- 비즈니스 목적에 따라 해석과 활용 방식이 다르고,
데이터 정의 또한 다를 수 있음을 이해하는 것이 중요



데이터를 보는 관점

개념적 정의 vs 조작적 정의


- 개념적 정의 : 데이터가 이론적·추상적으로 무엇을 의미하는가에 대한 정의 (Biz. 목적)
- 조작적 정의 : 개념을 실제로 측정 가능한 형태로 구체화한 정의 (분석 목적)
- 개념적 정의 예시

예시) 제조 “설비 이상 징후” 정의

- 설비 센서로 부터 나오는 데이터(온도, 압력, 전력 등) 를 활용

Time_Stamp	Tag_Name	Tag_Value
201210180903	BRP1FC1908_SP	9.0
201210180903	BRU1F4207	34.6
201210180903	BRU1FC1702	114.8
201210180903	BRU1FC1717	112.2

【 센서값 분포도 】



개념적 정의 (Biz. 목적)
: 추상적 정의


“센서 측정값이
정상 기간 내
분포/범위를
벗어날 수록
비정상 (설비 중단)
가능성이 높다”
(장기 거시 변동 관점)

데이터를 보는 관점

개념적 정의 vs 조작적 정의

- 조작적 정의 예시
 - 데이터 탐색을 통해서 비정상 구간을 통계적 or Rule 로 구체화 작업

개념적 정의 (Biz. 관점)



추상적 관점

➔ 데이터 분석은 "추상적인 개념을 측정 가능한 데이터로 변환하는 것"에서 시작

조작적 정의 (측정 가능)

$$z = \frac{X_t - \mu}{\sigma} \Rightarrow |Z\text{-score}| > 3 \text{ 이면 비정상 징후}$$

(Z-Score 기준)

X_t : t 시점의 Tag 측정값
 μ : 정상 기간 Tag 평균
 σ : 정상 기간 Tag 표준편차


측정 데이터 (Data)



분석 기준 (통계, Rule)

데이터를 보는 관점

개념적 / 조작적 정의 사례




사례

- | | | |
|-------------|--------|--|
| 1 이탈 고객 정의 |→ | <u>최근 6개월내 거래가 없거나, 연평균 거래금액의 10% 미만인 고객</u> |
| 2 고객의 충성도 |→ | <u>현재 자사에서 주유하는 양과 최대 주유가능량과의 비율</u> |
| 3 고객의 세대 규모 |→ | <u>설치 전화번호와 합산청구 여부를 활용하여 세대원 수의 추정</u> |

데이터를 보는 관점

개념적 / 조작적 정의와 데이터 처리 절차



분석 전문가는 현업 담당자와 협의를 통해 분석 데이터 항목에 대한 **조작적 정의**(변수용어정의서, 계산공식=Rule정의 등) 으로 문서화 후 데이터 전문가에 전달

데이터 전문가는 Rule 정의서에 기반하여 DB로부터 SQL, Hive 등을 이용하여 데이터를 추출하고 계산식에 따른 **Rule 정의 규칙에 따른 SQL 로직**을 구현하여 최종 데이터 셋을 생성함

데이터 분석 및 AIOps

2. 분석 프로세스 이해

- 분석 프로세스
- 분석 프로세스별 주요 Task
- 분석을 위한 핵심 고려사항

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.


분석 프로세스

데이터 분석 과제를 수행하기 위해 실제로 진행하는 단계별 작업 절차



분석 프로세스 예시

분석 가상 시나리오를 통한 분석 프로세스 이해



분석 프로세스별 주요 Task

분석 프로세스

1 비즈니스 이해
Business Understanding

2 데이터 이해
Data Understanding

3 데이터 준비
Data Preparation

4 모델링
Modeling

5 모델 평가
Evaluation

6 시스템 적용
Deployment

A. 비즈니스 목표에 대한 이해

- 현업이 해결하고자 하는 문제 정의, 예) “고객 이탈률을 줄이고 싶다”
- **비즈니스 목표를 데이터분석 목표(측정 가능한 형태)로 전환**
- 프로젝트 계획 수립: 일정, 단계별 산출물, 역할 분담

B. 데이터에 대한 이해

- 필요한 데이터 소스 확인
- 초기 데이터 수집: 내부 DB, 외부 API, 로그 파일 등 원천 데이터 확보
- **데이터 탐색 (EDA) : 데이터의 분포, 트렌드, 변수 간의 관계 파악**
- **데이터 품질 검증: 결측치, 이상치, 데이터 중복성 등의 문제점 발견**

C. 분석 시스템 환경에 대한 이해

- 시스템 사양(CPU, GPU)은?
- 데이터 용량에 따른 스토리지 용량은?
- 필요 패키지 버전은?

분석 프로세스별 주요 Task

분석 프로세스

1 비즈니스 이해
Business Understanding

2 데이터 이해
Data Understanding

3 데이터 준비
Data Preparation

4 모델링
Modeling

5 모델 평가
Evaluation

6 시스템 적용
Deployment

A. 데이터 변환

- 결측치 대체, 이상치 처리, 오류 수정 등의 데이터 정제 (Clean)
- 연속형 변수의 로그 변환, Scaling, 범주형 변수의 인코딩 등의 데이터 변환
- 기존 변수를 조합하여 새로운 파생변수 생성
- 여러 데이터 소스 병합
- 데이터 분할 (Partition): 학습용(Train)과 평가용(Test) 데이터셋 분리

B. 분석 변수 선택

- 변수간의 상관성이 높은 변수 제외
- 통계적 방법으로 변수 중요도가 높은 변수 위주로 선별

분석 프로세스별 주요 Task

분석 프로세스

1 비즈니스 이해
Business Understanding

2 데이터 이해
Data Understanding

3 데이터 준비
Data Preparation

4 모델링
Modeling

5 모델 평가
Evaluation

6 시스템 적용
Deployment

A. 모델 설계

- 모델링 기법 선택: 문제 유형(분류, 회귀, 군집 등)에 맞는 알고리즘 선정
- 모델 평가 방법 및 평가 지표 설정
- 모델 학습 단위인 세그먼트 설계

B. 모델 학습

- Train 데이터셋을 활용해 여러 모델을 학습시키고 파라미터 튜닝 수행
- 모델 학습과 검증을 반복적으로 수행

C. 모델 평가

- Test 데이터셋으로 모델 성능 지표 평가
- 예측력, 처리 속도, 해석 가능성을 고려하여 후보 모델 비교 및 최종 모델 선정
- 모델 성능을 비즈니스 목표 기준으로 해석

분석 프로세스별 주요 Task

분석 프로세스

1 비즈니스 이해
Business Understanding

2 데이터 이해
Data Understanding

3 데이터 준비
Data Preparation

4 모델링
Modeling

5 모델 평가
Evaluation

6 시스템 적용
Deployment

A. 배포 계획

- 모델을 기존 사내 시스템이나 클라우드 인프라에 어떤 방식으로 연동할지?
- 모델 예측 주기: API 기반의 실시간 예측 or 정기적 배치(Batch) 예측으로 할지?

C. 모델 유지보수

- 데이터의 변화, 모델의 성능 저하를 파악하는 방법은?
- 정기적인 모델 업데이트 주기는 어떻게 되는지? 절차는 어떻게 해야 하는지?

분석을 위한 핵심 고려사항

분석을 위한 3가지 Key Question

1. 분석 주제 선정

무엇을 분석할 것인가?

- 분석을 통해 해결 가능한가?
(분석 가능성, 분석 효과성)
- 필요한 데이터와 분석 환경 / 인력은
준비되어 있는가?
- 관련 내/외부 사례가 존재 하는가?

- 업무 or 분석 전문가 -

2. 데이터 준비

분석에 필요한 데이터는
준비되어 있는가?

- 분석 목적에 맞는 데이터가 충분히
있는가?
- 데이터 품질에는 이상이 없나?
- 어떤 원천 DB 에서 데이터를
수집할 것인가?

- IT or 분석 전문가 -

3. 분석 기법 선택

어떤 분석 기법을 사용할
것인가?

- 분석 목적에 맞는 적합한 분석
기법은?
- 분석 기법 선정시 고려사항은?
: 모델 정확도, 모델 설명력 등
- 분석 모델 평가 방법은?

- 분석 전문가 -

데이터 분석 및 AIOps

3. 기초 통계

- (1) 용어 이해
- (2) EDA
- (3) 기술 통계량
- (4) 확률분포
- (5) Preprocessing
- (6) 상관관계
- (7) 회귀분석

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

데이터 분석 및 AIOps

3. 기초 통계 - (1) 용어 이해

- 변수 및 데이터 셋
- 분석 단위

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

변수

개념

- 변수 (variable)는 “분석의 대상이 되는 항목”으로 두 가지 이상의 속성 (attribute)을 가질 때 변수라 함
- 속성 (attribute)은 대상을 설명하는 성질 또는 특성으로 변수가 가질수 있는 값(Value)임
- 값 (Value)는 변수가 실제로 가지는 구체적인 측정 결과로 실제 데이터 임

변수와 속성, Value 의 예시

변수 (Variable)		속성 (Attribute)		값 (Value)
성별	➡	남성, 여성	➡	남성
수학 점수	➡	0 ~ 100 점	➡	85점
사회적 계층	➡	상류층, 하류층	➡	하류층
종교	➡	기독교, 불교, 이슬람교 등	➡	기독교

변수

예시

- 변수의 또 다른 이름 : 컬럼, 열
- 13개의 행과 5개의 열로 이루어진 Dataset (테이블)

열 / column / 변수 (Variable)

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa
7	4.6	3.4	1.4	0.3	setosa
8	5	3.4	1.5	0.2	setosa
9	4.4	2.9	1.4	0.2	setosa
10	4.9	3.1	1.5	0.1	setosa
11	5.4	3.7	1.5	0.2	setosa
12	4.8	3.4	1.6	0.2	setosa
13	4.8	3	1.4	0.1	setosa

행 / row /
/ Observation

범주형 변수 vs. 연속형 변수

개념

【 A. 범주형 】

범주형 (Categorical) : 값을 그룹(범주)으로 구분하는 변수

이진척도(Binary)

- 2개의 서로 다른 상태를 구분
- 예: 합격 여부 (합격, 불합격)

명목척도(Nominal)

- 데이터를 서로 다른 그룹으로 구분하기 위한 변수
- 값 사이에 순서나 크기의 의미는 없음
- 예: 혈액형(A, B, AB, O), 지역(서울, 부산, 대전), 성별(남, 여)

순서척도(Ordinal)

- 값을 순서대로 나열할 수 있는 변수
- 예: 학점(D → C → B → A), 등급 (1, 2, 3등급)

【 B. 연속형 】

연속형 (Continuous) : 연속적인 숫자(값)로 표현되는 변수

구간척도(Interval)

- 숫자 간의 간격(interval)이 산술적 의미(크기)를 가짐
- 0은 기준점일 뿐 '없음'을 의미하지 않음
예: 온도(임의의 온도가 0도)
서기 년도(서기 0년은 예수님 태어나신 해로 구분)

비율척도(Ratio)

- 숫자 간의 비율이 산술적 의미를 가짐
- 0은 완전한 '없음'을 의미
변수의 특성에 따라서 실제 '0' 값인지, Missing 과 같은 의미 인지 구분 필요함(-> Missing 으로 처리)
예: 소득(0원), 몸무게(0kg), 소요시간(0초)

범주형 변수 vs. 연속형 변수

예시


예시) 학생별 전국 모의고사 데이터의 변수형은? 범주형 vs. 연속형 구분해보기

학년	• 1, 2, 3, NA	➡	범주형 / 연속형
연령	• 18, 19, 20, 21, ...	➡	범주형 / 연속형
연령대	• 10대, 20대 초반, 20대 후반, 30대 이상	➡	범주형 / 연속형
국어 점수	• 0 ~ 100	➡	범주형 / 연속형
국어 등급	• 1, 2, 3, ..., 9	➡	범주형 / 연속형


종속변수 vs. 독립변수

개념

- 분석가가 알고자 하는 값은 y (종속변수, 반응변수, *Target*, *Label*), 예) 내일 삼성전자 주가
- y 를 예측하기 위해 활용할 수 있는 값은 x (독립변수, 설명변수, *Feature*), 예) 오늘 미국 반도체 지수



독립변수 (Independent Variable)
설명변수 (Explanatory Variable)
Feature



종속변수 (Dependent Variable)
반응변수 (Response Variable)
Target

종속변수 vs. 독립변수

예시

- 1) 아래 분석 주제에서 변수를 설명(X)변수 vs. 종속(Y)변수로 분류하면?
- 2) 종속(Y) 변수를 범주형 vs. 연속형으로 분류하면?

설명변수 (X)

종속변수 (Y)

1. 방문고객수에 따른 매출액은 얼마인가?

2. 불만콜수에 영향을 주는 요인은 장애건수와 장애지속시간이다.


3. 품질 1등급이 나오려면 생산방식이 어떻게 바뀌어야 하는가?

4. 이탈 고객들의 주 연령층은 20대로 추정된다.

종속변수 vs. 독립변수

분석 기법 차이

- 독립변수와 종속변수가 어떤 변수형인지에 따라 분석기법이 다를 수 있음, 특히 종속변수 유형에 영향을 받음



파생 변수

개념

파생 변수

- 의미 : 기존 변수들을 가공·결합·변환하여 새롭게 만들어낸 변수

예시)

- 합계 = 매출액을 기반으로 "매출액 합계"
- 고객등급 = 구매건수가 2개 이상이고 합계가 500원 이상인 경우 "A등급"
- 월 매출 증가율 = (이번달 - 지난달) / 지난달
- 고객 가입기간 = 가입 일자 로 부터 현재 일자 까지의 유지 기간

- 필요성

- 모델 예측 성능 요인 중 파생 변수의 기여도가 매우 큼
- 모델이 '스스로 배우기 어려운 관계'를 사람이 먼저 만들어 주는 것
- 업무 전문가와 분석 전문가의 협업이 필요

원천 데이터 (트랜잭션 데이터)

이름	상품	수량	금액
이xx	상품A	1개	200원
홍xx	상품A	1개	200원
홍xx	상품B	1개	400원

원천 데이터 + 파생 변수

이름	상품	수량	금액	합계	고객등급
이xx	상품A	1개	200원	200원	B 등급
홍xx	상품A.B	2개	400원	600원	A 등급

Lag 변수 (시차 변수)

개념

- Lag 변수란? 과거 시점의 값을 현재 시점의 설명변수로 사용하는 파생변수
- 시계열 데이터에서 시간적 의존성을 반영하기 위한 핵심 Feature
- 왜 필요한가?

예시)

- 오늘의 주가 ← 어제 주가 영향
 - 오늘 매출 ← 최근 며칠 매출 영향
 - 고객 이탈 ← 과거 이용 패턴 영향
- ➔ 과거 정보를 변수로 만들어야 예측력이 향상

Lag 변수 예시

날짜	매출	Lag1	Lag2
1일	100	NaN	NaN
2일	120	100	NaN
3일	90	120	100
4일	130	90	120

- Lag1 : 1시점 전 값, Lag2 : 2시점 전 값

분석 단위

- 분석 단위는 데이터를 분석할 때 기준이 되는 최소한의 개체를 의미
- 데이터 셋에서 한 행(Row)의 기준이 됨

분석 단위의 예시

예시 질문	분석 단위	설명
어떤 고객이 이탈하는가?	고객	한 행 = 고객 1명
어떤 제품이 불량이 많은가?	제품	한 행 = 제품 1종
어떤 거래가 이상거래인가?	거래	한 행 = 구매 1건
어떤 방문이 구매로 이어지는가?	방문	한 행 = 방문 1회
언제 매출이 급증하는가?	시간	한 행 = 특정 시점
어떤 설비에서 불량이 발생하는가?	설비	한 행 = 설비 1대

데이터 분석 및 AIOps

3. 기초통계 – (2) EDA

- EDA 의미
- EDA 절차 및 방법

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

EDA 의미

용어 이해

EDA. Exploratory Data Analysis. 탐색적 자료 분석

- ✓ 데이터를 이해하기 위해 시각화·기초통계로 패턴, 이상치, 관계 등을 탐색하는 과정
- ✓ EDA 는 데이터의 과거와 현재를 이해하는 과정이고, 모델링은 미래나 미지의 값을 예측하는 과정
- ✓ EDA 자체가 분석 목적이 될 경우에는 EDA 단계 에서 분석 종료됨
- ✓ 모델링 과제에서는 모델 성능 향상을 위한 데이터 이해 및 데이터 가공을 위한 탐색 목적으로 진행

EDA 의미

EDA vs. CDA

정의

주요 분석 내용

활용

탐색적 데이터 분석 (EDA: Exploratory Data Analysis)

- 기 수집된 데이터로부터 데이터의 형태, 관계 파악
예) 범인을 찾기 위한 '수사' 과정
- 귀납적 분석
- 데이터 요약(중앙값, 사분위)와 그래프(산포도 등)
- 데이터 관계 분석 (상관 분석)
- 통계적 가설 설정 과정 없음(기술 통계)
- 데이터 품질 검증 (결측치, 이상치)
- 데이터 변환 여부 등 전처리 방안 수립 등
- 독립변수들의 관계 파악 (다중 공선성 문제)
- 독립변수와 종속변수 관계 파악
- 모델 개발 방향 설계 등

vs.

확증적 데이터 분석 (CDA: Confirmatory Data Analysis)

- 사전에 세운 가설이나 가정을 통계적인 검증 과정
예) 법정에서 유무죄를 가리는 '재판' (유죄이다 아니다)
- 연역적 분석
- 표본 데이터로부터 모집단 모수 추정
(대통령 선거 출구 조사 등)
- 통계적 가설을 설정하고, 데이터를 수집하여, 통계적 유의성 검증
- 가설, 신뢰수준, 통계량에 따른 결론 추정, 검증
- 분석의 본론 단계
- 탐색적 데이터 분석의 기초 하에 적절한 데이터 전처리 후 진행


EDA 의미 : 통계와의 관계

통계는 기술(기초)통계와 추론통계로 구분되고, 기술(기초)통계는 EDA를 수행하기 위한 여러 도구 중 하나임

통계학의 기본 구조

- 기업에서는 많은 경우 전체 모집단을 분석하기보다, 수집된 데이터(표본)를 분석함

EDA 주요 분석
기법



데이터 분석 및 AIOps

3. 기초통계 - (3) 기술 통계량

- 중심화 - 평균, 중앙값
- 퍼짐 - 편차, 분산, 표준편차, 사분위수, IQR
- 쓸림 - 왜도, 첨도

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

기술 통계량 (Descriptive Statistics)

- 데이터의 기본적인 특징을 통계 기법을 활용하여 확인하기 위함
- 다른 용어: 통계량 분석, 기초 통계량, 산술 통계량, 기술 통계 → *Descriptive Statistics*

중심화

평균

중앙값

최빈값

퍼짐

분산

표준편차

변이계수

범위

쓰림

왜도

첨도

사분위수

사분위수 범위

중심화

개념

- 데이터의 대표적인 수준이 어디인지 파악하기 위해 사용

중심화

퍼짐

쓸림

평균 (mean)

- Outlier 민감
- 특이값 존재시 → 중앙값 활용

연속형 변수


중앙값 (median)

- 데이터를 순서대로 나열할 때 가운데 있는 값
- Outlier 영향 덜함
- 관측값의 개수가 짝수인 경우 가운데 두 값의 평균

최빈값 (mode)

- 범주형 변수

- 범주형 변수에서 빈도가 가장 높은 값
예시) 직업별 건수
 - 직업A : 20
 - 직업B : 10
 - 직업C : 30
 → 최빈값 : 직업C



중심화

mean vs median

Example 1:

$$x = \{1, 2, 2, 3, 4, 7, 15\}$$

평균
(mean)

$$\begin{aligned} \text{mean}(x) &= \frac{(1 + 2 + 2 + 3 + 4 + 7 + 15)}{7} \\ &= \frac{34}{7} = 4.86 \end{aligned}$$

Example 2:

$$y = \{1, 2, 2, 3, 4, 7, 15, 79\}$$

$$\begin{aligned} \text{mean}(y) &= \frac{(1 + 2 + 2 + 3 + 4 + 7 + 15 + 79)}{8} \\ &= \frac{113}{8} = 14.13 \quad \text{Outlier 민감} \end{aligned}$$

중앙값
(median)

7개 중 middle 번째: $\frac{7+1}{2} = 4$ 번째 값

$$\text{median}(x) = x_{\frac{n(x)+1}{2}} = x_{\frac{7+1}{2}} = x_4 = 3$$

8개 중 middle 번째: $\frac{8+1}{2} = 4.5$ 번째 값 $\rightarrow$ 4번째 ~ 5번째 평균값

$$\begin{aligned} \text{median}(x) &= x_{\frac{n(x)+1}{2}} = x_{\frac{8+1}{2}} = x_{4.5} \\ &= \frac{x_{(\frac{n(x)+1}{2}-0.5)} + x_{(\frac{n(x)+1}{2}+0.5)}}{2} \\ &= \frac{x_{(4.5-0.5)} + x_{(4.5+0.5)}}{2} = \frac{3+4}{2} = 3.5 \end{aligned}$$

Outlier 영향 덜함

퍼짐

개념

- 데이터가 평균으로 부터 얼마나 흩어져 있는지 확인하기 위해 사용 (안정성)

중심화

퍼짐

쓸림

표준편차 (Standard Deviation)

- 평균 중심으로 퍼짐 정도
- 0에 가까우면 평균 근처 집중
- 측정 단위가 다른 변수를 비교하기에 부적합 → 변이계수 사용


변이계수 (Coefficient of Variance)

- 단위가 서로 다른 변수 퍼짐 비교
- 변이계수 = 표준편차 / 평균
- 값이 작을수록 평균치 가까이 분포

범위 (range)

- 최대 (max) - 최소 (min)

Example 1



퍼짐

예시

- 키(cm) 데이터의 평균, 편차, 분산, 표준편차, 변동계수를 구해보자.

	키 (cm)	편차	편차 ²
1	170	-5.2	27.04
2	170	-5.2	27.04
3	173	-2.2	4.84
4	173	-2.2	4.84
5	173	-2.2	4.84
6	176	0.8	0.64
7	178	2.8	7.84
8	178	2.8	7.84
9	180	4.8	23.04
10	181	5.8	33.64

$$\text{평균} = 175.2$$

$$\text{편차} = \text{관측값} - \text{평균}$$



$$\text{분산} = \frac{\text{편차}^2 \text{의 합}}{\text{관측값 수}} = \frac{(27.04 + 27.04 + \dots + 23.04 + 33.64)}{10} = \frac{141.6}{10} = 14.16$$

$$\text{표준편차} = \sqrt{\text{분산}} = \sqrt{14.16} = 3.76$$

$$\text{변이계수} = \text{표준편차} / \text{평균} = 3.76 / 175.2 = 0.021$$

왜도, 첨도

- 데이터가 얼마나 어느 쪽으로 쏠려 있는지 하나의 값으로 표현할 때 사용
- 이상치, 정규성 여부 판단에 주로 사용

통계량	설명	특징
왜도 (Skewness)	데이터의 대칭성을 알아보는 측도 (대칭 정도)	 오른쪽으로 꼬리가 긴 (right-skewed) 분포 (왜도 > 0) 좌우 대칭 (symmetric) 분포 (왜도 = 0) 왼쪽으로 꼬리가 긴 (left-skewed) 분포 (왜도 < 0)
첨도 (Kurtosis)	정규분포와 비교하여 봉오리가 얼마나 높은지 알아보는 측도 (뽕족한 정도)	 정규분포보다 뽕족 (첨도 > 0) 정규분포보다 납작 (첨도 < 0) 정규분포 높이 (첨도 = 0)

사분위수, 사분위수 범위

통계량	설명	특징
사분위수 (Quartile)	데이터를 순서대로 나열할 때 25, 50, 75, 100%번째에 있는 값	- 제1사분위수(Q1) : 25%번째 값 - 제2사분위수(Q2) : 50%번째 값 (중앙값과 같음) - 제3사분위수(Q3) : 75%번째 값 - 제4사분위수(Q4) : 100%번째 값 (최대값과 같음)
사분위수 범위 (IQR, Interquartile Range)	제3사분위수 - 제1사분위수	- Q1 또는 Q3에서 사분위수 범위의 1.5배 멀리 떨어진 관측치는 이상치로 판단할 수 있는 기준이 됨 → 사분위수 범위가 작고, 전체 범위 (최대-최소)가 크면 이상치가 많다는 의미 - 전체 범위 안에서 IQR이 어느 한쪽으로 치우쳐 있는지, 혹은 IQR 내부의 중앙값이 어디에 위치하는지에 따라 데이터의 편중 방향을 알수 있음

쏠림

박스플롯(Box Plot)

- 위치(중앙값), 퍼짐 정도(사분위수), 이상치(Outlier)를 동시에 확인하기 위한 시각화 도구


	키 (cm)	
1	170	← 0% (= 최소값)
2	170	
3	173	← 25% (Q1)
4	173	
5	173	← 50% (Q2 = 중앙값)
6	176	
7	178	
8	178	← 75% (Q3)
9	180	
10	181	← 100% (Q4 = 최대값)

사분위수 범위 (IQR) : $Q3 - Q1 = 178 - 173 = 5$

• 하한선 = $Q1 - 1.5 \times IQR = 165.5$

• 상한선 = $Q3 + 1.5 \times IQR = 185.5$

이 범위를 벗어나면 → 이상치 후보 (Outlier)



데이터 분석 및 AIOps

3. 기초통계 - (4) 확률분포

- 확률분포
- 정규분포
- 표준정규분포

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

확률, Probability

- 확률 : 어떤 사건이 발생할 가능성을 0과 1 사이의 숫자로 표현한 것

(예시)


- 수학적 확률
 - 이론 기반 확률
 - 주사위를 던져서 특정한 면(숫자)이 나타나는 확률 = $1/6$
 - 동전을 던져 특정한 면이 나타나는 확률 = $1/2$
- 통계적 확률
 - 실제 실험이나 관측을 여러 번 반복했을 때, 경험적으로 알 수 있는 확률
 - 제품 1,000개에 대해 평균 15개의 불량품이 나온다 → 불량품을 생산하는 확률 $15/1000 = 0.015$
 - 기업에서는 대부분 통계적 확률을 다루게 됨

확률 분포, Probability Distribution

- 확률 분포 : 변수가 가질 수 있는 모든 값들과 각 값을 가질 확률을 그래프 등으로 표현한 것

(예시)


- 주사위 눈 : 변수 (X)



이산형 확률분포

- 변수 (X) 가 고정된 값을 가짐
- 변수 (X) 값별로 확률 표시 가능

- 몸무게 : 변수 (X)




연속형 확률분포

- 변수 (X) 값을 미리 특정할 수 없음
- 값 사이에 무한히 많은 값을 가짐
- 특정 구간에 속할 확률을 표시
예) 70~ 80kg 사이일 확률

정규분포

- 정규분포 : 연속형 확률분포 중에서 가장 많이 볼 수 있는 좌우 대칭의 분포

μ : 평균
 σ : 표준편차
 σ^2 : 분산




[정규분포 특징]

- 평균(μ)을 중심으로 좌우 대칭인 종 모양
- 간단하게 $N(\mu, \sigma^2)$ 로 표기함
- $x = \mu$ 에서 곡선값이 최대가 되며, μ = 중앙값 = 최빈값
- 양쪽 꼬리부분은 x축으로 점점 접근
- 곡선과 x축 사이의 면적은 1

표준정규분포

개념

- 표준정규분포 : 평균 0, 표준편차 1로 표준화된 정규분포 (Z 분포)
- 다른 단위나 기준을 가진 데이터를 동일한 기준으로 비교하기 위해 정규분포 → 표준정규분포로 표준화 수행



- 간단하게 $N(\mu, \sigma^2)$ 로 표기함 (μ : 평균, σ^2 : 분산)

- 정규분포 X 값을 Z 값 (Score) 으로 변환,
$$z = \frac{(x - \text{평균})}{\text{표준편차}}$$
- 간단하게 Z (0, 1) 으로 표기함 (0: 평균, 1: 표준편차)
- 서로 다른 분포 또는 단위를 갖는 경우 상호 비교 가능


표준정규분포

예시

질문 1) 학생A 가 수학 90점, 국어 90점 받았다면 어느쪽이 더 잘한 것일까?

예시)


집단1	평균	표준편차
수학	60	30
국어	60	15



$$\text{수학 } Z = (90-60) / 30 = 1.0$$

$$\text{국어 } Z = (90-60) / 15 = 2.0$$

집단2	평균	표준편차
수학	50	15
국어	60	15



$$\text{수학 } Z = (90-50) / 15 = 2.667$$

$$\text{국어 } Z = (90-60) / 15 = 2.0$$

- 학생이 받은 원점수만으로는 비교가 안됨
- 표준화 Z (z-score) 값으로 상호 우열 비교 가능

표준정규분포


예시

질문 2) 학생A 가 받은 수학 90점은 상위 몇% 일까?

예시)


집단1	평균	표준편차
수학	60	30

집단2	평균	표준편차
수학	50	15



$$\text{수학 } Z = (90-60) / 30 = 1.0$$


Z가 1임으로 → 상위 약 16%



$$\text{수학 } Z = (90-50) / 15 = 2.667$$

Z가 2이상임으로 → 상위 약 2.3% 이내

표준정규분포



구간	누적 비율	꼬리(한쪽) 비율
$-1 \leq Z \leq 1$	68.27%	약 15.87%
$-2 \leq Z \leq 2$	95.45%	약 2.28%
$-3 \leq Z \leq 3$	99.73%	약 0.14%

“ Z 값의 표준정규분포값으로 상·하위 비율 확인 가능 ”

→ Outlier 판단 기준으로 활용, 예) $|Z| > 3$ 이면 이상치

데이터 분석 및 AIOps

3. 기초통계 – (5) Preprocessing

- 결측치 처리
- Outlier 처리
- 데이터 스케일링
- 분포 변환
- 연속형 변수 범주화
- 범주형 변수 수치화

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

결측치 처리

- Missing 존재 시 분석기법에 따라 연산자체가 불능. 예) Sum 함수, 선형 회귀 모델
- NA (Not Available), Missing Value, Null, 결측치
- 수치형 변수에서 '0' 값 의미 주의 필요

처리 방안 1

분석 제외

- 비즈니스 관점에서 제외해도 되는지 반드시 검토
- 제거해도 데이터 건수가 충분한지 검토

처리 방안 2

다른 값으로 대체

1) 대표값 대체 : 평균 or 중앙값 or 최빈값

1	NA	NA	7
	↑	↑	
	4	4	

2) 직전 대체 : 시계열 데이터인 경우 직전값

1	NA	NA	7
	↑	↑	
	1	1	

3) 보간 대체 : 선형으로 비례하는 방식 (Interpolation)

1	NA	NA	7
	↑	↑	
	3	5	

4) 범주형 변수 : 결측치 자체를 정보로 활용하여 "Unknown" 등의 새로운 범주를 할당하는 방법을 주로 사용

시계열 데이터
흐름을 반영


Outlier 처리

- 이상치, Outlier : 대다수 데이터와 달리 통계 관점에서 벗어난 값
- Outlier 는 분석 결과를 왜곡하거나 모델 성능을 떨어뜨릴 수 있음

Outlier 판단 방법

- 분위수 분석
 - 분위수에서 특정 범위를 벗어날 경우 탐지
예시) 백분위 수에서 5%~ 95% 범위 밖
- IQR (사분위수 범위) 분석
 - $IQR * 1.5$ 상하한 범위 밖 탐지
* IQR : Inter Quartile range, $Q3 - Q1$
- Z-score (표준점수) 기반
 - $Z = (\text{값} - \text{평균}) / \text{표준편차}$,
평균으로부터 상대적 거리를 계산
 $|Z| > 3$ 이면 이상치
- 휴리스틱 분석 : Biz 기준 or 경험 기반 기준점 설정
 - Fixed Value 범위 밖
 - 평균 대비 X% 이상

Outlier 처리 방안



- 이상치 처리 방안
 - 평균/ 중앙값/ **경계값**으로 대체
 - **분포 변환** : 로그 / 제곱근 변환

데이터 Scaling

개념

- 데이터 스케일링은 단위나 값의 범위가 서로 다른 데이터를 동일한 기준에서 비교·분석하기 위함
- 거리 기반 모델에서는 중요한 전처리 과정 : KNN, SVM, **신경망**, **K-Means**, PCA 등
단, **Tree 계열의 모델에서는 영향이 적음** (RandomForest, XGBoost, LightGBM 등)
- **대표적인 방법 : Z-Score 변환, Min-Max 변환 (0~1 변환)**

✓ Scale 차이로 인한 문제 예시

[Scaling 이전 - 단위가 제각각]

- 나이: [25, 30, 35, 40, 45] → 범위: 0~100
- 소득: [3000만, 4500만, 8000만, ...] → 범위: 0~수억
- 거리: [0.5km, 1.2km, 3.5km, ...] → 범위: 0~수십

➔ 모델이 단위가 큰 Feature에만 집중하게 됨 (**소득**)

[Scaling 이후 - 단위 통일]

- 나이: [-1.2, -0.5, 0.0, 0.5, 1.2] → 평균 0, 표준편차 1
- 소득: [-1.5, -0.3, 0.8, 1.5, 0.2] → 평균 0, 표준편차 1
- 거리: [-0.8, -0.2, 1.1, 0.5, 1.8] → 평균 0, 표준편차 1

➔ 모든 변수 공평하게 비교

데이터 Scaling

방법

- Z 변환 : 평균을 0, 표준편차를 1로 맞추어 변수 간 단위와 규모 차이를 제거

표준화 기법

변환 前

변환 後

평균 0, 표준편차 1
정규분포


Z변환

표준정규
분포


$$Z = \frac{x - \bar{x}}{s}$$

x : 관측값
 $\bar{x}$: 평균
 s : 표준편차

A 집단




B 집단



비교
불가

$$z_1 = \frac{19 - 10}{3} = 3$$

$$z_2 = \frac{3 - 2}{1} = 1$$



데이터 Scaling

방법

- Min-Max 변환 : 최소 0, 최대 1 이 되게 변환

표준화 기법

변환 前

변환 後

**Min-Max
Scaler**

[0-1] 변환

$$Z = \frac{x - \min}{\max - \min}$$

x : 관측값
 $\max$: 최대값
 $\min$: 최소값

C 집 단

D 집 단

Scale
차이

max=50
관측값=45

min=10

$$y_1 = \frac{45 - 10}{50 - 10} = 0.875$$

max=1
0.875

max=1,000

관측값=200

min=100

$$y_2 = \frac{200 - 100}{1000 - 100} = 0.111$$

0.111
min=0


분포 변환

로그/제곱근 변환 : 한쪽으로 치우친 데이터를 대칭 분포로 변환해서 이상치 처리 또는 정규분포로 만들

로그 / 제곱근 변환

한쪽으로 치우친 분포

- 오른쪽으로 꼬리가 긴(right-skewed) 분포



로그 변환
($= \log x$)

혹은


제곱근 변환
($= \sqrt{x}$)

관측값	로그변환	제곱근변환
10	1	3.2
100	2	10.0
1,000	3	31.6

대칭 분포

좌우 대칭 (symmetric) 분포로 변환

이상치 처리, 정규분포 가정 만족
(회귀분석, 판별분석, ANOVA, t-test 등)



로그변환

연속형 변수 범주화

주요 목적


- 모델의 해석성을 높이기 위함, 예) 연령 -> 연령대
- Out-lier 및 Missing 처리 효과

연속형 -> 범주화 (예시)

환자ID	체중	체중_그룹
P1001	49kg	체중 下
P1002	71kg	체중 中
P1003	86kg	체중 上
P1004	59kg	체중 中
P1005	77kg	체중 上
⋮	⋮	⋮


변환 시 유의사항

범주 개수, 범주 구간 설정 근거
(예: 데이터 분포, 변곡점 등)




구간화 방법

1) Frequency 기준 : 빈도수가 일정하게, 예) 구매횟수



2) Value 기준 : Value 간격이 동일하게, 예) 연령



범주형 변수 수치화

- 통계분석, 머신러닝은 범주형 데이터를 직접 계산할 수 없기 때문에 숫자 변환이 필요

One-Hot Encoding

- 각 범주를 별도의 0/1 컬럼으로 분리
→ 0, 1 만 갖는 변수를 dummy 변수라 함
- 범주의 순서가 의미 없을때

예시) 범주형 변수: 성별, 직업군

고객	성별	직업군
1	여성	A
2	여성	C
3	남성	B
4	남성	A

고객	성별_여성	성별_남성	직업군_A	직업군_B	직업군_C
1	1	0	1	0	0
2	1	0	0	0	1
3	0	1	0	1	0
4	0	1	1	0	0

→ 회귀분석에서는 모든 범주를 One-Hot으로 만들면 *다중공선성 문제 발생

그래서 회귀분석에서는 k개의 범주 중 1개 범주를 제외한 k-1개 dummy 변수를 생성함.

예) 성별 컬럼 중 '성별_여성' 컬럼만 남김

* 다중공선성: 설명변수간 상관관계가 높아 회귀 모델에서 변수 영향력 추정이 어려운 문제

Label Encoding

- 각 범주에 정수 라벨 부여
- 범주의 순서가 의미 있을때

예시) 범주형 변수: 학점, 등급

고객	학점	등급
1	A	2등급
2	C	3등급
3	B	1등급
4	A	1등급

고객	학점_Label	등급_Label
1	1	2
2	3	3
3	2	1
4	1	1

데이터 분석 및 AIOps

3. 기초통계 – (6) 상관분석

- 상관계수
- 상관계수 해석 시 유의사항

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

상관분석

두 변수 사이의 관계 살펴보기

✓ 많은 경우 두 변수 사이의 관계는 중요

- 근속연수와 연봉
- 키와 몸무게
- 공부 시간과 시험 점수
- 광고비와 매출액
- 운동량과 체지방률
- 담배 흡연량과 평균 수명
- 주행속도와 이동시간
- 가격과 수요
- 신발 사이즈와 토익 점수
- 출생월과 수학 점수
- 헤어 길이와 IQ
- 머리둘레와 폐활량

➔ 두 변수 사이의 상호관계를 분석하기 위한 방법은?


상관분석

두 변수 사이의 관계를 살펴보는 간단한 접근, 산점도(Scatter plot)

Scatter plot


- 두 연속형 변수의 값을 좌표평면에 점으로 나타낸 그래프
- 두 변수 사이의 관계를 살펴보기 위해 산포도를 활용
- 설명변수는 x로 표기하고 가로축에 표시
- 종속변수는 y로 표기하고 세로축에 표시

➔ 두 변수의 개략적인 관계를 알수 있지만,
관계의 정도를 확인할 수는 없음



상관분석

필요한 이유



- 두 산포도는 가로든 세로든 중심(평균)과 퍼진 정도(표준편차)가 동일하지만 (a)가 (b)보다 더 강한 선형관계를 보임

상관분석이 필요한 이유

- 두 변수간 선형관계의 방향과 강도가 얼마나 되는지 측정할 필요성
- 상관계수는 두 변수간 선형관계의 방향과 강도 측정하는 수단


상관계수

상관계수를 산출하여 상관관계 정도를 확인할 수 있음

【 상관계수 (r). Correlation Coefficient 】

$$: \text{Corr}(X, Y) = \rho = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y}, -1 \leq \rho \leq 1$$








- 두 변량 사이의 관계가 얼마나 강한지는 나타내는 숫자 (-1 ~ 1)
 - 양의 값 : 두 변수가 같은 방향으로 움직임
 - 음의 값 : 두 변수가 반대 방향으로 움직임
 - 0 : 선형관계 없음 (두 변량이 독립적이면 상관계수는 0). 단, 비선형 관계가 있더라도 파악하지 못함



상관계수 해석 시 유의사항(1)

선형관계만 알수 있음

- 상관계수는 선형적인 관계만을 알 수 있으며, 비선형 관계는 알 수 없음
- 상관계수 수치만 보고 판단하지 말고, 그래프 분석을 병행하는 것이 필요함 (Scatter Plot, 산점도)




비선형 관계에
있지만
상관계수=0

상관계수 해석 시 유의사항(2)

Outlier에 민감


키와 몸무게 데이터 및 산포도

	ID	H_cm	W_kg
1	1	175	52
2	2	173	64
3	3	163	54
4	4	175	65
5	5	171	67
6	6	169	60
7	7	167	55
8	8	171	65



특이값 제거 前

- 키-몸무게
상관계수 $r = 0.386$



특이값 제거 後


- 키-몸무게
상관계수 $r = 0.867$

→ Outlier에 민감하게 반응하므로 제거 후 상관관계 분석을 진행하는 것이 필요함


상관계수 해석 시 유의사항(3)

상관계수 해석 시 교란요인에 대한 주의가 필요함

제 3의 (교란) 요인은 없는가?



vs.



(*) 편상관계수, Partial Correlation : 어떤 변수들의 관련성을 특정 변수로부터 고정시킨 후 나머지 변수들간의 관계를 분석하는 것

상관계수 해석 시 유의사항(4)

상관계수 해석 시 시간 선/후 관계에 대한 주의가 필요함

시간 선/후 관계, 방향이 맞는가?

2000년 11월 조사한 '비행청소년의 식생활에 관한 연구'를 보면 **라면, 햄버거, 피자, 탄산음료 등 인스턴트 음식의 섭취량에서 일반청소년과 비행청소년들 사이에 상당한 차이**가 있는 것으로 드러났다.

즉 **비행청소년들은 일반 청소년들에 비해 이와 같은 음식물을 2배 가량 많이 섭취하고 있었다**. 박명운 이사장은 “대량의 카페인, 당분, 방부제, 향료, 인공 착색료 등이 들어 있는 음식을 '정크 푸드'라고 하는데 특히 어린이들의 경우 이런 인공물질에 대한 신체 저항력이 불완전하므로 지속적으로 **그런 음식을 섭취하면 주의력이 흩어지고, 욕구불만이 쌓여 폭력행동으로 나타날 가능성이 있다**”고 지적했다.”

- 주간동아 제345호 '공/공/의/적/햄/버/거' 중에서 -

라면, 햄버거, 피자, 탄산음료를
많이 먹어서 비행 청소년이 되는 것인가?

vs.

비행 청소년이 집에 못 들어가고
가정형편이 어려워서 어쩔 수 없이
정크 푸드를 먹을 수 밖에 없는 것인가?

상관계수 해석 시 유의사항(4)

상관관계 vs 인과관계

상관관계, Correlation

- 두 변수 중 **한쪽이 증가함에 따라, 다른 한쪽이 증가 또는 감소 경향**이 있는 관계
- 두 변수가 얼마나 **선형적 관계**에 있는지 알아내기 위함
예시) 키와 몸무게, 나이와 연봉



인과관계, Causal Relation

- 어떤 **선행사실(원인)**과 **후행사실(결과)**의 필연적 관계
- 인과관계 특징
 - A. X가 Y보다 시간적으로 먼저이고 (또는 논리적으로)
 - B. X가 있으면 Y가 있고, X가 없으면 Y가 없음
 예시) 흡연량과 폐암발병률



주의 : X, Y 변수의 상관관계가 **자동적으로 X가 Y의 원인을 의미하는 것이 아님**, 예시) 아이스크림 판매량 과 익사 사고 건수
→ 인과관계를 밝히기 위해서는 별도의 실험이나 인과 추론 과정이 필요함

데이터 분석 및 AIOps

3. 기초통계 - (7) 회귀분석

- 회귀분석 개념
- 회귀분석 방법
- 회귀모형 성능 평가
- 회귀분석 기본가정

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

회귀분석의 유래

- 영국의 과학자 프랜시스 골턴의 **부모 키와 자식 키 관계 분석**에서 유래
- 결론 : 키 큰 부모의 자녀 → 부모보다 조금 작아지는 경향이 있고,
키 작은 부모의 자녀 → 부모보다 조금 커지는 경향이 있음, **결국 평균으로 되돌아감 (회귀)**

성인 자녀	부모 키											Totals
	<64.0	64.5	65.5	66.5	67.5	68.5	69.5	70.5	71.5	72.5	>73.0	
>73.7	—	—	—	—	—	—	5	3	2	4	—	14
73.2	—	—	—	—	—	3	4	3	2	2	3	17
72.2	—	—	1	—	4	4	11	4	9	7	1	41
71.2	—	—	2	—	11	18	20	7	4	2	—	64
70.2	—	—	5	4	19	21	25	14	10	1	—	99
69.2	1	2	7	13	38	48	33	18	5	2	—	167
68.2	1	—	7	14	28	34	20	12	3	1	—	120
67.2	2	5	11	17	38	31	27	3	4	—	—	138
66.2	2	5	11	17	36	25	17	1	3	—	—	117
65.2	1	1	7	2	15	16	4	1	1	—	—	48
64.2	4	4	5	5	14	11	16	—	—	—	—	59
63.2	2	4	9	3	5	7	1	1	—	—	—	32
62.2	—	1	—	3	3	—	—	—	—	—	—	7
<61.7	1	1	1	—	—	1	—	1	—	—	—	5
Totals	14	23	66	78	211	219	183	68	43	19	4	928

- X축 : 부모 키, Y : 자녀 키
- 각 칸의 숫자 : 해당 부모 키 구간에서 태어난 자녀 수
- 빨간 동그라미 : 부모 키에 해당하는 자식 키 평균 위치
- 파란 점선 : 그 평균값들을 연결한 회귀선(regression line)


$$Y(\text{아버지 키}) = 33.73 + 0.516X(\text{아들 키})$$

회귀분석의 의미

회귀분석
이란?

“ 변수들 간의 상호 관련성을 규명하고, 어떤 변수들의 변화로부터 다른 변수들의 변화를 예측 하는 통계기법 ”

예시)



목적

1

Inference (추론)

- 왜? 원인이 무엇인가?
- 변수간 관계·해석 탐구 목적
- 검증값 : p-value


2

Prediction (예측)

- 얼마나 잘 맞히는가?
- 미래 값/미지 값 예측
- 검증값 : MAPE, MAE 등

회귀분석의 활용

선형회귀분석을 통해 답할 수 있는 질문, 관심 있어 하는 질문들은...



상관분석 vs 회귀분석


		상관 분석	회귀 분석
차 이 점	개념	"상관" 관계 (관계 유무) 	"영향력" 관계 (관계 유무 + 예측 가능) 
	분석 결과	두 변수간의 관련성을 '상관계수'로 표현	두 변수간의 영향력을 '회귀식'으로 표현
	결과 예시	상관계수 : 0.78 (범위 : -1 ~ 1)	회귀식 : $Y = 0.65 * X + 30$, 유의확률 : 0.001
분석 흐름	결과 해석	두 변수 관계 방향성, 관계 정도를 제시함	두 변수 관계 방향성, 관계 정도 제시, <u>Y 예측 가능</u>
	변수 선택	상관 → 회귀 - 상관분석 후 회귀분석 실행 - 회귀분석 수행 전 상관분석 수행으로 상관성이 매우 높은 독립변수를 제거함으로써 회귀분석의 *다중 공선성 문제 해결	

* 다중공선성: 설명변수간 상관관계가 높아 회귀 모델에서 변수 영향력 추정이 어려운 문제

회귀분석 종류


종속변수 형태, 독립변수 개수 등에 따라 다름

- 종속 변수의 형태에 따라 **선형 회귀분석**과 **로지스틱 회귀분석**으로 구분됨
- 선형 회귀분석에서는 독립변수의 개수에 따라 **단순 회귀분석**, **다중 회귀분석**으로 구분됨



회귀분석 기본 원리

- 회귀분석은 설명변수와 종속변수의 관계를 가장 잘 설명하는 회귀식을 찾는 분석 기법
- 회귀분석을 한다 = 회귀선을 찾는다 = 회귀모델을 생성한다 = 회귀모형 적합(Fitting)



- 잔차 : 관측값과 예측값의 차이 * 오차 : 모집단에서의 차이
- 회귀선 : 잔차²의 합이 최소가 되는 하나의 직선 (최소제곱법)


$$\sum \text{잔차}^2 = \sum (\text{관측값} - \text{예측값})^2 \rightarrow \text{MIN}$$
- 회귀식 : 회귀선을 함수식으로 나타낸 것으로
설명변수와 종속변수의 관계를 나타냄

$$y = a_1 \cdot x_1 + a_2 \cdot x_2 + \dots + a_n \cdot x_n + b$$
 종속변수(y) = 회귀계수(a_n) × 설명변수(x_n) + 상수(b)
- 회귀 분석 : 최적의 회귀식을 찾는 분석기법
- 회귀 모델(모형) : 회귀 분석 결과로 찾아진 설명변수와 종속변수간의 관계 모델

회귀분석 기본 원리

- 최소제곱법으로 회귀선 (회귀함수) 찾는 방법 예시

잔차² 합이 최소가 되는 직선은?



$$\sum \text{잔차}^2 = \sum (\text{관측값} - \text{예측값})^2 \rightarrow \text{MIN}$$

관측 데이터	x, y (관측값)	1 y_1 (예측값)	2 y_2 (예측값)	3 y_3 (예측값)
		$y = 2 * x$	$y = x + 2$	$y = x$
A	1, 1	2 (= 2 * 1)	3 (= 1 + 2)	1
B	2, 2	4 (= 2 * 2)	4 (= 2 + 2)	2
C	3, 3	6 (= 2 * 3)	5 (= 3 + 2)	3
$\sum \text{잔차}^2$		$(1-2)^2$ + $(2-4)^2$ + $(3-6)^2$	$(1-3)^2$ + $(2-4)^2$ + $(3-5)^2$	$(1-1)^2$ + $(2-2)^2$ + $(3-3)^2$
		14	12	0

➔ SUM(잔차²)가 최소가 되는 회귀선은 $y = x$ 임

회귀분석 결과 검증

- 검증 통계량 : F통계량, P value, 결정계수

최소제곱법으로 회귀식을 구함

$$\text{회귀식} : y = b + a_1 \cdot x_1 + a_2 \cdot x_2 + \dots + a_n \cdot x_n$$

n : 독립변수 개수,
 x_n : 독립변수_n의 값,
 y : 종속변수

a_n : 독립변수_n의 회귀계수,
 b : 상수(y절편),

→ 최소제곱법으로 회귀계수(a_n)와 상수(b)를 구함

$$\text{예시) } Y(\text{몸무게}) = 0.90 \times (\text{키}) + 0.15 \times (\text{나이}) - 90$$

구해진 회귀식이 통계적으로 유의한지 검증함

회귀식 유의성 검증

회귀식을 신뢰할 수 있는지?

F통계량의 유의확률 < 0.05(유의수준) → '유의'

회귀식이 유의하지 않으면 ...

- ① 독립변수를 제거/추가 후 회귀분석 재실행 (변수 재검토)
- ② 분석 대상에 대한 분할/추가 후 회귀분석 재실행 (데이터 재검토)

회귀계수 유의성 검증

각 회귀계수별 P-값 < 0.05(유의수준) → '유의'

회귀계수가 유의하지 않으면 ...

- ① 유의미하지 않는 독립변수를 제거
- ② 해당 변수를 변환하여 회귀분석 재수행

회귀식 설명력

신뢰할 수 있다면 얼마나 신뢰할 수 있는지?

조정된 결정계수(R^2_{adj}) = '설명력'

결정계수는 독립변수가 늘어날수록 커지게 되는데, 이를 보정한 통계량이 조정된 결정계수이며, 1에 가까울수록 좋음

회귀모형 성능 평가

회귀모형의 성능은 모델의 설명력 또는 오차 크기 관점에서 평가됨


- 모델 설명력 : 모델이 데이터를 얼마나 잘 설명하는지를 평가
- 오차 크기 : 모델이 얼마나 정확하게 예측하는지를 평가

평가 척도			수식	해석
모델의 설명력	R^2	R-Squared (결정계수)	✓ $SSR / SST = \text{잔차제곱합} / \text{총제곱합}$	1에 가까울수록 설명력이 좋은 모델임
	Adj. R^2	Adjusted R-Squared (조정된 결정계수)	✓ 독립변수가 여러 개일 때 결정계수에 독립변수의 개수와 데이터 크기를 반영한 값	
오차의 크기 *오차: 실제값과 예측값 차이	MAPE	Mean Absolute Percentage Error (평균절대백분율오차)	✓ 오차의 절대값을 실제값으로 나눈 후 모두 더한 다음 데이터 크기로 나눈 값 → $\sum (\text{실제값} - \text{예측값} / \text{실제값}) / n$	0에 가까울수록 예측 오차가 적은 모델임
	MAE	Mean Absolute Error (평균절대오차)	✓ 오차의 절대값을 모두 더한 다음 데이터 크기로 나눈 값 → $\sum \text{실제값} - \text{예측값} / n$	
	MSE	Mean Squared Error (평균제곱오차)	✓ 오차의 제곱을 모두 더한 다음 데이터의 크기로 나눈 값 → $\sum (\text{실제값} - \text{예측값})^2 / n$	
	RMSE	Root Mean Squared Error (평균제곱근오차)	✓ 오차의 제곱을 모두 더한 다음 데이터의 크기로 나눈 값의 제곱근 → $\sqrt{\sum (\text{실제값} - \text{예측값})^2 / n}$	

[참고] 회귀모형 성능 평가 (R^2)

- 결정계수(R^2)는 회귀모델에서 독립변수가 종속변수를 얼마만큼 설명해 주는지를 가리키는 지표

→ 설명력 (0~1, 1에 가까울 수록 성능이 좋음)




$$SST(\text{총변동}) = SSR(\text{회귀변동}) + SSE(\text{잔차변동})$$

- SST(총편차, 총변동, 제곱합)**
= 관측값 - 평균값 = $y_i - \bar{y}$
- SSR(설명되는 편차, 회귀변동, 회귀제곱합)**
= 예측값 - 평균값 = $\hat{y} - \bar{y} = (a \cdot x + b) - \bar{y}$
- SSE(설명 안 되는 편차, 잔차변동, 잔차제곱합)**
= 관측값 - 예측값 = $y_i - \hat{y} = y_i - (a \cdot x + b)$
- 결정계수(R^2)**
➤ $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$
- 조정된 결정계수(R^2_{adj})**
 $R^2_{adj} = 1 - \frac{SSE/(n-k-1)}{SST/(n-1)}$, n: 데이터수, k: 독립변수 수

[참고] 회귀모형 성능 평가 (MAPE)

- MAPE 는 오차의 절대값을 실제값으로 나눈 후 모두 더한 다음 데이터 크기로 나눈 값



$$MAPE = \sum (|실제값 - 예측값| / 실제값) / n$$

Test Data	x	y		ABS(관측값 - 예측값) / 관측값
	관측값	관측값	예측값 (y = x)	
D	1	1	1	$ABS(1-1)/1 = 0$
E	1.5	2	1.5	$ABS(2-1.5)/2 = 0.25$
F	2.5	3	2.5	$ABS(3-2.5)/3 = 0.17$
MAPE (평균절대백분율 오차)		$(0 + 0.25 + 0.17) / 3$		
		0.14		

회귀분석 결과 해석

Biz 상황

기업에서 상품 A에 대한 마케팅을 수행하여 구매 고객수를 높이하고자 한다.

분석 목적

- 1) 쿠폰 배포 매수와 상품 판매 가격 중 어떤 요인이 구매 고객 수에 더 큰 영향을 미치는가?
- 2) 쿠폰 배포 매수와 상품 판매 가격을 조정하면 예상되는 구매 고객수는 얼마인가?

요약 출력

회귀분석 통계량	
다중 상관계수	0.879
결정계수	0.773
조정된 결정계수	0.735
표준 오차	27.565
관측수	15

분산 분석

	자유도	제곱합	제곱 평균	F 비	유의한 F
회귀	2	30983.225	15491.613	20.389	0.000
잔차	12	9117.708	759.809		
계	14	40100.933			

	계수	표준 오차	t 통계량	P-값
Y 절편	274.375	45.401	6.043	5.817E-05
쿠폰배포매수(장)	0.109	0.017	6.326	3.795E-05
판매가격(원)	0.003	0.014	0.242	8.130E-01

회귀식 (회귀모델)

$$y = a \cdot x_1 + b \cdot x_2 + c$$

y : 구매고객수

x_1 : 쿠폰배포매수(장), x_2 : 판매가격(원)

a : 쿠폰배포매수 회귀계수, b: 판매가격 회귀계수

$$y = 0.109 \cdot x_1 + 0.003 \cdot x_2 + 274.375$$

→ 회귀계수 크기로 Y에 대한 상대적 영향력 판단 가능

단, 설명변수가 Z-Score 등으로 표준화된 단위일 경우

회귀분석 결과 해석

요약 출력

회귀분석 통계량

다중 상관계수	0.879
결정계수	0.773
2 조정된 결정계수	0.735
표준 오차	27.565
관측수	15

분산 분석

	자유도	제곱합	제곱 평균	F 비	1 유의한 F
회귀	2	30983.225	15491.613	20.389	0.000
잔차	12	9117.708	759.809		
계	14	40100.933			

	계수	표준 오차	t 통계량	3 P-값
Y 절편	274.375	45.401	6.043	5.817E-05
쿠폰배포매수(장)	0.109	0.017	6.326	3.795E-05
판매가격(원)	0.003	0.014	0.242	8.130E-01

1 회귀식의 유의성 검증

- 유의한 $F = 0.00 < 0.05$
 → 회귀모형이 유의함 (유의수준 0.05)
 → 모든 독립변수가 종속변수에 영향을 주지 않는다는 가설 기각

2 회귀식의 설명력 평가

- 조정된 결정계수(Adj. R^2)가 0.735
 → 회귀모형이 73.5%의 설명력을 가짐

3 회귀계수의 유의성 검증

- 쿠폰배포매수 P-값 = $3.795E-05 < 0.05$
 → 회귀계수가 유의함 (유의수준 0.05)
- 판매가격 P-값 = $8.130E-01 \geq 0.05$
 → 회귀계수가 유의하지 않음
 → 판매가격이 구매고객수에 영향을 주지 않음

“모델 목적이 변수 해석 (추론)이라면 제거하고, 예측 정확도라면 MAPE 등 평가 지표를 확인 하고 제거 여부 판단”

- 변수 제거 후 회귀식 다시 개발

$$y = 0.108 \cdot x + 282.892$$

회귀분석 결과 해석

상황

- 기업에서 상품 A에 대한 마케팅을 수행하여 구매고객수를 높이하고자 한다.

분석 목적

- 쿠폰배포매수와 판매가격 중 어떤 요인이 구매고객수에 더 큰 영향을 미치는가?
- 쿠폰배포매수와 판매가격을 조정하면 예상되는 구매고객수는 얼마인가?

예상 의사결정 사항

- 쿠폰과 가격 두 가지 모두에 반응한다면, 쿠폰배포매수를 높이고 판매가격도 낮춘다.
- 쿠폰에 더 민감하게 반응한다면, 쿠폰의 종류와 수를 다양화한다.

질의사항

- 쿠폰을 많이 배포하면 구매고객이 늘어나는가? 얼마나 늘어나는가?
- 판매가격을 낮추면 구매고객이 늘어나는가? 얼마나 늘어나는가?
- 쿠폰배포매수 3,000장, 판매가격 2,000원인 경우 예상되는 구매고객수는 몇 명인가?

최종 회귀식 : $y = 0.108 \cdot x + 282.892$ (Adj. $R^2 = 0.73$)
x : 쿠폰배포매수

판매가격은 구매고객수에 영향을 미치지 않는다.

쿠폰배포매수는 구매고객수에 영향을 미친다.

이 분석모형은 유의하며, 73%의 설명력을 가진다.

쿠폰을 10장 배포하면 구매고객수는 1명 증가한다.
 $(0.108 * 10 = 1.08)$

쿠폰을 3,000장 배포할 경우,
 구매고객수는 607명으로 예상된다.
 $(0.108 * 3000 + 282.892 = 606.892)$

[참고] 회귀분석 기본 가정 - 선형성

- 회귀모델의 결과(회귀계수, 유의성 검정, 예측값)를 신뢰하기 위해서는 회귀분석 기본 가정이 충족되어야 함
- 회귀분석의 4가지 기본 가정은 절대 조건이 아니라 회귀분석 결과 신뢰성을 점검하는 기준임
- 그 중 선형성 가정은 종속변수와 독립변수 산점도를 그려서 두 변수의 선형성 여부를 확인함 (선형 회귀모형인 경우)

1) 선형성이란?


- 독립변수(x)가 증가할수록 종속변수(y)가 증가하거나 감소하는 경향
- 독립변수와 종속변수 간의 관계가 직선 형태를 띤다는 의미

3) 선형성을 만족하지 않는 경우 대응 방법


- 변수 변환 : 독립변수를 범주형 변수로 변환 등
- 비선형 분석기법 검토 : 다항회귀(x^2 , x^3 등 고차항 추가), Tree 계열 모델 등

2) 선형성 확인 방법


- 산점도(산포도)를 통해 종속변수와 독립변수의 관계를 파악하고, 선형성을 확인함




관련성: 있음
선형성: 만족



관련성: 없음
선형성: 불만족



관련성: 있음
선형성: 불만족



관련성: 있음
선형성: 불만족

[참고] 회귀분석 기본 가정 - 독립성

- 설명변수간에 다중공선성이 발생한 변수들 중 하나를 제거하여 다중공선성 문제를 해결함

1) 독립성과 다중공선성이란?

- 독립성 : 설명변수간에 상관관계가 없다는 것을 의미
- 다중공선성 : 설명변수간에 상관관계가 있다는 것을 의미

3) 다중공선성 확인 방법


- 설명변수 간 상관계수(r) 확인 :
 - 예) $0.8 \leq |r|$ → 다중공선성 존재
 - $0.6 \leq |r| < 0.8$ → 다중공선성 의심

2) 다중공선성이 문제인 이유

- 다중 공선성은 1) 회귀 계수의 분산을 증가시켜 회귀계수가 불안정하고, 2) 회귀 계수가 해당 변수의 종속변수에 미치는 영향력을 올바르게 설명하지 못하게 됨 (회귀계수의 부호가 바뀌거나, 0에 가까운 값이 나옴)

4) 독립성을 만족하지 않는 경우 처리 방법

- 다중공선성이 발생한 설명변수 중 하나만 남기고 삭제



- PCA(principal component analysis) 적용으로 의존성 제거

[참고] 회귀분석 기본 가정 - 등분산성



- 잔차도를 그려 점들이 0을 중심으로 패턴 없이 랜덤하게 분포하는지 확인함

1) 등분산성이란?

- 잔차의 분산(값이 평균에서 흩어진 정도)이 동일하다는 의미

3) 등분산성 확인 방법

- 잔차도의 점들이 0을 중심으로(평균 $\approx$ 0) 특정 패턴 없이 랜덤하게 분포하는지 확인



2) 등분산성을 확인하는 이유

- 설명변수의 통계적 설명력이 떨어지고 종속변수에 대한 예측을 할 경우 오류가 발생할 확률이 높아짐

4) 등분산성을 만족하지 않는 경우 처리 방법

- 분산성이 만족되도록 변수 변환(로그 변환 등)
- 등분산성에 크게 어긋나는 경우 회귀분석 기법을 적용하지 않으나, 독립성을 만족하는 경우 계속 진행할 수 있음

[참고] 회귀분석 기본 가정 - 정규성

- 잔차에 대한 히스토그램을 그려 정규분포인지 확인함

1) 정규성이란?

- 잔차가 정규분포를 따른다는 것을 의미



*정규분포: 평균값을 중앙으로 하여 좌우 대칭인 종 모양을 이루는 것

2) 정규성을 확인하는 이유

- 회귀계수 유의성 검증과 모델 적합도 검증에서 사용되는 T 통계량, F 통계량 등이 정규분포로부터 파생된 확률분포이기 때문임

3) 정규성 확인 방법

- 잔차 히스토그램을 그려 정규분포인지 확인



4) 정규성을 만족하지 않는 경우 처리 방법

- 정규성이 만족되도록 변수 변환(로그 변환 등)
- 정규성에 크게 어긋나는 경우 회귀분석 기법을 적용하지 않으나, 독립성을 만족하는 경우 계속 진행할 수 있음

회귀분석 절차

분석 절차	수행 내용	초점
분석 과제 정의	회귀분석을 통해 해결하고자 하는 문제를 정의하고, 예측하고자 하는 목표 변수 선정 및 예상되는 가설을 수립함.	Q. 주택가격을 예측하고자 한다. 영향을 미칠 것으로 예상되는 요인은?
업무 이해 및 분석 요건 정의	관련 업무 이해를 바탕으로, 변수 정의 등 분석 요건을 정의함.	Q. 종속변수 및 설명변수 정의 등 회귀모델링을 위한 상세 분석 요건은?
데이터 준비	분석 요건을 근거로 하여 회귀모델링을 위한 데이터 수집 및 가공	Q. 필요 데이터 존재 여부 및 데이터 추출 및 파생변수 등 데이터 변환 방법은?
데이터 탐색	데이터 이해 및 Missing 데이터 처리 등 데이터 클린징 작업	Q. 회귀분석 목적에 맞게 데이터가 잘 준비되어 있는가?
회귀모델 생성	분석 프로그램을 이용하여 회귀모델 생성	Q. 어떤 분석 기법을 선택할 것인가?
회귀모델 평가	회귀식 및 회귀계수가 유의미한지 검증 회귀모델 성능 평가	Q. 모델성능이 Baseline 모델 대비 효과가 있는가?
분석 결과 해석	최종 모델 선택 및 회귀모델 해석	Q. Best Model 선택 및 회귀식 도출

데이터 분석 및 AIOps


Appendix

- 머신러닝 분석 기법
- statsmodels vs scikit-learn
- Data Partition
- Baseline 모델 vs Navie 모델
- 모델 개발 프로세스

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

머신러닝 분석 기법

데이터 특성에 따른 분석 기법 종류



statsmodels vs scikit-learn

회귀분석을 위한 대표적 Python 라이브러리

구분	statsmodels	scikit-learn (머신러닝)
주 목적	통계적 해석 (추론)	예측
주 관심사	변수의 영향력	예측 정확도
F통계량, p-value	제공	제공하지 않음
Hyperparameter	없음	존재
대표 평가	R^2 , p-value	RMSE, MAE, MAPE 등
Data Partition	거의 사용 안 함	기본적으로 사용
활용 분야	논문, 정책 연구, 원인 분석	예측 시스템, AI 서비스 개발


→ 과거 : 통계적 유의성 검증을 위한 statsmodels 기반 통계 분석이 중심

→ 현재 : 예측 성능을 극대화하는 머신러닝(scikit-learn 등)이 대세

※ 단, 정책 연구나 원인 분석 등 변수 영향력 검증에는 여전히 statsmodels가 강점이 있음.

Data Partition

모델 개발을 위해서 Dataset 을 모델 학습 데이터와 모델 평가 데이터로 나누는 것



**모델 학습
위한 데이터**

**학습에
반영되지 않는
데이터**

Baseline 모델 vs Navie 모델

성능 비교 위한 기준 모델

- 모델 성능 평가는 평가지표 절대값보다 “비교 기준”이 더 중요

Baseline 모델

- 모델 성능 평가시 비교 대상으로 사용하는 모델
- 예시)
 - 이전에 개발한 모델
 - 가장 단순한 ML 모델, 예) 선형 Regression 모델
 - 규칙기반 Rule 모델
 - Navie 모델

Navie 모델

- 학습 없이 가장 단순한 규칙만으로 예측하는 모델
- 예시)
 - 회귀 모델 : Y 변수의 평균값(mean) 으로 예측, (시계열의 경우) 직전 값으로 예측
예) 내일 주가 예측 시 “전일 종가” 로 예측
 - 분류 모델 : Y 변수의 다수 클래스(Majority Class) 로 예측
예) 불량 5%, 정상 95% → 전부 “정상” 예측





수고하셨습니다.

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.