



SKALA

데이터분석 및 AIOps

실전 Feature Engineering

2026.07

전임교수 : Byung-sun, Park

Ver.4

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.



1. Intro

2. EDA

3. Pre-processing : Basic

4. Pre-processing : Advanced

5. Creating Better Features

실전 Feature Engineering

Intro


- 분석 Framework
- 분석 프로세스별 고려사항

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

분석 Framework

“분석 모델 개발”을 위한 작업 활동, 절차, 산출물을 체계화하여 분석 업무 수행을 위한 가이드라인

분석 방법론 개요



분석 방법론 프로세스

- 1 비즈니스 이해**
Business Understanding
 - Determine Business Objects
 - [Determine Analysis Goals](#)
- 2 가설 수립**
Data Understanding
 - Define Hypothesis
 - [Nominate & Define Data Items](#)
- 3 데이터 준비**
Data Preparation
 - Pre-processing for Analysis
 - Add Data for Analysis
- 4 분석 모델 정의**
Modeling
 - [Nominate Modeling Techniques](#)
 - Build (Several) Models
- 5 모델 평가**
Evaluation
 - Evaluate Results
 - [Determine Strong Model](#)
- 6 시스템 적용**
Deployment
 - Plan for System Deployment
 - Monitoring Results

분석 방법론 프로세스별 고려사항

분석 방법론 프로세스

1 **비즈니스 이해**
Business Understanding

2 **가설 수립**
Data Understanding

3 **데이터 준비**
Data Preparation

4 **분석 모델 정의**
Modeling

5 **모델 평가**
Evaluation

6 **시스템 적용**
Deployment

A. 비즈니스 목표 정의, 분석 목표 정의

B. 가설 수립, 데이터 정의

C. 개발 시스템 구축

절차별 FAQ

A. 비즈니스 목표에 대한 이해

- 경쟁사는 누구인가?
- 기업 가치를 높이기 위한 전략은 무엇인가?
- 공정 효율화를 위한 방향성은 무엇인가?

B. 데이터에 대한 이해

- 어떤 분석을 위해 어떤 데이터가 필요한가? ◀ 업무 기반으로 정의
- 분석 목적에 따라 현재 수집되고 있는 데이터 항목은? 데이터 량은? 품질은?
- 외부 수집/구매가 필요한 데이터는?

C. 분석 시스템 환경에 대한 이해

- 시스템 사양(CPU, GPU)은?
- 데이터 용량에 따른 스토리지 용량은?
- 필요 패키지 버전은?

분석 방법론 프로세스별 고려사항

분석 방법론 프로세스

1 비즈니스 이해
Business Understanding

2 가설 수립
Data Understanding

3 데이터 준비
Data Preparation

4 분석 모델 정의
Modeling

5 모델 평가
Evaluation

6 시스템 적용
Deployment

A. 데이터 이해 및 정의 (데이터셋 정의)

B. 데이터 전처리 (구조, 내용, 생성)

C. 데이터 특징 (Feature Engineering)

절차별 FAQ

A. 데이터 이해 및 정의

- 분석 모델에 적합한 데이터 선정 및 정의
- 업무 전문가와 협의를 통한 데이터 이해 및 구조화
- 데이터 해석을 위한 메타데이터 확보 (분류체계, 기준정보 등)

B. 데이터 전처리

- 이상치 데이터 처리를 위한 제거 방법은?
- 결측치 데이터를 처리하기 위한 방법은?
- 업무 전문가와 협의를 통해 도출/계산된 항목을 반영하는 방법은? 로직은? 반영 주기는?

C. Feature Engineering

- 전체 데이터 항목에서 분석 목적에 맞게 선별해야 하는 중요 변수는?
- 선별된 변수의 데이터 분포는? 추가 전처리는 요구되는지?
- EDA 통한 접근이 유효한지? Baseline Model 통한 접근이 필요하지는 않은지?

분석 방법론 프로세스별 고려사항

분석 방법론 프로세스

1 비즈니스 이해
Business Understanding

2 가설 수립
Data Understanding

3 데이터 준비
Data Preparation

4 분석 모델 정의
Modeling

5 모델 평가
Evaluation

6 시스템 적용
Deployment

A. EDA, 탐색적 데이터 분석 (기술통계, 시각화)

B. 모델 설계 및 학습

C. 모델 최적화 및 모델 평가

절차별 FAQ

A. 기술 통계 분석

- 평균, 표준편차 통해 이상치 파악이 되는지? 업무 기준으로 적용해야 하는지?
- 데이터 분포의 겹침유무로 분류 가능성이 파악되는지?
- 산점도 통해 회귀 분석 가능성이 파악되는지?

B. 모델 설계 및 학습

- 문제 해결에 필요한 알고리즘은 어떤 근거로 선정하였는지?
- 선형 모델, Boosting 계열 모델, 앙상블 모델의 장단점은 무엇인지? 선택한 근거는 무엇인지?
- 데이터셋 구성 (Train, Validation, Test)은 어떻게 하는 것이 유효한지?

C. 모델 최적화 및 모델 평가

- 정확도는 높는데 재현율이 낮으면 모델이 활용 가능한지?
- 예측 모델에서 RMSE를 낮추려면 어떻게 해야 하는지?

분석 방법론 프로세스별 고려사항

분석 방법론 프로세스

1 비즈니스 이해
Business Understanding

2 가설 수립
Data Understanding

3 데이터 준비
Data Preparation

4 분석 모델 정의
Modeling

5 모델 평가
Evaluation

6 시스템 적용
Deployment

A. 모델 평가 = 비즈니스 평가

B. 모델 배포 (배포 계획 수립)

C. 모델 유지보수 (모니터링 및 유지보수 계획)

절차별 FAQ

A. 모델 평가

- 모델의 예측/분류 결과값을 어떻게 결합하여 사용할 것인지? ◀ 업무 기반으로 정의
- 분석 결과를 XX 시스템과 어떻게 결합하여 활용할 것인지?
- 모델 성능은 만족스러우나 과도한 이상탐지 개수를 줄일 수 있는 방법은 무엇인지? 후처리 로직이 요구되는지?

B. 모델 배포

- 개발된 모델을 상용 시스템 통해 어떻게 배포할 것인지?
- 상용 시스템은 개발 시스템 환경과 동일한지? 추가 설정이 필요하지는 않은지?
- 배포된 모델이 어떤 흐름으로 처리되는지? 주기는 어떻게 되는지? (feat. MLOps)

C. 모델 유지보수

- 모델 성능 모니터링 방법은? 얼마 주기로 모델 변화가 필요한지?
- 데이터의 변화, 모델의 성능 저하를 파악하는 방법은?
- 정기적인 모델 업데이트 주기는 어떻게 되는지? 절차는 어떻게 해야 하는지?

What is Feature Engineering?

”

Garbage In, Garbage Out

데이터 품질이 나쁘면 좋은 모델을 만들 수 없다.

But Clean Data Is Not Enough

데이터가 깨끗한 것만으로는 충분하지 않다.


Better Features In, Better Predictions Out

좋은 Feature가 더 좋은 예측을 만든다.

Feature Engineering turns data into information

Feature Engineering은 데이터를 모델이 학습하기 좋은 의미 있는 Feature로 만드는 과정이다

”



실전 Feature Engineering

EDA

- Why EDA?
- Basic Data Exploration
- EDA Visualization Toolkit
- Question-driven EDA

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Why EDA?

Exploratory Data Analysis

”

In Academia)

EDA(Exploratory Data Analysis)는 데이터를 탐색하여 구조와 특성을 이해하는 과정


In Practice)

EDA는 선입견없이 데이터를 살펴보고 문제를 발견하여,

Feature Engineering 및 모델링의 등 다음 분석 방향을 결정하는 과정

단순히 그래프를 그리고 숫자를 살펴보는 과정이 아니라, 데이터에게 질문하는 과정


”



EDA Workflow

데이터 이해 → 인사이트 도출 → 데이터 개선 → 모델링의 Workflow

✓ EDA는 Insight를 만드는 과정이고, 그 Insight를 바탕으로 Feature Engineering을 수행



- 구조 확인 : 데이터의 형태, 변수 타입, 결측치 등 확인
- 기술 통계 : 요약 통계량, 특성 파악
- 시각화 : 분포, 패턴, 관계 등을 그래프로 확인
- 질문 하기 : 데이터에 대해 가설을 세우고 의문점 도출

- 데이터에서 발견한 인사이트와 문제점 정리

- 결측치, 이상치, 스케일링, 인코딩 처리, 파생변수 생성 등 모델링에 적합하게 변환

- 모델 학습 및 평가를 통해 예측, 분류 등 목표 달성

EDA Workflow

데이터 이해 → 인사이트 도출 → 데이터 개선 → 모델링의 Workflow



✓ Basic Data Exploration : 무엇을 살펴보는가?


✓ Visualization Toolkit : 어떤 시각화 도구를 쓰는가?

✓ Question-driven EDA : 무엇을 물어볼 것인가? 왜 이 분석을 하는가?

✓ Preprocessing : 무엇을 바꿀 것인가?

[참고] Descriptive Statistics

- 기술 통계량은 데이터의 특성을 요약하여 이해하는 가장 기본적인 분석 방법
- 데이터의 중심 위치(중심화), 흩어진 정도(산포:Dispersion), 분포의 형태를 살펴봄으로써 데이터의 전반적인 특성을 빠르게 파악할 수 있음



EDA Checklist Summary

Basic Data Exploration

목적	대표 함수
데이터 구조 확인	<code>shape, columns, info()</code>
데이터 미리보기	<code>head(), tail(), sample()</code>
기술 통계량 확인	<code>describe()</code>
범주형 분포 확인	<code>value_counts(), nunique()</code>
결측치 확인	<code>isnull().sum()</code>
변수 관계 확인	<code>corr()</code>

EDA Checklist

Basic Data Exploration

데이터 구조 확인

- shape, columns, info()

```
> df.shape
(10, 5)

> df.columns
Index(['Age',
       'Salary',
       'Department',
       'Gender',
       'Purchased'],
      dtype='object')

> df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10 entries, 0 to 9
Data columns (total 5 columns):

Age                9 non-null float64
Salary             10 non-null int64
Department         10 non-null object
Gender             10 non-null object
Purchased          10 non-null int64
```

EDA Checklist

Basic Data Exploration

데이터 미리보기

- head(), tail(), sample()

```
> df.head()
```

```
   Age  Salary Department Gender Purchased
0  25.0   3200      HR      F         0
1  32.0   4500      IT      M         1
...
```

```
> df.sample(5, random_state=42)
```

```
   Age  Salary Department Gender Purchased
8  22.0   3000      HR      F         0
1  32.0   4500      IT      M         1
5  35.0   6100      IT      M         1
0  25.0   3200      HR      F         0
7  50.0   7200      IT      M         1
```

EDA Checklist

Basic Data Exploration

기술 통계량 확인

- describe() : 수치형 변수만 요약
- describe(include='all') : 모든 변수(수치형+범주형) 요약

```
> df.describe(include='all')
```

	Age	Salary	Department	Gender	Purchased
count	9.000000	10.000000	10	10	10.000000
unique	NaN	NaN	3	2	NaN
top	NaN	NaN	IT	M	NaN
freq	NaN	NaN	4	6	NaN
mean	34.111111	4880.000000	NaN	NaN	0.600000
std	9.117750	1453.960826	NaN	NaN	0.516398
min	22.000000	3000.000000	NaN	NaN	0.000000
25%	28.000000	3975.000000	NaN	NaN	0.000000
50%	32.000000	4350.000000	NaN	NaN	1.000000
75%	41.000000	6025.000000	NaN	NaN	1.000000
max	50.000000	7200.000000	NaN	NaN	1.000000

EDA Checklist

Basic Data Exploration

범주형 변수 살펴보기

- `unique()` : 무슨 값들이 있는가?
 - 고유한 값 자체를 반환
- `nunique()` : 몇 종류가 있는가?
 - 고유한 값의 개수만 반환
- `value_counts()` : 몇 번 나왔는가?
 - 각 값이 몇 번 등장했는지(도수)를 계산
- `value_counts(normalize=True)` : 몇 %인가?
 - 각 값의 비율(상대도수)을 계산

```
> df["Department"].unique()  
array(['HR', 'IT', 'Sales'], dtype=object)
```

```
> df["Department"].nunique()  
3
```

```
> df["Department"].value_counts()  
  
IT      4  
HR      3  
Sales   3
```

```
> df["Department"].value_counts(normalize=True)  
  
IT      0.40  
HR      0.30  
Sales   0.30
```

Case Study

Basic Data Exploration

Q. 아래는 각 범주형 변수의 고유값 개수(nunique)입니다. 이 결과만 보고 어떤 사실을 추론할 수 있을까요?

```
> df.nunique()
```

CustomerID	100000
Gender	2
Region	5
Department	3

- High Cardinality 변수는 무엇인가? 정보력이 있는 경우가 있을까?
- 가장 쉽게 Encoding 가능한 변수는?
- nunique() 결과만으로 알 수 없는 것은 무엇일까?

What is Cardinality?

- 범주형 변수에 존재하는 서로 다른 값(고유값)의 개수
- Cardinality 수준에 따라 적절한 Encoding 방법이 달라짐
- High Cardinality 변수는 적절한 Encoding 또는 활용 여부를 검토

EDA Checklist

Basic Data Exploration

결측치 확인

- `isnull().sum()` : 변수별 결측치 개수 확인
- `isnull().mean()` : 변수별 결측치 비율 확인
- Ex) 10행 중 Age가 1개 결측이므로 결측률은 0.1, 즉 10%

missingno

- 결측치를 시각화하는 전용 라이브러리
- 변수가 많고 결측 패턴이 복잡한 데이터에서 유용
 - 행별로 결측치가 어디에 있는지 확인
 - 결측이 특정 구간에 몰려 있는지 확인
 - 변수 간 결측이 함께 발생하는 패턴 확인

```
> df.isnull().sum()
```

Age	1
Salary	0
Department	0
Gender	0
Purchased	0

```
> df.isnull().mean()
```


Age	0.1
Salary	0.0
Department	0.0
Gender	0.0
Purchased	0.0

dtype: float64

[참고] 결측값 탐색 by missingno

Basic Data Exploration


```
msno.matrix(df)
```



[참고] 결측값 탐색 by missingno

Basic Data Exploration

```
msno.heatmap(df)
```



EDA Checklist

Basic Data Exploration

변수간 상관관계 탐색

- `df.corr(numeric_only=True)` : 수치형 변수만 대상으로 상관관계를 계산
- 변수가 많을 경우 한눈에 보기 어려우므로 Heatmap을 활용하여 관계를 직관적으로 파악할 수 있음

- Q. 가장 강한 상관관계를 가지는 변수는?
- Q. Age는 Purchased와 어떤 관계가 있는가?

```
> df.corr(numeric_only=True)
```

	Age	Salary	Purchased
Age	1.000	0.82	0.71
Salary	0.82	1.000	0.88
Purchased	0.71	0.88	1.000

```
> import seaborn as sns  
import matplotlib.pyplot as plt
```

```
sns.heatmap(  
    df.corr(numeric_only=True),  
    annot=True,  
    cmap="Blues"  
)
```

```
plt.show()
```

Quantitative Variable 살펴보기


EDA Visualization Toolkit

Recommendation

- 수치형 단일 변수는 히스토그램으로 살펴보는 것만으로도 대부분 충분
- 도수를 직선으로 연결하는 도수 폴리곤 차트 (frequency polygon), 확률분포를 활용해 곡선으로 추정하는 커널밀도차트(kernel density)를 활용할 수도 있음

Think to look for

- 이상점은 없는가?
- 분포의 모양은 어떠한가?
 - 종모양인가? 치우침이 있는가? 봉우리는 하나인가?
- 히스토그램이 거칠다면 좀 더 큰 bin값을 주어서 살펴보자




Categorical Variable 살펴보기

EDA Visualization Toolkit

Recommendation

- 범주형 단일 변수의 시각화는 Bar Chart or Pie Chart를 통해 살펴봄
- 많은 경우 Table 형식의 통계량(도수분포표, 도수 or 상대도수) 출력만으로도 충분



파이종류	도수 (판매량)	상대도수 (판매비율)
애플	59	0.252
딸기	52	0.222
블루베리	47	0.201
초코	32	0.137
고구마	27	0.115
바나나	17	0.073
합계	234	1.000

Quantitative vs Quantitative 살펴보기


EDA Visualization Toolkit

Recommendation

- 두 변수의 관계를 직관적으로 알 수 있는 산점도 (scatter plot) 활용이 기본

Think to look for

- 데이터 관계가 선형인가? 비선형인가?
- 데이터의 관계가 선형이라면 관계성은 강한가? 약한가?
- 이상점이 있는가?
- 두 변수에 로그변환은 필요한가?
- 두 변수에 인과관계는 존재하는가? 한 변수가 다른 변수에 영향을 끼친다면 원인변수를 X, 결과변수를 Y에 위치
- 데이터의 개수가 너무 많다면, Sampling하거나 alpha 옵션으로 반투명하게 만든다



Quantitative vs Categorical 살펴보기


EDA Visualization Toolkit

Recommendation

- 수량형 변수와 범주형 변수의 관계를 시각화 할 때에는 box-plot을 활용
- box-plot을 통해 범주형 변수의 Class별 수량형 변수의 분포를 확인할 수 있음

Think to look for

- 범주형 변수의 Class별 이상치는 있는가?
- 범주형 변수의 Class별 관측치는 충분한가? (점표시+반투명 옵션)
- 범주형 변수의 Class의 적절한 순서는 있는가?
- 로그변환은 필요한가?
- 축의 교환은 필요한가?




Categorical vs Categorical 살펴보기

EDA Visualization Toolkit

Recommendation

- 도수 분포표로 표시하거나 모자이크(mosaic-plot) 차트를 활용
- 두개의 범주형 변수를 다루는 일은 흔하지 않음
- 관찰하고 싶은 타겟 변수를 제 3의 변수로 추가해 활용하는 것은 하기도 함 (예시는 성별, 승객등급별 생존율)



Question-driven EDA

무엇을 물어볼 것인가? : From Questions to Insights

Question	Analysis	Next Action
결측치는 어디에, 얼마나 존재하는가?	결측치 개수·비율, 변수별 행렬 결측..	결측치 처리(삭제, 대체..)
데이터에 중복이나 유효하지 않은 값은 없는가?	중복행·키, 타입, 유효범위, 논리적 조건..	중복 제거, 타입 변환, 오류값 대체..
수치형 변수들의 분포는 어떠한가?	기술통계, Histogram, KDE, Skewness..	변환, 스케일링 검토, 구간화..
이상치는 존재하는가?	Box Plot(IQR), Z-score..	이상치 처리(제거, 대체..)
범주형 변수의 구성과 빈도는 적절한가?	nunique(), value_counts(), Cardinality..	범주 재정의, 인코딩 방식 결정..
서로 비슷한 정보를 가진 변수는 없는가?	Correlation Matrix, Heatmap..	변수 제거, 다중공선성 검토..

Question-driven EDA

무엇을 물어볼 것인가? : From Questions to Insights

Q. 각 변수는 Target과 어떤 관계가 있는가?

회귀: Target이 수치형인 경우

Question	Analysis	Next Action
수치형 변수의 변화에 따라 Target도 함께 변하는가?	Scatter Plot, Correlation..	변환, 비선형 관계 검토, 변수선택..
범주에 따라 Target의 분포나 평균에 차이가 있는가?	Box Plot, Group Statistics..	범주 통합, 변수선택..

분류: Target이 범주형인 경우

Question	Analysis	Next Action
Target 그룹에 따라 수치형 변수의 분포에 차이가 있는가?	Box Plot, KDE, Group Statistics..	변환, 변수선택..
범주에 따라 Target의 비율이 달라지는가?	Mosaic-plot, Target Rate..	범주 통합, 변수선택..

실전 Feature Engineering

Pre-processing : basic

- Missing value
- Outlier
- Scaling
- Encoding

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Missing Value

Concept

- Null
- NA (Not Available)
- NaN (Not a Number)

Why?

- 결측값은 알고리즘 수행에서의 방해요인, 연산 불가
- 결측치가 포함된 행을 모두 삭제한다면? .. Label Imbalance 초래?
- 결측치를 잘못 대체 한다면?
- 일괄적이고 기술적인 대체는 언제나 정답인가?

Missing Value

How

제거 (Deletion)

- Guide line1 : 결측값의 비율이 적을 경우 해당 row 제거를 검토 (10%이하)
- Guide line2 : 개별 Feature의 결측값이 50%이상인 경우 Column 제거를 검토
- 무작위 결측(Missing at Random) vs 비무작위 결측(Missing at Not Random)
 - - 발생한 결측치는 다른 변수와 연관성이 없다 : 미입력, 시스템 오류로 인한 누락..
 - - 체중 NA : 뚱뚱한 사람은 체중을 공개할 가능성이 적다
- Row vs Column
- 결측값의 비즈니스 적 의미는 있을까?

Missing Value

How

대체 (Imputation)

- 최빈값 (범주형 Feature)
- 평균값
- 중앙값
- Conditional Imputation

Imputation for time-series

- 대부분의 시계열 데이터는 구간에 따라 평균과 분산이 달라지는 비정상성을 가지기 때문에 평균값 등의 대체는 올바른 선택이 아닐 확률이 높음
- Last observation
- 직전 n일의 Moving Average/Median
- Interpolation (보간법) – Linear, Spline
- Cubic Spline Interpolation 은 언제나 최선의 선택일까?

Missing Value

How

예측 (Prediction)

- 결측치들이 어떠한 패턴을 가진다고 가정
- 결측값이 없는 Dataset을 활용해서 결측값을 예측
- Model based (Regression, KNN..)


유의할 점

- 결측값 자체도 Trend의 일부분이고, 네거티브 성과를 예측하는데 설명력이 있을 수 있음을 유의
- Statistical Imputation 시 생성값이 비즈니스 센스에 부합하지 않을 수 있음을 유의

Outlier

Concept

- 전체 데이터 범위에서 크게 벗어난 아주 크거나 작은 극단적인 일부 관측치



Why?


- Outlier는 표본집단의 평균이나 편차, 총합 등 통계량을 추정하는 것에 문제를 일으킴
- Outlier가 포함되어 있을 경우 분산을 과도하게 증가시킴
- Outlier와 같이 극단적인 값은 모델의 예측력을 약화시키는 주요 원인
- 많은 경우 모델의 성능에 큰 영향을 끼침
- 전체 데이터의 수가 많을 수록 이상치의 영향은 감소하는 경향을 띰

Outlier

어떻게 찾을까?

IQR(interquartile range) Based

- Quantile을 활용하여 Outlier를 탐색하는 방법
- Q1(25Percentile), Q3(75percentile) Point에서 IQR(3분위수-1분위수)
*1.5 보다 멀리 떨어져 있으면 Outlier로 판단




Outlier

어떻게 찾을까?

Z-score Based

- Z-score 을 활용하여 Outlier를 탐색하는 방법
- Z-score는 개별값에서 평균을 차감하고 표준편차를 나누어준 값 (68-95-99.7)
- $|Z\text{-score}|$ 값이 3보다 크면 Outlier로 판단



Outlier

처리

제거 (Deletion)

- 가장 간단한 방법
- 예측치의 분산은 감소하지만, 과도한 이상치의 제거는 예측력을 과장하여 편의가 발생할 수 있음

대체 (Imputation)

- 일괄 변경 vs 조건부 변경
- Outlier의 상한값/하한값 변경 (value modification)
- Outlier의 영향을 감소시키기 위해 가중치 조정 (weight modification)
- Outlier의 경향을 나타내는 값으로 변경

Outlier


유의할 점

- 분석 도메인에 따라 Outlier가 중요한 의미일 수 있음, 어떻게 반영할 수 있을까?
- 통계량에 의한 무조건적인 이상치 탐색은 위험할 수 있음, Outlier 발생원인에 대한 고찰이 필요
- 입력오류/에러값이 Outlier로 인식될 수 있음 (연령항목에 355.. 이때에는 어떤 처리를?)

Data Scaling

Concept

- 연속형 feature들의 범위는 제 각각임
- 이때 모든 feature의 범위 혹은 분포를 동일하게 조정하는 것



Data Scaling

Why?

- Feature의 Scale이 다르면 많은 경우 모델의 성능을 저해 (Scaling후 대부분 성능이 향상됨)
- 데이터의 값이 너무 크거나 작은 경우에 모델 학습과정에서 0으로 수렴하거나 무한으로 발산할 수 있음
- 자료의 Overflow나 Underflow 를 방지
- Scaling은 다차원의 값들을 비교 분석하기 쉽게 만들어 줌
- 안정성과 수렴속도를 향상

참고) 독립변수간 행렬의 조건수(Condition number)

- 작은 변화의 비율에 대해 함수가 얼마나 변화할 수 있는지에 대한 measure
- Condition number가 크면 약간의 오차만 있어도 해가 전혀 다른 값을 가짐, 예측값의 오차범위도 커짐
- 발생원인

(1) 다중공선성 (상관관계가 큰 독립변수가 있는 경우)

(2) 변수간 단위 차이 (숫자의 Scale 차이가 큰 경우)

0 10
↔
Feature 1


1,000 100,000
↔
Feature 2

- Feature1(2 → 3), Feature2 (2,000 → 2,001) 가 1씩 증가한다면?
- Target(Y)의 범위가 Feature2와 유사하다면?
- 값의 변화폭이 큰 Feature의 영향은 모델에 어떻게 작용할까?

Data Scaling


Min-Max Scaling

- 모든 Feature를 0~1의 범위로 조정
- Feature별로 최소값은 0, 최대값은 1
- 이상치가 존재할 경우 매우 좁은 범위로 압축될 수 있음, 이상치에 매우 민감



Standard Scaling


- 모든 Feature를 평균이 0, 표준편차가 1인 정규분포를 가지도록 조정 (표준화)
- 이상치가 있다면, 평균과 분산에 영향을 주기 때문에 균형 잡힌 척도를 보장할 수 없음
- 최소, 최대값을 제한하지 않음



Data Scaling

Robust Scaling

- Standard Scaling과 유사하지만, 평균과 분산대신 median과 quartile을 사용
- 이때 Quartile은 IQR(Interquartile range, Q3-Q1) 값을 사용
- 즉 중앙값이 0, IQR이 1이 되도록 조정
- 이상치의 영향을 받지 않음
- Standard Scaling에 비해 Scaling 결과가 더 넓은 범위로 분포



Normal Scaling

- 벡터의 길이가 1이 되도록 데이터 값 조정 (L2 Norm)
- 통계량을 사용하여 개별 Feature단위로 수행하는 것이 아니라 각 Sample(행)에 대해 수행
- 빠르게 학습할 수 있고, 과대 적합 방지하는 효과

$$x_{i,scaled} = \frac{x_i}{\sqrt{x_i^2 + y_i^2 + z_i^2}}$$

Data Scaling

유의할 점

- Train set에만 적용해야 함, 이때 얻은 통계량을 Test set에 활용 (fit vs transform)
- 거리 기반의 모델에서는 Scaling이 매우 중요, 모든 알고리즘에서 Scaling이 중요할까?

Data Encoding

Categorical variable

- Category or Label을 나타내기 위한 변수로 그 개수는 유한
- 각각의 Category를 '범주'라 함
- 각각의 범주는 독립
- 수치로 표현될 수 있지만 서로 비교되거나 정렬될 수 없음
- 값이 얼마나 차이 나는지가 중요한가?(수치형 변수) Vs 단지 다르기만 하면 되는가? (범주형 변수)

Why?

- 범주형 변수는 수리적인 처리가 가능한 형식(수치)로 변환해야 알고리즘에서 사용가능
- 대부분의 M/L 알고리즘과 M/L Library 는 문자열값을 입력값으로 허용하지 않음

Data Encoding

Label Encoding

- 각각의 고유한 범주를 순차적으로 정수형 수치로 변환하는 방법

City	City Encoding
San Francisco	1
New York	2
Seattle	3
Seattle	3
New York	2

Pros & Cons

- 직관적이고, 변환이 쉬움
- 수치값의 크고 작음에 대한 특성이 작용해서 모델 성능의 저하를 야기 (큰 수치에 가중치가 더 부여되거나 더 중요하게 인식될 가능성) * ordinal한 특성을 반영하는 모델下
- 독립적인 관측값에 관계성이 생겨 왜곡이 생김 (서로 가까운 수치를 유사한 데이터라고 인식)
- 주로 분류문제의 Target(Y)이 범주형으로 구성되어 있을 경우 사용

Data Encoding

One-Hot Encoding

- 범주의 고유값 개수를 구하고, 개수만큼 피처를 추가해 각 고유값에 해당하면 1 아니면 0으로 변환하는 방법
- 여러 개의 범주값 중 하나(One)씩만 활성화(Hot) 하는 인코딩
- 범주가 k개 라면 k개의 변수가 생성됨

City	City1	City2	City3
San Francisco	1	0	0
New York	0	1	0
Seattle	0	0	1
Seattle	0	0	1
New York	0	1	0

Pros & Cons

- Label Encoding의 수치 변환에 대한 문제가 해소, 각 변수가 명확하게 하나의 범주에 상응
- 위의 예시에서 2개 칼럼이 주어졌다면 나머지 칼럼값을 알 수 있음 → 어떤 변수의 결과가 다른 변수의 도움으로 쉽게 예측되어 질 수 있음, 독립변수간 종속성이 생김 → 다중공선성, Dummy Variable Trap
- 열 개수 증가로 인한 모델 학습속도 저하, 메모리 낭비

Data Encoding

Dummy Coding

- K-1개의 변수만 생성해서 불필요한 변수(자유도)를 제거하는 방법
- 하나의 범주는 생성된 Dummy 칼럼이 모두 '0' 인 값으로 표현됨 → Reference Category
- 범주가 k개 라면 k-1개의 변수가 생성됨

City	City1	City2
San Francisco	0	0
New York	1	0
Seattle	0	1
Seattle	0	1
New York	1	0

Pros & Cons

- 불필요한 요소 없이, 고유하고 해석가능한 모델 생성, On-Hot Encoding 대비 모델 해석이 용이
- 기준 범주가 '0'으로 변환되기 때문에 누락 데이터 처리에 어려움
- 각 범주의 효과를 기준 범주에 대해 상대적으로 인코딩 되는 개념이기에 직관성이 떨어질 수 있음

Data Encoding

Large-size Category Problem

- One-hot encoding과 Dummy Coding은 수치변환에 대한 문제를 해결해 주지만..
- 범주의 수가 매우 커진다면... (ex: 100,000명의 사용자ID..)
- 범주의 수가 커질수록 급격히 성능이 떨어질 수 있음
- 범주의 수가 많은 범주형 변수의 처리, 어떻게 해야 할까?

Ideation

- 유사 고유값을 그룹화
- 빈도가 낮은 고유값을 하나로 묶어서 처리 (ex: Etc..)
- Bin Counting - 범주별로 피처를 생성하지 말고 타겟 변수의 통계량으로 변환해 보면 어떨까?
- → 범주의 값을 인코딩하는 대신에 그 값일 때 타겟 변수에 대한 조건부 통계량을 계산하여 사용

실전 Feature Engineering

Pre-processing : advance


- Transformation
- Imbalance

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Variable Transformation

Concept

- 변수변환은 정보는 유지하면서 새로운 표현(Representation)으로 바꾸는 과정
- 데이터 자체를 바꾸는 것이 아니라 분석과 모델링에 적합하도록 변수의 표현 방식을 변경하는 과정
- 변환 후에는 Distribution, Scale, Relationship, Variance가 달라질 수 있음 → 모델이 학습하기 쉬워짐
- 변환 후에도 데이터의 의미, 값의 순서(Order), 큰 값과 작은 값의 관계는 대부분 유지



Variable Transformation

Why?

적절한 변수변환이 이루어지지 않으면..

- 이상치의 영향을 더욱 크게 받아 모델이 왜곡될 수 있음
- 비선형 관계를 충분히 학습하지 못해 예측 성능이 저하될 수 있음
- 큰 값에 학습이 집중되어 대부분의 데이터 패턴을 충분히 반영하지 못할 수 있음
- 통계적 분석과 회귀모형의 신뢰성이 낮아질 수 있다. 있음 (ex: 꼬리가 긴 데이터에서는 평균이 대표값 역할을 못함)

Effects

- **Reduce Skewness** : 분포의 비대칭성이 줄어들어 보다 균형 있는 형태가 됨
- **Reduce the Impact of Extreme Values** : 극단값을 제거하는 것이 아니라 상대적인 영향력을 줄임
- **Improve Linearity** : 곡선 형태의 관계가 직선에 가까워질 수 있음
- **Stabilize Variance** : 값의 크기에 따라 달라지던 오차의 퍼짐이 상대적으로 일정해짐

Variable Transformation

What is a Logarithm?

$$a^y = x \Leftrightarrow y = \log_a(x)$$

밑 a 를 몇 번 거듭제곱해야 x 가 되는가?


x	지수 표현	$\log_{10}(x)$
10	10^1	1
100	10^2	2
1,000	10^3	3
10,000	10^4	4
100,000	10^5	5
1,000,000	10^6	6

- 값의 순서는 유지하면서 큰 값의 범위를 압축하는 변환
- 절대적인 차이를 배수(비율)의 차이로 표현
- (밑이 10인 경우 원래 값이 10배 증가할 때 로그값은 1씩 증가)
- 큰 값은 강하게 압축되고, 작은 값 사이의 차이는 상대적으로 더 잘 드러남
- 넓게 퍼진 데이터를 좁은 범위로 변환하여 데이터의 전체 패턴을 쉽게 파악할 수 있음

Variable Transformation

Log Transformation

- 큰 값이 압축된다 → 왜도가 줄어든다 → 이상치 영향이 줄어든다 → 선형성이 좋아진다 → 모델의 예측 성능과 해석력이 향상된다



Variable Transformation

유의할 점

- 로그는 양수에서만 정의, 0 이하의 값에는 바로 적용할 수 없음
- 실무에서는 0이 포함된 데이터가 매우 흔함 → 필요시 $\log(x + 1)$ 을 사용
- 음수가 포함된 경우에는 Yeo-Johnson 변환을 고려
- 해석에 유의 → 변환 후의 값은 원래 단위가 아닌 로그 스케일
- 실무에서는 대부분 자연로그(ln)를 사용하지만, 로그의 밑이 달라도 변환의 효과는 본질적으로 동일

```
np.log(x)      # 자연로그 (ln)
math.log(x)    # 자연로그 (ln)
np.log1p(x)    #  $\log(x + 1)$ 
```

x	ln(x)	log ₁₀ (x)
10	2.30	1
100	4.61	2
1000	6.91	3

Other Transformation Options

Transformation	When to Use	Key Effect
Log	오른쪽 꼬리가 길고 큰 값의 범위가 넓을 때	큰 값을 강하게 압축
Square Root	횟수·건수와 같은 Count 데이터	로그보다 완만하게 압축
Box-Cox	양수 데이터에 적절한 변환을 탐색할 때	최적의 해(lambda)를 추정
Yeo-Johnson	0이나 음수가 포함된 데이터	Box-Cox를 음수까지 확장

Imbalanced data

Concept


- Target variable의 Class별 관측치 수(비율)가 현저하게 차이나는 데이터
- Target variable이 categorical variable일 때 나타날 수 있음
- Majority class vs Minority class
- Class비가 9x% : x% 와 같이 극단적인 경우 extremely imbalanced data 라고 함
- 예측하고자 하는 관측치수가 작은 경우는 현실 세계에서 흔하게 볼 수 있음

ex) 제조업 불량품 판정 (vs 정상 제품)

금융업 사기거래 탐지 (vs 정상 거래)

의료기관 질병분류 (vs 정상 상태)

통신/플랫폼 사업자 이탈고객(Churn) (vs 유지 고객)



Imbalanced data

Why?

- Imbalanced data를 그대로 학습한다면, 관측치수가 많은 normal class에 편향됨
- 찾고자 하는 minority class를 제대로 분류할 수 없음
- extremely imbalanced data(정상:비정상의 비가 99:1)로 분류모델을 학습한다면 모든 값에 '정상'이라고 판단해도 Accuracy 99%
- 일부 학습된 minority class도 과적합의 특성을 보임 (unseen data에 대해 분류 가능성이 떨어짐)

Imbalanced data

How




Imbalanced data

Undersampling Technique

Random Sampling

- Majority class에서 무작위(random)로 샘플들을 선택하여 제거하는 접근법
- 빠른 처리를 보장하지만, 무작위 샘플링을 시행하므로 시행시마다 다른 결과를 얻음





Imbalanced data

Undersampling Technique

Tomek Links

- What is tomeK Link?
- → 서로 다른 Class 2개를 연결했을 때, 그 거리가 주변의 임의의 데이터와의 거리보다 짧을때..
- Tomek Link를 형성한 후 다수 범주에 속한 관측치를 제거해주는 접근법
- Ideation) 결정 경계선 근처에 있는 두 샘플중 하나는 노이즈 일 수 있다
- 분류 경계면의 Majority 샘플을 삭제하여 경계선을 선명하게 만드는 효과가 있지만 제거 샘플이 한정적임




Imbalanced data

Undersampling Technique

Condensed Nearest Neighbor

- Idea) 데이터가 많은 Majority Class에 밀집된 데이터가 없을 때까지 데이터를 제거해보자
 - (1) Majority Class중 무작위 샘플1개 + Minority class로 sub data 구성
 - (2) 선택되지 않은 나머지 Majority sample 하나 하나씩 1-Nearest Neighbor을 이용해 어디와 가까운지 판단 (Majority Class중 무작위 샘플 vs Minority sample)
 - (3) (2)작업이 끝난 후 Majority로 남아있는 sample 제거
- 다수 클래스로 쏠리게 하는 Majority sample을 상당수 제거하는 효과



Imbalanced data

Oversampling Technique

Resampling

- Minority class data를 무작위 복제하여 데이터 수를 늘리는 방법
- Minority class 관측치를 단순히 증폭 시키는 방법 (random copy)
- 무작위로 선택하여 복제하기 때문에 특정 패턴의 데이터가 많이 복제될 수도, 적게 복제 될 수도 있음
- → 소수범주/특정 데이터에 대한 과적합 가능성
- → 소수범주 전체 모집단을 대표하지 않을 가능성

Imbalanced data

Oversampling Technique



SMOTE

Synthetic Minority Oversampling TEchnique

- Minority class 에서 가상의 sample을 생성
- Ideation) Minority sample 주변에 원본과 동일하지 않는 sample을 생성할 수는 없을까?
- KNN (k-Nearest Neighbor) 알고리즘 기반
- (1) Minority sample 중 하나를 무작위 선택
- (2) k개의 소수 클래스 이웃을 탐색
- (3) 선택점과 k이웃점의 연결선상에 임의의 점(데이터)를 생성

주의 사항

- Minority class 관측치들 사이의 직선 위에서만 생성
- Noise sample이 증가될 수 도 있음




Imbalanced data

Oversampling Technique

Borderline-SMOTE

- Ideation) 결정경계선 근처에 있을수록 상대적으로 분류하기 어려운데, 이를 감안한 오버샘플링 방법은?
- 결정경계선 근처의 Minority sample에 대해 집중적으로 oversampling하는 방법
- (1) Minority 관측치에 대해 class구분없이 kNN을 시행, 가까운 이웃을 도출함
- (2) 도출된 이웃 중에서 50% 이상이 majority class인 경우 분류하기 어려운 샘플(Danger set)이라 명명
- (3) Danger set에 대하여 SMOTE 시행하여 데이터 생성




Imbalanced data

Oversampling Technique

ADASYN

Adaptive Synthetic Sampling Approach

- 주변 상황에 따라 Minority sample수를 다르게 생성하는 방법
- Ideation) 주변에 Majority Sample이 많은 Minority sample에 집중해보자
- (1) Minority 관측치에 대해 class구분없이 kNN을 시행, 가까운 이웃을 도출함
- (2) Majority class의 비율을 산출 (r_i)
- (3) r_i 를 고려하여 sample을 생성함



Imbalanced data

Consideration (Undersampling vs Oversampling)

- undersampling vs oversampling 결정은 분석가가 내려야할 중요한 결정 중 하나
- Sampling 후에도 예측에 어려움이 없어야 함
- 이는 결정경계(decision boundary)를 찾는 것이 용이해 지거나 혹은 적어도 불리해지지 않는 것의 의미
- 어떻게 확인할까? → 시각화를 통해 확신의 정도를 높일 수 있음

Undersampling에 대한 오해

- extremely imbalanced 상황에서는, 매우 작은 비중의 minority class 외에 나머지 데이터가 거의 대부분을 차지하고 있기 때문에 분포의 모든 부분에 걸쳐 있어, undersampling이 크게 해가 되지 않는 경우가 많음
- 상대적으로 oversampling에 비해서 안전한 측면도 있음
- 오버피팅을 줄임으로써 unseen data 예측했을 때 error가 줄어드는 효과가 있음

실전 Feature Engineering

Creating Better Features

- Derived Features: Feature Creation Strategies

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Feature Creation Strategies

How can we create more informative features?

Category	Strategy	Concept	Example
Combine Features	비율(Ratio)	변수 간 상대적 크기를 표현	구매금액 / 구매횟수
	차이(Difference)	변수 간 간격이나 변화를 표현	납기일 - 주문일
	상호작용(Interaction)	변수들의 결합 효과를 표현	면적 × 층수
Transform Features	시간(Date Features)	날짜에서 새로운 시간 정보를 추출	요일, 월, 경과일
	구간화(Binning)	연속값을 의미 있는 구간으로 변환	연령대, 가격대
Aggregate Features	집계(Aggregation)	여러 행을 하나의 요약 정보로 변환	고객별 구매금액 평균·횟수

From Questions to Features

좋은 질문이 좋은 Feature를 만들고, 좋은 Feature가 좋은 모델을 만든다.

What information is missing?



Create a Better Feature

Original Features	Question	New Feature	Strategy
Height, Weight	체형을 더 잘 표현할 수 있을까?	BMI	Ratio
Order Date, Delivery Date	배송은 얼마나 걸렸을까?	Delivery Time	Difference
Purchase Amount, Purchase Count	고객은 한번에 얼마나 구매할까?	Average Purchase	Aggregation
Join Date	고객과 얼마나 오래 거래했을까?	Membership Duration	Date

From Questions to Features

좋은 질문이 좋은 Feature를 만들고, 좋은 Feature가 좋은 모델을 만든다.

Original Features	Question	New Feature	Strategy
Birth Date	나이를 더 쉽게 활용할 수 있을까?	Age Group	Binning
Customer Purchase History	평균적으로 얼마나 자주 구매할까?	Purchase Frequency	Aggregation
Building Area, Floor	넓이에 따라 층수의 영향이 달라질까?	Area × Floor	Interaction
Loan Amount, Income	상환 부담을 더 잘 표현할 수 있을까?	Debt-to-Income Ratio (DTI)	Ratio
Distance, Travel Time	평균 이동 속도는 어떨까?	Average Speed	Ratio
Login Date	최근에 얼마나 활동했을까?	Days Since Last Login	Date Feature

- ✓ 좋은 Feature는 '무엇을 계산할까?' 보다 '무엇을 표현할까?'에서 시작
- ✓ '파생변수 = 계산식'이 아니라 '파생변수 = 문제를 더 잘 표현하는 방법'

Where Do Good Features Come From?

Domain Knowledge + Data → Meaningful Features

Original Features

Customer	Purchase Date	Amount
A	7/1	50,000
A	7/15	80,000
A	8/1	30,000
B	1/10	20,000
B	2/5	30,000

✓ 어떤 고객이 좋은 고객인가?

Feature	의미	계산
Recency	최근에 구매했는가	오늘 - 마지막 구매일
Frequency	얼마나 자주 구매했는가	구매 횟수
Monetary	얼마나 많이 구매했는가	총 구매금액

New Features

Customer	R	F	M
A	3일	3회	160,000
B	180일	2회	50,000

Where Do Good Features Come From?

Domain Knowledge + Data → Meaningful Features

- ✓ 어떤 정보가 실제 문제와 관련 있는가? 어떻게 계산해야 하는가? 어떤 기준이 의미 있는가?
- ✓ 가능한 계산은 많지만, 의미 있는 Feature는 도메인 지식이 결정
- ✓ BMI, Sharpe Ratio, Drawdown, Credit Utilization, Conversion Rate, RFM은 모두 단순 계산식이 아니라, 각 분야에서 오랜 기간 검증되어 사용되는 대표적인 Feature

Domain	Original Features	Domain Question	Derived Feature
Healthcare	Height, Weight	체형과 비만 정도를 어떻게 표현할까?	BMI
Investment	Return, Volatility	위험을 감수한 만큼 수익을 냈는가?	Sharpe Ratio
Investment	Peak Value, Current Value	고점 대비 얼마나 하락했는가?	MaxDrawdown
Credit Risk	Used Credit, Credit Limit	신용한도를 얼마나 사용하고 있는가?	Credit Utilization
E-commerce	View Count, Purchase Count	조회가 구매로 얼마나 연결되었는가?	Conversion Rate

수고하셨습니다.

본 문서는 SK(주)AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.