



AI Campus 데이터분석 및 AIOps

4. 머신러닝 및 딥러닝 이해

Part A – Machine Learning

2026.08

배기주 / SK AX

본 문서는 SK(주) AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.



Part A – Machine Learning

1. Artificial Intelligence
2. Machine Learning
3. ML Algorithm

AI Campus 데이터분석 및 AIOps > Part A – Machine Learning

1. Artificial Intelligence


- Short Overview of AI History
- AI – ML – DL
- Statistics vs ML
- 모델 접근 방향

본 문서는 SK(주) AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.




2022.11.30

Short Overview of AI History



S. McCulloch – W. Pitts



- Adjustable Weights
- Weights are not Learned


생물 신경세포 모방한 형식적 신경모형 발표 (신경회로망 모형)



F. Rosenblatt



B. Widrow – M. Hoff




- Learnable Weights and Threshold

컴퓨터로 뉴런의 결합 가중치 학습(퍼셉트론)



M. Minsky – S. Papert




- XOR Problem

단순 퍼셉트론 만으로는 선형분리 불가능하다!! → 계층적 구조. HOW?



D. Rumelhart – G. Hinton – R. Williams




- Solution to nonlinearly separable problems
- Big computation, local optima and overfitting

- 계층적 퍼셉트론 구조 → Forward/Backward
- Neocognitron (by Fukushima)
- CNN (by LeCun)




V. Vapnik – C. Cortes



- Limitations of learning prior knowledge
- Kernel function: Human Intervention



G. Hinton – S. Ruslan



- Hierarchical feature Learning

Machine Learning은 인공지능 연구 분야 중 하나이며, Deep Learning은 그 중 인공신경망의 한계를 극복하기 위해 제안된 머신러닝 방법 중 하나임

인공지능(Artificial Intelligence)

지각/인지

언어 처리 (NLP)

학습 (Learning)

행동 (Robot)

...

Machine Learning

randomForest

Support Vector Machine

AdaBoost

Regularization

Neural Network

...

Deep Learning

CNN
(Convolution Neural Network)

RNN
(Recurrent Neural Network)

GAN
(Generative Adversarial NN)

...

GPT →

2022.11.30

1. Short Overview of AI History

년도	History	개요	기여 내용
1956	Dartmouth Conference	"인공지능(Artificial Intelligence)"이라는 용어를 처음 사용한 회의	- AI 연구의 공식 시작점 - 지능을 기계로 구현할 수 있다는 새로운 연구 영역 제시
1966~73	First AI Winter	초기 언어 처리 시스템(예: ELIZA)이 기대에 못 미치자 연구 지원이 급감	- 과도한 기대와 현실 간의 격차 발생 - 연구 자금과 관심을 급격히 낮춘 대표 사례
1980	Raise of Expert System	Rule-based Expert System(XCON)이 기업 문제 해결에 활용	- AI가 실무 문제 해결에 적용 가능하다는 인식 확산 - 상업적 가능성 첫 인정
1987~93	Second AI Winter	전문가 시스템 유지비용과 한계로 인해 다시 투자 축소	- 지식 기반 시스템의 확장성 문제 확인 - 데이터 기반 접근의 필요성 부각
1997	Deep Blue vs Kasparov	IBM Chess AI, Deep Blue가 인간 세계 챔피언을 이김	- 기호 기반 AI - 특정 규칙 기반 문제에서는 인간을 능가 할 수 있음을 입증
2012	딥러닝의 부활 - AlexNet	이미지넷 대회에서 CNN 기반의 AlexNet의 혁신적 성과	- 딥러닝이 기존 방식 보다 압도적으로 우수함을 보여줌 - GPU 기반 학습 확산
2016	알파고 vs 이세돌	DeepMind의 알파고가 바둑에서 인간 프로기사 이세돌에게 승리	- 딥러닝 기법의 성공적 융합 사례 - 강화학습, 딥러닝, 몬테카를로 트리 탐색 등
2018	BERT 등장	Google이 문맥 이해 중심의 NLP 모델, BERT 발표	- Transformer 기반의 양방향 사전학습 모델 - NLP 문맥 처리 능력을 대폭 향상
2022	ChatGPT 공개	OpenAI가 일반 사용자 대상의 대화형 LLM 서비스, ChatGPT 출시	- LLM이 일반 사용자에게 개방 - 생성형AI와 대화형 시스템의 대중화 시작
2023 ~ 현재	Multimodal (2023) RAG (2024) AI Agent (2025)	하나의 데이터 유형이 아닌 다양한 유형의 데이터를 입력으로 처리하고, LLM을 목적지향 에이전트 형태로 활용	- 단순 생성에서 벗어나 - 사용자 의도(Context) 이해 → 실행까지

[참고] ELIZA

단순한 패턴 매칭 기반 → ELIZA Effect : 사용자가 기계에 감정이나 지능이 있다고 착각하는 현상, 기술의 과대 평가로 이어짐

Welcome to

```

EEEEEE LL      IIII  ZZZZZZ  AAAAA
EE      LL      II    ZZ    AA   AA
EEEEEE LL      II    ZZ    AAAAAA
EE      LL      II    ZZ    AA   AA
EEEEEE LLLLLL IIII  ZZZZZZ  AA   AA
  
```

Eliza is a mock Rogerian psychotherapist.
The original program was described by Joseph Weizenbaum in 1966.
This implementation by Norbert Landsteiner 2005.

ELIZA: Is something troubling you ?

YOU: Men are all alike.

ELIZA: What is the connection, do you suppose ?

YOU: They're always bugging us about something or other.

ELIZA: Can you think of a specific example ?

YOU: Well, my boyfriend made me come here.

ELIZA: Is it important to you that your boyfriend made you come here ?

YOU: He says I'm depressed much of the time.

ELIZA: I am sorry to hear that you are depressed.

YOU: It's true. I am unhappy.

ELIZA: Can you explain what made you unhappy ?

YOU:

Rogarian Psychotherapy Style

환자의 말을 되묻거나,
감정을 반영하는 문장을 사용하는 상담 방식

[참고] Deep Blue

Chess-playing Expert System

It was the first computer to win a chess-game, and **the first to win a match**, against a reigning world champion **under regular time controls**.



[참고] ELIZA vs Deep Blue


두 시스템 모두 "AI의 초창기 방식"이라는 공통점은 있지만, 작동 방식과 평가는 명확히 다름

구분	ELIZA	Deep Blue
개요 (기여 중심)	- 초기 언어 처리 시스템 - 과도한 기대와 현실 간의 격차 확인	- 기호 기반 AI - 특정 규칙 기반 문제에서는 인간을 능가 할 수 있음을 입증
사용 목적	심리상담 시뮬레이터 (대화 모사)	체스 플레이 (전략 게임)
작동 방식	Pattern matching	Rule-Based + Search 규칙 기반 문제에서는 인간을 능가할 수 있음을 증명한 최초 사례
지식/전략 사용	사전 정의된 문장 패턴	인간 전문가의 체스 규칙 + 수백만 수의 시뮬레이션
대표적 기술	기호 기반 NLP 초기 실험	고성능 Rule engine + 탐색 최적화 기법
지능	지능처럼 보이지만 전혀 관련 없음	고도의 계산. 처리 속도 고려
한계	의미 이해 불가, 단순 키워드 반응	일반화 어려움, 체스 이외는 활용 제한

두 시스템 모두 규칙 기반, "학습과 일반화"를 하지 못함 !!


1. Short Overview of AI History

History of Game AI




NOPE !

Generally




[참고] AI Evolution

Model to Intelligence



2. Statistics vs ML in ANI


분석 모델은 전문가 직관을 기반으로 가설을 확인하는 통계분석과 데이터 관계를 학습하여 가설을 발견하는 머신러닝 기법을 활용




비교를 통한 우월함의 강조가 아닌 발전의 방향과 영역의 확대

2. Statistics vs ML (방법론)

분석 방법론

통계
기반ML
기반

방법론 변화 영역 비교





2. Statistics vs ML (모델링)

Statistic Modeling	Machine Learning
정해진 분포와 가정에 부합하는 신뢰도 높은 모델 → 모델의 복잡성 보다 단순성	모델의 정확도
선형 방정식 형태로 변수 간의 관계를 공식화 함 - 데이터에 대한 모델 피팅 전에 모델 곡선의 모양을 가정해야 함 - 변수는 해석 가능한 수준으로 모델링에 반영	- 규칙 기반이 아닌 데이터에서 학습할 수 있는 알고리즘 활용 학습 데이터 기반으로 패턴을 학습하는 방식으로 기본적인 관계를 가정할 필요 없음
- Train : Test = 7 : 3 - Train 데이터에서 전체 정확도와 개별 변수 수준에서 진단 수행	- Train : Test = 7 : 3 - Train = train : validation = 50 : 20 - Train 데이터셋으로 모델 개발 - 개발된 모델로 validation 데이터셋으로 Hyperparameter 조정 등을 통해 모델 성능 검증
모델링에서 P-value와 같은 다양한 매개변수 진단이 필요함	통계적 진단 테스트를 수행하지 않음

3. 모델 접근 방향


Classification vs Regression

	【 Classification 】	【 Regression 】
목적	- 독립변수(X)로 답(Y)을 구분하기 위한 경계 찾기 - Decision Boundary	- 독립변수(X) 통해 답(Y)과 가장 유사하도록 예측($\hat{Y}$) - Best Fit Line
결과값	- Discrete (이산형, 불연속의) - Class Labels	- Continuous (연속형) - Number
모델평가	- 분류 정확도. $Y \leftrightarrow \hat{Y}$ - Accuracy	- 예측 정확도. $Y \leftrightarrow \hat{Y}$ - Sum of Squared Error (r^2)
		


[참고] Which algorithm is good?

● ■ 두 집단을 분류하는 Classifier?


Case 1



Case 2




Case 3



Consider the conformability of the **model structure** with the **data (shape)**

[참고] Which algorithm is good?

데이터 성격과 특징을 잘 반영한 결과를 보이는 알고리즘을 선택하는 것!!



4. 모델 성능 영향 요인

전체 과정 중 모델링 (알고리즘 적용) 전까지의 과정에 80~90% 노력이 필요함

Step	Task	Effort	Importance
모델 설계 (분석 요건 정의)	Target / Feature 정의	15%	45%
	분석 모집단 / 모델 Segmentation 정의		
	분석 방법론 선정		
데이터 준비	분석 Mart 설계	55%	10%
	데이터 추출 / 정제 / 변환		
	Missing / Outlier 처리		
분석 준비	변수 변환 (표준화/ Grouping)	5%	10%
	Sampling (Random/ Over sampling)		
	Data Partition (Out of Data/Time)		
변수 탐색	Feature Extraction (파생변수)	10%	20%
	변수 Selection (안정성 / 예측력)		
Modeling	알고리즘 적용 / 최적화	15%	15%
	모델 평가 / 해석		

85%

당부 말씀

공모전이나 Kaggle에서는

최대한 변수를 넣어 XGBoost/Ensemble 등으로 최대의 성능을 획득하는 접근 방식은 적합 합니다. 목적이 우수한 모델 성능이기 때문입니다.

비즈니스에서는

목적에 맞고 활용 가능한 데이터를 확인하고, 안정적인 모델 성능을 획득하는 것이 접근 방식입니다.

목적이 비즈니스 문제를 해결해야 하기 때문입니다.

비즈니스에서의 모델링은

성능 점수 싸움이 아니라, “현장의 문제 해결책 싸움” 입니다.



모델의 정확도 보다 중요한 것은 현업이 그 결과를 이해하고, 수용하고, 활용할 수 있는가 입니다.

1. Artificial Intelligence



바나나

Rule-based, Statistics




Machine Learning

바나나


[참고] AI Evolution

Model to Intelligence



2. Statistics vs ML in ANI



분석 모델은 전문가 직관을 기반으로 가설을 확인하는 통계분석과 데이터 관계를 학습하여 가설을 발견하는 머신러닝 기법을 활용



비교를 통한 우월함의 강조가 아닌 발전의 방향과 영역의 확대

3. 모델 접근 방향

Classification vs Regression

	【 Classification 】	【 Regression 】
목적	- 독립변수(X)로 답(Y)을 구분하기 위한 경계 찾기 - Decision Boundary	- 독립변수(X) 통해 답(Y)과 가장 유사하도록 예측($\hat{Y}$) - Best Fit Line
결과값	- Discrete (이산형, 불연속의) - Class Labels	- Continuous (연속형) - Number
모델평가	- 분류 정확도. $Y \leftrightarrow \hat{Y}$ - Accuracy	- 예측 정확도. $Y \leftrightarrow \hat{Y}$ - Sum of Squared Error (r^2)
		

AI Campus 데이터분석 및 AIOps > Part A – Machine Learning

2. Machine Learning

- Learning Approach
- Machine Learning Type

본 문서는 SK(주) AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

"유튜브가 어떻게 나보다 더 내 취향을 잘 아는 걸까?"

"자율주행차는 어떻게 장애물을 피해 갈 수 있을까?"

"배민은 왜 내가 배고플 때마다 광고 팝업이 뜨는 걸까?"

사람이 일일이 알려주지 않아도, **머신**이 데이터 기반으로 상황을 파악하고 예측 결과를 알려줌
점점 더 잘 하기 위해 성능(수치)로 확인하는 방법도 사용

1. 용어의 이해

Machine Learning : 컴퓨터가 학습할 수 있도록 하는 알고리즘과 기술을 개발하는 분야

"컴퓨터에게 명시적으로 프로그래밍 하는 것 없이 배울 수 있는 능력을 주는 학문 분야"

Machine Learning is the field of study that gives computers the ability to learn **without** being explicitly programmed

- Arthur Samuel -

1. 용어의 이해


"컴퓨터 프로그램이 어떤 유형의 **과업(T, Task)**들에 대해
성과평가 지표(P, Performance measure)의 관점에서
경험(E, Experience)으로 부터 배워서,
만약 성과평가 지표(P)의 값이 향상이 된다면 컴퓨터 프로그램은 학습을 할 수 있다고 말할 수 있다."

"A computer program is said to learn from experience E with respect to some class of tasks T
and performance measure P if its performance at tasks in T, as measured by P, improves with experience E."

- Tom M. Mitchell -

- 반복 시도 중 얻는 시행착오
- 모델링 전략

2. Approach



Target(Label) 사전에 확보 되어 있어야 함

Improve with Experience : 반복 시도 중 얻는 시행착오


Multi-run,
Data-driven

2. Approach




3. Learning

하나의 모델을 만들고 Train-Valid-Test 성능을 비교하여 모델의 활용 여부를 확인함 (Single-Split Evaluation)



4. Machine Learning Type




4. Machine Learning Type

<u>Learning Type</u>	<u>Process</u>	<u>Description</u>
Supervised Learning (Task-driven)		- Input, Output 데이터 모두 제공 - 답(Y)을 찾기 위한 학습 (Supervised. 감독학습) - 최적의 정확도를 보이는 모델로 미래 데이터 예측 (Predict ↔ Output 비교)
Semi-Supervised Learning		- Unlabeled 분포가 Labeled 보다 더 많이 고려 - Labeled 데이터로만 학습한 모델 보다 더 좋은 성능의 모델을 만들어낼 가능성 있음 - Unlabeled 데이터를 함께 활용한다는 측면에서 Supervised와 차이가 있으나 Output은 동일
Unsupervised Learning (Data-oriented)		- Input 데이터만 제공 - 답(Y)를 알려주지 않은 상태 or 답(Y)을 알지 못하는 상태에서 스스로 학습 (Unsupervised. 자율학습) - 예상 패턴/clustering과 비교하여 insight 도출

[참고] Semi-Supervised Learning

라벨링 작업에 어려움이 있는 경우 혹은 학습 데이터량이 부족한 경우에 지도학습과 비지도학습을 함께 적용하여 학습시키는 방법




unlabeled data를 학습에 사용하는 경우 분류경계면 생성 예시

[배경]

- Labeled 보다 Unlabeled Data 데이터를 확보하기 쉬움
- Unlabeled를 학습에 사용하는 경우 데이터의 분포를 더 자세히 고려 할 수 있기 때문에, Labeled Data로만 학습한 모델 보다 더 좋은 성능의 모델을 만들어 낼 가능성 있음
- Label별 데이터 개수가 동일하다는 가정 하에
Labeled Data만 사용하는 경우보다 **Unlabeled Data를 학습에 함께 활용하는 경우 모델 성능이 향상되는 경향** 있음

[가정사항]




- X1과 X3은 가깝지 않더라도 X3의 라벨이 X1과 같을 것이라는 기대 (Smoothness)
- 라벨을 구분하는 Optimal Boundary 주변에는 데이터가 적을 것 (Low-Density)

2. Machine Learning

SUMMARY

3. Learning

하나의 모델을 만들고 Train-Valid-Test 성능을 비교하여 모델의 활용 여부를 확인함 (Single-Split Evaluation)



4. Machine Learning Type

Learning Type	Process	Description
Supervised Learning (Task-driven)	<pre> graph LR A[All data is Labeled] --> B[Model] B --> C[Predict] C <--> D[Label] </pre>	- Input, Output 데이터 모두 제공 - 답(Y)을 찾기 위한 학습 (Supervised. 감독학습) - 최적의 정확도를 보이는 모델로 미래 데이터 예측 (Predict ↔ Output 비교)
Semi-Supervised Learning	<pre> graph LR A[Small portion, Labeled] --> B[Model] C[Lots of Data Unlabeled] --> B B --> D[Predict] D <--> E[Label] </pre>	- Unlabeled 분포가 Labeled 보다 더 많이 고려 - Labeled 데이터로만 학습한 모델 보다 더 좋은 성능의 모델을 만들어낼 가능성 있음 - Unlabeled 데이터를 함께 활용한다는 측면에서 Supervised와 차이가 있으나 Output은 동일
Unsupervised Learning (Data-oriented)	<pre> graph LR A[All data is Unlabeled] --> B[Model] B --> C[Predict] </pre>	- Input 데이터만 제공 - 답(Y)를 알려주지 않은 상태 or 답(Y)을 알지 못하는 상태에서 스스로 학습 (Unsupervised. 자율학습) - 예상 패턴/clustering과 비교하여 insight 도출

3. ML Algorithm

- Tree-based : Decision Tree, Random Forest, Boosting
- Kernel-based : SVM
- Regularization : LASSO, Ridge

Algorithm

- 사전적 의미

어떤 문제를 해결하기 위해 정해진 일련의 절차나 방법

- Input/output : 입력/출력이 있고
- Definiteness : 각 단계가 모호하지 않고
- Finiteness : 유한 번에 끝나며
- Effectiveness : 실제로 수행 가능해야 함

- Machine Learning

- Learning Algorithm : 데이터로부터 **학습하는 절차** 자체
- Model : 그 절차로 데이터에 돌려서 나온 **결과물** - 학습 규칙/파라미터



ML Algorithm


【 CART 】

Classification and Regression Trees

Tree

Decision Tree


- Decision Rule
- 트리 형태로 Rule 구분



Random

Random Forest

- Data random subset
- Making random trees
- Building random forest



【 Boosting 】

Weak to Strong

XGboost

- 오분류 데이터에 가중치 부여
- 여러 학습 모델 생성(weak model)
- 성능이 더 이상 향상되지 않을 때 까지 수행(boosting)



LightGBM

- XGBoost의 연산방식 개선 (병렬처리, Leaf-Wise)




【 Kernal 】

Maximum Margin

SVM

- 그룹간 경계가 가장 크도록 구분
- 비선형 데이터에서는 커널로 구분




【 Regularization 】

Regular-ization


LASSO

- 기존 regression 보다 예측력 (설명력) 높은 모델 정의
- 회귀 계수를 조정하면서 학습



Ridge

- 변수선별 없이 모두 반영
- 낮은 회귀계수는 0에 가깝게 처리




CART-series

Decision Tree to Boosting


ML BASE

Decision Tree




물음표살인마

Random Forest



물음표살인마 * 100

Gradient boosting



오답노트 + 물음표 살인마*100

XGboost
Light GBM(((가벼워진)))
오답노트 + 물음표 살인마*100

CART-series

Decision Tree to Boosting

비유적 표현:

- 날씨가 좋으면 나간다 → 비가 오면 나가지 않는다
- 내일 우산을 챙기지 말지 어떻게 판단하나요? → 날씨를 본다, 예보를 본다, ...

데이터 기반:

- 조건 → 판단 → 결론에 이르는 과정
- 사람이 정한 규칙이 아니라, **데이터에서 조건과 판단을 자동 생성**하여 결정함

알고리즘 확장:


- 트리 하나 : Decision Tree
- 트리 하나 → 트리 여러 개 : randomForest
- 트리 하나씩 연결하여 오답을 줄이는 방향 : Gradient Boosting
- 계산 속도, 정밀도까지 개선 : XGBoost, LightGBM

1. Decision Tree

나무 구조의 모형 기반으로 분류/예측 하는 분석 방법

- 의사결정나무, Decision Tree, DT, CART
- 의사결정규칙을 도표화 하여 관심대상이 되는 집단을 몇 개의 소집단으로 분류 *Classification* 하거나 예측 *Prediction* 하는 분석 방법
- 모델링 내용은 나무구조로 한눈에 파악되어 쉽게 이해하고 설명할 수 있음

Outlook	Temperature	Humidity	Wind	PlayTennis
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Overcast	Hot	High	Weak	Yes
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes
Rain	Cool	Normal	Strong	No
Overcast	Cool	Normal	Strong	Yes
Sunny	Mild	High	Weak	No
Sunny	Cool	Normal	Weak	Yes
Rain	Mild	Normal	Weak	Yes
Sunny	Mild	Normal	Strong	Yes
Overcast	Mild	High	Strong	Yes
Overcast	Hot	Normal	Weak	Yes
Rain	Mild	High	Strong	No





분류 또는 예측 하고자 하는
목표변수(Target Variable)

1. Decision Tree

모델의 특징으로 다양한 분야에서 활용 되고 있음

- 분야 : 마케팅, CRM, 시장조사, 광고조사, 의학연구, 품질관리 등
- 주제 : 고객 신용점수, 캠페인 반응분석, 고객세분화, 시장세분화, 광고효과측정, 자동차 잔가 예측 등

[Case] 고객세분화



해석할 수 있는 것

- **분류 규칙(if-then)이 그대로 읽힌다**
: (e.g.) 남성 + 월소득 500만원 이상.
→ Target 92%
- **변수 중요도와 상호작용이 확인된다**
: Root가 "성별"로 가장 중요한 변수.
남성은 소득, 여성은 신용도로 갈리는 특징 있음

해석할 수 없는 것

- **세그먼트 규칙(n)과 신뢰성은 모른다**
: 세그먼트별 %는 비율.
92%가 몇 명인지 알 수 없음
- **Target의 정의와 인과관계를 모른다**
: 트리는 연관성만 확인 가능.
"남성이라서"라는 인과는 확인할 수 없음

1. Decision Tree

Decision Tree의 나무 형성은 불순도가 최소화 되는 방향으로 진행됨



분리 기준

- 부모 마디에서 자식 마디로 형성될 때 필요한 변수와 값의 부분집합
 - 연속형 : 분리기준 보다 작으면 왼쪽 자식 마디로, 크면 오른쪽 자식 마디로 데이터 분리
 - 범주형 : 전체 범주를 2개의 부분집합으로 분리하는 방향으로
- 불순도가 최저가 되는 방향으로 분리 결정
 - 연속형 : 분산 활용
 - 이산형 : 카이제곱 통계량, 지니 지수 *Gini Index*, 엔트로피 지수 *Information Theory*

나무 형성 과정

- 나무 성장, Growing : 각 마디에서 최적의 분리규칙을 찾아서 나무를 성장시킴. 정지규칙을 만족하면 중단
- 정지규칙 : 더 이상 분리가 일어나지 않고 현재 자식마디가 끝이 되도록 하는 규칙
- 가지치기, Pruning : 오분류율을 크게 할 위험이 높거나 부적절한 추론규칙을 가지고 있는 가지 제거

[참고] 불순도 최저 방향

의사결정나무는 불순도를 최소로 줄이는 방법으로 진행되는데, 그 불순도를 측정하는 방안으로 지니 지수와 엔트로피 지수를 사용함

Gini Index

$$1 - \sum_{i=1}^K p(i)^2 = 1 - \left(\left(\frac{2}{10} \right)^2 + \left(\frac{3}{10} \right)^2 + \left(\frac{5}{10} \right)^2 \right) = 1 - (0.04 + 0.09 + 0.25) = 0.62$$


- 불순도를 측정하는 하나의 지수 (0에 가까울수록 불순도 낮음)
- 해당 값을 참조하여 불순도를 감소시켜주는 변수와 그 때의 분류 방법을 선택
- 한 집단에서 임의로 두 개를 뽑았을 때 서로 다른 클래스가 나올 확률

어떤 변수를 기준으로 분할하면 불순도가 가장 많이 낮아지는가를 찾는 것이 핵심

Entropy


$$\sum_{i=1}^K -p_i \log_2 p_i = -\frac{2}{10} \log_2 \left(\frac{2}{10} \right) - \frac{3}{10} \log_2 \left(\frac{3}{10} \right) - \frac{5}{10} \log_2 \left(\frac{5}{10} \right) = 1.485$$

- {혼잡도, 자유도, 예측의 불확실성}을 측정하는 지표 (0에 가까울수록 불순도 낮음)
- 엔트로피가 높을수록 많은 정보를 보유하여 불확실성이 높음을 의미
- 로그를 통해 정보량(불확실성)을 직접 측정 (서로 다른 사건의 독립성 반영)



[참고] Entropy, 쉽게 이해하기


- 빨간색 공과 파란색 공 50개씩 있을 때
 - 각 바구니에 한 종류만 있으면 (전부 빨간색) → 완전히 순수 → entropy 0
 - 정확히 반반씩 있으면 (빨강 50, 파랑 50개) → 가장 많이 섞임 → entropy 최대
- 분류 후...
- 각 바구니에서 무작위로 하나 뽑았을 때 무슨 색깔인지 알려면, 질문이 평균 몇 번 필요할까?
 - 전부 빨간색 → 물어볼 필요도 없음 = 0번 → entropy 0
 - 색깔 반반 → 한 번은 꼭 물어봐야 함 = 1번 → entropy 1(bit)
- Entropy : 정답을 알아내는 데 드는 평균 질문 수 (불확실성)
- 의사결정나무에서 Entropy가 하는 일 : 분할 전 보다 분할 후에 entropy가 얼마나 줄어드는가를 보고, 가장 많이 줄이는 분할을 선택함



1. Decision Tree


Feature Importance

- 1번의 분할 기준 → entropy 감소량
- 특성별로 전부 합산 → Feature Importance



- 성별 : root에서 1번 분할, 전체 샘플 대상 → 가중치 큼
- 월 소득 : 남성 그룹을 92% vs 14% → 한 번의 분할로 크게 제거
- 신용도 : 여성 그룹을 좋음/나쁨으로 가름 (나쁨 2%, 거의 순수)
- 연령 : 여성 & 신용 좋음이라는 하위 그룹에서만 → 샘플 비율 작아 기여 작음

→ Importance는
트리 위쪽에 있어서 매우 중요하다 라는 해석 보다는
(Entropy를 얼마나 줄였나) * (몇 명에게 적용되나)의 합



* 막대 길이 : 그 특성이 없앤 Entropy 총량
(참고) 개념 설명 위한 예시 값으로, 실제 계산값 아님

1. Decision Tree

의사결정나무의 장점과 단점

Pros


- **직관적이고 이해하기 쉬움**
 - 모델 시각화가 가능하고, 비전문가도 이해하기 쉬움
 - **규칙 기반**으로 분류/예측을 수행하고 결과 해석이 간단함
- 데이터 전처리 부담이 적음
 - 범주형 데이터와 연속형 데이터를 모두 처리할 수 있음
 - 표준화나 정규화 등의 작업이 필요하지 않음
 - 이상치, 결측치에 덜 민감함
- **변수 중요도 파악 (Feature Importance)**
 - 분할 기준으로 사용된 특성을 기반으로 데이터에서 가장 중요한 변수를 쉽게 파악할 수 있음
- 작은 데이터셋에 적합
 - 비교적 작은 데이터셋에서도 잘 동작
 - 빠르게 학습이 가능

Cons

- **과적합(Overfitting) 가능성**
 - 나무가 깊게 성장 할수록 훈련 데이터에 과적합 될 가능성이 높음
 - 이를 방지하기 위해 가지치기(Pruning), 최대 깊이 제한이 필요함
- 불안정성
 - **데이터에 민감**하여 작은 변화를 반영한 별도 트리를 생성할 수 있음
 - 이를 극복하기 위해 앙상블 기법(eg, RandomForest, Bagging)이 자주 사용됨
- **모델의 일반화 성능이 낮을 수 있음**
 - 나무의 깊이에 따라 일반화 성능이 낮아질 수 있음
 - 단일 트리는 복잡한 데이터 특징을 반영하는데 한계가 있음 (변수 간의 상호작용을 반영하는데 한계 있음)
- 데이터셋 영향
 - 큰 데이터셋에서는 분할 기준을 찾는 과정에서 계산량이 많아질 수 있음
 - **클래스 불균형 데이터**에서는 잘못된 분류 결과를 계산할 가능성 있음 (데이터 편향)

[참고] Overfitting

ML 알고리즘 적용 시 발생하지 않도록 **반드시** 고려해야 하나는 유일 포인트 !!



사전적 의미 :

- **Overfitting : Fit too much, 너무 잘 맞추다**
- Train dataset의 노이즈나 특수한 패턴까지 학습하여, test dataset 또는 production에서 성능이 저하됨
- (e.g.) 모의고사 문제를 외워 100점을 받았으나, 실전 수능에서 50점을 받음


모델 관점에서의 의미 :

구분	정상적인 학습	Overfitting
학습 대상	데이터의 본질적 패턴	데이터의 노이즈나 특수 상황 까지 반영
모델 복잡도	적절 : 규칙적 구조	과도 : 지나치게 복잡
검증 성능	안정적 유지	전반적으로나 낮거나, 안정적으로 유지되지 못함

- Overfitting은 모델이 단순히 데이터를 외운 상태에 가까움
- 복잡한 모델 구조(e.g., 깊은 트리, 많은 파라미터)일수록 쉽게 발생
- 학습 데이터가 적을 때, Feature 수가 많을 때, Noise가 다수 포함되어 있을 때도 발생 가능성 있음


주의사항 :

- ML 알고리즘은 성능을 올리기 위해 계속 학습하는 구조 → 기본적으로 overfitting 위험 내제
 → 예외적인 문제가 아니라 **기본적으로 항상 발생 가능성 있음**
- 반드시 train - valid - test 성능 비교하여 안정적인 성능인지 확인




2. Random Forest

#tree, #random




- **random subset** : 데이터 변수를 무작위로 선택하여
- **random trees** : 여러 개의 트리들을 임의적으로 생성하여 각 트리들로부터 얻어질 결과가 평균 이상이 되면
- **feature selection** : 최대의 정보가 반영되도록 정답을 잘 설명할 수 있는 변수를 선택하여
- **random forest** : 생성된 트리들의 성능에 투표하여 모델을 정의한다 (voting using bagging to build random forest)



3. Boosting

Gradient Boosted Tree Machines


#tree, #week2strong



- **weak model**: 같은 가중치를 가지는 여러 개의 성능이 낮은 모델을 생성하고
- **gradient**: 낮은 성능을 높이기 위해 학습을 진행하여 (= 가중치 업데이트), 샘플 데이터로 모델 성능을 fitting 한 후, 전체 학습데이터셋에 반영하는데
- **boosting**: 해당 과정을 반복하여 오차를 최소화 시키는 모델을 생성한다


XGBoost *eXtreme Gradient Boosting*

- 순차적으로 트리를 만들어 이전 트리보다 더 나은 트리를 만들어내는 알고리즘으로 예측 성능이 좋은 편임
- 변수 종류가 많고 데이터가 클수록 상대적으로 뛰어난 성능을 보임
- 복잡한 모델만큼 모델 해석에 어려움이 있음
- Depth-Wise 방식



LightGBM


- Leaf 중심으로 트리를 분할하는 방식
- XGBoost 보다 빠르고 높은 정확도를 보여주는 경우가 많아지고 있음
- 변수 종류가 많고 데이터가 클수록 상대적으로 뛰어난 성능을 보임
- Leaf-Wise 방식



3. Boosting


#tree, #week2strong

XGBoost



Depth-Wise


LightGBM



Leaf-Wise

1. 이전 모델이 예측에 실패한 부분을
 2. 다음 모델이 더 잘 맞추도록 보완하며
 3. 반복해서 성능을 보임
- 라벨을 너무 많이 참조하면서 학습하여
"정답을 외우는", 과적합 위험 증가
(data leakage 위험)


CatBoost



- 범주형 데이터를 전처리 없이 직접 처리할 수 있는 Boosting 알고리즘
- 튜닝 난이도가 낮고 기본 설정만으로도 높은 성능을 보여 현장에서 선호
- Leaf-Wise + Ordered Boosting
 - 학습데이터 내 정답을 미리 다 보는 것이 아니라
 - 학습에 사용된 데이터만 기반으로 다음 트리를 학습시켜 과적합 방지
(같은 train 안에서 지금까지 풀어본 문제만 보고 다음 문제를 풀도록 하는 방식)


4. Support Vector Machine

#kernel, #margin




- 데이터를 2개 그룹으로 구분할 수 있는 **선형 분류**를 먼저 하고
- **maximum margin** : 그룹 간 분류를 좀 더 정확하게 하기 위해 그룹간 경계가 가장 큰 선형식을 찾는다
- **kernel** : 선형으로 분류할 수 없는 경우 feature space를 변형하여 그룹간 경계가 가장 큰 선형식을 찾는다
- **soft margin** : 반복 수행하여 경계는 크고, 분류 오류는 작은 것들로 모델을 정의한다

Linear SVM




Non-linear



[용어] 독일어 "Kern"에서 유래 → 'core', 'essence' → (사상, 주체의) 핵심, 중심
 [수학] 두 개체 사이의 관계나 핵심적인 부분을 나타내는 함수

4. Support Vector Machine


Kernel, Feature Space, Decision Surface to extract features from data



4. Support Vector Machine

모델 복잡도

```
1 svm = SVC(kernel='rbf', random_state=1, gamma=0.008, C=0.1)
2 svm.fit(X_train_std, y_train)
```



■ gamma

- 두 샘플 사이의 거리에 얼마나 민감하게 반응할지를 결정하는 하이퍼파라미터 → **경계의 복잡도 조절**
- 값이 커질수록 값(거리)에 민감하게 반응, 과적합 가능성 높아짐

■ C (Cost)

- 오차에 얼마나 벌점을 부과할지 결정하는 파라미터
→ **오분류를 얼마나 허용할 것인가**
- Regularization parameter that determines how heavily errors (or margin violations) should be penalized.
- **Gamma와 함께 조절하여 모델 최적화 진행**
- 값이 큰 경우:
 - 오분류를 최대한 줄이려는 방향으로 학습
 - Margin이 상대적으로 좁아질수록, 모델이 데이터에 더 민감해져서 과적합(overfitting) 위험이 높아짐
- 값이 작은 경우:
 - Margin을 더 넓게 잡아서 오분류에 대한 벌점을 낮게 부여
 - “Training set에서 일부는 틀려도 괜찮다”는 방향으로 모델을 학습시킴. 값이 많이 작을수록 과소적합(underfitting) 가능성 있음

5. Regularization

사전적 의미:

- 규칙이나 표준에 맞춰 정돈하다

Machine Learning :

- 목적 : 모델이 과도하게 복잡해져 일반화 성능이 떨어지는 문제 완화
- 모델의 파라미터나 구조에 인위적으로 제한(패널티)을 가하는 기법

1. Overfitting 방지
2. 모델 복잡도 제어

- 대표적인 방법

- 1) L2 Regularization (Ridge Regression) : 가중치 제곱합에 대한 패널티 통해 큰 가중치가 생성되지 못하도록
- 2) L1 Regularization (Lasso Regression) : 가중치 절대값의 합에 대한 패널티를 통해 유도 (특정 가중치를 0으로 만들어 변수 선택 효과 기대)
- 3) Dropout
- 4) Batch Normalization

[참고] L1/L2 Regularization 쉽게 이해하기

비유적 상황:

- 여러분이 발표를 위해 30장의 슬라이드를 준비했습니다.
- 30장에 많은 내용은 있지만 무슨 내용을 발표하려 하는지 잘 안보입니다. → 핵심 안보임/없음 → 과적합, Overfitting
- 교수님이 발표자료 제출은 5장으로 제한하셨습니다.

쉽게 이해하기:


- 발표자료 5장 제한 → Regularization. 규칙 부여
- 줄이는 방식은...
 - 모든 슬라이드를 조금씩 줄여서 정리 → L2 Regularization
 - 필요 없는 슬라이드는 모두 삭제 → L1 Regularization

→ L2 (Ridge): 모든 가중치를 균등하게 조절 → 변수는 모두 반영되 전체 가중치 조절 (줄이는 방향으로)

→ L1 (Lasso): 일부 가중치를 0으로 조절 → 변수 선택 효과

5. Regularization

#regular, #performance




- 통계에서의 회귀분석을 통해 유효변수를 찾더라도, 높은 상관관계를 가진 변수로 인해 설명력이 낮아질 수 밖에 없음
- Regularization = Regular(규칙, 기준, 일반) + -ization(과정 또는 결과)
- 모델이 너무 복잡해지는 것을 방지하고, 데이터의 노이즈를 과도하게 학습하지 않도록
= **모델이 일반화된 성능을 확보할 수 있도록**
= **모델 예측력(설명력)이 높은 모델 정의**
- 설명력을 향상시키는 회귀계수를 선별하는 과정을 반복하여 모델 예측력(설명력)이 높은 모델 채택

LASSO *Least Absolute Shrinkage and Selection Operator*

- 낮은 회귀계수는 강제로 "0" 으로 처리하여 변수 선택 효과 발생 (alpha 값을 조정하여 사용자 정의 가능, 보통은 0.1에서 시작)
→ 작은 alpha부터 시작해서 조심스럽게
- 모델이 단순해지면, 중요한 변수만 남음
- L1 규제 적용 : 회귀계수의 절대값에 패널티 부여

- 예) 유사한 의미를 가지는 단어를 모두 없애 버리고, "사랑한다" 라는 단어만 채택하여 모델 해석력 상승되는 효과




- 계수가 0에 수렴
- 변수 선택 및 모델 단순화가 필요할 때

Ridge *mountain crest, 능선/산등성이*

- 회귀계수를 표준화 처리하고 (center/scale), 낮은 회귀계수는 0에 가깝게 처리 (shrinkage)하여 다중공선성 문제 완화
→ 1.0 정도부터 시작해서 안정적으로
- 변수 선별 또는 제거 없이 처리된 변수 모두 반영
- L2 규제 적용 : 회귀계수의 제곱합에 패널티 부여

- 예) 관계가 없는 데이터는 모두 없애버리고, 유사한 의미는 최대한 반영하여 "사랑한다", "사모한다" 선택 (모델 복잡도가 상대적으로 있음)



- 모두 0 근처로 수축
- 다중공선성 문제가 우려되거나 모든 변수를 활용하고 싶을 때

3. ML Algorithm

SUMMARY

ML Algorithm

3. ML Algorithm


【 CART 】

Classification and Regression Trees

Tree

Decision Tree


- Decision Rule
- 트리 형태로 Rule 구분



Random

randomForest

- Data random subset
- Making random trees
- Building random forest



【 Boosting 】

Weak to Strong

XGboost

- 오분류 데이터에 가중치 부여
- 여러 학습 모델 생성(weak model)
- 성능이 더 이상 향상되지 않을 때 까지 수행(boosting)



LightGBM

- XGBoost의 연산방식 개선 (병렬처리, Leaf-Wise)




【 Kernal 】

Maximum Margin

SVM

- 그룹간 경계가 가장 크도록 구분
- 비선형 데이터에서는 커널로 구분




【 Regularization 】

Regular-ization


LASSO

- 기존 regression 보다 예측력 (설명력) 높은 모델 정의
- 회귀 계수를 조정하면서 학습



Ridge

- 변수선별 없이 모두 반영
- 낮은 회귀계수는 0에 가깝게 처리



TODAY QUIZ

Q1. 아래 상황에서 가장 먼저 고려할 1순위 후보는 무엇인가요?

대출 심사 모델의 거절 사유를 규제 담당자와 비전공 임원에게 한 장의 그림으로 설명해야 합니다.
정확도 보다 설명 가능성이 우선입니다.

- (A) Decision Tree
- (B) Random Forest
- (C) XGBoost
- (D) SVM

Q2. 아래 상황에서 가장 먼저 고려할 1순위 후보는 무엇인가요?

새로운 분류 문제에서 튜닝에 시간을 많이 쓰지 않고, 빠르게 안정적인 기준 성능을 잡고 싶습니다.
이 때 과적합도 함께 줄이고 싶습니다.

- (A) Decision Tree
- (B) Random Forest
- (C) SVM
- (D) LASSO

Q3. 아래 상황에서 가장 먼저 고려할 1순위 후보는 무엇인가요?

정형 데이터로 진행되는 예측 대회에 참가하고자 합니다.
튜닝 노력을 들여 마지막 한 방울의 정확도까지 짜내야 합니다.

- (A) Decision Tree
- (B) Random Forest
- (C) SVM
- (D) XGBoost

Q4. 아래 상황에서 가장 먼저 고려할 1순위 후보는 무엇인가요?

수천만 행 규모의 정형 데이터이고 학습 속도와 메모리 효율이 매우 중요하게 고려되고 있습니다.
성능 정확도도 중요하여 부스팅 계열을 쓰기로 정했습니다.

- (A) AdaBoost
- (B) XGBoost
- (C) LightGBM
- (D) CatBoost

Q5. 아래 상황에서 가장 먼저 고려할 1순위 후보는 무엇인가요?

고유값이 많은 범주형 변수가 다수인 데이터입니다.
인코딩 전처리에 손을 많이 대고 싶지 않습니다.

- (A) Random Forest
- (B) XGBoost
- (C) CatBoost
- (D) Ridge

Q6. 아래 상황에서 가장 먼저 고려할 1순위 후보는 무엇인가요?

표본은 수백 개인데 변수는 수천 개인 데이터셋입니다. (예: 유전자 발현, 텍스트 등)
EDA 통해 비선형 경계가 필요함을 확인하였습니다.

- (A) Decision Tree
- (B) Random Forest
- (C) LightGBM
- (D) SVM

Q7. 아래 상황에서 가장 먼저 고려할 1순위 후보는 무엇인가요?

변수가 수백 개인데 대체로 선형 관계를 가짐을 확인하였습니다.
진짜 중요한 변수만 남긴 간결하고 해석 가능한 모델이 필요합니다.

- (A) LASSO
- (B) Ridge
- (C) SVM
- (D) LightGBM



수고하셨습니다.

본 문서는 SK(주) AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.