

LoRA SFT 파인튜닝 결과 해석 보고서

Epoch 변화 및 LoRA Rank 실험

1. 학습 결과 요약

Baseline 규칙 준수율은 32.2%였고, rank 8·1 epoch LoRA SFT 이후 92.7%로 60.5%p 상승했다. 정답 SQL(completion)에만 loss를 적용했으며 train loss는 0.1376, eval loss는 0.0122였다.

구분	설정	Train loss	Eval loss	규칙 준수율
Baseline	학습 전	-	-	32.2%
Fine-Tuned	400건 / 1 epoch / r=8	0.1376	0.0122	92.7%

규칙별 변화

규칙	Baseline	Fine-Tuned	해석
alias / formula / orderdesc	0%	100%	실매출 계산·별칭·정렬 패턴 학습
completed	10%	100%	완료 주문 필터가 안정화
semicolon	40%	100%	출력 형식 규칙 개선
groupby	0%	75%	대부분 개선, 차원 선택 오류 잔존
period	0%	55%	개선됐으나 가장 낮은 준수율
select_only / table / limit	100%	100%	Baseline부터 이미 충족

관찰 사례: '7월 지역 기준' 질문에서 Fine-Tuned 모델은 계산식, 완료 상태, 기간, 정렬은 맞췄지만 GROUP BY category를 출력했다. 즉 SQL 골격은 학습했으나 자연어의 집계 차원(region/category)을 정확히 연결하는 문제는 남았다.

2. Epoch·LoRA Rank·실행 시간 결과

학습 데이터 400건과 seed 42를 고정하고 rank를 8로 진행했다. Rank 8의 학습 가능 파라미터는 540,672개(0.1093%)이다

Epoch	Rank	Train loss	Eval loss	준수율	실행 시간
1	8	0.1376	0.0122	92.7%	244.32초
3	8	0.0423	0.0047	97.8%	210.29초
10	8	0.0125	0.0006	100.0%	316.20초




그림 1. Rank 8의 Epoch별 loss·준수율·실행 시간


개인 해석

Rank 8은 1→3 epoch에서 rank 16보다 각각 5.6%p, 2.2%p 낮았지만 10 epoch에는 동일한 100%에 도달했다. 즉 rank 축소는 초기 학습 속도를 늦췄으나 충분히 반복하면 이번 과제 수준의 규칙을 표현할 용량은 확보했다. 파라미터 효율을 우선하면 rank 8·10 epoch, 빠른 성능 도달을 우선하면 rank 16·3 epoch가 후보가 된다.

실행 시간은 1→3 epoch에서 오히려 244.32→210.29초로 줄고 10 epoch에서 316.20초로 늘었다. 모델 로딩, 평가, 20건 SQL 생성, GPU 상태가 모두 포함된 1회 실횣이므로 epoch와 순수 학습 시간의 선형 관계로 해석할 수 없다. 반복 측정의 중앙값과 trainer의 train_runtime을 별도로 기록해야 공정하다.

3. 조별 토의 및 고찰

A: Epoch 1→3→10 변경 테스트




Epoch	Rank	Train loss	Eval loss	준수율	실행 시간
1	8	0.1376	0.0122	94.5%	244.32초
3	8	0.0423	0.0047	97.8%	210.29초
10	8	0.0125	0.0006	100.0%	316.20초

1~3 epoch에서 점차 감소한 Loss를 확인할 수 있고 10 epoch에는 동일한 100%에 도달했다. 에포치 증가에 따라서 학습 실행 시간이 증가했지만 학습 및 평가 Loss를 줄이며 준수율 또한 높일 수 있다.

B : Train size 50 -> 100 -> 400 변경 테스트


train size 별 실험결과 (epochs=1, lora_r=8)



학습 데이터 크기	Epoch	LoRA Rank	Train Loss	Eval Loss	규칙 준수율
50	1	8	0.5928	0.5627	35.6%
100	1	8	0.4632	0.3844	53.8%
400	1	8	0.1403	0.0162	94.5%

학습 데이터 증가에 따라 같은 패턴을 다양하게 변형하여 여러번 학습하면서 규칙을 안정적으로 일반화 한 것으로 판단된다.

C: LoRA Rank 2 -> 8 -> 16 -> 32 변경 테스트



Rank (r)	학습 가능 파라미터	Train Loss	Eval Loss	규칙 준수율
2	135,168 (0.0274%)	0.3507	0.2309	68.5%
8	540,672 (0.1093%)	0.1403	0.0162	94.5%

16	1,081,344 (0.2184%)	0.0848	0.0038	98.3%
32	2,162,688 (0.4359%)	0.0521	0.0013	100.0%

관찰:r=2→8에서 규칙 준수율이 26.0%p로 가장 크게 상승했고, r=8 이후에는 3.8%p, 1.7%p씩 상승하며 개선 폭이 작아졌다. Train/Eval Loss는 Rank 증가에 따라 일관되게 낮아졌다.

"어떤 요인이 규칙 준수율에 가장 큰 영향을 주는가"

학습 데이터 크기가 규칙 준수율에 가장 큰 영향을 미친다고 판단했다. Rank와 Epoch를 최소 수준으로 고정해 비교했을 때, 학습 데이터 크기를 증가시킨 실험에서 초기값 대비 규칙 준수율의 상승폭이 가장 크게 나타났기 때문이다. 이는 데이터가 많아질수록 기간 조건, 집계 기준, 정렬 방식 등 다양한 SQL 규칙의 조합을 모델이 반복적으로 접할 수 있기 때문으로 해석된다.

다만 이러한 결과를 모든 파인튜닝 작업에 일반화하기는 어렵다. 이번 실험은 출력 형식이 비교적 정형화된 SQL 쿼리 생성 과제이며, 검사 대상 규칙도 명확하고 반복적이다. 따라서 적은 데이터와 낮은 Rank로도 일정 수준 이상의 규칙 준수율을 달성할 수 있었고, Epoch를 늘리면 낮은 Rank의 성능도 보완할 수 있었다. 즉, 이번 실험에서는 **학습 데이터의 양과 다양성이 가장 중요한 요인이었으며, Rank와 Epoch는 목표 성능에 도달하는 속도와 학습 효율을 조정하는 요인**으로 보는 것이 적절하다.

또한 규칙 준수율은 SQL의 형식적 조건을 측정한 값이므로, 실제 실행 정확도나 의미적 정답률까지 보장하지는 않는다. 최종 결론을 강화하려면 동일 조건에서 여러 번 실험한 평균값과 별도 테스트 데이터의 SQL 실행 결과를 함께 비교할 필요가 있다.