



데이터분석 및 MLOps

ML 모델 개발 및 최적화

Day1. Building & Evaluating Models

2026.07

전임교수 : Byung-sun, Park

parkbs@sk.com

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.



Day1


좋은 모델을 어떻게 만들고 평가할 것인가?

Building & Evaluating Models

Day2

모델 성능을 어떻게 최적화하고 신뢰할 수 있을까?

Optimizing & Understanding Models



day1

1. Intro : Why Machine Learning?
2. Type of Machine Learning
3. Model Development Workflow
4. Data Partitioning Strategy
5. Generalization & Overfitting
6. Model Evaluation
7. Why Linear Models Still Matter

ML 모델 개발 및 최적화


Intro

- Why Machine Learning?
- Rule-based vs Machine Learning
- Machine Learning Finds Patterns
- From ML to Deep Learning

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Machine Learning Across Industries

머신러닝은 금융·제조·유통·의료 등 다양한 산업의 예측과 의사결정에 활용되고 있음



Industry Applications

- Finance — 신용평가, 이상거래 탐지, 고객 이탈 예측
- Manufacturing — 품질 예측, 설비 이상탐지, 수요 예측
- Retail / Service — 추천, 수요예측, 고객 세분화
- Healthcare — 질병 위험 예측, 환자 분류, 치료 반응 예측

- ✓ 다양한 산업 문제는 Classification, Regression, Ranking, Forecasting 등의 머신러닝 문제로 정의할 수 있음
- ✓ Global ML market: CAGR 30.5% expected through 2032

Why Machine Learning?

Can we write rules for everything?

Fraud Detection

어떤 거래가 이상 거래인가?

Customer Churn

어떤 고객이 이탈할 것인가?

Demand Forecasting

다음 달 수요는 얼마나 될 것인가?

Customer Segmentation

비슷한 특성의 고객을 어떻게 그룹화할 것인가?

Rules are hard to define

- 모든 문제의 규칙을 사람이 직접 정의할 수는 없음



Data contains patterns

- 어려운 규칙도 데이터에는 반복되는 패턴이 존재



Learn → Predict

- 과거 데이터에서 패턴을 학습
- 새로운 데이터에 대한 예측/의사결정에 활용

✓ Complex Problems → Data → Learn Patterns → Predict / Decide

✓ Machine Learning은 데이터에서 패턴을 찾아 새로운 상황을 예측

Rule-based vs Machine Learning

Case Study : 대출 연체 예측

Rule-based

- Who defines these rules and thresholds?
- 사람이 직접 기준과 임계값을 정의 (3,000만원, 60%, 2회..)

소득 < 3,000만원 AND 부채비율 > 60% → 위험

최근 6개월 내 연체 횟수 ≥ 2회 → 위험

월 상환액 / 월 소득 > 40% → 위험

...



조건 충족 → 위험

Machine Learning

- Who finds the patterns?
- 모델이 과거 데이터로부터 연체와 관련된 패턴과 관계를 학습

과거 고객 데이터(소득, 부채, 거래내역 등)

+

실제 연체 여부



모델이 데이터로부터 연체 패턴 학습



신규 고객의 연체 가능성 예측

" Data + Rules → Output "

- 어떤 변수를 사용해야 하는가?
- 기준을 왜 3,000만원으로 해야 하는가?
- 여러 조건을 어떻게 조합해야 하는가?

" Data(X) + Output(Y) → Model "

" New Data + Model → Prediction "

- Patterns are learned from data

Rule-based vs Machine Learning

Machine Learning이 사람의 판단까지 대체하는 것은 아님

	Rule-based	Machine Learning
규칙 생성	사람이 직접 작성	데이터에서 학습
기준값	사람이 결정	모델이 학습
복잡한 관계	표현하기 어려움	다수 변수의 관계 학습 가능
데이터 증가	규칙 수정 필요	재학습 가능
예측	정해진 규칙 적용	학습된 패턴 기반 예측

머신 러닝의 역할

- 머신러닝이 대신하는 것은 주로 복잡한 데이터 속에서 예측 규칙을 찾는 과정

분석가의 역할

- 어떤 데이터를 사용할지..
- 무엇을 예측할지..
- 어떤 모델을 사용할지..
- 모델 결과를 어떻게 평가할지..

Machine Learning Finds Patterns

머신러닝은 데이터에서 Input → Output 사이의 패턴을 학습

Why Not Just Write More Rules?

[대출 연체 예측 case]

- 고객의 연체 가능성은 수많은 변수의 영향을 받음

소득	거래기간
부채	대출금액
나이	직업
신용점수	과거 연체
...	...

- 더 어려운 문제는 변수들이 서로 결합해서 작동한다는 것

부채비율 60% + 고소득 → 상대적으로 낮은 위험
부채비율 60% + 저소득 → 상대적으로 높은 위험
: 같은 부채비율 60%라도 고객에 따라 의미가 다를 수 있음

- ✓ 현실의 문제는 하나의 조건만으로 설명되지 않음
- ✓ 현실에서는 단일 Rule보다는 여러 변수의 조합과 상호작용이 중요



- ✓ Machine Learning은 이러한 복잡한 패턴과 변수 간 관계를 데이터에서 학습

All Models Are Approximations

모델 = 근사 + 일반화

Model = Approximation + Generalization

”
**Essentially, all models are wrong,
but some are useful.**

- George Box

”

- ✓ 모델은 현실을 완벽하게 설명하는 것이 아니라, 문제 해결에 유용한 패턴을 근사하고 일반화한다
 - Good Model $\neq$ Perfect Model
 - Good Model = Useful Generalization

ML 모델 개발 및 최적화


Type of Machine Learning

- Learning Paradigm
- Prediction Task
- Model Family

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Three Views of Machine Learning

How Can We Classify Machine Learning?




- ✓ 같은 알고리즘도 관점에 따라 서로 다른 분류에 속할 수 있음
- ✓ 예를 들어 Decision Tree는 Supervised Learning이면서 Classification/Regression에 쓰이고, 동시에 Tree-based Model임

Learning Paradigm : 어떻게 학습하는가?

Type of Machine Learning

Supervised Learning


- 학습 데이터에는 불량/정상, 판매량 등 정답에 해당하는 레이블 또는 결과값이 포함됨
- 입력과 정답의 관계를 학습하여 새로운 데이터의 결과를 예측
- 학습 과정에서 예측 오차를 줄이거나 분류 기준을 개선하도록 모델의 구조 또는 파라미터를 결정
- 대표적인 문제 : Classification, Regression



Supervised Learning Algorithms

Unsupervised Learning

- 정답(Label) 없이 데이터 자체의 구조와 패턴을 탐색
- 모델은 입력 데이터에 존재하는 구조를 추론
- 유사한 데이터를 묶거나, 데이터의 차원을 줄이거나, 잠재적인 구조를 발견
- 대표적인 문제: Clustering, Dimensionality Reduction



Unsupervised Learning Algorithms

Learning Paradigm : 어떻게 학습하는가?


Type of Machine Learning

Semi-Supervised Learning

- 입력 데이터는 레이블이 지정된 샘플과 레이블이 지정되지 않은 샘플이 혼재
- 소량의 라벨이 있는 데이터 + 대량의 라벨이 없는 데이터의 상황이 일반적
- 데이터 라벨링 비용이 비싼 문제(의료, 자연어처리, 이미지 인식 등)에서 주로 활용
- 라벨링 비용을 줄이면서 비라벨 데이터의 정보까지 활용할 수 있음

Workflow

- (1) 소량의 라벨 데이터로 초기 모델 학습
- (2) 학습된 모델을 사용하여 비라벨 데이터의 예측 결과를 추가 정보로 활용
- (3) 라벨 데이터와 비라벨 정보를 함께 활용하여 모델 개선



Semi-supervised
Learning Algorithms

Prediction Task : 무엇을 예측하는가?


Type of Machine Learning

Classification

- 입력 데이터를 미리 정의된 범주(Class) 중 하나로 분류
- 예측 결과는 불량/정상, 이탈/유지, 승인/거절 등 범주형 값
- 모델은 서로 다른 범주를 구분하기 위한 Decision Boundary를 학습
- 대표적인 문제 : 이진 분류(Binary Classification), 다중 분류(Multi-class Classification)

[Examples]

- 제조 : 불량 / 정상
- 금융 : 연체 / 정상
- 고객 : 이탈 / 유지
- 의료 : 질병 있음 / 없음



Classification Algorithms

Prediction Task : 무엇을 예측하는가?


Type of Machine Learning

Regression

- 입력 데이터를 기반으로 연속적인 수치값을 예측
- 예측 결과는 판매량, 가격, 수요, 온도 등 연속형 값
- 모델은 실제값과 예측값의 차이가 작아지도록 관계 또는 함수를 학습
- 새로운 입력 데이터에 대해 가장 적절한 수치값을 예측

[Examples]

- 판매 : 판매량 예측
- 부동산 : 주택 가격 예측
- 제조 : 제품 수명 예측
- 수요 : 향후 수요량 예측




Regression
Algorithms

Model Family : 어떤 모델 계열인가?

Types of Machine Learning

Linear Models


- 여러 입력 변수와 결과값 사이의 관계를 선형식으로 표현하고 예측
- 해석이 쉽고 계산이 단순하며 기본 모델(Baseline)로 많이 활용
- Regression은 '연속값을 예측하는 Task 유형'과 '회귀 모델 계열'을 모두 의미할 수 있음
- Ex) 선형 회귀, 로지스틱 회귀
- Ex) 비모수 회귀(LOESS: Locally Estimated Scatterplot Smoothing)



Regression Algorithms

Instance-based Models

- 저장된 학습 샘플을 직접 비교하여 예측
- 거리 또는 유사도를 기준으로 가장 가까운 사례를 탐색
- Memory-based / Lazy Learning 방식
- 학습은 단순하지만 예측 시 계산 비용이 커질 수 있음
- Ex) k-Nearest Neighbor(kNN)




Instance-based Algorithms

Model Family : 어떤 모델 계열인가?

Types of Machine Learning

Probabilistic / Bayesian Models


- 확률을 이용해 불확실성을 표현하고 데이터를 기반으로 예측
- Bayesian Model은 새로운 데이터가 관측되면 기존 믿음(Prior)을 갱신해서 더 나은 믿음(Posterior)으로 업데이트
- 예측값뿐 아니라 불확실성까지 정량적으로 표현할 수 있음
- 복잡한 모델에서는 사후분포 계산이 어려워 근사 추론이 필요할 수 있음
- Ex) Naive Bayes, Bayesian Network



Bayesian Algorithms

Kernel-based Models

- 커널 함수(Kernel Function)를 사용하여 데이터를 더 높은 차원의 공간으로 변환하여 비선형적인 패턴도 학습
- 원본 공간에서는 구분하기 어려운 데이터를 커널을 통해 선형적으로 구분할 수 있음
- Kernel 종류와 하이퍼파라미터 선택에 따라 성능이 크게 달라질 수 있음
- Ex) Support Vector Machine (SVM)




Kernel-based Algorithms

Model Family : 어떤 모델 계열인가?

Types of Machine Learning

Tree-based Models


- 데이터의 특성값을 기준으로 반복적으로 분할하여 의사결정 규칙을 생성
- 루트 노드에서 조건에 따라 가지를 따라 내려가며 최종 예측값을 결정
- Classification과 Regression 모두에 활용 가능
- 해석이 쉽고 학습·예측이 비교적 빠르지만, 깊어질수록 과적합될 수 있음
- Ex) Classification and Regression Tree (CART), Iterative Dichotomiser 3 (ID3)



Decision Tree Algorithms

Ensemble Algorithms

- 여러 개의 모델을 학습한 뒤 예측 결과를 결합하여 더 안정적이고 강한 모델을 생성
- 여러 모델의 다양성을 확보하고, 결과를 어떻게 결합할지가 핵심
- 단일 모델보다 분산을 줄이거나 편향을 보완하여 성능과 안정성을 높일 수 있음
- Boosting
- Bootstrapped Aggregation (Bagging)
- Stacked Generalization (Stacking)




Ensemble Algorithms

Model Family : 어떤 모델 계열인가?

Types of Machine Learning

Artificial Neural Network


- 인공 신경망은 생물학적 신경망의 구조와 동작 방식에서 영감을 얻은 모델
- ANN은 오늘날 다양한 분야에 적용되는 수백 가지 알고리즘과 변형 모델들의 기본 구성 요소(building block)
- Training: Backpropagation, Gradient Descent
- Ex) Perceptron, Multilayer Perceptrons (MLP)



Artificial Neural Network Algorithms

Deep Learning Models

- 여러 개의 은닉층을 가진 깊은 신경망을 이용해 복잡한 표현을 학습
- 이미지, 텍스트, 음성, 비디오 등 고차원·비정형 데이터 처리에 강점
- 대규모 데이터와 높은 계산 자원을 활용해 복잡한 패턴을 학습
- Ex) Convolutional Neural Network (CNN)
- Ex) Recurrent Neural Network (RNN) / Long Short-Term Memory (LSTM)
- Ex) Transformer




Deep Learning Algorithms

Model Family : 어떤 모델 계열인가?

Types of Machine Learning · Unsupervised Methods

Clustering


- 유사한 데이터끼리 그룹으로 묶어 데이터의 구조를 파악
- 데이터 간 유사성을 기준으로 비슷한 특성을 가진 그룹을 탐색
- Ex) k-Means, Hierarchical Clustering, DBSCAN



Clustering Algorithms

Dimensionality Reduction

- 많은 변수로 구성된 데이터를 핵심 정보를 최대한 유지하면서 더 적은 차원으로 표현
- 고차원 데이터를 시각화하거나 이후 모델링을 위해 데이터를 단순화하는 데 활용
- Principal Component Analysis (PCA)
- t-distributed Stochastic Neighbor Embedding (t-SNE)
- Uniform Manifold Approximation and Projection for Dimension Reduction (UMAP)



Dimensional Reduction Algorithms

ML 모델 개발 및 최적화


Model Development Workflow

- Machine Learning Workflow
- Building a Good Model

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Core Concept of Model Learning

좋은 머신러닝 모델은 어떻게 만들어지는가?




- What do we learn from?
 - 학습에 사용할 입력 데이터와 정답
- How do we find patterns?
 - 데이터의 패턴을 학습하는 과정
- What has been learned?
 - 학습된 규칙과 관계
- How do we use it?
 - 새로운 데이터에 대한 예측

✓ 머신러닝은 데이터에서 패턴을 학습하고, 이를 이용해 새로운 데이터의 결과를 예측하는 과정

Machine Learning Workflow

From problem definition to model deployment




- 모델 개발은 문제 정의에서 시작하여 데이터 수집, 피처 엔지니어링, 학습, 평가, 배포의 단계를 거쳐 진행
- 좋은 모델은 알고리즘 자체보다 데이터 품질, 피처 구성, 데이터 분할, 성능 평가 과정에 크게 영향을 받음
- 모델 성능은 학습 단계만이 아니라, 전체 Workflow를 얼마나 체계적으로 수행했느냐에 의해 결정

✓ 좋은 모델은 학습 단계만이 아니라 전체 개발 과정에서 만들어진

Model performance depends on the entire workflow.

How Does a Model Learn?

Learning means reducing prediction error



모델의 학습


- 모델은 입력 데이터로부터 예측값을 만듦
- 예측값은 실제값과 비교하여 오차를 계산
- 모델은 오차를 줄이는 방향으로 수정되며, 이 과정을 반복

✓ Learning = Finding model parameters that reduce prediction error

Prediction → Error → Update → Repeat


Training Is Not Enough

Can the model perform well on unseen data?



- 모델이 학습 과정에서 사용한 데이터
- 여기서 성능이 좋은 것은 출발점일 뿐
- 이것만으로는 실제 성능을 판단할 수 없음

Vs




- 모델이 처음 접하는 데이터
- 실제 예측 상황에 더 가까움
- 여기서도 좋은 성능을 보여야 좋은 모델

- ✓ Good Model = Good Fit + Good Generalization
- ✓ 좋은 모델은 학습 데이터를 잘 설명할 뿐 아니라, 새로운 데이터에도 잘 작동해야 함

Building a Good Model

좋은 모델은 학습만으로 만들어지지 않는다



- 좋은 데이터와 적절한 데이터 분할
- 문제에 맞는 알고리즘 선택과 적절한 학습
- 새로운 데이터에서도 안정적인 성능
- 적절한 평가지표를 통한 신뢰성 있는 평가
- 과소적합·과적합을 피하는 적절한 복잡도

ML 모델 개발 및 최적화

Data Partitioning Strategy

- Resampling
- LOOCV
- K-Fold Cross Validation
- Stratified K-Fold Cross Validation

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Resampling

재표본 추출, 현대 M/L에서 없어서는 안될 도구

Definition

- 훈련 데이터셋에서 반복적으로 표본을 추출하고 모델을 적합하여 적합된 모델에 대해 추가적인 정보를 얻는 과정
- Ex) 반복적으로 추출된 표본에서 회귀적합을 수행하여 적합결과가 다른 정도를 탐색 → 회귀적합의 변동을 추정
- 모델 적합을 한번만 하는 경우에 비해 얻을 수 없는 정보를 얻을 수 있음

[참고] Sampling

- 모집단에서 임의의 표본들을 뽑아내는 것 → 표본추출
- Why? 모집단을 전부 조사하는 것은 불가능. 때문에 샘플링을 이용하여 모집단에 대한 추론을 수행
- 리샘플링을 수행하는 이유는 샘플의 부분집합을 뽑아서 통계량의 변동성 탐색

Cross-validation vs Bootstrap

가장 일반적으로 사용되는 Resampling 접근


교차검증(Cross-validation)

- 주어진 모델링 방법과 연관된 검정오차를 추정하여 성능을 평가하거나 적절한 수준의 유연성(복잡도)을 선택하는데 사용
- 모델평가(Model Assessment), 모델선택(Model Selection)
- 데이터셋을 여러 부분(fold) 으로 나눠서, 훈련(train)과 검증(validation)을 번갈아가며 수행하는 방법, 모든 샘플이 최소 한 번은 검증에 쓰임
- 평가의 안정성, 일반화 성능 추정에 활용


Bootstrap

- 다양하게 활용될 수 있는데, 일반적으로 파라미터 추정의 정확도를 측정하는데 활용
- 원본에서 랜덤 복원추출(재표본화, with replacement) 하여 여러 개의 새로운 데이터셋(bootstrap sample) 생성
- 한 샘플이 여러 번 선택될 수도 있고, 아예 빠질 수도 있음
- 통계량의 분포, 신뢰구간의 추정 → 불확실성 추정

“새로운 데이터에서도 잘 작동할까?”




“추정치가 얼마나 불확실할까?”



데이터 분할

Train, Valid, Test



- 모델을 학습 시키기 위한 데이터셋
- 입력과 정답의 관계를 학습하여 데이터의 패턴을 모델에 반영
- 일반적으로 Train : Test = 8:2 또는 7:3 등으로 분할

**모델 학습을
위한 데이터**

- 학습된 모델을 검증하기 위한 데이터셋
= 모델의 최적의 Hyper-parameter를 찾는 과정
→ Validation 결과를 바탕으로 Hyperparameter 조정


- Training Data를 다시 Train : Validation = 8:2로 분할
- 예) Train Set : Validation Set : Test Set = 6 : 2 : 2

- 최종 모델의 일반화 성능을 평가하기 위한 데이터셋
- 학습 및 Hyperparameter 조정 과정에는 사용하지 않음

**학습에
반영되지 않는
데이터**


Statistical Modeling vs Machine Learning

From hypothesis-driven modeling to performance-driven model selection



- ✓ 통계 기반 접근은 비교적 명확한 가정과 모델을 먼저 설정한 뒤, 데이터를 통해 관계를 추정하고 해석하는데 초점
- ✓ 머신러닝 기반 접근은 여러 후보 모델을 학습하고 예측 성능을 비교하여 더 좋은 모델을 선택하는데 초점

Machine Learning Process



- Test data에 일관된 Scaling 적용은 유의

홀드아웃 검증


전체 데이터를 한 번만 분할

Concept

- 머신러닝 모델의 성능을 평가하는 기본적인 방법 중 하나로, 전체 데이터셋을 두 부분으로 학습용과 검증용으로 활용
- 이를 통해 모델이 새로운 데이터에 대해 얼마나 잘 일반화되는지 평가
- 많이 쓰는 비율은 7:3, 8:2, 9:1
- 데이터셋을 나누고 모델을 평가하는 과정이 간단하고 직관적
- 데이터셋을 한 번만 나누고 평가하므로 계산 비용이 적음
- 한 번의 분할 결과에 성능이 크게 의존 (테스트셋에 특정 클래스가 거의 없으면?)
- 데이터셋이 작을 때, 훈련 세트와 테스트 세트의 분할에 따라 모델의 성능 평가가 크게 달라질 수 있음 → 검증결과의 신뢰성 저하


언제 사용하나?

- 데이터가 충분히 많을 때
- 빠르게 모델 성능을 확인하고 싶을 때
- 실험 초기 단계 (베이스라인 모델, 프로토타이핑 단계)



Cross Validation

교차검증은 학습 데이터셋의 특징을 충분히 반영하여 일관된 성능을 가질 수 있도록 하는 것이 목적임



K-Fold Cross Validation


- 학습 데이터셋을 K개의 부분집합으로 나눔 (K-Fold, K equal sized-Folds)
- K번의 실험을 통해 각각 다른 부분집합을 Validation Set 으로 사용하여 Hyperparameter Tuning
- 모든 부분집합이 한번씩 Validation Set 으로 사용

LOOCV : Leave-One-Out Cross Validation

하나를 남기고, 나머지로 학습한다

- 단 하나의 샘플만 Validation Set으로 사용
- 나머지 $n-1$ 개 샘플로 모델을 학습
- 모든 샘플이 한 번씩 Validation에 사용되므로 총 n 번 학습·평가
- 데이터셋의 규모가 작은 경우 고려
- 거의 전체 데이터를 학습에 사용하므로 학습 데이터 감소에 따른 Bias가 작음
- 데이터 분할 방식이 고정되어 있어 Random Split에 따른 임의성이 없음
- 모델을 n 번 학습해야 하므로 연산 비용이 높음
- 각 Validation Set이 1개 샘플뿐이어서 평가 결과의 Variance가 클 수 있음

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n MSE_i.$$




K-Fold Cross Validation

K개로 나눠 번갈아 검증한다

- 전체 데이터를 K개의 Fold로 분할
- 매번 1개 Fold는 Validation, 나머지 K-1개 Fold는 Train으로 사용
- 이 과정을 총 K번 반복
- 각 반복에서 얻은 성능지표를 평균하여 최종 Validation 성능으로 사용
- 모든 데이터가 한 번씩 Validation에 사용됨
- LOOCV보다 계산 비용이 낮고 실무에서 널리 사용
- 단일 Train/Validation Split보다 평가 결과가 안정적
- 여러 Fold의 결과를 평균하므로 Variance는 상대적으로 낮아질 수 있음
- 일반적으로 K=5 또는 K=10을 많이 사용


$$CV_{(k)} = \frac{1}{k} \sum_{i=1}^k MSE_i.$$



Stratified K-Fold Cross Validation

클래스 비율을 유지하며 K개로 나눈다

- Stratified = 계층화된 분할
- 주로 분류 문제에서 사용
- 각 Fold가 전체 데이터와 유사한 클래스 비율을 유지하도록 분할
- 특정 클래스가 적은 Class Imbalance 데이터셋에서 특히 유용
- 클래스 비율 차이로 인한 평가 성능의 왜곡을 줄이는 데 도움
- 일반 K-Fold보다 분류 문제에서 더 안정적인 Validation 성능을 얻을 수 있음




Cross Validation

Comparison

Method	핵심 특징	장점	고려사항
K-Fold	K개 Fold를 번갈아 검증	계산비용과 평가 안정성의 균형	불균형 분류에서는 Fold별 클래스 비율 차이 가능
Stratified K-Fold	클래스 비율을 유지하며 K-Fold	불균형 분류에서 안정적인 평가	주로 분류 문제에 사용
LOOCV	매번 1개만 검증, n-1개로 학습	거의 모든 데이터를 학습에 활용	계산비용이 높고 평가 Variance가 클 수 있음

Choosing a Cross Validation Method

Selection Guide



- ✓ 일반적인 경우 K-Fold, 불균형 분류에서는 Stratified K-Fold, 매우 작은 데이터에서는 LOOCV를 고려

Think About

관습적인 분할 비율은 언제나 효율적일까?.. 딥러닝의 세계에서 바라보자..

- 권고되는 학습 데이터의 수는 점차 증가
- 디지털화, 데이터의 중요도 인지 등으로 확보 가능한 데이터 수 역시 과거에 비해 늘어나고 있는 추세
- 내가 가진 데이터가 수백만 개라면.. 전통적인 7:3 접근?

Test Data의 목적을 유념하자..

- 더 나은 결과에 대한 갈망, Test Data가 Train Data화 되지 않도록..

학습한 최종 모델을 Real World에 배포해보자, 고려할 수 있는 추가 전략은?

- Validation data, Test data에 담겨있는 추가 패턴을 고려할 수 있는 방법은?
- 시계열에서 최근의 Dynamics를 고려할 수 있는 방법은?
- Statistical Learning에서는 활용 주의

ML 모델 개발 및 최적화

Generalization & Overfitting

- Learning vs Inference
- Learning Curve
- Bias vs Variance

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Learning vs Inference

학습 데이터를 활용하여 모델을 생성하고, 추론 데이터에 적용하여 Y를 예측

학습(Learning)이란?


- Learning or Training or Fitting
- 분류/예측을 위한 모델(함수)을 생성하는 과정
- 학습 데이터는 Target(Y)가 알려져 있음
- 과적합을 방지하기 위해 Validation data 활용

추론(Inference)이란?

- 학습 단계에서 생성한 모델을 새로운 데이터에 적용하는 것
- 추론 데이터는 Target(Y)이 알려지지 않음

일반화(Generalization)란?


- 모델링의 목적은 추론 데이터의 Target(Y) 예측임
- 학습 데이터는 다른 표본에도 적용가능한 일반화 가능한 패턴과 예외적이고 특수한 패턴이 혼재
- 학습 데이터에만 잘 맞는 모델이라면?
- 모델이 학습 데이터의 예외적이고 특수한 패턴까지 학습했다면?



Learning Curve

복잡도가 높아질수록 일반화 성능은 감소



- 어느 지점까지 학습할 것인가?
- 학습이 잘되고 있는 Learning Curve의 모양은?



Under-fitting vs Over-fitting

Bias vs Variance

- High Bias – 정답과 멀리 떨어져 있는 예측값, **Under-fitting**, 너무 단순한 모델
- High Variance – Sample에 따라 Error의 차이가 큼, **Over-fitting**, 너무 복잡한 모델
- Bias와 Variance는 Trade-off
- Cross validation은 적절한 Trade-off 지점을 찾아가는 방법론 중 하나
- Bootstrapping, Regularization



Why use Cross-validation?




Validation Set Approach

Hold-out Validation

- 데이터를 한 번 나누어 Train / Validation으로 사용
- 데이터 분할 방식에 따라 평가 결과가 달라질 수 있음


Cross-validation

- 학습 데이터를 여러 번 나누어 반복적으로 Train / Validation 수행
- 각 검증 결과를 평균하여 더 안정적인 성능 추정



알고리즘 선택

비즈니스 문제를 해결하기 위해 알고리즘을 선택할 때 "모델 운영의 효율성"과 "모델 활용 목적"을 고려하여 최적의 기법을 선택하는 것이 필요함

**B type**
Simple Model로
해결되지 않는
Y값

모델 성능 영향 요인

전체 과정 중 모델링 (알고리즘 적용) 전까지의 과정에 80~90% 노력이 필요

Step	Task	Effort	Importance
모델 설계 (분석 요건 정의)	Target / Feature 정의	15%	45%
	분석 모집단 / 모델 Segmentation 정의		
	분석 방법론 선정		
데이터 준비	분석 Mart 설계	55%	10%
	데이터 추출 / 정제 / 변환		
	Missing / Outlier 처리		
분석 준비	변수 변환 (표준화/ Grouping)	5%	10%
	Sampling (Random/ Over sampling)		
	Data Partition (Out of Data/Time)		
변수 탐색	Feature Extraction (파생변수)	10%	20%
	변수 Selection (안정성 / 예측력)		
Modeling	알고리즘 적용 / 최적화	15%	15%
	모델 평가 / 해석		

85%

ML 모델 개발 및 최적화

Model Evaluation

- Regression – RMSE, RMSE, MAPE
- Classification – Confusion Matrix, AUROC

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Regression Measurement

Intro

- Target Data의 분포를 파악하고, 과제의 목적에 맞는 올바른 Metric을 선정하는 것은 중요
- 성과측정 Metric들의 특징과 장단점에 대한 이해가 동반되어야 함
- Metric의 한계점을 극복하기 위해 복수의 Metric을 활용하기도 함

Purpose


- 실제값(Actual)과 예측값(Predict)의 평균적인 차이를 측정하는 것이 목적
- MAE
- MSE
- RMSE
- MAPE
- ...

MAE(Mean Absolute Error)

Regression Measurement

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|$$

- Target과 Scale이 같아 이해하기 직관적
- Scale에 의존적
Ex) 삼성전자의 주식가격은 60,000원, LG생활건강의 주식가격은 660,000원
주식가격을 예측하는 각각의 모델의 MAE가 10,000 이었다면 동일한 에러율인가?
- 이상치에 상대적으로 덜 민감 → 이상치에 대한 검정에 분리



MSE(Mean Squared Error)


Regression Measurement

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

- Target과 단위가 다름, 해석력이 떨어짐
- Scale에 의존적
- 이상치에 보다 민감하게 반응
잔차를 제곱 → 큰 값에 높은 penalty → 이상치를 바로 파악할 수 있음

MAE vs MSE

- MAE는 오류가 선형적으로 증가, MSE는 지수적으로 증가
- 오류가 1에서 10이 되었다면 MAE는 10배 커짐, MSE는 100배 커짐




Case Study

문제 상황에 적합한 평가지표를 선정해보세요.

과열이 되면 고장나는 공장설비, 기계 내부 온도 예측모형을 개발해야 한다면?

→ 어떤 상황이 치명적일까?



RMSE(Root Mean Squared Error)

Regression Measurement

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$$

- MSE에 제곱근을 취하여 Target과 단위를 동일하게 함으로써, 해석성 확보
- Scale에 의존적
- 이상치에 민감하게 반응하는 것은 MSE와 같지만, 그 정도가 덜함
- 이상치에 의해 MSE가 매우 크게 나오는 경우 연산 속도 느려지는 단점 상쇄

MAPE(Mean Absolute Percentage Error)

Regression Measurement

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{Forecast_i - Actual_i}{Actual_i} \right|$$

- MAE를 비율로 표현, 지표자체가 직관적
Ex) 판매량 예측모형의 MAPE가 5%라면 실제 판매량과 5% 차이
- Scale에 의존적이지 않음, Scale이 서로 다른 모델간 비교에 용이
→ 서로 다른 척도 간의 오차의 크기를 비교할 수 있음
Ex) 각 판매 매장별 매출 예측, 품목별 판매량 예측
- Actual값에 '0'이 있을 경우 계산불가 (zero-division error) 이므로 주의

[참고] MPE (Mean Percentage Error) 의 활용도는?

- 잔차의 (+)(-)값이 상쇄되므로 유의

$$MPE = \frac{100}{n} \sum_{i=1}^n \frac{F_t - A_t}{A_t}$$

MAPE(Mean Absolute Percentage Error)

Regression Measurement

사용시 유의해야 할 때..(Calculation bias)

- 실제값(Actual)이 "0" 이면 계산불가 (zero-division error)
- 실제값(Actual)에 "0" 에 근접한 값이 있는 경우 오류율 왜곡
ex) Actual 0.5, Forecast 2 → MAPE는 300%
Actual 0.2, Forecast 2 → MAPE는 900%
Actual 0.1, Forecast 2 → MAPE는 1,900%

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{Forecast_i - Actual_i}{Actual_i} \right|$$

Solution

- WAPE(Weighted APE)
 - 분모의 실제값(A_i)을 평균(실제값)으로 대체, 실제값이 아닌 데이터의 전체 규모를 반영
- sMAPE(Symmetric MAPE)
 - 분모의 실제값(A_i)을 실제값과 예측값의 평균으로 대체
 - 상하한 값을 제한하여 오류율의 왜곡을 방지
 - 분모 값을 2로 나누어 주면 상하한 값은 0~200%, 나누어 주지 않으면 0~100%가 됨

$$WAPE = \frac{\sum_{i=1}^n |A_i - F_i|}{\sum_{i=1}^n |A_i|} * 100$$

$$sMAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{A_i - F_i}{\frac{|A_i| + |F_i|}{2}} \right|$$

MAPE vs sMAPE

산출 예시

절대 오차가 1인 경우, MAPE는...

- 실제값이 1 이고, 예측값이 2 이면, $MAPE = \left| \frac{1-2}{1} \right| * 100 = 100\%$
- 실제값이 100 이고, 예측값이 101 이면, $MAPE = \left| \frac{100-101}{100} \right| * 100 = 1\%$

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{A_i - F_i}{A_i} \right|$$

절대 오차가 1인 경우, sMAPE는...


- 실제값이 1 이고, 예측값이 2 이면, $sMAPE = \left| \frac{1-2}{\frac{1+2}{2}} \right| * 100 = \frac{1}{1.5} * 100 \approx 66.67\%$
- 실제값이 100 이고, 예측값이 101 이면, $sMAPE = \left| \frac{100-101}{\frac{100+101}{2}} \right| * 100 = \frac{1}{100.5} * 100 \approx 0.995\%$

$$sMAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{A_i - F_i}{\frac{|A_i| + |F_i|}{2}} \right|$$

R-Squared

Regression Measurement

- 결정계수, Coefficient of Determination, R-Squared, R^2 , 설명력
- 적합된 회귀선이 주어진 데이터를 얼마나 잘 설명하고 있는가? = Goodness of Fit의 관점
- 결정계수가 높을수록 독립변수가 종속변수를 많이 설명함으로 해석 (0.0~1.0)
- R Squared 0.6 = 원인변수의 분산이 결과변수의 분산을 60% 설명하고 있다.



$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

SST: Sum of Squares Total
SSR: Sum of Squares Regression
SSE: Sum of Squares Error

Case Study

Customized Metric

객단가가 비교적 큰 제품을 생산/유통하는 업체 A는 +2주 뒤의 수요예측을 통해 재고 관리를 진행하고 있다.

신뢰할 수 있는 정확한 예측값을 제공하면 가장 좋지만..

→ Over-estimate vs Under-estimate 어떤 상황이 치명적일까?



Classification Measurement

Intro

- 확률을 예측 → 임계치에 따른 분류
- 모델에서 예측한 확률이 특정치 이상일 때 True라고 판단
- 임계치 = Threshold = Cut-off
- 대부분의 평가지표는 모델의 일부분 성능에 대한 단편적인 부분만을 반영함
- 평가지표를 적절하게 사용할 수 없다면 모델 자체의 문제를 발견할 수 없고 잘못된 결론에 도달 할 수 있음

Purpose

- 모델이 실제 데이터를 얼마나 잘 분류하는지 측정
- 분류 모델이 적용되는 도메인, 비즈니스에 따라 적절한 성능지표는 달라짐에 유의

Case Study

다음의 예측 모형에 대해 논의해 보세요.

병원에서 개개인의 진료내역을 바탕으로 암진단 예측 모형을 개발했습니다.

모형의 Test를 위한 표본은 100명입니다. (정상 95명, 암환자 5명)

모형의 Test 결과는 다음과 같습니다.

- 정상 95명에 대해 정상(0) Signal 95번 / 암(1) Signal 0번
 - 암환자 5명에 대해 정상(0) Signal 5번 / 암(1) Signal 0번
- Accuracy = $95/100 = 95\%$

Confusion Matrix

실제값과 예측값의 비교 분류표

ConfusionMatrix		Actual	
		Positive	Negative
Predict	Positive	TP	FP
	Negative	FN	TN

- **TP** : Actual Positive – Pred Positive
- **TN** : Actual Negative – Pred Negative
- **FP** : Actual Negative – Pred Positive (Type I Error)
- **FN** : Actual Positive – Pred Negative (Type II Error)

- **TP & TN** : Actual 값과 같은 값으로 예측
- **FP & FN** : Actual 값과 다른 값으로 예측 → 오분류 (Confuse)

- **Accuracy** = $\frac{TP+TN}{TP+FP+FN+TN}$

- **Error Rate** = $\frac{FP+FN}{TP+FP+FN+TN}$

※ 클래스간 불균형이 크지 않은 경우 유용

Confusion Matrix

실제값과 예측값의 비교 분류표

- 모델이 분류한 결과의 True/False수를 확인할 수 있도록 표현한 행렬
- Ex) 100명의 환자를 대상으로 암 진단 예측을 수행 (암일 경우 Positive Signal)

Confusion Matrix		Actual		Total
		Positive	Negative	
Predict	Positive	TP (40)	FP (20)	60
	Negative	FN (30)	TN (10)	40
Total		70	30	100

Accuracy

- $TP + TN / TP + TN + FN + FP$
- $40 + 10 / 100 = 0.5$

Precision(정밀도)

- $TP / TP + FP$
- $40 / 40 + 20 = 0.67$
- 모델이 출력한 양성(Positive) 신호의 정확도
- Positive 신호가 부정확할 경우 큰 영향을 주는 경우 중요
- ex. 금융사기

Recall(재현율) = Sensitivity(민감도) = TPR(True Positive Ratio)

- $TP / TP + FN$
- $40 / 40 + 30 = 0.57$
- Actual Positive인 샘플 중 모델이 Positive로 분류한 비율 (커버리지)
- Positive를 분류해내지 못하는 것이 중요한 영향을 주는 경우 중요
- ex. 질병예측

Precision과 Recall은 Trade-off !

확실할 때만 예측하면 Precision 증가,
조금만 증상이 있어도 예측하면 Recall이 증가

Confusion Matrix

실제값과 예측값의 비교 분류표

- 모델이 분류한 결과의 True/False수를 확인할 수 있도록 표현한 행렬
- Ex) 100명의 환자를 대상으로 암 진단 예측을 수행 (암일 경우 Positive Signal)

Specificity와 Fall-out은 정반대 개념!
Specificity + Fall-out = 1

Confusion Matrix		Actual		Total
		Positive	Negative	
Predict	Positive	TP (40)	FP (20)	60
	Negative	FN (30)	TN (10)	40
Total		70	30	100

Specificity (특이도)

- $TN / TN + FP$
- $10 / 10 + 20 = 0.33$
- Actual Negative중 음성(Negative)으로 분류한 비율
- 음성신호의 커버리지

Fallout(위양성률) = 1 - Specificity = FPR(False Positive Rate)

- $FP / TN + FP$
- $20 / 10 + 20 = 0.67$
- Actual Negative중 양성(Positive)으로 잘못 분류한 비율

Accuracy

- $TP + TN / TP + TN + FN + FP$
- $40 + 10 / 100 = 0.5$

Precision-Recall Trade-off

사과를 분류하는 경우라면...

- Precision (정밀도) : 사과를 사과라고 예측한 것 중 실제로 사과가 얼마나 많은지..
- Recall (재현율) : 실제로 사과인 것 중 모델이 사과라고 예측한 것이 얼마나 되는지..

예를 들어,

- 10개를 사과라고 예측했는데, 그 중 8개가 사과라면 → Precision 80%
- 실제 사과가 10개 있는데, 그 중 6개를 사과라고 예측했다면 → Recall 60%

모델 성능 관점에서 1가지 성능만 낮다면...

- Recall 90%, Precision 10% → 실제 사과 중 90% 맞추었지만, 예측한 것 중에서는 10%만 맞춤
 - Recall 10%, Precision 90% → 실제 사과 중 10%만 맞추고, 사과라고 예측한 것 중 90%는 맞춤
- 안정적으로 학습되었다고 보기 어려움
- 2가지 성능이 모두 안정적인 때, 전체 모델 성능을 확인할 수 있음

F1 Score

Classification Measurement

단편적인 성능이 아닌 종합적으로 보기 위한 노력들

- Precision과 Recall의 조화평균 (역수의 산술평균의 역수)
- 불균형한 데이터에서 잘 동작

$$\text{F1 Score} = \frac{2}{\frac{1}{\text{ReCall}} + \frac{1}{\text{Precision}}} = 2 \times \frac{(\text{Precision} \times \text{Recall})}{(\text{Precision} + \text{Recall})}$$


조화평균(harmonic mean)을 사용하는 이유

- Precision, Recall 둘 중 하나가 극도로 낮을 때에도 지표에 그것이 잘 반영되도록 하기위해
- 두 지표 모두를 균형 있게 반영하기 위해
- Ex) Precision 1, Recall 0.01 경우
 - 산술평균 = $(1+0.01)/2 = 0.505$ → 절반은 맞추는 모형일까?
 - 조화평균 = $2 * (1*0.01) / (1+0.01) = 0.019$

ROC Curve (Receiver Operating Characteristic Curve)

Classification Measurement

- 다양한 임계값 설정에서 분류 모델의 성능을 평가하기 위해 사용
- ROC 커브가 좌상단에 붙을 수록 더 좋은 분류기를 의미
- ROC 곡선은 클래스 분포의 변화에 불변



TPR(True Positive Ratio) = Recall(재현율) = Sensitivity(민감도)

- Actual Positive인 샘플 중 모델이 Positive로 분류한 비율 (커버리지)

FPR(False Positive Rate) = Fallout(위양성률) = 1- Specificity


- Actual Negative중 양성(Positive)으로 잘못 분류한 비율

단편적인 성능이 아닌 종합적으로 보기 위한 노력들

어떻게 그리나?

- 임계치(Threshold)를 높은 수준에서 낮은 수준으로 이동하면서 각 임계치마다 점(x:FPR, y:TPR)을 그리고 이어줌


Threshold	FPR (x 축)	TPR (y 축)
0.1	0.8	1.0
0.2	0.6	1.0
0.3	0.4	1.0
0.4	0.4	0.6
0.5	0.2	0.6
0.6	0.2	0.4
0.7	0.0	0.4
0.8	0.0	0.4
0.9	0.0	0.2



AUROC (Area Under ROC)


Classification Measurement

- ROC Curve 아래 면적을 통해서 모델성능을 하나의 수치로 정량화
- 샘플의 분포에 변화가 생기더라도 급격한 변화를 보이지 않음
- 안정적으로 모델 성능을 테스트할 수 있음



단편적인 성능이 아닌 종합적으로 보기 위한 노력들

[참고] PR Curve




AUROC						
< 0.5	0.5	0.6	0.7	0.8	0.9	1.0
Something Wrong	Random	Poor	Mediocre	Good	Excellent	Perfect

Log Loss

Classification Measurement

- 55%의 확률로 암환자를 맞춘 경우와 99%의 확률로 암환자를 맞춘 경우를 동일하게 취급해야 할까?
- 운이 좋아서 맞춘 경우 vs 강한 확신(실력)으로 맞춘 경우
- 예측값을 얼마나 확신하는지를 평가에 반영하는 방법은 없을까?
- "맞춘 결과만으로 성능을 평가하지 않고, 예측의 확신(확률)을 반영하여 평가하고 싶다" = Logloss의 아이디어



- 100%확률(확신)로 분류했다면 $\rightarrow -\log(1) = 0$
- 80%확률(확신)로 분류했다면 $\rightarrow -\log(0.8) = 0.22$
- 60%확률(확신)로 분류했다면 $\rightarrow -\log(0.6) = 0.51$
- 40% 확률(확신)로 분류했다면 $\rightarrow -\log(0.4) = 0.91$
- 20% 확률(확신)로 분류했다면 $\rightarrow -\log(0.2) = 1.6$

확률(확신)이 낮을 수록 Logloss값(패널티)은 기하급수적으로 증가

ML 모델 개발 및 최적화

Why Linear Models Still Matter

왜 선형 모형은 여전히 중요한가?

- Linear Models Depend on Assumptions
- 더 좋은 추정량을 얻으려면
- Model Complexity & Robustness

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Linear Model Is More Than a Line

회귀모형은 평균적인 관계와 오차 구조를 함께 표현한다.

회귀 방정식

- N개 데이터 Sample을 대표하는 하나의 Regression Line이 있을 때 X와 Y의 평균적인 관계

$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i$$

- 실제 모집단의 Y에 대해서 생각하면..

$$Y_i = \hat{Y}_i + \hat{e}_i$$

- Y_i 를 설명할 때 X_i 에 의해서 설명이 되는 부분과 설명이 되지 않는 부분으로 나눌 수 있음

$$Y_i = \hat{\beta}_1 + \hat{\beta}_2 X_i + \hat{e}_i$$

- 모집단 회귀 방정식 → 우리가 보고자 하는.. 연구 대상으로 삼고 싶어하는 세상(모집단)에 대한 정의와 가정이 필요
 - 표본이 소득(x)과 소비(y)의 관계를 나타낸다면, 모집단 내의 모든 사람이 $B_1 + B_2 X_i$ 형태로 소비하는 것은 아님
 - 이 함수에는 모집단의 특성이 반영되어야 함

$$Y_i = \beta_1 + \beta_2 X_i + e_i$$

Linear Models Depend on Assumptions

단순한 모델은 강력하지만, 가정을 확인하지 않고 사용해서는 안 된다.

Assumption



$$Y_i = \beta_1 + \beta_2 X_i + e_i \quad (i = 1, 2, \dots, n)$$

$$\text{Assumption1. } E(e_i) = 0, \quad \forall_i$$

$$\text{Assumption2. } E(e_i^2) = \text{Var}(e_i) = \sigma^2, \quad \forall_i$$

$$\text{Assumption3. } E(e_i \cdot e_j) = \text{Cov}(e_i \cdot e_j) = 0, \quad i \neq j$$

- 교육수준(x) 와 소득(y)을 예시로 생각해보자
- e_i 의 기대값이 0이라는 것은 평균보다 많이 소득을 얻거나 적게 얻을 수 있지만, 모두 합산했을 때 이들이 상쇄되어 그 합이 0이라는 것



Linear Models Depend on Assumptions

가정이 현실과 맞지 않으면 추정과 예측의 신뢰성이 떨어질 수 있다

Assumption


$$Y_i = \beta_1 + \beta_2 X_i + e_i \quad (i = 1, 2, \dots, n)$$

Assumption1. $E(e_i) = 0, \quad \forall_i$

Assumption2. $E(e_i^2) = Var(e_i) = \sigma^2, \quad \forall_i$

Assumption3. $E(e_i \cdot e_j) = Cov(e_i \cdot e_j) = 0, \quad i \neq j$

- 교육수준이 상관없이, 즉 x_i 가 어떤 값을 가지더라도 e_i 의 분포는 똑같다는 것(등분산)
- 교육수준 16년일 때의 평균소득이 500만원이고 약 90%사람들이 500만원 +- 50만원에서 소득을 얻는다면..
- 교육수준 22년일 때의 평균소득이 800만원이라면 약 90%사람들이 800만원 +- 50만원에서 소득을 얻는다는 의미
- 현실적인가?



Linear Models Depend on Assumptions

단순한 모델은 강력하지만, 가정을 확인하지 않고 사용해서는 안 된다.

Assumption

$$Y_i = \beta_1 + \beta_2 X_i + e_i \quad (i = 1, 2, \dots, n)$$

$$\text{Assumption1.} \quad E(e_i) = 0, \quad \forall_i$$

$$\text{Assumption2.} \quad E(e_i^2) = \text{Var}(e_i) = \sigma^2, \quad \forall_i$$

$$\text{Assumption3.} \quad E(e_i \cdot e_j) = \text{Cov}(e_i \cdot e_j) = 0, \quad i \neq j$$


- 서로 다른 e_i 들 사이에는 아무런 관계가 없음을 의미
- 자기상관(Auto Correlation, Serial Correlation) 이 없다는 의미와 동일

더 좋은 추정량을 얻으려면?


불편 추정량(Unbiased estimator)

- 불편추정량은 반복해서 표본을 뽑아 추정했을 때, 추정값의 평균이 실제 모수와 일치하는 추정량
- 말그대로 편향이 없는, 치우침이 없는 정확한 추정량이라는 것
- 좋은 추정량은 낮은 Bias와 낮은 Variance를 함께 고려해야 함
- Unbiased = 평균적으로 맞다 / Low Variance = 표본이 바뀌어도 덜 흔들린다

$$Y_i = \hat{\beta}_1 + \hat{\beta}_2 X_i + \hat{e}_i$$



Var(hat{B}_2) 가 작은 경우



Var(hat{B}_2) 가 큰 경우

Proof of Var(hat{B}_2)

$$Y_i = \hat{\beta}_1 + \hat{\beta}_2 X_i + \hat{e}_i$$

$$Var(\hat{\beta}_2) = E[\hat{\beta}_2 - E(\hat{\beta}_2)]^2$$

$$= E[\hat{\beta}_2 - \beta_2]^2$$

...

$$= \frac{\frac{\sigma^2}{n-1}}{Var(X)}$$

$Var(e_i) = \sigma^2$,
n = sample count

복잡한 모델이 항상 더 좋은 것은 아니다

Model Complexity & Robustness


강건성(Robustness)

- 다양한 상황과 예상하지 못한 데이터 변화에서도 안정적인 예측 성능을 유지하는 능력
- 노이즈나 입력값의 작은 변화에 대해 출력값이 과도하게 변하지 않는 특성

모형의 복잡도와 강건성

- 지나치게 복잡한 모델은 데이터의 작은 변화에도 민감해질 수 있음
- 단순한 모델은 상대적으로 과적합 위험이 낮고 안정적인 일반화를 제공할 수 있음
- 선형모델은 구조가 단순하고 설명가능성이 높아 강건성과 해석가능성이 중요한 업무에서 여전히 유용

✓ *Simple Models Can Be More Robust*



수고하셨습니다.

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.