



데이터분석 및 AIOps

ML 모델 개발 및 최적화

Day2. Optimizing & Understanding Models

2026.07

전임교수 : Byung-sun, Park

parkbs@sk.com

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.



Day1

좋은 모델을 어떻게 만들고 평가할 것인가?

Building & Evaluating Models

Day2

모델 성능을 어떻게 최적화하고 신뢰할 수 있을까?

Optimizing & Understanding Models



day2

1. Model Performance Optimization
2. Hyperparameter Optimization
3. Ensemble Strategy
4. Explainable AI (XAI)
5. Model Monitoring & Drift

ML모델 개발 및 최적화


Model Performance Optimization

- Where Can We Improve Model Performance?
- After Deployment

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Model Performance Optimization

How can we make a good model even better?



- ✓ Baseline Model을 통해 현재 모델의 성능 수준과 비교 기준을 확보했다면, 다음 단계는 다양한 최적화 방법을 적용해 더 나은 모델을 찾는 것
- ✓ 모델 최적화는 개선하고, 비교하고, 선택하는 반복적인 과정

Where Can We Improve Model Performance?

성능 향상은 모델뿐 아니라 데이터와 학습 전략을 함께 개선하는 과정

Better Data

모델이 학습하기에 충분히 좋은 데이터인가?

- Data Quality — 결측치, 이상치, 오류, Noise..
- Feature Engineering — 데이터 변환, 유용한 변수 생성·선택..
- Class Imbalance — 불균형 데이터 처리

Better Model

문제에 적합한 모델을 사용하고 있는가?

- Model Selection — 적합한 알고리즘 선택
- Hyperparameter Optimization — 최적의 모델 설정 탐색
- Regularization — 과적합 제어 및 일반화 성능 향상..

Better Strategy

더 효과적인 학습·검증 전략은 없는가?


- Ensemble — 여러 모델의 강점 결합
- Sampling Strategy — 효과적인 데이터 구성
- Validation Strategy — 안정적인 성능 검증

Optimization Is More Than Performance

가장 높은 성능 점수를 가진 모델이 항상 최선의 모델은 아니다


관점	핵심 질문
Performance	예측 성능이 충분히 좋은가?
Generalization	새로운 데이터에서도 성능이 유지되는가?
Robustness	데이터 변화나 노이즈에도 안정적인가?
Interpretability	모델의 판단을 이해하고 설명할 수 있는가?
Efficiency	시간·비용·자원을 효율적으로 사용하는가?

- ✓ 모델 최적화는 단순히 점수를 높이는 것이 아니라,
실제 문제에 맞는 최적의 균형점을 찾는 과정



After Deployment

좋은 모델은 배포 시점뿐 아니라 운영 중에도 신뢰할 수 있어야 함



모델의 판단을 이해한다

- Feature Importance
- SHAP

모델의 상태를 확인한다

- Model Performance
- Prediction Distribution

환경의 변화를 탐지한다

- Data Drift
- Concept Drift
- Prediction Drift

필요하면 모델을 개선한다

- Retraining
- Model Replacement

ML모델 개발 및 최적화


Hyperparameter Optimization (HPO)

- Parameter vs Hyperparameter
- Grid search
- Random search
- Bayesian search

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Parameter vs Hyperparameter

Hyperparameter는 모델 외부에서 분석가가 직접 설정해 주는 값



Parameter

- 모델 내부에서 주어진 데이터로부터 결정
Regression의 회귀계수(coefficient)
D/L의 가중치(weight) ..
- 작업자에 의해 조정되지 않음

Hyperparameter

- 모델 외부에서 작업자가 직접 세팅해 주는 값
D/L의 Learning rate
Tree Model의 max depth..
- 학습 데이터에 의해 변경되지 않음
- Heuristics 혹은 반복된 실험을 통해 결정

최적의 Hyperparameter 어떻게 찾을까?

XGBoost 주요 하이퍼 파라메타

Hyper-parameter	Default	Range	Description
n_estimators	100	[1, ∞]	앙상블에 포함될 트리(모델)의 개수
learning_rate (eta)	0.3	[0, 1]	각 트리의 기여도
max_depth	6	[0, ∞]	트리의 최대 깊이. 0은 깊이 제한 없음을 의미
min_child_weight	1	[0, ∞]	노드 분할에 필요한 최소 가중치 합, min_sample_leaf와 유사
subsample	1	[0, 1]	각 트리 훈련 시 사용할 데이터 샘플의 비율, ex: 0.8 → 80%만 사용
colsample_bytree	1	[0, 1]	각 트리 생성 시 사용할 특성(피쳐)의 비율
min_split_loss(gamma)	0	[0, ∞]	노드 분할을 위한 최소 손실 감소량
colsample_bylevel	1	[0, 1]	각 레벨(깊이)에서 사용할 특성의 비율
lambda	1	[0, ∞]	가중치에 대한 L2 규제(정규화항), 가중치를 부드럽게 만들어 과적합 억제
alpha	0	[0, ∞]	가중치에 대한 L1 규제(정규화항), 일부 가중치를 0으로 만듦
early stopping	None	[0, ∞]	학습함수의 인자로 validation set의 성능이 N번 연속으로 향상되지 않으면 학습을 중단

Motivation of HPO

최적의 Hyperparameter를 얻기 위해 점차 증가하는 연산비용 문제를 해결하기 위해 HPO가 태동

HPO process by human



Problem

- HPO는 최적의 모델을 얻기 위해 Best Hyperparameter를 역으로 찾는 과정
- Hyperparameter 재조정에 따른 Model 재학습 등 반복적인 탐색과정으로 많은 시간과 비용이 소요되는 절차
- 데이터 양이 많아질수록, 모델의 복잡도가 증가할수록 연산비용은 급격히 증가
- 대용량 학습 데이터를 사용하는 거대모델의 등장, 학습을 결정하는 Hyperparameter수의 늘어나는 경향

Grid Search



Concept

Hyperparameter의 탐색 범위를 제한한 후 모든 조합을 순차적으로 비교 탐색

- {Min, Max, 간격}을 통해 탐색범위를 제한
- 탐색할 Hyperparameter 조합들을 Grid에 보관
- Grid의 범위와 하이퍼 파마메타수가 늘어날수록 연산량이 기하급수적으로 증가

[Hyper-parameter 탐색범위 제한 예시]


- Parameter A : {'Entropy', 'Gini' }
- Parameter B : Range(6,20,2) $\rightarrow$ {6, 8, 10, 12, 14, 16, 18, 20}
- ..



Grid Search

Pros & Cons

- 구성이 쉽고 직관적인 방법
- 작업자가 원하는 탐색 범위를 정확하게 비교 분석 할 수 있음
→ 작업자가 숙련된 Data Scientist여서 적절한 탐색범위를 제한할 수 있다면 효율적
- 느리고 느리고 느리다!
- 균일한 간격으로 탐색하기 때문에 최적의 해를 지나칠 수 있음
- 모든 구간을 전부 탐색하기에 비효율적



Random Search

Concept


Hyperparameter의 탐색 범위를 제한한 후 설정된 횟수만큼 임의의 조합을 탐색

- 균일 간격 탐색이 아니라 Random 탐색을 통해 최적해를 발견할 가능성을 높임
- 탐색할 임의의(Random) 조합 수를 직접 설정하기에 불필요한 반복 탐색 감소

Pros & Cons

- 탐색범위가 넓을 경우 일반화된 결과가 나오지 않음 (할 때마다 결과 상이)
- 성과가 설정하는 탐색 횟수에 의존적일 수 있음

“성능이 가장 높은 최적해로 점차 찾아가는 기법이 아니라
단순히 탐색 시행을 통해 비교 분석해서 최적해를 찾아가는 기법”




[Grid Search vs Random Search]

Bayesian Search

Bayesian Inference ?

- 새로운 관측이 들어올 때마다 믿음을 업데이트
- 처음에는 알고 있는 정보에 기반해 사전 믿음(Prior) 을 가짐
- 새로운 관측값이 들어오면, 그 증거를 반영해 믿음을 업데이트
- 업데이트된 결과는 사후 분포(Posterior) 가 됨
- 새로운 데이터가 들어올 때마다 이 과정을 반복



Bayesian Search

Concept


이전 시행의 정보로부터 최적의 성과를 낼 수 있을 것 같은 Hyper-parameter를 추론해 보자.

- 이전 시행의 정보 = Hyperparameter set + Validation Score
- 지금까지의 탐색 결과를 학습해서 다음 후보를 선택
- 성능이 좋을 가능성이 높은 영역을 우선 탐색
- 적은 횟수의 시도로 좋은 Hyperparameter를 찾는 것을 목표로 함

Bayesian Search

How Bayesian Search Works

- 이전 탐색 결과를 바탕으로 다음 후보를 더 똑똑하게 선택한다
- 각 시행에서 얻은 Hyperparameter 조합과 성능을 바탕으로, 성능이 좋을 가능성이 높은 영역을 추정




Bayesian Search

How Bayesian Search Works

- 이전 탐색 결과를 바탕으로 다음 후보를 더 똑똑하게 선택한다
- 각 시행에서 얻은 Hyperparameter 조합과 성능을 바탕으로, 성능이 좋을 가능성이 높은 영역을 추정

 After 5 Steps




Bayesian Search

How Bayesian Search Works

- 이전 탐색 결과를 바탕으로 다음 후보를 더 똑똑하게 선택한다
- 각 시행에서 얻은 Hyperparameter 조합과 성능을 바탕으로, 성능이 좋을 가능성이 높은 영역을 추정




After 7 Steps



Bayesian Search

How Bayesian Search Works : Full Process



Bayesian Search

Pros & Cons

- 이론적 근거를 기반으로 이전 탐색 결과를 활용하여 유망한 영역을 우선적으로 탐색
 - Grid / Random Search보다 적은 시도로 좋은 Hyperparameter 조합을 찾을 가능성이 높음
 - Exploitation(활용)과 Exploration(탐색)의 균형을 통해 효율적으로 최적값 탐색
 - 평가 비용이 큰 모델에서 효율적인 HPO 전략이 될 수 있음
-
- 이전 탐색 결과를 순차적으로 반영하는 Sequential Approach
 - Grid / Random Search에 비해 병렬화가 제한적
 - 각 시행 결과를 반영해 다음 후보를 결정하므로 탐색 자체의 오버헤드가 존재
 - 단순하거나 탐색 공간이 작은 문제에서는 Grid / Random Search가 더 실용적일 수 있음

Bayesian Search-TPE


고차원 공간에서 효율적인 TPE(Tree-Structured Parzen Estimator)

Concept

더 큰 탐색 공간에서도 효율적으로 탐색할 수 있는 방법은?

좋았던 시도와 나빴던 시도를 나누어, 다음 후보를 더 똑똑하게 선택한다.


- 처음에는 여러 Hyperparameter 조합을 시도해 성능을 수집
- 성능이 좋은 Trial과 좋지 않은 Trial을 두 그룹으로 나눔
- 각 그룹에서 Hyperparameter가 어떤 값에 몰려 있었는지 분포를 추정
- 좋은 Trial에서 자주 나타나고, 나쁜 Trial에서는 덜 나타나는 값을 다음 후보로 우선 선택.. 저성능일 확률이 낮으면서 고성능일 확률이 높은..
- 이 과정을 반복하며 유망한 영역에 탐색을 집중



Bayesian Search-TPE


고차원 공간에서 효율적인 TPE(Tree-Structured Parzen Estimator)

1. Objective function and observed trials (minimization problem)



Split trials by performance

2. Parzen density estimates over hyperparameters



ML모델 개발 및 최적화


Ensemble Strategy

- Bagging
- Boosting
- Stacking(Meta Ensemble)

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Ensemble

여러 개의 Weak Model을 조합/결합하여 최적의 모델을 만드는 것



Ensemble

아쉬운 예측력의 보완책

약한 학습기(weak learner)도 모이면 강한 학습기(strong learner)가 된다.

- 왜 하나의 모델만 사용해야 하는가?
- 같은 데이터로 같은 문제를 풀기위해 여러가지 방법을 사용해 보자
 - Ex) Input이 들어왔을 때 여러 분류기로 예측하고 합산(평균)값을 취하자
- 어떻게 learner를 구성하고, 어떻게 합산하느냐, 어떻게 일반화 하느냐..

Ensemble


앙상블의 핵심 아이디어

다수의 약한 학습기의 결합을 통해 우수한 일반화 성능을 얻는다

- 과적합을 줄이면서 예측성능을 향상시키고자 하는 방법론
- 객체 학습기는 일정 수준의 정확성이 있어야 하고 동시에 다양성도 가져야 함
 - 랜덤 학습기(50% accuracy) 보다는 나은 성능을 보여야 함
 - 기초 학습기 사이의 오차가 상호 독립적이면 좋음
 - 실질적으로 객체 학습기의 정확성과 독립성(다양성)은 trade-off
 - Why? 같은 학습 데이터를 사용하기 때문

Ensemble

아쉬운 예측력의 보완책, Bagging



✓ 한번에 전체 Tree를

Parallel하게 학습

✓ 복잡한 모델을 평균 내는 개념

Concept


- 샘플링을 통해 얻은 여러 모델의 결과값을 결합
- Regression은 avg. / Classification은 Voting
- Decision tree의 높은 Variance을 줄여줌
- 예측값들이 유사해지는 단점

Random Forests

- Sub Model들을 어떻게 decorrelating 하게 만들까?
- 기본적으로 Bagging과 유사
- 각각의 Sub model에서 m개의 Random한 Predictors만 고려
- 예측값들이 유사해지는 단점을 극복
- 모델의 Variance는 줄었지만, under fitting 이슈

Ensemble

아쉬운 예측력의 보완책, Boosting



✓ Tree를 Sequential하게 학습

✓ 단순한 모델을 더해가는 개념

Concept

- 이전 Sub Model의 부족한 성과를 다음 Sub Model에 반영하여 순차적으로 개선해 나가는 방식
- 일반적으로 예측력(성능)을 향상시키나 Overfitting 이슈

Gradient Boosting



- 이전 Sub Model의 error를 다음 Sub Model에서 학습한다면? (residual fitting)
- 긴 처리속도와 Overfitting 이슈
- XGBoost(+일반화 튜닝)
- Light GBM(+computational cost reduce)

Ensemble

Gradient Boosting의 직관

Boosting improves performance by repeatedly correcting what previous models got wrong


- 이전 모델의 Residual / Error를 다음 모델이 학습
- 각 단계에서 Loss를 줄이는 방향으로 새로운 모델을 추가
- Learning Rate와 Number of Trees의 균형이 중요



Base Ensemble


여러 개의 개별 모델들의 예측을 직접적으로 결합하여 최종 예측을 만들어내는 방식

【 Voting 】




- 보통 서로 다른 알고리즘이 같은 학습 데이터셋에 대해 학습하여 예측
- Voting 방법
 - ① Hard Voting (Majority Vote)
 - : 다수의 학습모델의 예측값으로 결정 (4개 중 3개 모델이 같은 값으로 예측)
 - ② Soft Voting
 - : 모델별 예측 확률을 반영하여 확률이 가장 높은 것으로 결정 (Average, Weighted Sum)

【 Bagging 】



- 보통 같은 알고리즘의 여러 개 모델로 학습
- 각 모델에 할당된 학습 데이터는 여러 번 복원 추출하는 Random Sampling
→ Bootstrapping 분할방식, Bootstrap Sample
- 개별적인 예측 결과를 투표(Voting) 하여 최종 예측 결과 산정
- 대표 알고리즘 : randomForest

【 Boosting 】




- 보통 같은 알고리즘의 여러 개의 모델이 순차적으로 학습 하면서 이전 오류를 보완
- 대체적으로 예측 성능이 뛰어나 Ensemble Modeling 주도
- 대표 알고리즘: Adaptive Boosting, Gradient Boost(XGBoost, LightGBM)

Stacking: Meta Ensemble


메타 앙상블은 기본 모델들의 예측을 독립변수로 활용하여 최종 예측을 수행하는 기법으로 Overfitting 이슈를 신중하게 고려해야 함

ML
기본
방법론



- Train Set (X_Train, y_train)을 사용하여 모델 학습
- Cross Validation 적용하여 Hyperparameter Tuning
- 학습 모델에 X_test 적용하여 예측
- y_test와 예측값을 비교하여 모델 성능 평가

메타
앙상블
방법론



[기본 방법론]

- 각 모델별로 Train Set을 사용하여 각각 모델 학습
- Cross Validation 적용하여 Hyperparameter Tuning
- 각 학습 모델에 X_test 적용하여 예측 (각 모델별 예측 결과)

[메타 앙상블 방법론]

- **각 모델별 예측결과를 독립변수로 정의**
- 최종 모델에 Train Set (y_train_예측값, y_train) 적용하여 최종 학습
- 최종 학습 모델에 y_test_예측값 적용하여 예측 및 모델 성능 평가

Stacking process


보다 똑똑하게 모델을 결합하는 방법은?

Key Idea

- 앙상블 결합시 보팅(Voting) 등은 heuristic한 규칙, 모델 조합의 최적화도 학습 문제
- 데이터로부터 조합 규칙을 학습하자.. Data-driven combination

1단계 : Base learners

- 여러 모델(예: 로지스틱, 랜덤포레스트, XGBoost 등)을 학습
- 각 모델이 예측한 값을 모아서 "메타 데이터셋" 생성



2단계 : Meta learners

- 1단계에서 얻은 예측값들을 feature로 사용해 학습
- 최종 예측을 담당

Stacking에서 Cross-Validation은 왜 중요할까?

데이터 누수(Data Leakage)의 방지, 필수 Technique

Problem

- 만약 Base learners를 학습 데이터로 훈련 → 같은 데이터에 대해 예측값을 뽑아 Meta learner 훈련 → 이미 정답을 본 모델의 예측을 메타 모델이 학습 → 과적합 발생

Solution


- 교차검증 기반 Out-of-Fold (OOF) Prediction
- (1) 학습 데이터를 K-fold로 나눔
- (2) fold k를 검증셋으로 두고, 나머지 fold로 Base learners 학습
- (3) k개의 검증 fold에 대한 Data set 보관 (Base learners 예측값 + y) → 훈련에 사용되지 않은 Base learners 모델의 예측값이 확보됨
- (4) 이 Data set으로 메타모델 학습
- 메타 모델이 Unseen 데이터에 대한 base 모델 예측을 학습하므로, Data Leakage에 의한 과적합을 피할 수 있음
- 교차검증(OOF predictions)을 사용하지 않으면 성능이 과대평가되고 실제 일반화 성능은 떨어짐

Case Study

Ensemble은 여러 개의 Weak Model을 조합/결합하여 최적의 모델을 만드는 것

Ensemble은 언제 고려해야 할까?

- Used Car Price Prediction Example
- Lift Chart를 통해 구간별 성과를 분석
- Base Model을 구축했지만 구간별 예측력에 편차가 있음




Case Study

Ensemble은 여러 개의 Weak Model을 조합/결합하여 최적의 모델을 만드는 것


Ensemble은 언제 고려해야 할까?

- Used Car Price Prediction Example

[Model A vs Model B Ensemble 검토]



[Model A vs Model C Ensemble 검토]



Case Study

앙상블은 만능일까?

최종모델로 앙상블 모델을 사용했습니다.

20개의 XGBoost모델, 5개의 랜덤 포레스트, 6개의 랜덤결정트리, 3개의 규제가 적용된 그리디 포레스트, 3개의 로지스틱 회귀, 5개의 인공신경망, 3개의 Elastic Net 모델과 1개의 SVM모델로 구성됩니다.

- 캐글 우승자 인터뷰中

ML모델 개발 및 최적화

Explainable AI (XAI) **: Understanding Model Decision**

- Why XAI?
- Permutation Importance
- SHAP

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Why XAI?


M/L 에서의 모델 해석력

모델을 해석한다는 것의 의미

- Modeling을 통해서 해결해야하는 많은 문제, 높은 예측력만 보이면 되는 문제도 있지만..
- 현실의 많은 문제는 Why에 관심

OLS Regression Results							
Dep. Variable:	MEDV	R-squared:	0.727				
Model:	OLS	Adj. R-squared:	0.722				
Method:	Least Squares	F-statistic:	132.0				
Date:	Wed, 26 Apr 2023	Prob (F-statistic):	1.01e-132				
Time:	18:05:24	Log-Likelihood:	-1511.5				
No. Observations:	506	AIC:	3045.				
Df Residuals:	495	BIC:	3092.				
Df Model:	10						
Covariance Type:	nonrobust						
	coef	std err	t	P> t	[0.025	0.975]	
const	40.0360	4.961	8.070	0.000	30.289	49.783	
CRIM	-0.1185	0.033	-3.555	0.000	-0.184	-0.053	
ZN	0.0368	0.014	2.692	0.007	0.010	0.064	
CHAS	3.1323	0.872	3.593	0.000	1.419	4.845	
NOX	-21.5397	3.657	-5.890	0.000	-28.724	-14.355	
RM	3.8374	0.420	9.137	0.000	3.012	4.662	
AGE	0.0021	0.013	0.157	0.875	-0.024	0.029	
DIS	-1.4413	0.199	-7.257	0.000	-1.832	-1.051	
RAD	0.1052	0.041	2.570	0.010	0.025	0.186	
PTRATIO	-1.0035	0.131	-7.654	0.000	-1.261	-0.746	
LSTAT	-0.5562	0.051	-10.899	0.000	-0.656	-0.456	

- ✓ 영향력의 수준
- ✓ 영향력의 기여도
- ✓ 영향력의 방향
- ✓ 변수의 유의성



Easy Way?

모델 설명력 확보를 위한 손쉬운 방법은 있을까?


Problem

- 복잡도가 증가하는 모형들.. Black-Box Model은 어떻게 해석해야 할까?
- 다양한 알고리즘을 동일한 기준으로 해석해 볼 수는 없을까?

“Hint는 어떠한 모형이더라도 가시적으로 주어지는 Input과 Output ”

Easy Way

- 각각의 개별변수만 남기던가 빼고 학습해서 비교해보면 어떨까?
- 좋은 생각인가?
(ex: Feature가 10개라면 10개의 개별모델을 각각 학습하여 성과 비교)



“Model-agnostic”

Permutation Importance

Key Idea

특정 Feature 값들을 임의로 섞으면 모형성과는 얼마나 나빠질까?

- 임의의 값을 어떻게 부여할까?
 - 생소한 Random값보다 실제 있을 법한 기존 값들을 재배치 하자
- 모형 성과는 어떻게 측정하고 비교할까?
 - 재학습하지 말고 기존의 학습된 모형에 Original set vs Permutataion set을 예측하여 오차를 비교하자

Permutation Importance

Concept for Calculation

X2의 Permutation Importance를 구해보자

curb_weight (X1)	cylinder_num (X2)	num_of_doors (X3)	...	city_mpg (x10)	car_price (Y)
2765	4	2	...	16	21105
3055	4	4	...	17	24565
...	...	...	...	...	...
3230	6	4	...	22	36880
1874	3	4	...	29	6575

curb_weight (X1)	cylinder_num (X2_permuting)	num_of_doors (X3)	...	city_mpg (x10)	car_price (Y)
2765	3	2	...	16	21105
3055	6	4	...	17	24565
...	...	...	...	...	...
3230	4	4	...	22	36880
1874	4	4	...	29	6575

1874 4 4 ... 29 6575

Original Data Set

Pre-trained Model


“X2 Permutation Set Error” 와
“Original Set Error” 의 차이값

X2의 Feature Importance

Permutation Data Set (X1..X10)

Permutation Importance

어떤 DataSet을 활용할까?



Permutation FI가 (-) 의 값을 보이는 Feature는 어떤 의미일까?

Permutation Importance

Pros

- 모델을 재학습할 필요가 없기 때문에 계산 비용의 장점
- 비교가 용이한 직관적인 Feature 중요도를 얻음
- Feature간의 상호작용이 자동적으로 고려됨

Cons

- 영향의 방향은 알 수 없음
- Outlier가 있다면 편향될 수 있음
- 알고리즘 실행시마다 중요도는 다르게 계산될 수 있음 (why? Permutation 정도, 에러에 기반한 추정한계)
- 상관관계가 높은 Feature가 포함되어 있다면 해당 Feature의 중요도가 왜곡될 수 있음

SHAP(SHapley Additive exPlanations)

Key Idea


Feature간의 상호작용을 면밀히 고려해볼 수 없을까? Feature 조합의 모든 경우의 수를 따져보자

- Inspired by Game Theory – 2012 노벨 경제학상 수상, Lloyd Shapley

Game Theory

- 상대방의 행위가 자신의 이익에 영향을 미칠 경우 이와 관련해 이익을 극대화 하는 최선의 의사결정에 대한 연구
- 상대방의 결정에 상관없이 취할 수 있는 최선의 전략 → Dominant Strategy
- 각 참가자의 전략이 주어져 있을 경우 → Nash Equilibrium
- 각 참가자가 협조적일때 (Win-Win) 최선의 전략 → Cooperative Game (Stable allocations)
- ...

모두를 만족하게 하는 상금의 배분



SHAP(SHapley Additive exPlanations)

Concept for Calculation

X1, X2, X3 3개의 Feature를 활용해 Y를 예측,
X1의 Shapley Value?

$${}_3C_0 = 1$$

$${}_3C_1 = 3$$

$${}_3C_2 = 3$$

$${}_3C_3 = 1$$

모든 경우의 수(조합)를 도출하자

{ }		
{X1}	{X2}	{X3}
{X1,X2}	{X1,X3}	{X2,X3}
{X1,X2,X3}		

X1이 포함되어 있는
조합 추출

{X1}
{X1,X2}
{X1,X3}
{X1,X2,X3}



X1이 미포함되어 있는
Pair 조합 추출

{ }
{X2}
{X3}
{X2,X3}



개별 Feature마다
반복


Shapley Value Estimation

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S)]$$

예측값 차이의 가중평균 = X1의 Shapley Value = Marginal Contribution Avg.

SHAP(SHapley Additive exPlanations)

Concept for Calculation



“ Base value와 개별 Instance의 예측값과의 차이 = Sum(Shapley Value) ”

SHAP(SHapley Additive exPlanations)

Shapley Value of Real World

- Shapley value은 견고한 이론적 기반과 흥미로운 속성을 가지고 있지만 계산하기 쉽지 않음
- Feature 3개 – 8조합
- Feature 10개 – 1,024조합
- Feature 20개 – 1,048,576조합
- ..

Kernel SHAP : Linear LIME + Shapley Value

Tree SHAP : Tree Based Model

Deep SHAP : Deeplearning based model

SHAP(SHapley Additive exPlanations)

Pros

- 예측값(Y)를 결정하는 기준을 균형있게 해석할 수 있음
- Feature간 의존성을 고려해서 모델 영향력을 계산
- 음의 영향력을 고려할 수 있음 (Negative Feature Importance)
- Feature 값에 따라 Y가 어떻게 변화하는지 설명이 가능

Cons

- Feature수 에 따라 기하급수적으로 늘어나는 연산비용
- 연산비용의 한계로 Sample 계산량을 줄이면 오차의 분산이 커짐

SHAP(SHapley Additive exPlanations)

Application – Explainer

EXPLAINER	COMPATIBILITY WITH...
TreeExplainer	XGBoost, LightGBM, CatBoost, Pyspark, sklearn.tree.*, sklearn.ensemble.*
DeepExplainer	tf.keras.Model, torch.nn.Module
GradientExplainer	tf.keras.Model, torch.nn.Module
LinearExplainer	sklearn.linear_model.*
KernelExplainer	Model-Agnostic
SamplingExplainer	
PermutationExplainer	
PartitionExplainer	
AdditiveExplainer*	

```
explainer = shap.TreeExplainer(model)
shap_values = explainer.shap_values(X)
shap.plots.beeswarm(shap_values)
```

- DL모델은 DeepExplainer(TensorFlow/Keras), GradientExplainer(TensorFlow/Keras/PyTorch)
- ...

SHAP(SHapley Additive exPlanations)

General Code

```
# 설치
# pip install shap scikit-learn pandas matplotlib

import shap
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report

# 1. 데이터 로드
data = load_breast_cancer()
X = pd.DataFrame(data.data, columns=data.feature_names)
y = data.target

# 2. Train/Test 분리
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42,
    stratify=y
)
```

SHAP(SHapley Additive exPlanations)

General Code

```
# 3. 모델 학습
model = RandomForestClassifier(
    n_estimators=300,
    random_state=42,
    class_weight="balanced"
)
model.fit(X_train, y_train)

# 4. 성능 확인
pred = model.predict(X_test)
print(classification_report(y_test, pred))
```

SHAP(SHapley Additive exPlanations)

General Code

```
# 5. SHAP Explainer 생성
explainer = shap.Explainer(model, X_train)

# 6. SHAP 값 계산
shap_values = explainer(X_test)

# 7. 전체 변수 중요도
shap.plots.beeswarm(shap_values[:, :, 1])

# 8. 변수 중요도 bar plot
shap.plots.bar(shap_values[:, :, 1])

# 9. 개별 샘플 설명
sample_idx = 0
shap.plots.waterfall(shap_values[sample_idx, :, 1])
```

Explainer는 Train으로 생성해야 하나?


- Train Data는 baseline (background distribution) 역할

shap_values object

- shap_values (n_samples, n_features, n_classes)
- shap.plots.beeswarm(shap_values)
- → default positive class 선택

SHAP(SHapley Additive exPlanations)

Chart explanation




[Bees warm Plot]

- 개별 Sample은 단일점, 점이 쌓이는 구간(밀도)을 표현
- 기여도가 높은 순으로 정렬
- LSTAT(하위계층비율) 높을수록 Y(집값)에 Negative impact
- RM(룸갯수)가 클수록 Y(집값)은 높은 경향(Positive impact)

SHAP(SHapley Additive exPlanations)

Chart explanation




[Bar Plot]

- 개별 Feature의 기여도 (SHAP value 절대값 평균)를 표현

SHAP(SHapley Additive exPlanations)

Chart explanation



[Waterfall Plot]

- Y축은 Sample의 값을 X축은 Yhat 을 표현
- Base value는 22.533, Sample의 예측값은 22.248
- 개별 Feature의 SHAP value가 표현

SHAP(SHapley Additive exPlanations)

Chart explanation



[Force Plot]

- Waterfall Plot의 또 다른 표현

ML모델 개발 및 최적화


Model Monitoring & Drift

- Drift
- How to detect Drift
- Handling Drift

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

Why Model Monitoring Matters

모델은 그대로여도, 세상은 변한다



- ✓ 모델 자체가 변하지 않더라도 모델이 사용되는 환경과 데이터는 계속 변화
 - 고객 행동 및 시장 환경 변화
 - 설비·공정 조건 변화
 - 센서 및 데이터 수집 방식 변화
 - 정책 및 업무 프로세스 변화..
- ✓ 오늘 잘 동작하는 모델이 내일도 잘 동작한다는 보장은 없다 → 배포 이후에도 지속적인 모니터링 필요

Types of Drift

무엇이 변할 수 있는가?

Data Drift

- 입력 데이터의 분포가 변한다
- 학습 당시와 실제 운영 환경에서 들어오는 입력 데이터의 특성이 달라지는 현상

Concept Drift

- 입력과 결과의 관계가 변한다
- 같은 입력 데이터라도 과거와 현재의 결과를 만들어내는 패턴이나 규칙이 달라지는 현상


Prediction Drift

- 모델 예측값의 분포가 변한다
- 운영 중 모델이 만들어내는 예측값 자체의 분포가 과거와 달라지는 현상

- ✓ 변화는 입력 데이터, 데이터와 결과의 관계, 그리고 모델의 예측 결과에서 나타날 수 있음
- ✓ Drift는 어디에서 변화가 발생했는지를 구분해서 관찰하는 것이 필요

Monitoring Loop

Detect → Diagnose → Decide → Update



- Detect: 변화가 있는가?
- Diagnose: 무엇이 변했는가?
- Decide: 성능에 영향이 있는가?
- Update: 재학습 또는 조정이 필요한가?


✓ Drift가 발생했다고 해서 반드시 모델이 실패한 것은 아니다

Data Drift

Shift in the distributions of the ML model input features

Concept

- 입력 데이터의 통계적 속성과 특성이 변화하는 현상으로 모델이 처리하도록 훈련되지 않은 모델 입력이 들어올 때
- 머신러닝 모델이 운영 환경에서, 모델이 처음 학습한 데이터와 다른 데이터가 생성될 때 발생
- 머신러닝 모델을 만들 때 학습에 사용된 데이터와 유사한 데이터에서 보다 좋은 성능을 기대할 수 있기 때문에 입력 데이터 분포의 이러한 변화는 모델 성능 저하로 이어질 수 있음
- 이를 감지하고 해결하는 것은 ML 모델의 안정성을 유지하는 데 필요



Data Drift

Shift in the distributions of the ML model input features

Example

- 수요 예측 모델을 통해 재고를 관리중인 소매 체인점의 경우
 - 일부 제품군을 시작으로 온라인 판매로의 전환이 뚜렷하게 목격 목격
 - 훈련 데이터에 온라인 판매 정보가 충분하지 않아 이 세그먼트에서는 모델이 제대로 작동하지 않음
 - 온라인 판매가 사업에서 차지하는 비중이 작은 변화의 초기에는 큰 문제는 아니었으나..
 - 온라인 쇼핑이 급증하면서 모델 예측의 품질이 크게 저하



Concept Drift

Concept drift is a change in input-output relationships


Concept

- 입력 변수와 목표 변수 간의 관계 변화를 의미
- 예시) 동일한 제품군에 대해 경쟁자가 대폭 할인을 제공하는 경우 이는 고객의 행동을 변화시켜 기대 매출 크기가 급격히 감소하는 상황
- 예시) COVID의 발생으로 인해 쇼핑 방식이 변화하는 경우
- Drift 이전에 만들어진 모든 모델의 성과는 급속히 저하될 수 있음


vs Data Drift

- 데이터 드리프트는 입력 특성 분포의 변화를 나타내는 반면, 개념 드리프트는 모델 입력과 출력 간의 관계의 변화를 나타냄
- 동시에 나타날 수 있고 데이터 분포 드리프트는 개념 드리프트의 징후일 수 있음

Data drift



Concept drift



Concept Drift

Concept drift is a change in input-output relationships

트렌드A 트렌드B

Sudden Drift:

A new concept occurs within a short time.




Gradual Drift:

A new concept gradually replaces an old one over a period of time.



Incremental Drift:

An old concept incrementally changes to a new concept over a period of time.



Reoccurring Concepts:

An old concept may reoccur after some time.




- A가 갑자기 B로 바뀐 현상
- Ex) 코로나에 따른 온라인 주문량 변화
- 시간이 지날수록 A로부터의 샘플링 확률은 감소하고 B로부터의 샘플링 확률은 높아지는 현상
- Ex) 결제방식의 변화(카드→간편결제)
- 데이터의 변화가 매우 적기 때문에, 긴 시간 동안 바라만 봐야 인지할 수 있는 현상
- Ex) 몇 년에 걸친 카드 소비습관의 장기적 변화
- A가 B에 의해 안 보이다가 시간이 지나 다시 나타나지는 현상
- Ex) 겨울마다 난방용품 구매 급증

Prediction Drift

Prediction drift is a change in the model outputs

예측(Predicted value) 분포의 변화는 점검의 신호

- 예측 드리프트는 모델 출력의 분포 변화를 의미
- 모델 출력의 변화는 환경 변화나 모델 품질 문제를 나타내는 징후일 수 있음
- 예시) 사기 예측 모델의 사기 예측 빈도가 급격히 높아지거나, 가격 예측 모델이 현재보다 Under-estimate하는 경우 → 모델 점검의 충분한 이유
- 다만 항상 모델 성능 저하를 의미하는 것은 아님 → 사기 시도가 실제로 증가하고 일반화된 모델이 이를 잘 예측한다면 예측된 사기 사례의 분포가 달라짐 → 모델 품질 저하 없이 예측 드리프트가 관찰



Training-serving skew

모델 운영 환경에서의 loss는 없는가?

Concept

- 학습된 데이터와 실제 운영 환경에서 접하는 데이터 사이에 불일치가 있는 상황
- 데이터 전처리, 특성 엔지니어링 등과 관련된 문제를 포함하여 두 데이터 세트 간에 발생할 수 있는 모든 불일치가 포함
- Ex) 학습에서 사용 가능한 특성이 실제 운영 환경에서 계산할 수 없거나 지연이 발생하는 경우
- 데이터 드리프트는 입력 데이터 분포의 점진적인 변화를 의미하지만 Training-serving 편향은 모델 프로덕션 시작 직후 나타나는 불일치를 의미
- 운영 데이터와 학습 데이터를 대조하여 이의 감지가 필요

Data quality


Data Drift의 일부는 데이터 품질 문제에서 야기

Concept

- 데이터 드리프트는 데이터의 온갖 변화와 이상 현상을 포함할 수 있음
- Ex) 데이터 스키마의 변화, 값 누락, 일관되지 않은 형식, 잘못된 입력 등
- 데이터 품질 문제는 파이프라인 버그나 데이터 입력 오류 등으로 인해 발생할 수 있는 손상되고 불완전한 데이터를 의미하는 반면 데이터 드리프트는 환경 변화로 인해 유효한 데이터의 분포가 변하는 것을 의미
- 데이터 품질 문제와 데이터 드리프트를 구분하는 것이 필요

vs Data Drift

- 데이터 드리프트는 데이터 품질이 높더라도 발생하는 데이터 분포의 통계적 변화를 의미



Outlier


Data Drift의 일부는 데이터 품질 문제에서 야기

Concept

- 이상치 감지는 데이터에서 다른 객체와 다르게 보이는 개별 객체를 식별하는 것으로 해당 객체 수준에서 조치를 취하는 것을 목표함
- 이상치에 대해 전문가에게 결정을 내리도록 요청하거나, 특정 결과에 대해 예측을 거부하는 것과 같은 비즈니스 로직을 적용할 수 있음

vs Data Drift

- 데이터 드리프트는 전체 데이터 분포의 변화를 나타내어 전반적인 모델 신뢰도를 평가하는데 도움
- 이상치 탐지는 데이터에서 개별적인 비정상 입력값을 식별하여 모델이 처리하기에 적합하지 않을 수 있는 입력값을 발견




Data Drift 감지의 중요성

Shift in the distributions of the ML model input features

Concept

- 데이터 분포 드리프트를 추적하는 것은 프로덕션 레벨에서 모델 품질을 모니터링하는 주요 접근
- 모델이 예측을 하고 그 예측의 정확도에 대해 피드백을 받는 시간 간격이 상당할 때를 피드백 지연이라 함, 이 경우 데이터 드리프트의 관찰은 더욱 중요
- 데이터 드리프트 분석은 모델 품질 저하를 해석하고 모델 환경의 변화를 이해하는 데 도움이 될 수 있음
- 모델의 일반화된 학습을 통해서 실제 외부 데이터에서도 좋은 성능을 보일 것이라고 기대하지만 데이터가 고정된 상태로 유지될 것이라는 가정은 비현실적, 때문에 지속적인 모니터링과 대응이 필요



How to detect Data Drift

Data drift 어떻게 감지할 것인가?

요약 통계(Statistics) 활용

- 두 분포를 비교하는 일반적인 방법은 평균, 중앙값, 분산, 분위수 등과 같은 주요 통계를 살펴보는 것
- 수치형 변수의 현재 평균값이 기준값으로부터 2표준편차 이내에 있는가?
- 값이 최소-최대 범위 내에 있는가?
- 특성의 유효 범위 내에 있는가?, 주문 감소 등 특성 크기의 급격한 변화 감지

통계적 검정(Statistical tests)

- 두 데이터 세트 간의 차이가 통계적으로 유의미한지 평가
- KS검정(Kolmogorov Smirnov) – 수치형 변수의 확률분포의 차이를 검정
- 카이제곱 검정(Chi-square test) – 범주형 변수

How to detect Data Drift

Data drift 어떻게 감지할 것인가?

Distance metrics

- 거리 지표를 활용하여 분포 간 거리를 정량적으로 측정
- 두 표본의 변화를 정량화, 결과 지표는 시간 경과에 따라 관찰할 수 있는 "드리프트 크기 " 라고 간주할 수 있음
- Wasserstein Distance – 두분포는 얼마나 다른가? (하나의 분포를 다른 분포로 옮기는 최소 비용은?)
- PSI(Population Stability Index) - 기준 시점(Base population)의 데이터 분포와, 새로운 시점(Current population)의 데이터 분포가 얼마나 달라졌는가?

규칙 기반 검사(Rule-based)

- 규칙을 사용하여 드리프트 검사를 수행
- 의미 있는 변경 사항이 있을 경우 이를 알리는 경고 방식으로 활용
- Ex) 예상되는 '사기' 범주의 점유율은 10%가 넘는 경우
- Ex) "제품 유형" 속성에 새로운 범주형 값이 나타난 경우
- Ex) "급여" 속성 값의 10% 이상의 데이터가 정의된 최소-최대 범위를 벗어난 경우

Handling Data Drift

Data drift의 체계적 조치

분석을 통한 조치 유형 식별



- 제품 변경과 같은 정당한 사업적 사유가 있어 별도의 조치가 필요하지 않을 수 있음
- 진정한 데이터 드리프트가 발생한 것인지, 단순 데이터 품질 문제인지 구별
- 데이터 드리프트의 많은 문제는 데이터 품질 버그에서 비롯됨, 이 경우 데이터 관리 담당자와 협업하여 피처 변환 파이프라인을 수정하는 등 문제를 파악하고 해결

Handling Data Drift

Data drift의 체계적 조치

모델 재학습

- 새로 관측된 분포에서 레이블된 데이터를 사용하여 모델을 재학습
- 모델의 진부화를 해결하고 새로운 패턴을 학습하도록 하는 일반적인 접근
- 레이블이 지정되어 있고 재학습에 필요한 충분한 새 데이터가 있는 경우, 일반적으로 권장
- 모델 업데이트에 대해 다른 전략을 선택할 수 있음. ex) 최신 데이터에 더 높은 가중치를 부여하거나 이전 데이터를 완전히 삭제




Handling Data Drift

Data drift의 체계적 조치

프로세스 개입(Process intervention)

- 모델의 예측이 드리프트로 인해 부정적인 영향을 받는 경우 일시적으로 운영 중지를 검토
- 특정 제품 그룹과 같이 영향을 받는 일부 세그먼트에 대해서만 검토할 수 있음
- 데이터 드리프트, 모델 출력 분석 내용에 기반하여 의사결정 프로세스를 수정하는 것 검토
- ex) 사기탐지의 의사결정 임계값 조정



수고하셨습니다.

본 문서는 SK AX의 콘텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.