모델 결과 보고서

SKALA 4기 · 데이터분석 미니프로젝트 · 4반 최승우 · 2026-10-14

과제: 3일 뒤 KOSPI(Target_1)와 건강식품 쇼핑 지수(Target_2)가 오늘보다 오를 **확률** 예측 · 평가지표 AUC

0. 한 장 요약

0.637	0.967	0.802	≈0.79
T1 검증 AUC (Baseline 0.522)	T2 검증 AUC (Baseline 0.945)	두 Target 평균 (Baseline 0.734, **+0.068**)	Private 기대치 (200일을 한 번에 채점하는 방식으로 환산)

	Target_1 · KOSPI	Target_2 · 건강식품 지수
문제의 성격	신호가 약하고 시기마다 흔들림. 확실한 단서는 **직전 미국 증시 등락** 하나	거의 **요일 리듬** 문제. 요일만 써도 AUC 0.926
최종 모델	E13 = 얕은 랜덤포레스트(85개 변수) 50% + 강하게 규제한 로지스틱(핵심 9개) 50%	E10 = 로지스틱 + 랜덤포레스트 + XGBoost 평균 (80개 변수)
점수를 올린 것	모델이 아니라 **입력**: 주말 보정, 변화율→차이, 환율·검색량 신호	"3일 뒤 요일의 평소 값 ÷ 오늘" 파생변수, 오늘 이상치
안전장치	미래 값 사용 금지(과거만 참조) · 시계열 5-fold 검증 + 3일 간격 · "평균 − 표준편차"로 선택 · Public 점수는 선택에 반영하지 않음 · 선택 편향까지 통계 검정으로 확인	

분석 파이프라인 전체

① 데이터 이해 — Target 구조, 요일 번호, 변수군별 성격 (EDA · Prophet)

→

② 전처리 — 상수 제거, 클릭 0→결측, inf→결측, fold 안에서 중앙값 대체

→

③ 변수 만들기 — 과거 값만으로 변화량·요일 비교 파생변수

→

④ 변수 고르기 — EDA 근거로 블록 선택 → 블록 제거 실험으로 확인

→

⑤ 모델·검증 — Target별 모델, 시계열 CV, 평균 −std 기준

→

⑥ 판단 검증 — 잡음·선택 편향·시기 변화 통계 검정

코드: `01_EDA_피처인사이트.ipynb` (①③) · `02_Prophet_시계열분석.ipynb` (①) · `train.ipynb` (②~⑤, 제출 파일 생성) · `03_T1_분기점검증.ipynb` (⑥). 실험 기록 `experiments.csv`.

1. 데이터 이해 — 두 Target은 전혀 다른 문제였다

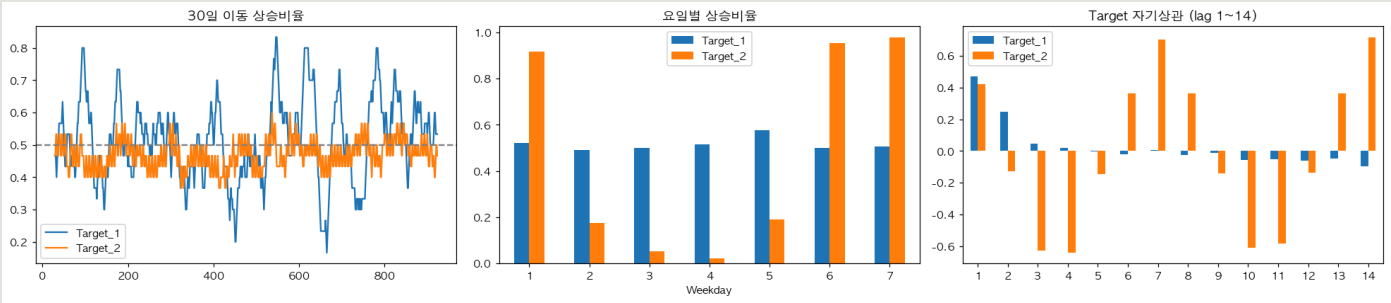


그림 1. 왼쪽: T1의 30일 상승비율이 0.17~0.83으로 출렁임(국면 변화). 가운데: 요일별 상승비율 — T2만 요일에 따라 0.02~0.98로 갈림. 오른쪽: T2는 정확히 7일 주기.

> **쉽게 말하면** — T2는 "3일 뒤가 평일이면 오르고, 주말이면 내린다"에 가깝다. 사람들은 평일에 쇼핑을 더 많이 클릭하기 때문이다. 반대로 T1(KOSPI)은 요일과 무관하고, 오르는 날·내리는 날이 시기마다 몰려 다닌다.

확인한 것	결과	그래서
요일 번호의 정체 (설명서에 없음)	금융 18개 중 16개가 요일 1·7에서 전날 값과 100% 같음 (휴장)	**1 = 일요일, 7 = 토요일**. 주말엔 미국 지수 변화율이 0이 되는 문제 발견 → 주말 보정 변수
요일만으로 맞힌 AUC	T1 0.484 / T2 **0.926**	T2는 요일을 **이용**, T1은 요일을 **지운다**
변수군별 성격 (Prophet 분해)	금융: 추세 66% · 포털 검색: 요일 54% · 쇼핑: 추세 40% + 요일 18~29% · 날씨: 설명 안 됨 88%	금융은 원값 대신 **변화량**, 쇼핑·검색은 **같은 요일끼리 비교**
신호가 시기를 넘어 유지되나 (앞 절반 vs 뒤 절반)	T1 상관 0.39 (대부분 잡음) / T2 0.97 (안정)	T1은 강한 규제 + 소수 핵심 변수

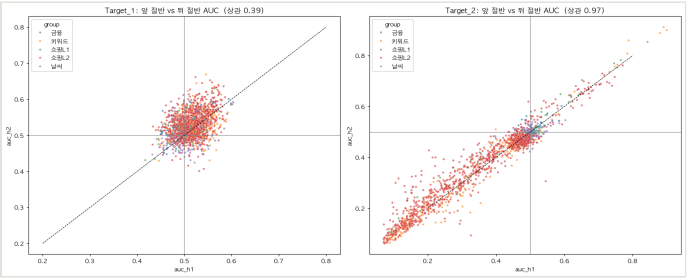


그림 2. 변수마다 앞 절반 AUC(가로)와 뒤 절반 AUC(세로). 점이 대각선에 붙을수록 시간이 지나도 통하는 신호. T1(왼쪽)은 흩어져 있다.

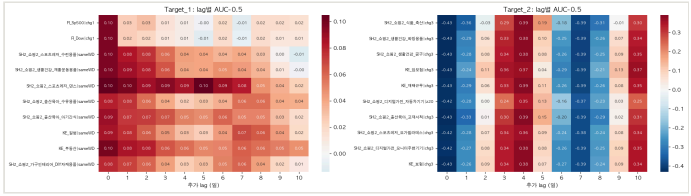


그림 3. 며칠 전 값까지 신호가 남나. T1의 미국 지수는 **하루만 밀어도 사라진다** → 최신 값만 쓴다. T2는 7일 간격으로 부호가 반복(요일).

2. 데이터 설계 — 전처리 · Feature Extraction · Feature Selection

2-1. 전처리

처리	이유
값이 하나뿐인 `KE_QR체크인` 제거 (Train 기준)	정보 없음
쇼핑·검색 클릭량 0 → 결측 (날씨 강수량 0은 유지)	클릭 0은 실제 0보다 수집 누락일 가능성이 크고, 비율 계산 시 무한대를 만든다
변화율의 무한대 → 결측, 결측은 **각 fold 학습 구간의 중앙값**으로 대체 (Pipeline 안)	검증 구간 정보가 학습에 새지 않게
표준화는 로지스틱에만	원데이터가 이미 0~1이고 트리는 단위와 무관. 로지스틱은 규제가 변수 크기에 공평하게 걸리도록

2-2. Feature Extraction — 모든 파생변수는 그날까지의 과거 값만 사용

파생변수	계산	근거 (쉬운 설명)	사용
`us_last`	미국 지수 3개 전일 변화율, 주말 0은 직전 거래일 값으로	주말엔 미국장이 쉬어 핵심 신호가 7일 중 2일 꺼져 있었다 (일·토 AUC 0.50 → 0.57·0.60)	T1
`us_diff` · `fx_diff`	미국 지수·환율의 최근 거래일 **차이**	데이터가 0~1로 눌려 있어 0 근처에서 변화율(%)이 수천 %로 폭발 → 차이가 실제 변화에 비례. 원화 약세(환율↑) → 3일 뒤 KOSPI↓	T1
`kefin_swd`	검색어 6개의 "오늘 ÷ 지난 4주 같은 요일 평균" 중앙값	평소보다 검색이 많은 날 → 3일 뒤 상승 경향 (§5에서 검증)	T1
`fi_chg` · `samewd_grp`	금융 1·3·5일 변화율 + 20일 변동성 / 쇼핑·검색 군별 같은 요일 대비 중앙값	금융은 추세가 커서 원값을 쓰면 "몇 월쯤인가"를 외운다 / 수백 개가 같은 정보라 군별 1개로 압축	T1
`d3ratio`	"지난 4주 동안 **3일 뒤와 같은 요일**의 평균 ÷ 오늘"	T2의 정의(3일 뒤 > 오늘)를 이미 아는 과거 값으로 흉내. 단독 AUC 0.954	T2 핵심
`sh1_anom` · `z20_kw`	쇼핑 11개 "오늘 ÷ 지난 4주 같은 요일 평균" / 검색어 20일 z-score	오늘이 평소보다 튀면 3일 뒤엔 평소로 돌아온다(평균회귀). 요일로 못 가르는 월·목 보강	T2
`wd_onehot`	요일 7칸 0/1	숫자 1~7은 크기 순서가 생겨 부적절	공통

> **왜 "지난 4주 같은 요일"인가** — 쇼핑·검색은 요일마다 수준이 다르다. 월요일을 지난 월요일들과 비교하면 요일 차이가 사라지고 "평소보다 많다/적다"만 남는다. 1주 전 하루와만 비교하면 그날의 우연에 흔들려서 4주 평균을 썼다(1주 0.935 → 4주 0.952).

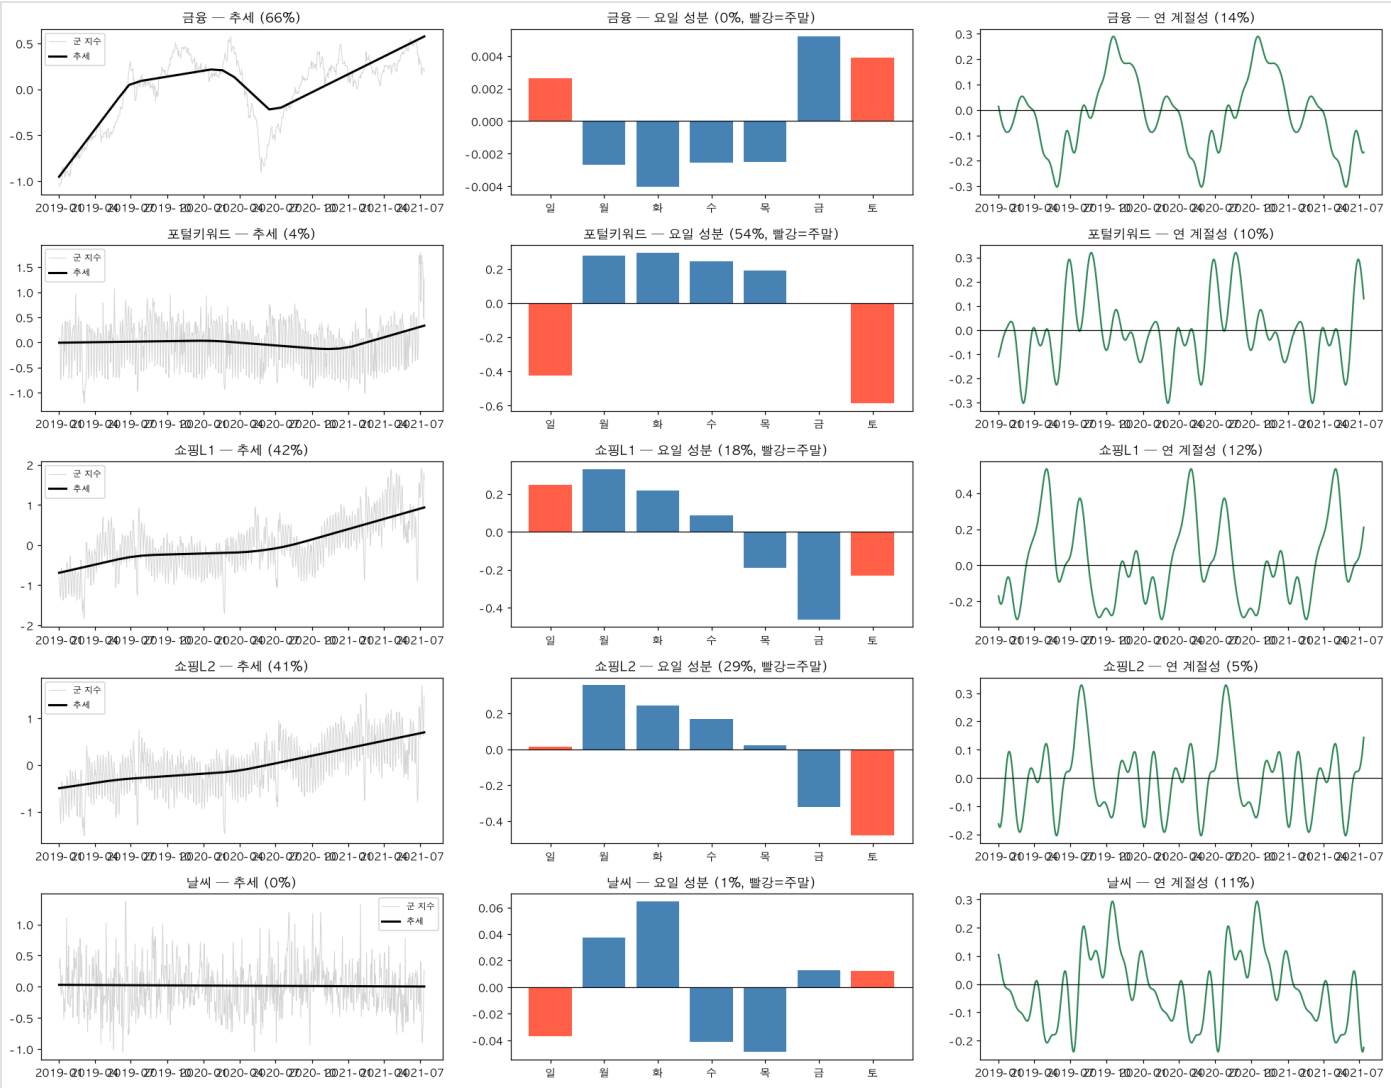


그림 4. Prophet 분해: 검정 = 추세, 막대 = 요일 성분. 포털 검색은 요일이 절반 이상, 금융은 요일 0%·추세 위주 → 변수군마다 다른 변환을 쓴 근거.

2-3. Feature Selection — 사람이 고르고, 실험으로 확인

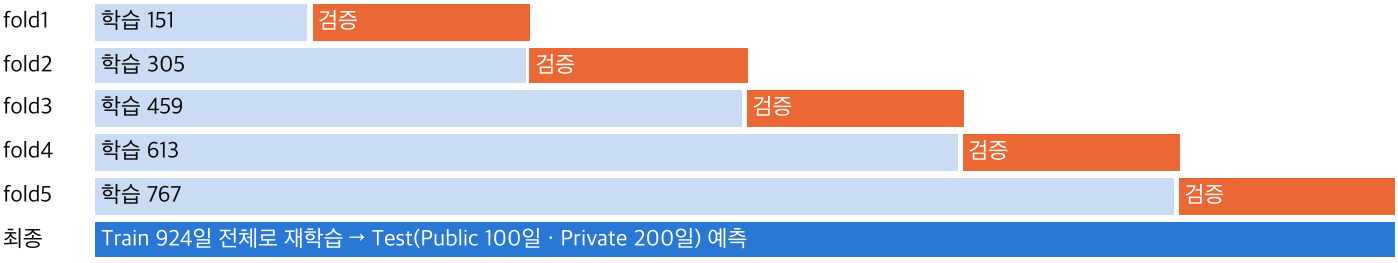
방법	결과	판단
EDA 근거로 **블록 단위** 선택 (565개 → T1 85+9개, T2 80개)	T1 0.540 → 0.596, 가장 큰 도약	채택
fold 안 자동 선택 8종 (F검정, 상호정보, L1, 트리 중요도)	모두 하락 (T1 평균−std 0.520~0.565)	기각: 작은 표본에선 선택 자체가 우연을 고른다
블록 하나씩 빼 보기 (5개 fold 중 4개 이상 하락 + 하락폭 ≥ 표준편차/2면 유지)	`samewd_grp` 빼면 0.599→0.584, `d3ratio` 빼면 0.967→0.959	유지
금융 상관 0.8 이상 중복 제거 (E7)	평균은 같고 흔들림 2배 (std 0.048)	기각

3. 모델 설계 — 알고리즘 · 검증 · 최적화

3-1. 검증 설계: 항상 "과거로 학습 → 미래로 시험"

장치	내용	왜
시계열 5-fold	`TimeSeriesSplit(n_splits=5, gap=3)`. 검증 구간 약 154일 = Public(100일)과 비슷한 규모	무작위로 섞으면 미래를 보고 과거를 맞히는 셈
3일 간격 (gap)	학습 끝과 검증 시작 사이 3일 비움	Target이 "3일 뒤"라 학습 마지막 날의 정답이 검증 기간 가격을 포함한다
Pipeline	결측 대체·표준화·변수 선택을 fold 학습 구간으로만 학습	검증 정보 누수 차단
선택 기준	**검증 평균 − 표준편차**, Train–Valid 격차 감시. Public 점수는 반영 안 함	Private 200일에서 무너지지 않는, 높으면서 꾸준한 모델

Train 924일을 나눈 방법 — 무작위로 섞지 않고 시간 순서대로 5번 나눴다. 매번 과거 전체로 학습하고, 3일을 비운 뒤 다음 154일로 검증한다.



Time_step 1 → 924 (왼쪽 → 오른쪽). 학습과 검증 사이 흰 틈 = 비운 3일.

fold	학습 (Time_step)	비운 3일	검증 (Time_step)	학습 / 검증 일수
1	1 ~ 151	152 ~ 154	155 ~ 308	151 / 154
2	1 ~ 305	306 ~ 308	309 ~ 462	305 / 154
3	1 ~ 459	460 ~ 462	463 ~ 616	459 / 154
4	1 ~ 613	614 ~ 616	617 ~ 770	613 / 154
5	1 ~ 767	768 ~ 770	771 ~ 924	767 / 154

> **쉽게 말하면** — 시험은 항상 "공부한 기간 다음"에 본다. 실제 평가도 Train 이후의 날들을 맞히는 구조라 같은 방식으로 연습했다. 제공된 Baseline은 시간순 7:3 분할(앞 70% 학습, 뒤 30% 검증) **한 번**이었다. 그러면 점수가 그 한 시기의 운에 좌우되고, 간격이 없어 학습 마지막 날의 "3일 뒤" 정답이 검증 기간 가격과 겹친다. 그래서 5번 나누고 3일을 비웠으며, Baseline(E0)도 이 방식으로 다시 쟀다. 검증 구간 154일은 Public(100일)과 Private(200일) 사이 크기이고, 시기가 다른 5개 구간의 **평균과 흔들림(표준편차)**을 함께 보고 모델을 골랐다.

3-2. 최종 모델 구조

Target_1 · E13 (94개 변수)

RandomForest 300그루 · 깊이 2 · 잎 최소 20일 · 변수 √n ← 85개: `fi_chg` 72, `samewd_grp` 3, `wd_onehot` 7, `us_last` 3

표준화 → 로지스틱 L2, C = 0.01 (강한 규제) ← 9개: 미국 지수 3, 환율 2, 유가 3 차이 + `kefin_swd`

두 확률을 50:50 평균

RF는 여러 변수의 약한 조합을, LR은 원인이 분명한 소수 신호를 맡는다. LR 단독(3개 변수, 0.625)이 RF 85개(0.603)보다 높았던 것이 이 구조의 출발점.

Target_2 · E10 (80개 변수)

표준화 → 로지스틱 L2, C = 0.1

RandomForest 300 · 깊이 4 · 잎 20

XGBoost 300 · 깊이 2 · 학습률 0.03 · λ=5 · 표본 80%·변수 50%

세 확률 평균 (soft voting) ← `wd_onehot` 7, `d3ratio` 12, `z20_kw` 50, `sh1_anom` 11

관계가 단순해 로지스틱 단독도 0.964. 트리가 "요일 × 평소 대비" 조합을 보완하고, 성격이 다른 모델 평균으로 시기별 흔들림을 줄인다.

3-3. 최적화 과정 — 실험 16개(T1)의 흐름

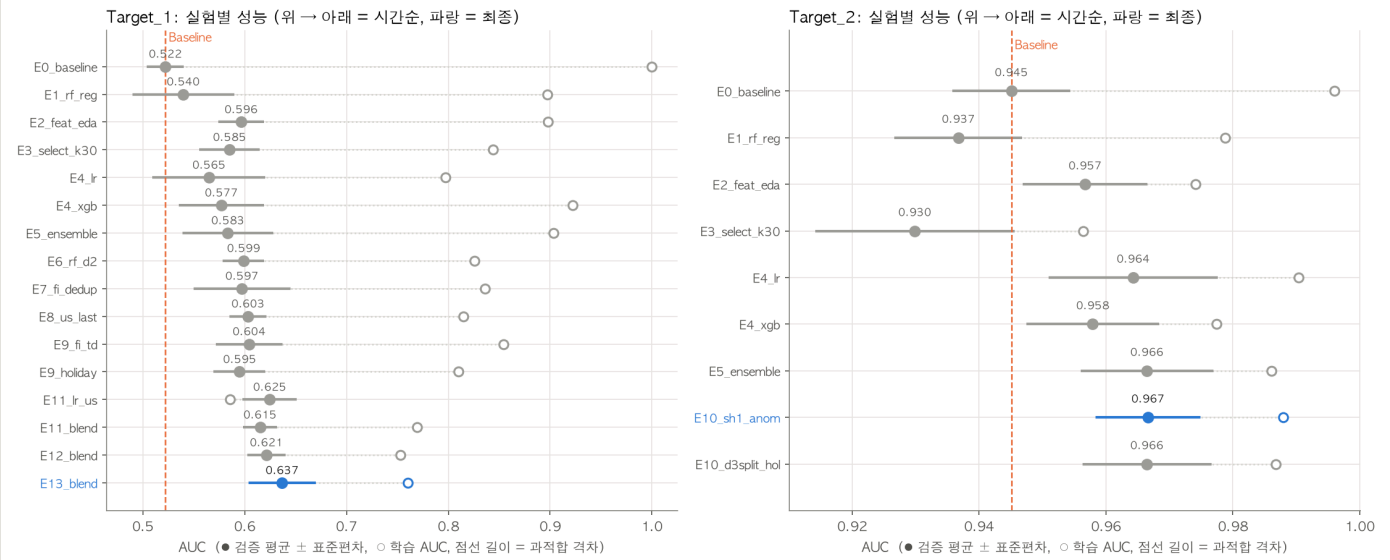


그림 5. ● 검증 AUC(가로 막대 = 표준편차), ○ 학습 AUC. 둘 사이 점선이 길수록 "외워서 맞힌" 정도(과적합). 파랑 = 최종.

단계	시도	T1 검증 AUC	배운 것
E0 → E1	같은 변수, 나무만 얕게	0.522 → 0.540	격차는 줄지만 점수는 그대로 → **모델이 아니라 입력이 문제**
E2	EDA 근거 변수 82개	0.596	가장 큰 도약
E4·E5·E6	로지스틱·XGB·앙상블, 깊이·잎·C 그리드 24개	0.565~0.599	하이퍼파라미터는 병목이 아님. 같은 점수면 단순한 쪽(깊이 2)
E8	주말 미국 지수 보정	0.603	이유가 분명한 개선
E11 → E12	미국장 로지스틱 혼합 → 변화율을 차이로 + 환율	0.615 → 0.621	핵심 신호를 단순 모델에 맡기기
E13	+ 유가 차이, 검색량 심리	**0.637**	§5에서 우연이 아님을 검정

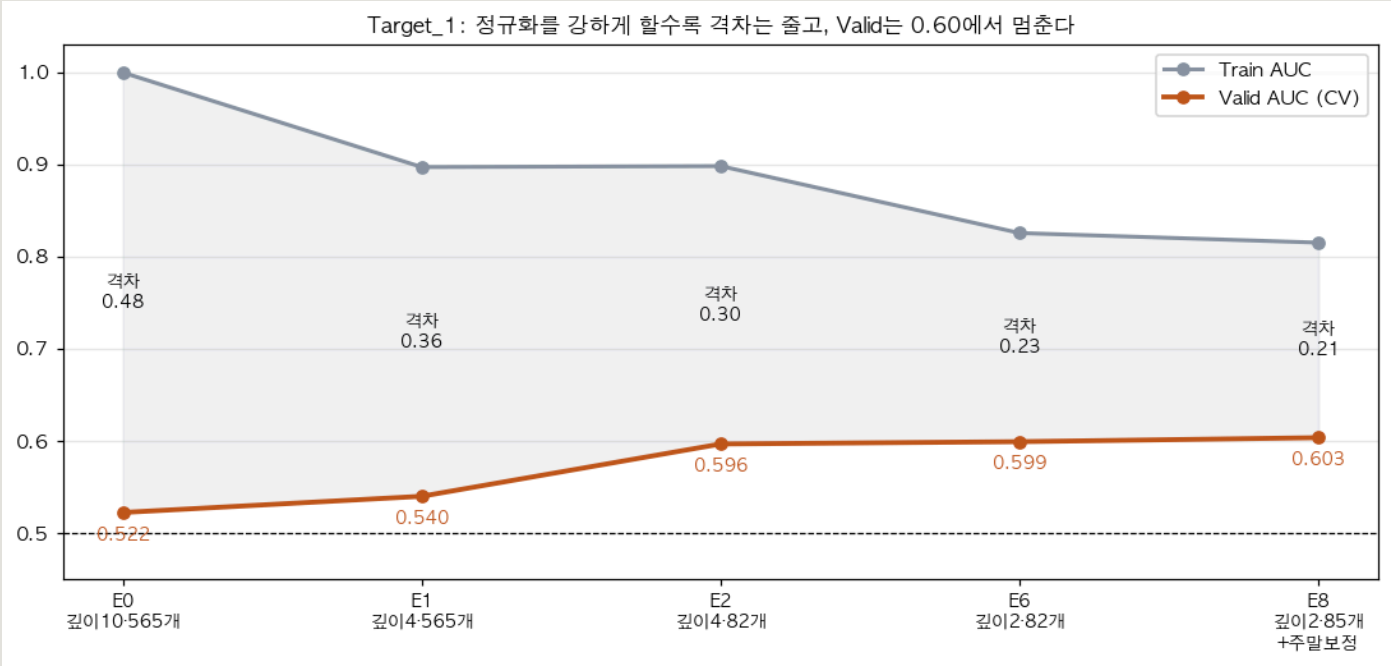


그림 6. T1에서 규제를 강하게 할수록 과적합 격차는 0.48 → 0.21로 줄었지만 검증 점수는 0.60 근처에서 멈췄다 → 남은 한계는 모델이 아니라 **데이터에 담긴 신호의 양**. 그 뒤의 개선(E11~E13)은 모두 새 입력에서 나왔다.

4. 결과

	Baseline (E0)	최종	개선	검증 표준편차	학습–검증 격차	이어 붙인 검증 AUC*
T1 (E13)	0.522	**0.637**	+0.115	0.033	0.124 (Baseline 0.478)	0.620
T2 (E10)	0.945	**0.967**	+0.022	0.008	0.021	0.964
평균	0.734	**0.802**	**+0.068**			**0.792**

* 5개 fold의 검증 예측을 이어 붙여 한 번에 계산한 AUC. Private은 200일을 한 번에 채점하므로 이 값이 기대치에 더 가깝다.

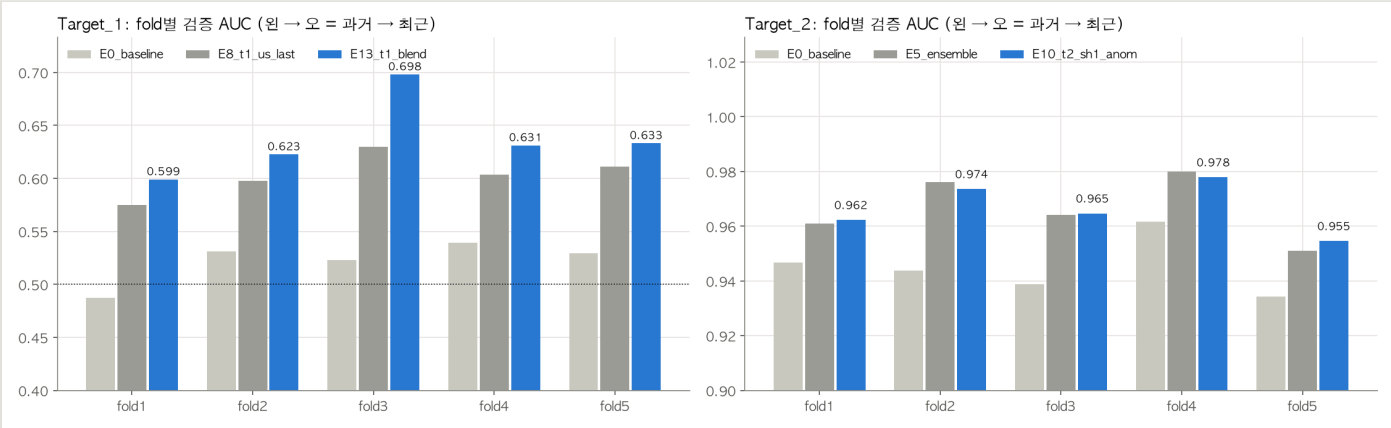


그림 7. fold별 검증 AUC. 최종(파랑)이 과거·최근 어느 시기에서나 Baseline(연회색)보다 높다. 특정 시기 운이 아니라는 뜻.

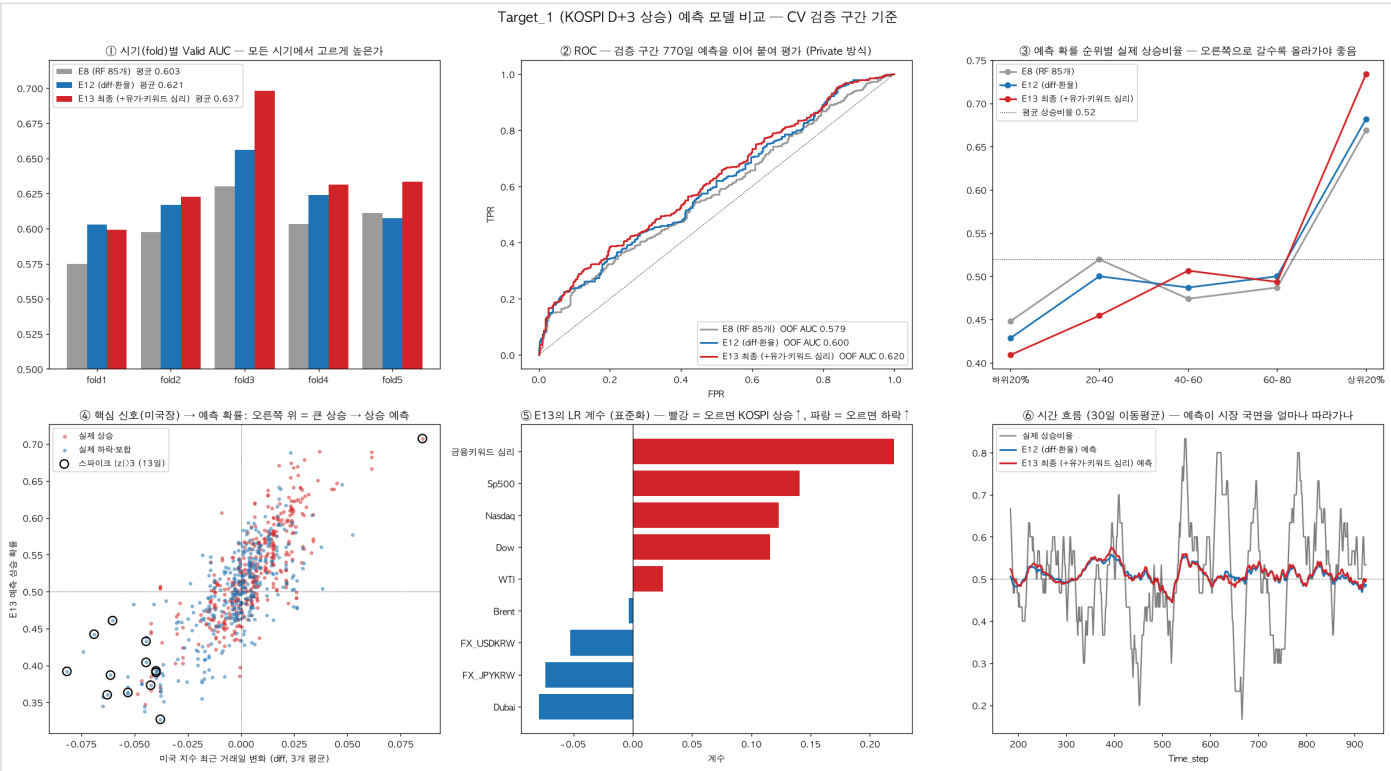


그림 8. T1 예측 모델 진단: 예측 확률 상위 20%의 실제 상승률 0.73 (평균 0.52). 미국장이 크게 오른 날 확률이 높아지고, 로지스틱 계수는 검색량 심리·미국 지수(+), 환율(–) 순.

Public 리더보드 — 참고만 하고 선택에는 쓰지 않았다

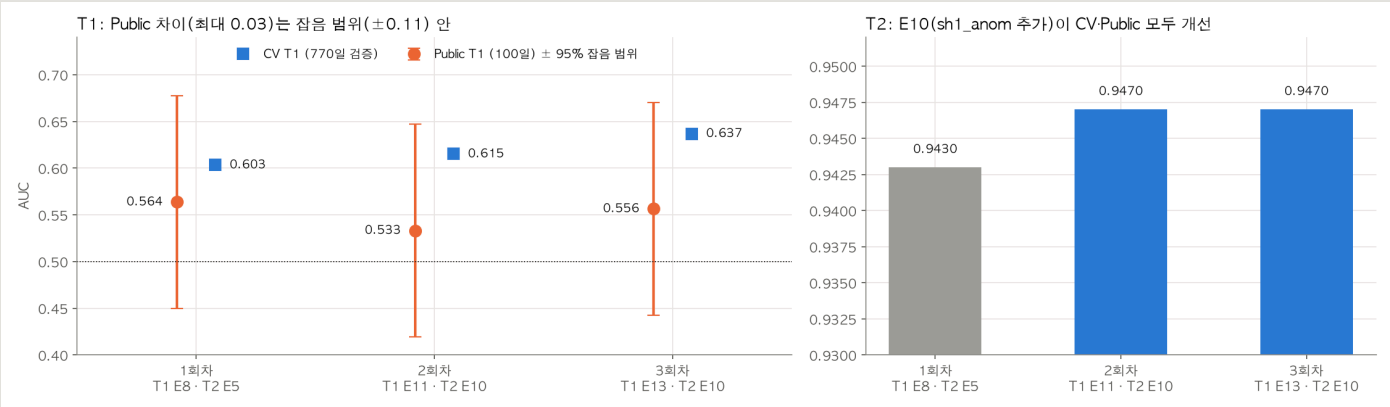


그림 9. Public 3회 제출. T1은 1회차가 가장 높았지만, 100일짜리 AUC는 우연만으로 ±0.11 흔들린다(주황 막대). 세 회차 차이(최대 0.03)는 그 안에 있다. 770일로 잰 CV(파랑)는 E13이 가장 높다.

> **왜 Public 1등 구성을 고르지 않았나** — 100일 시험 한 번의 점수에 맞추면 그 100일에 과적합한다. Private은 다른 200일이다. 770일 검증 + 통계 검정(§5)에서 일관되게 앞선 E13을 고른 것이 Private에 더 안전하다. T2는 CV와 Public이 같은 방향(E10 개선)이었다.

왜 Public에서 1회차(E8)가 E13보다 높았나 — Test 정답 없이 분석

차이는 T1에서만 났다(T2는 Public에서도 E10 > E5). 우리 검증 예측과 **Test 설명변수의 분포만** 써서 원인을 찾았다.

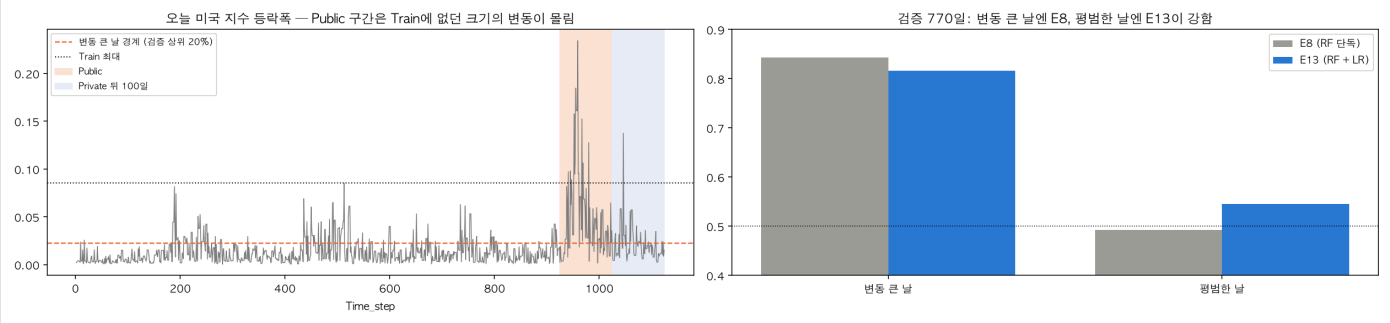


그림 10. 왼쪽: 오늘 미국 지수 등락폭. Public 구간(주황 배경)에 Train에서 본 적 없는 크기의 변동이 몰려 있다(폭락·급반등, Train 끝의 코로나 검색량 급등과 이어짐). 오른쪽: 검증 770일에서 변동이 큰 날엔 E8이, 평범한 날엔 E13이 강하다.

구간 구성 (변동 큰 날 비율)	E8 기대 AUC	E13 기대 AUC	E13이 나을 확률
우리 검증 770일 (20%)	0.579	0.620	96%
Public 100일 (72%)	0.765	0.766	**51%**
Private 200일 (52%)	0.702	**0.719**	82%

검증 예측을 각 구간의 "변동 큰 날" 비율에 맞춰 200일씩 2,000번 다시 뽑아 계산한 기대 AUC.

> **쉽게 말하면** — 미국장이 크게 움직인 날은 그 방향만으로 3일 뒤가 꽤 맞는다(AUC 0.8대). 이때 랜덤포레스트(E8)는 극단값을 "Train에서 본 가장 큰 값" 정도로만 다뤄 안정적이지만, E13의 로지스틱은 극단값을 직선으로 그대로 늘려 확률을 0.01~0.98까지 밀어붙였다(Train에서는 0.14~0.87). Public은 이런 날이 72%라 두 모델의 기대치가 **같았고**, 실제 0.007 차이는 동전 던지기 수준이다. Private은 앞 100일만 극단이고 뒤 100일은 비교적 잠잠해 E13이 여전히 유리하다(+0.017). 단, Train 최대를 넘는 극단값 날의 위험은 검증 구간에 그런 날이 없어 이 추정에 들어 있지 않다.

그렇다면 변동이 큰 날만 E8로 바꾸면? → 이득 없음 (기각)

"변동이 큰 날"은 **미리 예측할 필요가 없다**. 기준이 *오늘 이미 마감된 미국장 등락폭*이라 예측 시점에 알고 있는 값이다. 경계값은 매 fold 학습 구간의 상위 20%로만 정했다.

모델	CV 평균	평균 −std	검증 구성 기대 AUC	Private 구성 기대 AUC	Private에서 E13보다 나을 확률
E13 (현재)	**0.637**	**0.604**	**0.621**	0.718	—
S1: 오늘 등락폭이 크면 E8	0.623	0.580	0.612	0.720	58% ❌
S2: 최근 20일 변동성이 크면 E8 (위기 국면)	0.627	0.596	0.614	0.717	48% ❌

> **쉽게 말하면** — 변동 큰 날에 E8이 강한 것은 맞지만, 날마다 다른 모델의 확률을 섞으면 두 모델의 확률 수준이 달라 한 줄로 세울 때 (AUC) 손해가 생긴다. 그 비용이 이득을 상쇄해 Private 구성에서도 E13과 같고, 평범한 날이 많은 구성에서는 0.008 손해였다. 미리 정한 기준(Private 구성에서 나을 확률 ≥ 90%, 평범한 구성 손실 ≤ 0.005)을 둘 다 넘지 못해 **E13을 유지**했다.

5. 판단 검증 — "이 개선이 우연은 아닌가"를 통계로 확인

T1은 신호가 약해, 후보를 여러 개 시도하다 보면 우연히 좋아 보이는 것을 고를 위험이 있다. 마지막 세 가지 판단을 **결과를 보기 전에 기준을 정해 두고** 검정했다 (`03_T1_분기점검증.ipynb`).

> **검정 도구 두 가지 (시계열용)**
> · **순환 이동 검정**: 변수를 통째로 k일 밀어 붙인다. 변수 자체의 흐름은 그대로, Target과의 날짜 관계만 끊긴다 → "이런 흐름을 가진 아무 변수"가 우연히 낼 수 있는 점수의 기준선.
> · **블록 부트스트랩**: 20일씩 연속 구간을 뽑아 다시 이어 붙여 수천 번 재계산 → 기간이 달랐다면 결과가 얼마나 흔들렸을지.

5-1. 검색량 심리 신호는 믿을 만한가 → 믿을 만함, 단 정체는 "검색량 공통 요인"

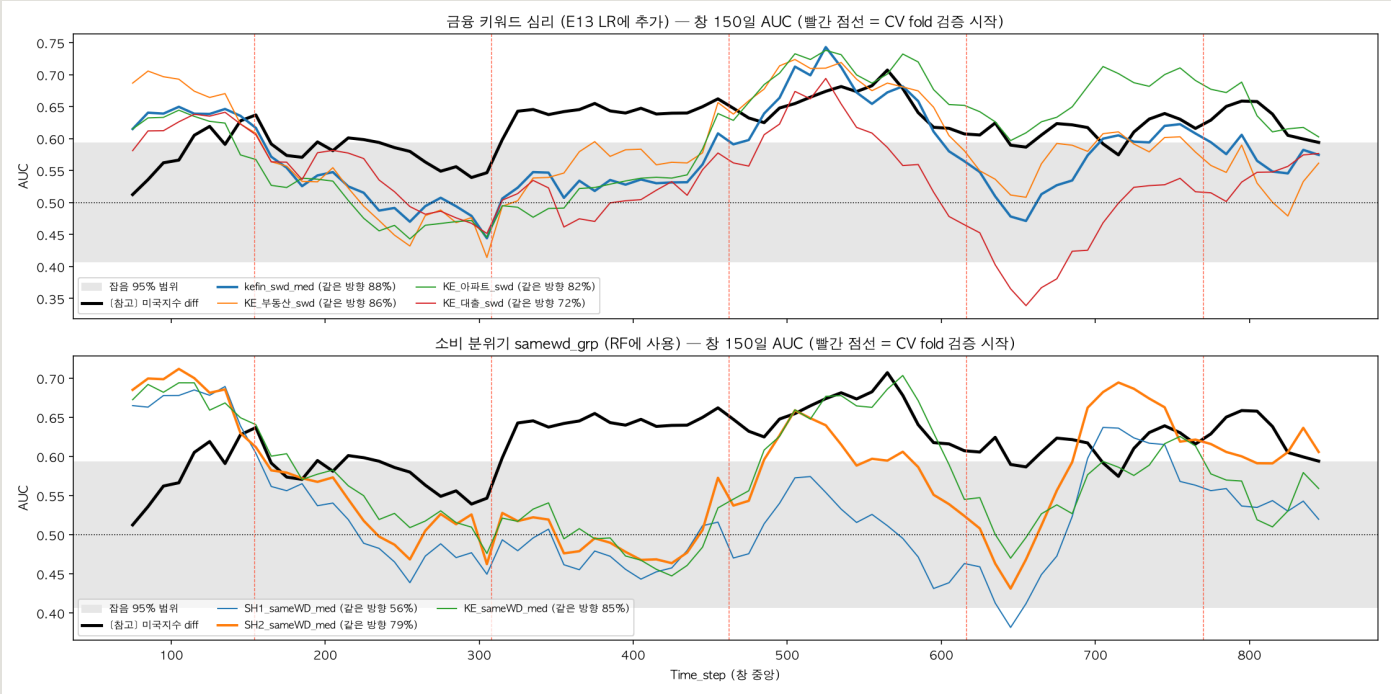


그림 11. 150일씩 끊어 본 AUC. 회색 띠 = 순수 잡음 범위, 검정 = 미국장(기준). 검색량 심리(파랑)는 88% 기간에서 같은 방향이지만 Time_step 170~450 구간엔 잡음 범위로 약해진다.

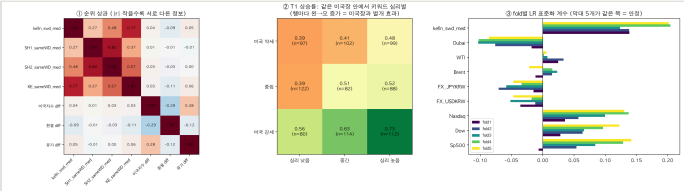


그림 12. 가운데: 미국장 조건이 같아도 검색량 심리가 높을수록 상승률↑ (미국 강세일 0.56 → 0.63 → 0.73) → 미국장과 다른 정보. 오른쪽: 계수 부호가 5개 fold 모두 같음.

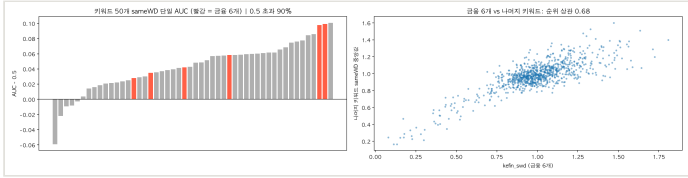


그림 13. 검색어 50개 중 90%가 같은 방향(빨강 = 고른 6개). 고른 6개 (0.581)와 나머지(0.582)가 같다 → "금융 심리"보다는 **"평소보다 검색이 많은 날"**이라는 공통 요인.

기준 (미리 정함)	검색량 심리 `kefin_swd`
순환 이동 p < 0.05	✅ 0.002
블록 부트스트랩 95% 구간이 0.5 제외	✅ 0.521 ~ 0.636
앞·뒤 절반 같은 방향 / 150일 창 70% 이상 같은 방향	✅ 0.550·0.606 / ✅ 88%
fold별 계수 부호 일치, 미국장 고정 후에도 효과	✅ 5/5 · ✅ 3개 조건 모두 증가

5-2. E12에서 멈출까, E13까지 갈까 → E13 (선택 편향을 감안해도 진짜 개선)

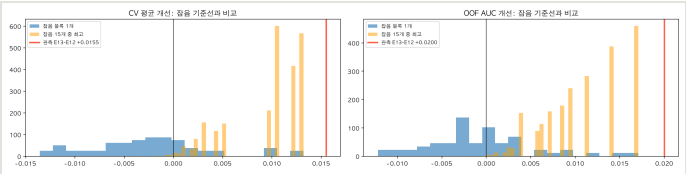


그림 14. 파랑: 의미 없는 변수를 넣었을 때 개선(≈0). 주황: 그런 후보 15개 중 **가장 좋은 것**을 골랐을 때(운만으로 얻는 몫, 평균 +0.010). 빨강(실제 +0.016)이 그보다 오른쪽.

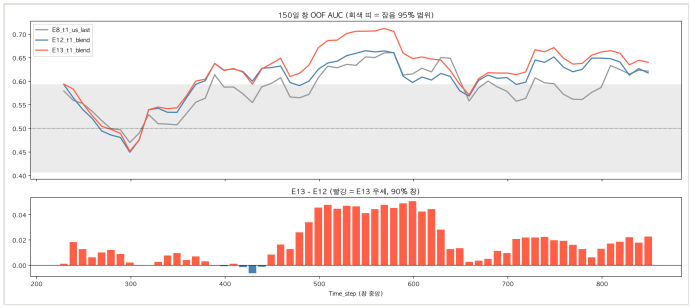


그림 15. 150일 구간별 검증 AUC. 아래 막대 빨강 = E13 우세, 90% 구간에서 앞섬. 최근 300일 0.605 → 0.625.

기준 (미리 정함)	결과	
블록 부트스트랩에서 E13 > E12일 확률 ≥ 90%	99% (차이 +0.020, 95% 구간 +0.004 ~ +0.039)	✅
"잡음 후보 15개 중 최고"보다 클 확률 p < 0.10	p ≈ 0.016	✅
랜덤포레스트 난수 10개 중 8개 이상 E13 우세	10 / 10 (차이 +0.014 ~ +0.017)	✅

5-3. 시기가 바뀌는 T1, 최근 데이터에 무게를 더 주면? → 지금 방식 유지

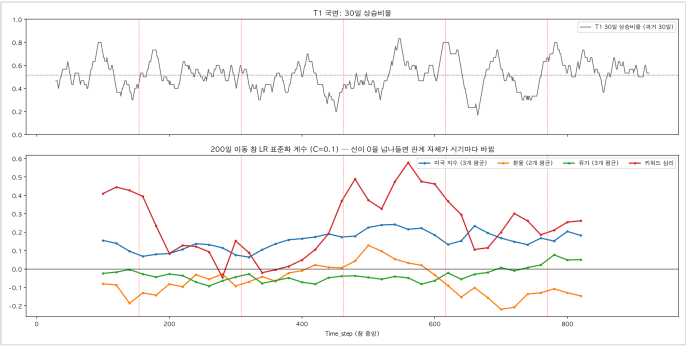


그림 16. 200일 창마다 다시 추정한 계수. 미국 지수(파랑)는 **전 기간 양수** — 핵심 관계는 시기와 무관하게 안정적이다. 환율·검색량은 크기가 오르내린다.

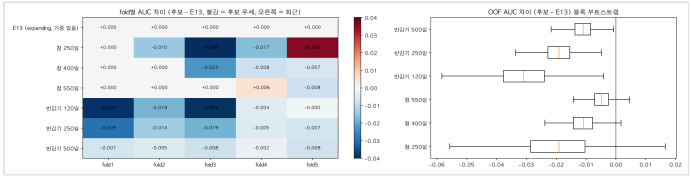


그림 17. 최근 250·400·550일만 학습하거나, 반감기 120·250·500일로 최근에 무게를 준 6가지 모두 E13보다 낮다(상자가 0의 왼쪽).

> **쉽게 말하면** — 오래된 데이터도 같은 규칙("미국장이 오르면 KOSPI도 오른다")을 가르쳐 준다. 최근만 보면 표본이 줄어 잃는 것이 더 크다. 그래서 Train 924일 전체를 같은 무게로 학습한다.

5-4. Prophet이 남긴 단서 — T1에 1년 주기가 있나? → 없음 (기각)

Prophet으로 T1을 직접 예측했을 때 1년 주기를 켜면 0.565, 끄면 0.492였다. 그래서 1년 주기 위치(sin·cos)를 E13의 로지스틱 쪽에 넣어 같은 방식으로 검정했다.

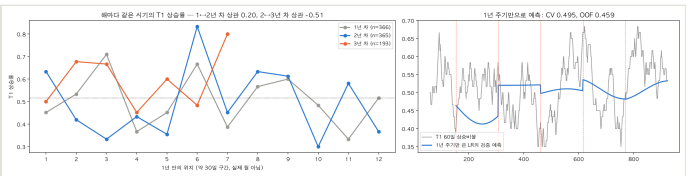


그림 18. 왼쪽: 해마다 같은 시기의 상승률이 서로 다른 모양(1↔2년 차 상관 0.20, 2↔3년 차 −0.51). 오른쪽: 1년 주기만으로는 미래 구간을 못 맞힌다(CV 0.495).

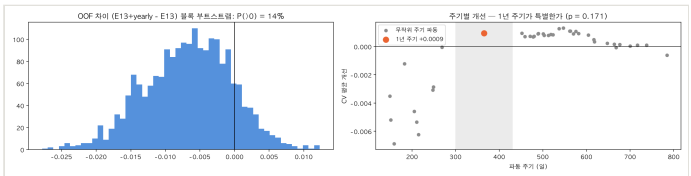


그림 19. 오른쪽: 1년 주기(주황)의 개선 +0.001은 아무 주기의 느린 파동(회색)과 다르지 않다(p = 0.17).

기준 (미리 정함)	결과	
블록 부트스트랩에서 후보 > E13일 확률 ≥ 95%	14%	❌
무작위 주기 파동보다 나을 p < 0.05	0.171	❌
최근 fold 4·5 ≥ E13	0.6305 vs 0.6322	❌
seed 10개 중 8개 이상 우세	10/10 (차이 +0.001)	✅

> **쉽게 말하면** — 924일은 1년이 2.5번뿐이라, Prophet의 1년 주기는 "매년 반복되는 계절"이 아니라 그 기간의 오르내림을 따라 그린 곡선이었다. 미래에 반복된다는 근거가 없어 쓰지 않았다. Prophet의 쓸모는 예측이 아니라 **변수군 성격을 설명**하는 데(그림 4) 있었다.

5-5. 최신 논문 방법 — TabPFN(작은 표 데이터용 기초 모델) → 기각, 최근 구간 우세는 관찰

TabPFN(Hollmann et al., *Nature* 2025)은 합성 데이터로 사전학습한 신경망이 학습 구간을 예시로 보고 바로 예측하는 방식이다. 표본 1만 개 이하에서 부스팅보다 강하다고 보고돼, 과적합이 가장 큰 문제였던 T1에 시험했다. **외부 데이터와 새 변수 없이** E13과 같은 입력만 썼고, 사전학습 가중치는 공개된 v2를 사용했다.

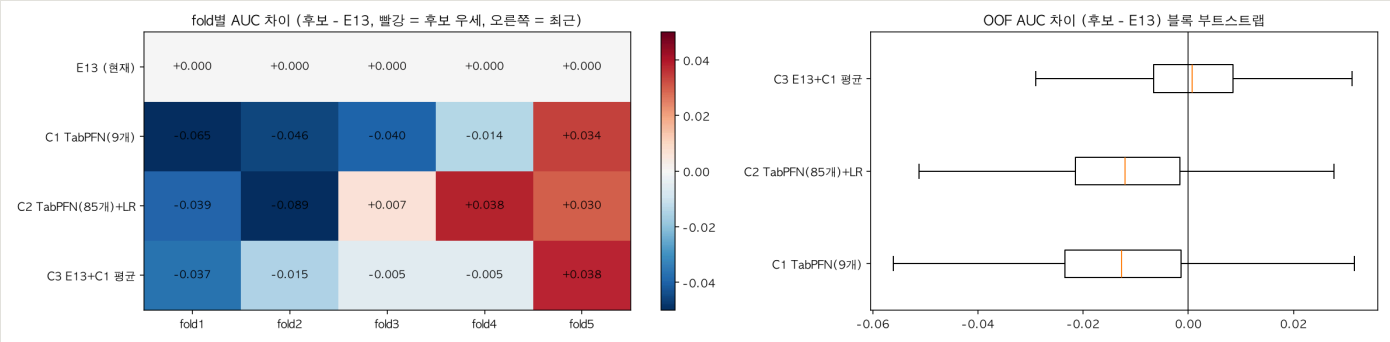


그림 20. 왼쪽: fold별 E13 대비 차이(빨강 = TabPFN 우세). 학습 기간이 짧은 초반 fold에서 크게 지고, 최근 fold 4·5에서는 앞선다. 오른쪽: 검증 구간 전체 기준으로는 E13보다 낫다고 할 수 없다.

후보 (미리 3개로 고정)	CV 평균 ± std	평균−std	E13보다 나을 확률	판정
E13 (현재)	0.637 ± 0.033	0.604	—	유지
C1 TabPFN 단독 (핵심 9개)	0.611 ± 0.050	0.561	23%	❌
C2 TabPFN(85개) + 로지스틱	0.626 ± 0.067	0.559	21%	❌
C3 E13 + C1 평균	0.632 ± 0.046	0.586	52%	❌

> **쉽게 말하면** — 전체 기간으로 보면 TabPFN은 E13을 넘지 못했다. 다만 학습 데이터가 600일 이상인 최근 구간에서는 앞섰고(최근 308일 +0.02, 나을 확률 88%), 같은 검증 구간에서 학습 기간을 150일 → 767일로 늘릴수록 차이가 +0.004 → +0.03으로 커졌다. 데이터가 더 쌓이면 유리해질 가능성이 있지만, 결과를 보고 고른 관찰이라 이번 제출에는 반영하지 않았다. (분석 코드 `04_T1_TabPFN검증.ipynb`는 별도 패키지 `tabpfn`이 필요해 제출 코드에서 제외)

6. 인사이트 · 한계 · 재현 방법

6-1. 인사이트

1. **점수를 올린 것은 입력이었다.** 모델만 바꾼 E1은 +0.018, 변수를 바꾼 E2는 +0.057. 마지막 개선(E8→E13 +0.034)도 모두 새 입력에서 나왔다.
2. **데이터의 "생김새"가 변수 설계를 정한다.** 주말 휴장(→ 직전 거래일 값), 0~1 압축(→ 변화율 대신 차이), 요일 리듬(→ 같은 요일끼리 비교).
3. **신호의 성격이 모델을 정한다.** 약하고 흔들리는 T1은 얕은 트리 + 강한 규제의 단순 모델, 단순하고 뚜렷한 T2는 로지스틱 중심 앙상블.
4. **비즈니스 관점**: 건강식품 클릭은 평일(특히 월~수)에 몰리고 주말에 빠진다 → 판촉·재고는 주초 집중. KOSPI는 전날 밤 미국장·환율·검색 활동으로 3일 뒤 방향을 약하게나마(상위 20% 확률 구간 실제 상승 73%) 가늠할 수 있다.

6-2. 한계

- T1은 신호 자체가 약하다. 100~200일 평가에서는 ±0.06~0.08 흔들리는 것이 정상 범위다.
- EDA 변수 고르기에 Train 전체를 사용해 CV가 약간 낙관적일 수 있다 (선택 편향 검정 §5-2로 일부 보정).
- 검색량 심리는 Time_step 170~450처럼 약해지는 시기가 있다. 해석은 "금융 심리"가 아니라 "검색 활동 공통 요인"으로 한정한다.
- 요일 번호(1=일, 7=토)와 클릭 0의 결측 처리, 평일 공휴일(국내 금리·환율 정지일) 추정은 데이터에서 추론한 것이다. 실제 날짜가 없어 미래 공휴일은 쓸 수 없다.

6-3. 재현 방법 (운영 가이드)

#	할 일	결과
1	압축을 풀면 `1_notebooks` (노트북) · `2_data` (제공 데이터) · `3_outputs` (제출본·실험 기록) · `4_figures` (보고서 그림, 번호순) 폴더. 커널: Python 3.11 (scikit-learn 1.9, xgboost, pandas)	노트북은 `1_notebooks` 에서 실행 (상대경로)
2	`1_notebooks/train.ipynb` §1에서 `MODE = 'private'` 확인 후 **Run All**	§4 실험은 `experiments.csv` 캐시로 몇 초 만에 지나가고(`FORCE=True` 면 전부 재학습), §5에서 T1=E13·T2=E10 자동 선택 → Train 924일 전체로 재학습
3	§6 제출 셀	`3_outputs/private_4반_최승우.csv` 생성 + 형식 검증(열 이름·행 수·0~1·결측 없음)
4	(선택) `01_EDA` · `02_Prophet` · `03_T1_분기점검증`	보고서 그림 1~4, 10~19의 근거 (그림 20의 04_T1_TabPFN 검증은 tabpfn 패키지가 필요해 제외)

> **Leakage 방지 체크** — ① 모든 파생변수는 `shift(+n)` ·과거 rolling만 사용(미래 값·중앙 정렬 없음) ② Test 행의 Target은 어디에도 쓰지 않음 ③ Test는 학습에 쓰지 않고, 시간순으로 이어 붙여 Test 행이 **자기보다 과거의 설명변수**만 참조하게 함 ④ 결측 대체·표준화는 fold 학습 구간으로만 학습 ⑤ 상수 제거·상관 계산은 Train 행만 사용.