SKALA

데이터분석 및 AIOps

데이터분석 미니 프로젝트

2026.10



본 문서는 SK(주)AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX



1. 핵심 개념 Review
2. 프로젝트 개요
3. 프로젝트 평가 방안

데이터 분석 및 AIOps

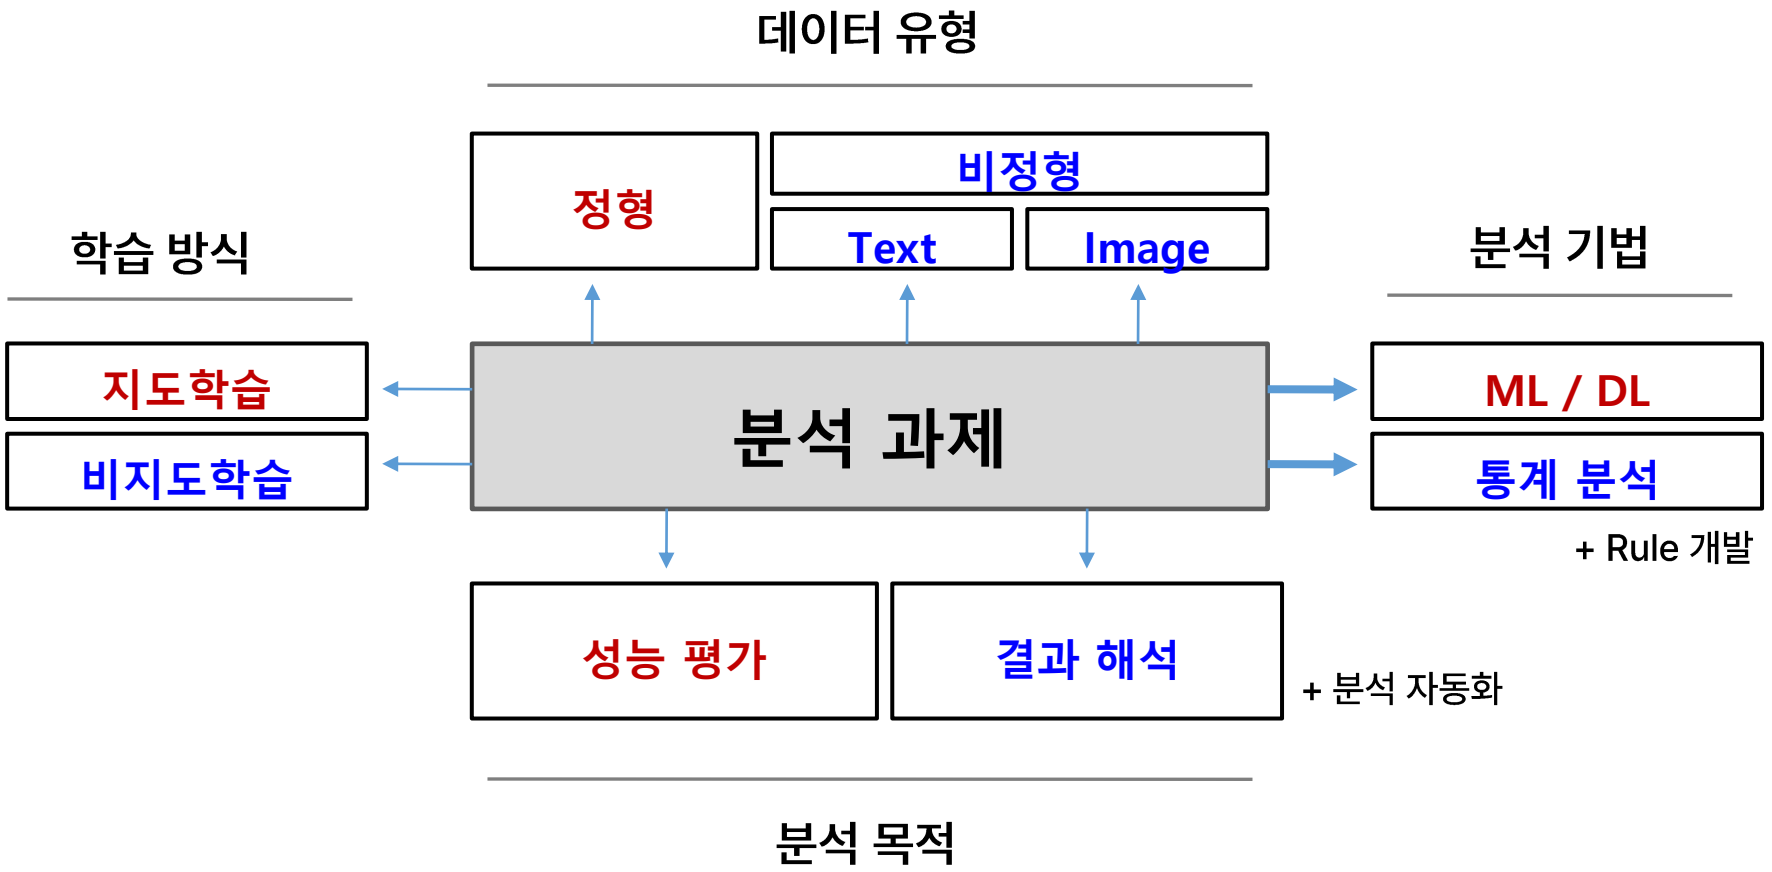
1. 핵심 개념 Review

- 데이터 분석 분류 체계
- Feature Engineering
- Data Partition
- 모델 최적화 전략
- Overfitting
- Data Leakage

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX

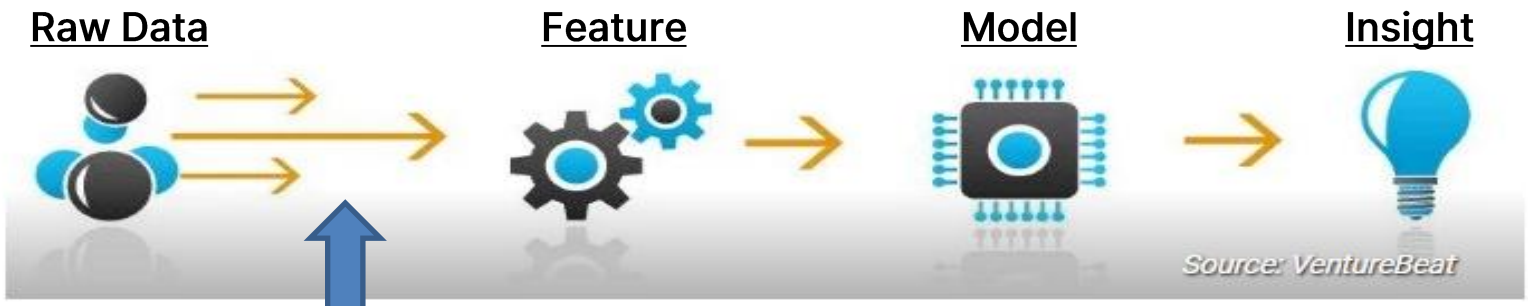
데이터 분석 분류 체계


데이터 유형
정형
비정형
Text
Image
학습 방식
분석 기법
지도학습
비지도학습
분석 과제
ML / DL
통계 분석
+ Rule 개발
성능 평가
결과 해석
+ 분석 자동화
분석 목적

Feature Engineering 정의

정의

- 원본 데이터(Raw Data)를 모델 성능에 도움이 되는 형태(Feature)로 가공하는 모든 과정
- ML / DL 에 사용되는 Feature 를 개발하는 과정으로 시간이 많이 걸리고, 모형 성능에 영향을 크게 줌
- 모델에 도움이 되는 한 어떤 요소도 Feature 가 될 수 있음



Feature Engineering

Feature Extraction	• Raw Data 를 변환, 병합해서 New Feature 생성
Feature Selection	• Feature 중에 유의미한 것만 선정 하여 학습 진행

Feature Extraction

Feature Extraction 방법

Feature Transformation	• 알고리즘 기반 추출, 기계적 추출 방법 • 데이터 자체의 통계적·수학적 구조로 부터 자동 추출 • 사람의 해석 없이도 생성 가능한 Feature 예시) Missing 변환/ 표준화/ Min/ Max...
Feature Creation (파생변수 생성)	• 도메인 지식 기반 추출, 창의력 영역 • 업무 이해를 바탕으로 의미있는 Feature 추출 (파생 변수) 예시) 가입기간(현재일-가입일), 소득 대비 부채 비율(DTI) ...

시계열 Feature 추출

개념 및 예시

- 시간 흐름에 따라 수집된 시계열 데이터에서 의미 있는 정보 추출
- 주요 시계열 파생 변수 : Lag, Rolling 변수

✓ Lag, Rolling 변수 예시

예시) 주가 데이터

날짜	종가
1/1	100
1/2	105
1/3	103
1/4	108
1/5	110

시계열 특징 추출

Lag 변수 (과거)

- 1일 전 종가 = 어제 가격
- 7일 전 종가 = 일주일 전 가격

➔ 단기 변동을 포착

Rolling 변수 (이동평균)

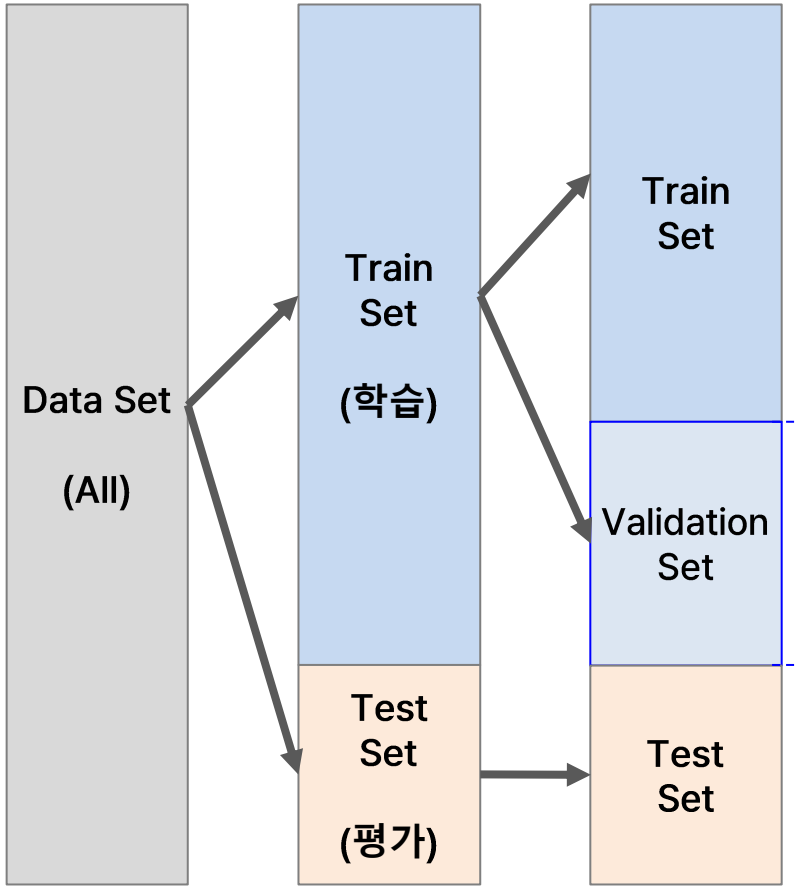
- 7일 이동평균 = 최근 7일 평균
- 30일 이동평균 = 최근 30일 평균

➔ Trend 를 포착

* Lag 데이터, Rolling 데이터를 이용해서 2차 파생변수 생성
  - 전일 종가 대비 금일 종가 비율
  - 최근 일주일 평균 대비 금일 종가 비율

Data Partition 개념

모델 개발을 위해서 Dataset 을 모델 학습 데이터와 모델 평가 데이터로 나누는 것



- **모델 학습** 위한 데이터셋
- Train Set : Test Set = 8:2 (or 7:3)

- 학습된 모델을 검증하기 위한 데이터셋
  : 최적의 **Hyper-parameter**를 찾는 과정
- Train : Validation : Test = 6 : 2 : 2

- 학습과 검증이 완료된 **모델의 성능 평가**
- 전체 데이터 셋의 약 20~30% 데이터로 진행

모델 학습 위한 데이터

학습에 반영되지 않는 데이터

Data Partition 방법

Hold Out, Cross Validation

Hold Out

- ▪ Random Split

- - 데이터를 적정 비율로 해서 무작위로 분할
  Ex) Train : Valid : Test = 6 : 2 : 2

- ▪ Timeseries Split

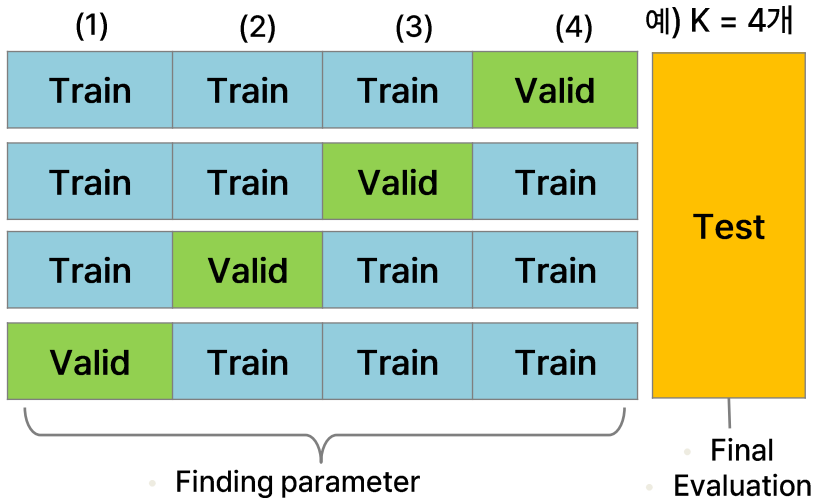
- - 시간 순서로 데이터 분할
- - 시계열 데이터 분석 시 사용



CV (Cross Validation)

- ▪ K-fold Cross Validation

- - 데이터를 K 번 나누어 학습·검증을 반복하고, Valid 성능의 평균으로 모델을 검증하는 방법



- * Test set 평가 방법
- - Holdout : Train 학습 모델 그대로 사용 or Train + Valid Set 으로 재학습
- - CV : 전체 Train Set 으로 재학습

모델 최적화 전략

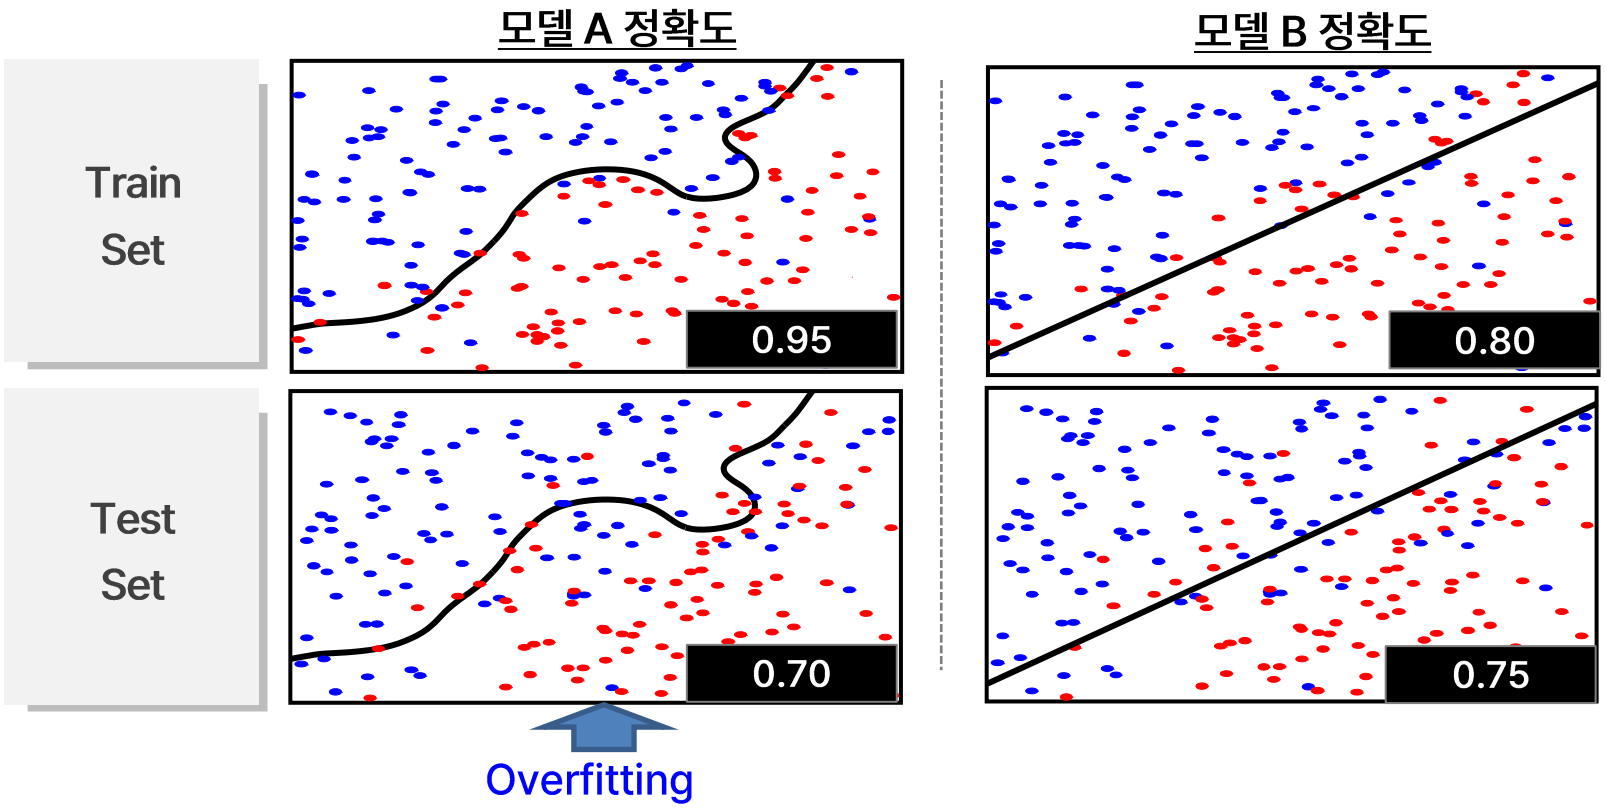
대표적인 최적화 전략

최적화 전략		핵심 목적	최적화 기법
데이터 전략	Training Data Design	• 모델 학습에 최적화된 데이터셋 구성	• Segmentation, Sampling • Data Partition : Hold Out, Cross Validation
	Feature Engineering	• 예측에 유용한 Feature 생성 및 변환	• 특성 생성 : 파생변수 생성, Lag 변수 등 • 특성 변환 : Missing 대체, Scaling 등 • 특성 선택 : 신뢰성 검증, 변수 중요도, 논리적 판단
모델 전략	Model Selection	• 문제 및 데이터 특성에 적합한 알고리즘 선정	• 통계분석 / ML / DL • Regression 계열, Tree 계열 (XGBoost/LightGBM)
	Hyperparameter Tuning	• 모델 성능을 최적화하는 하이퍼파라미터 탐색	• Grid / Random / Bayesian Search • 경험 및 사례 기반 탐색
	Regularization	• 과적합 방지 및 일반화 성능 향상	• L1, L2 정규화 (LASSO, Ridge) • 뉴런 Dropout, 학습 Early Stopping
	Ensemble	• 여러 모델을 결합하여 예측 성능과 안정성 향상	• Bagging : Random Forest • Boosting : XGBoost, LightGBM • Stacking : 이질적인 모델 예측값을 메타 모델의 Input

Overfitting 개념

모델 과적합

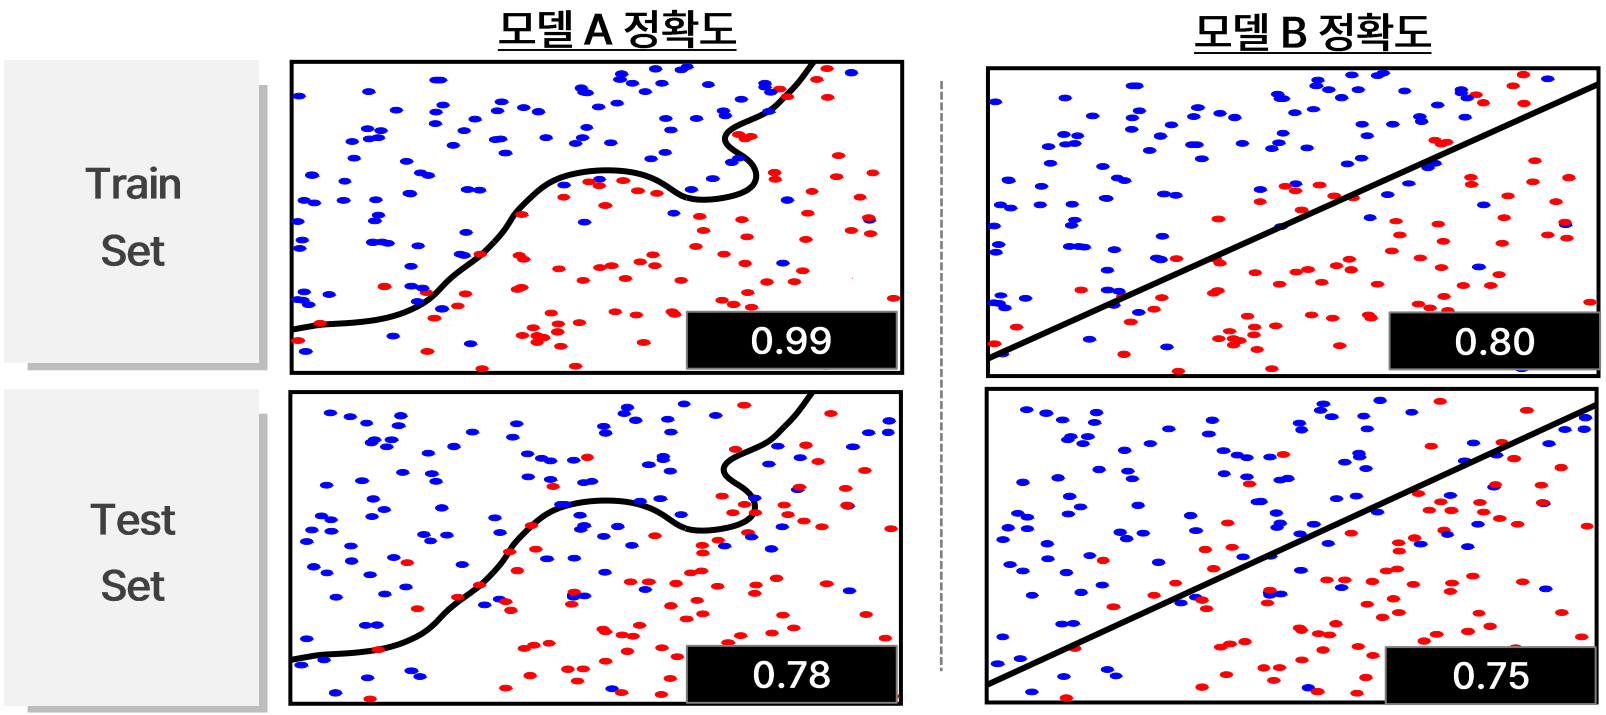
- Overfitting 은 학습(Train) 데이터에서는 잘 맞는데, 새로운(Test) 데이터에서는 그렇지 않은 경우를 의미
- Overfitting 영향 요인 : 데이터 특성 (Train/Test 비유사도), 데이터 건수, Feature 개수, 알고리즘 복잡도 등



Overfitting 개념

모델 과적합

Q) 모델 A와 B 중 어느 모델이 좋은 모델일까요?

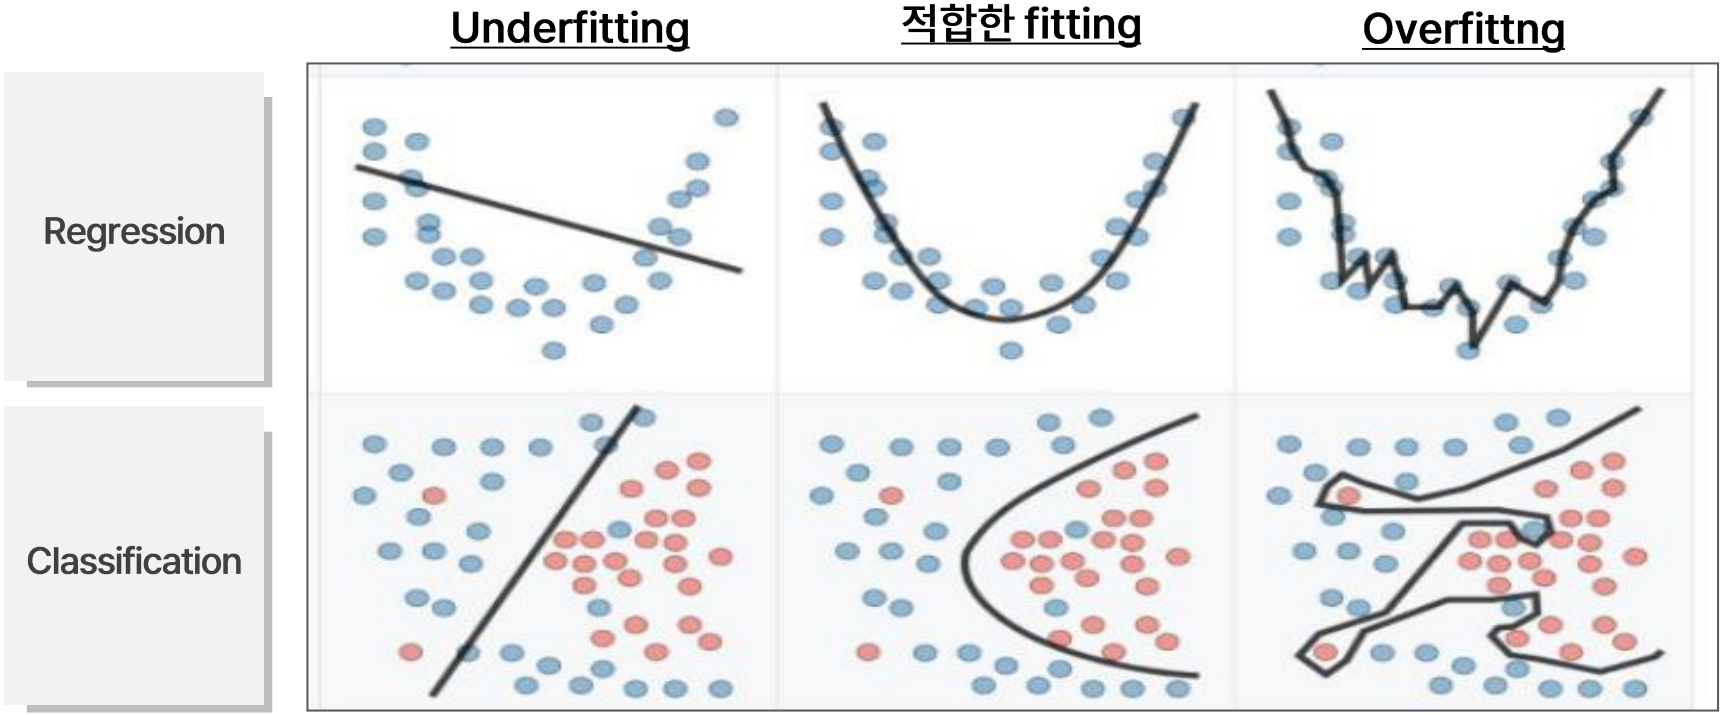


Overfitting vs Underfitting

과대 적합, 과소 적합

- Overfitting은 학습이 너무 과해서 학습데이타만 잘 맞추는 것
- Underfitting은 학습이 너무 부족해서 학습데이타도 잘 못 맞추는 것

Q) Overfitting 과 Underfitting 중 어떤 것이 더 문제일까요?



Data Leakage

학습에서 치명적인 함정

- Data Leakage : 모델이 예측 시점에 알 수 없는 정보를 학습에 사용한 경우
- 모델 개발 시에는 정확도가 매우 높게 나오는데 (예: 99%), 실제 데이터를 넣으면 현저히 성능이 저하되는 이유
- Overfitting 은 주로 모델 설계 문제, Data Leakage 는 데이터 설계 문제

Data Leakage

Target Leakage

- Feature에 Target 정보가 직접/간접 포함

예시) 폐렴 환자 예측시 "항생제 처방 여부" 피처 사용,
고객 이탈 예측시 "'해지 위약금 지불 여부" 피처 사용



Train-Test Contamination

- Test 데이터가 학습 과정에 일부라도 노출된 상태

예시) 전체 데이터의 평균, 표준편차로 Scaling,
전체 데이터 평균으로 Missing 대체



Quiz

1. [Feature Engineering] Missing 대체 작업시 평균값을 산출하는 데이터와, 그 값을 적용하는 데이터의 올바른 관계는?

   (산출 대상 Dataset -> 적용 대상 Dataset)

   ① All -> Train / Validation / Test
   ② Train -> Train / Validation / Test
   ③ Train + Validation -> Train / Validation / Test
   ④ Train -> Train, Validation -> Validation, Test -> Test
   ⑤ 과제에 따라 다름

2. [모델 튜닝] Hyperparameter Tuning 을 통해서 모델 성능을 최대로 올리고자 함. 어떤 데이터셋의 성능을 기준으로 하이퍼파라미터를 최적화해야 하는가?

   ① Train ② Validation ③ Test ④ Train, Validation 평균값 ⑤ Validation, Test 평균값

Source : https://www.nb-data.com/p/6-common-hyperparameter-optimization

모델 평가 지표 종류

모델 평가 지표는 문제 유형, 비즈니스 목적에 따라 선택해야 함

문제 유형	Output 유형	평가 지표 (Metrics)
분류 (Classification)	Class (1, 0)	• Confusion Matrix (Accuracy / Precision / Recall / F1 Score)
	Probability (0~1)	• AUC / LIFT / AUCPR / K-S
회귀 (Regression)	실수값	• Mean Absolute Error : ∑ |예측값 – 실제값| / n
		• Mean Squared Error : ∑ (예측값 – 실제값)^2 / n
		• Root Mean Squared Error : Root(∑ (예측값 – 실제값)^2 / n)
		• Mean Absolute Percentage Error : ∑(|예측값 – 실제값| /실제값)/ n
		• R-Square : 1- (∑ (실측값 – 예측값) / ∑ (실측값 – 평균값)2)

데이터 분석 및 AIOps

2. 프로젝트 개요

- 프로젝트 배경 및 목표
- 프로젝트 수행 구조 및 절차
- 분석 데이터 정의
- 프로젝트 주제

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

프로젝트 배경 및 목표

데이터 융합 기반 AI 예측 모델링 역량 강화

■ **AI 기반의 선제적 문제 해결 및 리스크 관리**

금융·소셜·공공 등 외부 오픈데이터를 활용하여 이종(異種) 데이터의 융합 분석과 자동화된 AI 모델을 활용해 단순 현상 파악을 넘어 미래의 불확실성을 예측하고, 기업 및 사회 문제에 선제적으로 대응하는 체계를 구축

■ **데이터 기반 비즈니스 인사이트 및 실무 활용성 극대화**

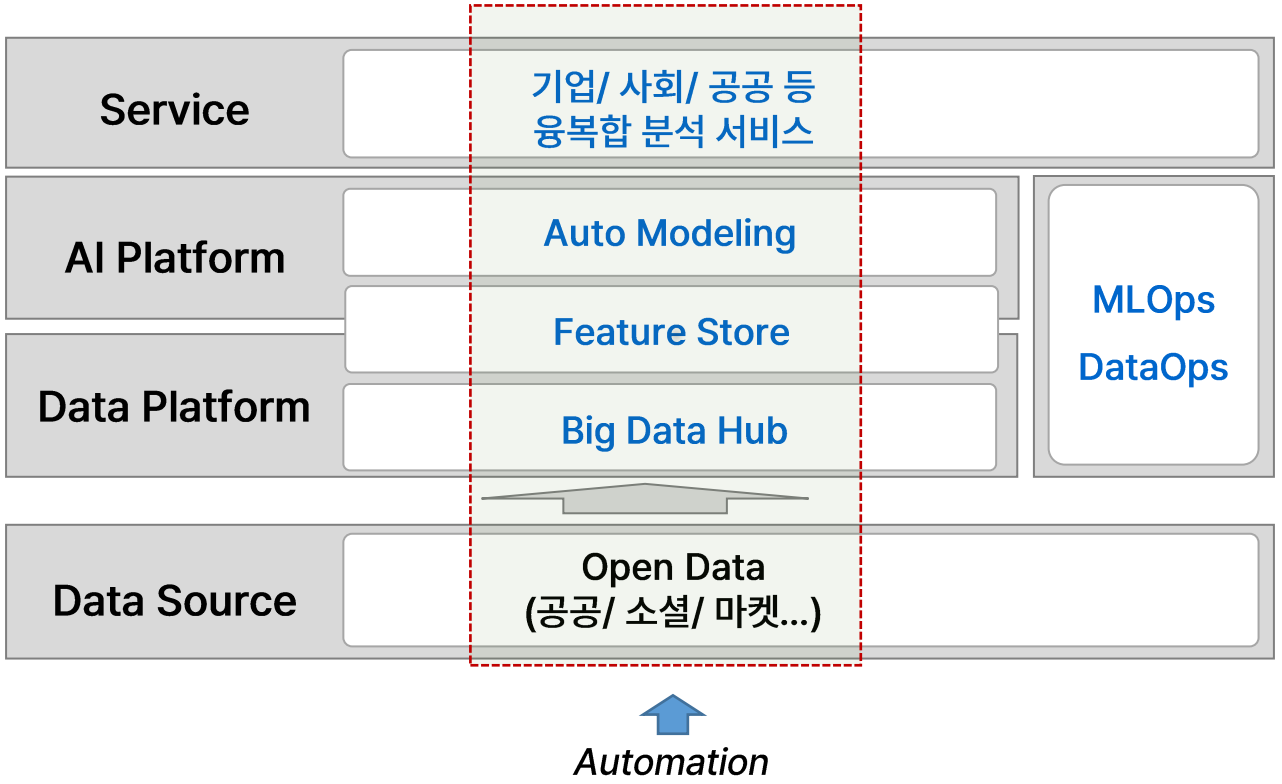
수요 예측과 소비자 행동 패턴 분석을 통해 창업 지원, 재고 관리, 업종 전환 등 실무 현장에 즉시 적용 가능한 고부가가치 인사이트를 도출하고 데이터의 실질적 성과를 경험

➔ **목표 : [외생 변수 융합] → [선제적 AI 예측] → [실질적 비즈니스 해결]**

프로젝트 수행 구조

Open Data 기반 AI 융합 분석 플랫폼 아키텍처

- 공공/ 소셜/ 금융마켓 등 Open 데이터를 수집, 적재하여 Big Data Hub 구축
- Feature 자동화 구축으로 예측 성능 확보와 융복합 분석 체계 마련
- AI-driven Auto Modeling 기술로 자동화된 분석 서비스 제공

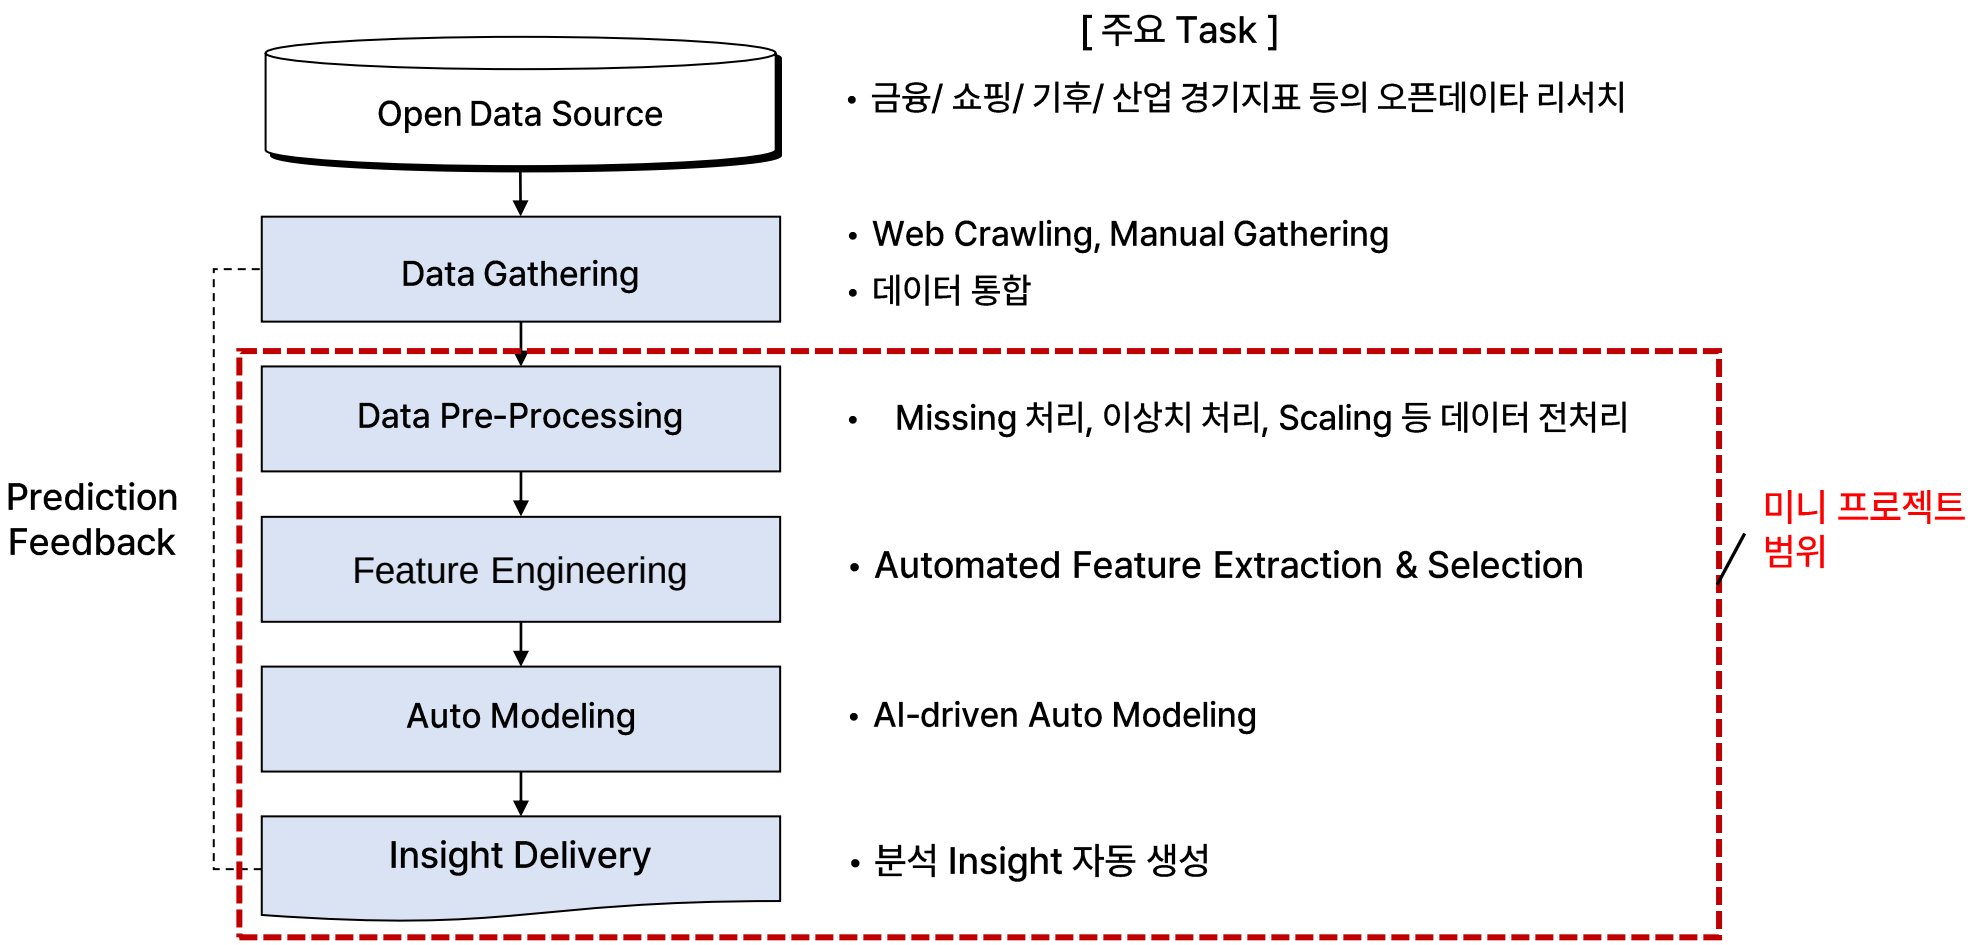


Business Value

- AI 기반 분석 역량 확보
- 분석 자동화를 통한 업무 생산성 향상
- 융복합 데이터 기반 인사이트 발굴

프로젝트 수행 절차

Open Data 기반 AI 자동 분석 파이프라인



분석 데이터 정의

Open Data 수집 내역

▪ 각 영역별 공통기간 약 3년치의 데이터 수집

Data Category		Description	Source	Time Cycle
FI_	Finance, 금융	- 국내/해외 주가지수, 국내/해외 유가, 환율, 국내 금리, 원자재 값 등 (19개)	네이버 금융, https://finance.naver.com	Daily
SH1_	Shopping 1, 쇼핑 Level 1	- 패션의류, 패션잡화, 화장품미용, 디지털 가전, 식품 등 쇼핑 클릭량 (11개)	네이버 데이타랩, ttps://datalab.naver.com	Daily
SH2_	Shopping 2, 쇼핑 Level 2	- 쇼핑 Level 1에 해당하는 상세 쇼핑품목별 클릭량 (189개)		
KE_	Keyword, 포털 키워드 검색량	- 미세먼지, 비대면, 보험, 질병 등 관심 Keyword 검색량 (51개)		
WE_	Weather, 날씨	- 미세먼지 등 오염도 지표, 기온, 풍속, 강수량 지표 (15개)	에어코리아 http://www.airkorea.or.kr	Daily
PU_	Public, 공공	- 실업자수, 입출국자수, 경기선행/후행지표, 경기체감지수, 온라인/백화점/마트 소비실적 등 (111개)	국가통계포털, https://kosis.kr	*Monthly

➔ 금번 프로젝트에서는 일단위 분석으로 월단위 데이타인 공공데이타 (PU_)는 제외

분석 시나리오 예시

Open Data 기반 분석 예시

분석 유형		분석 시나리오 예시
데이터 검증	검색량 vs 실 데이타 연관성 검증	Ex) 미세먼지 검색량 vs 미세먼지 실제 수치 관계, 코로나 검색량 vs 코로나 확진자 수 관계
EDA	Trend 분석	▪ 최근 Trend 경향 (상승 또는 하락 수준 분석) ▪ 선형 회귀분석의 Slope 값 활용 Ex) 쇼핑품목 중 최근 소비 관심도가 상승/하락 품목은 ?
	상관성 분석	▪ 2개 이상 변수간의 연관성 분석 Ex) 코스피 지수 vs 쇼핑품목
	Signal 분석	▪ 최근 급상승(하락) 변수 탐색 ▪ 최근 패턴 급변동 변수 탐색 Ex) 코로나 급상승 시점 전후로 쇼핑 변동이 심한 품목은?
	Anomaly Detection	▪ 비정상 패턴 자동 탐지 Ex) 유가, 쇼핑 검색 등
Predictive Modeling	원인 분석	▪ Feature Importance 분석 활용 Ex) 미세먼지 원인 분석
	예측	Ex) 주가지수 예측, 유가 예측, 특정 쇼핑품목 예측 등

➔ 금번 프로젝트에서의 문제 유형은 Predictive Modeling 이고, 예측 성능 중심으로 프로젝트를 평가함

프로젝트 주제

KOSPI 지수 & 상품지수 상승 가능성(Probability) 예측

- 분석 단위 : Daily
- 문제 유형 : 분류 문제 (Binary Classification)
- 종속 변수 : Target_1 (D+3 일 KOSPI 지수 상승 여부),
  Target_2 (D+3 일 건강식품 지수 상승 여부)
- 설명 변수 : 거시경제·금융시장·소비 트렌드·기상 요인 (해외 지수, 유가, 금리, 쇼핑 지수, 날씨 등 284개)
  * 변수 상세 내역 : 별첨) 분석 Mini-Project 변수 설명서.xlsx
- 학습 데이타 기간 : 924일 (약 2년 6.5개월)
- 평가 데이터 기간
  - Public 평가 : 100일
  - Private 평가 : 200일
- 평가 지표 : AUC (Area Under the ROC Curve)



데이터 분석 및 AIOps

3. 프로젝트 평가 방안

- 프로젝트 평가 구조
- 프로젝트 평가 방안

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

프로젝트 평가 구조

정량 평가와 정성 평가로 최종 평가

- 평가 배점

평가 항목			점수
정량 평가 (실제값 vs 예측값 비교 평가)	Target_1, Target_2 Private Score 의 평균		60
정성 평가 (보고서 와 Code 기반 평가)	데이터 설계 완성도	데이터 전처리 Feature Extraction Feature Selection	40
	모델 설계 완성도	학습 알고리즘 설계 검증 방법 설계 모델 최적화 노력	
	분석 결과 전달력	분석 결과 커뮤니케이션 역량 모델 구조 설명 전달력	
	운영 가이드 준수	프로젝트 납기 준수 프로젝트 산출물 준수	

- 정성 평가용 제출 자료

  1) 모델 결과 보고서 : 전체 모델 파이프라인을 이해할 수 있는 자유 양식의 PDF로 작성 후 제출

  2) 모델 개발 Code : Private Score 재현 가능한 형태의 Code 제출 (.ipynb)

프로젝트 평가 방안

제공 데이터 및 Baseline Code

- 제공 데이타
  - train.csv : 학습용 데이터
  - test_public.csv : Public 평가용 데이터 (전체 테스트 데이터 중 50%)
  - test_private.csv : Private 평가용 데이터 (전체 테스트 데이터 100%)
  - sample_submission_public.csv : Public 평가용 제출 데이타 양식
    *결과 제출은 반드시 양식 컬럼명과 일치해야 하고, 예측 확률 (pred_1, pred_2) 은 0 이상 1 이하의 실수값이어야 함
  - sample_submission_private.csv : Private 평가용 제출 데이타 양식
    *결과 제출은 반드시 양식 컬럼명과 일치해야 하고, 예측 확률 (pred_1, pred_2) 은 0 이상 1 이하의 실수값이어야 함

(주의)

1) 제공된 데이터 외 외부 데이터 사용 금지
2) 평가용으로 제공된 데이터는 학습에 활용 할 수 없음 (Data Leakage)

- Baseline Code
  - 프로젝트 참가자가 참고할 수 있도록 제공하는 기본 분석 코드 또는 최소 성능 기준 모델 코드

데이터 분석 및 AIOps

Appendix

- 기존 유사 분석 사례

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

국내 유가 예측

Feature 영역 : 금융

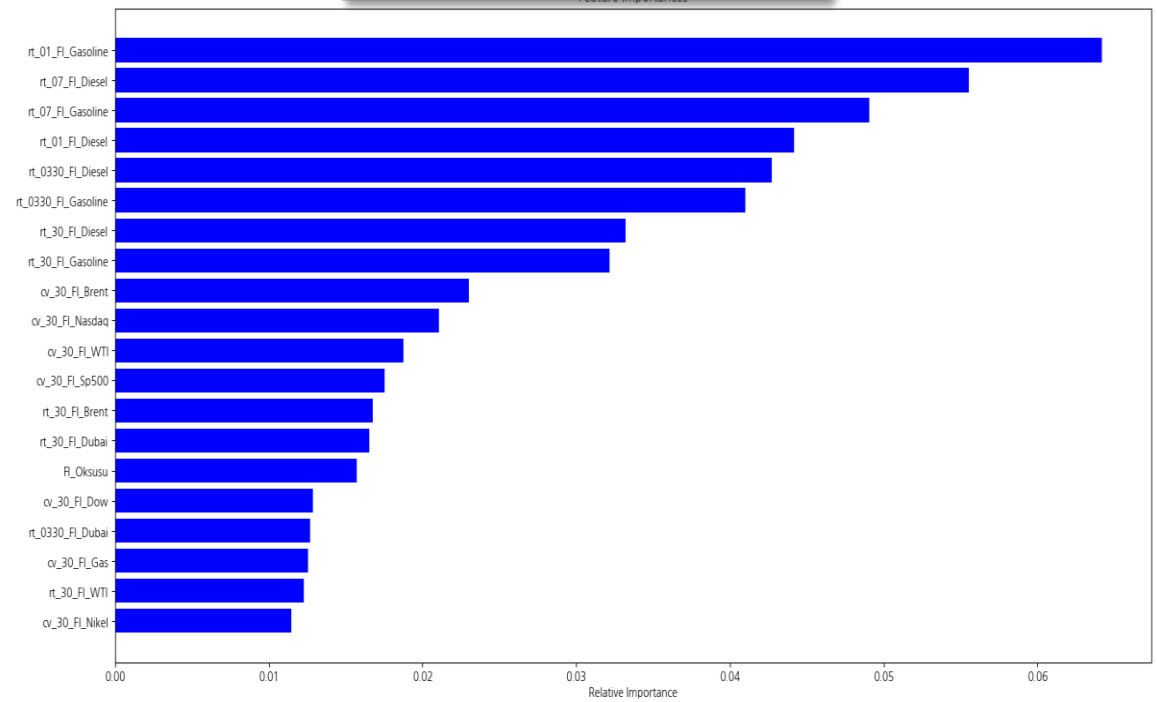
Input Parameter

Target	FI_Gasoline
예측 기간	1일
Feature 영역	FI (금융)
Metric	AUC
Train Ratio	0.7

Model Evaluation

Metric	Value
accuracy	0.884
macro avg	0.884
auc	0.969

Feature Importance



국내 유가 예측

Feature 영역 : 전체

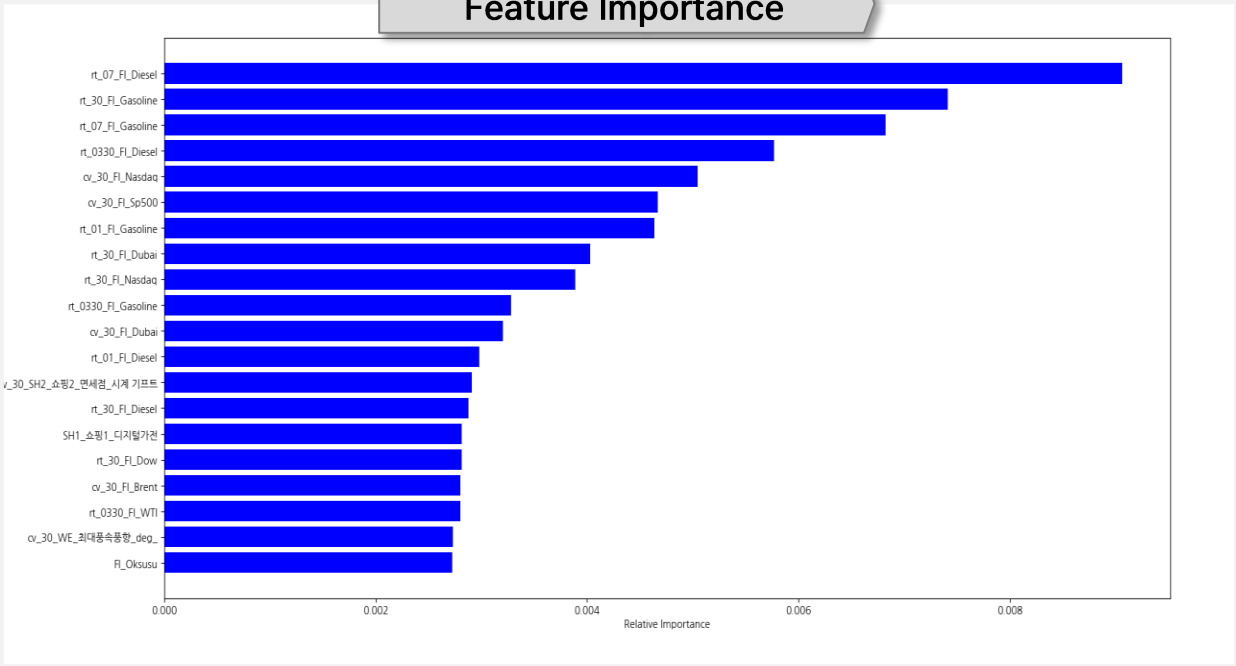
Input Parameter

Target	Fl_Gasoline
예측 기간	1일
Feature 영역	전체
Metric	AUC
Train Ratio	0.7

Model Evaluation

Metric	Value
accuracy	0.890
macro avg	0.890
auc	0.977

Feature Importance



➔ 전체 Feature 를 사용한 경우 금융 Feature 만 사용한 경우 보다 향상된 모델 성능을 확인할 수 있음 (auc 0.969-> 0.977)

쇼핑 지수 예측

Feature 영역 : 전체

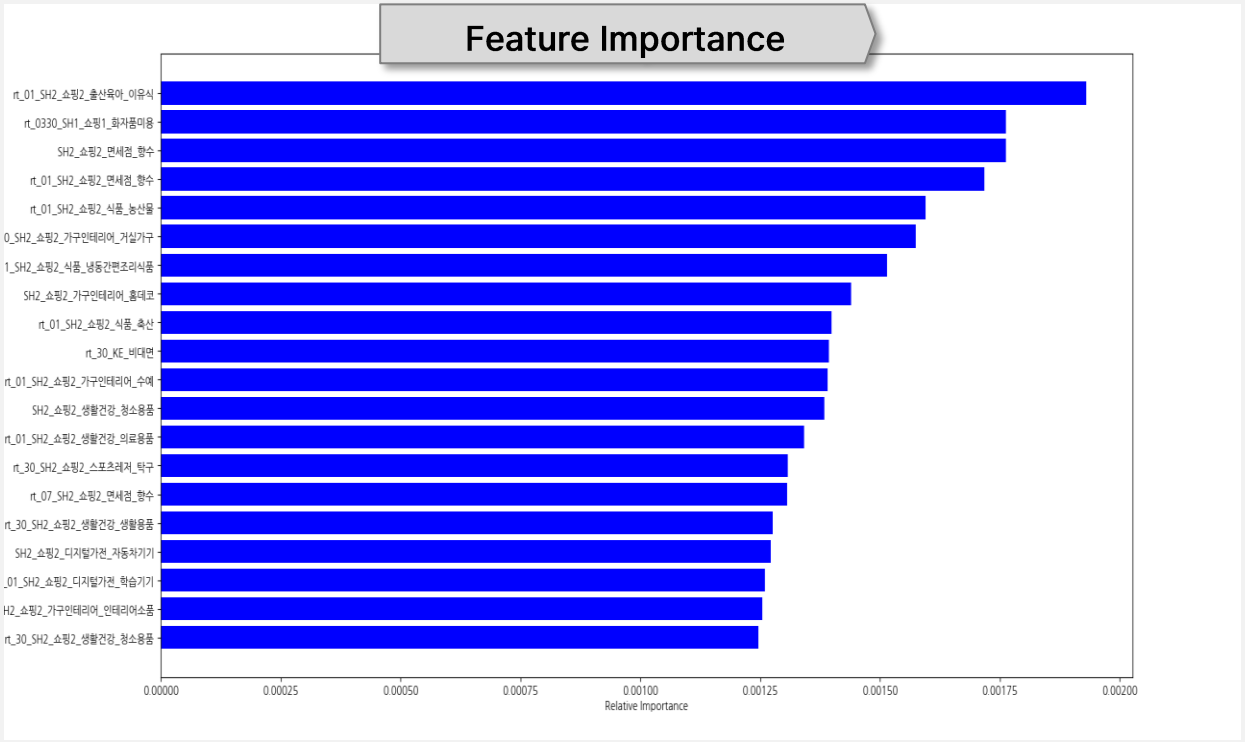
Input Parameter

Target	면세점_향수
예측 기간	3일
Feature 영역	전체
Metric	AUC
Train Ratio	0.7

Model Evaluation

Metric	Value
accuracy	0.690
macro avg	0.689
auc	0.744

Feature Importance



➔ Open Data 및 AI 기반 모델을 이용하여 향후 소비 트렌드 및 수요 변화에 대한 예측 가능성을 확인할 수 있음



수고하셨습니다.

본 문서는 SK(주)AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX